



UNIVERSIDAD
POLITÉCNICA
DE MADRID



Aprendizaje profundo aplicado a la microestructura de mercados de predicción

Predicción de corto plazo en mercados de Bitcoin de Polymarket

Marc Maldonado Lorca

Directora: Dra. María Inmaculada Santamaría Valenzuela

Máster de Formación Permanente en Deep Learning · UPM

No definiendo rentabilidad; definiendo una metodología de evaluación.


Qué se predice, exactamente

Un contrato binario de Polymarket **no es el precio de Bitcoin**. Es una probabilidad negociada: cuánto paga el mercado por un resultado futuro.

En los mercados de Bitcoin está acoplado a referencias externas, y ese acoplamiento es lo que se estudia.

No predigo el evento final. Predigo movimientos locales del contrato, a escala de segundos.

Un contrato binario no es Bitcoin: hay que definir con precisión qué se predice.




El sistema de captura: la parte que decide qué se puede afirmar

Captura propia y continua que alinea cuatro fuentes en una malla de dos segundos, con control de calidad por sesión.

- ▶ **2,5 M** filas multifuente
- ▶ **50** días de ventana prospectiva
- ▶ Latencia medida contra el mercado real: **429,7 ms** (p95), con una orden efectivamente casada


La unidad no es un mercado: es una observación temporal con información causal hasta ese instante.

La parte de datos no es decorativa: define qué se puede afirmar después.



El protocolo está diseñado contra el autoengaño

- ▶ Particiones **estrictamente temporales**; características causales.
- ▶ El candidato se **congela** antes de ver el bloque de test.
- ▶ Todo se reporta en **ticks netos**: costes y latencia dentro.
- ▶ El compromiso se **sella en la cadena de Bitcoin** antes de mirar los datos (OpenTimestamps).



Verificable por terceros: la atestación no se puede retro-fechar.

La métrica que decide es económica, no la *accuracy*.

Primer hallazgo: acertar no es ganar

≈ 90 %

acierto direccional

negativo

resultado económico con 2 s de latencia

El primer *baseline* tabular parecía excelente mirando solo la clasificación. Introduciendo el retardo de entrada, el resultado se vuelve negativo.

Eso cambia el eje del trabajo: no basta con acertar la dirección, hay que entrar a un precio que todavía permita capturar valor.

Precisión sobre el alcance: los 2 s son la resolución del instrumento, no la latencia medida. Entre 0 y 2 s no hay observaciones.

El modelo puede tener razón demasiado tarde.


La escalera de modelos: el aprendizaje profundo sí se evaluó

- ▶ Tabulares regularizados · sensibles a latencia
- ▶ GRU, *BookEncoder* convolucional (DeepLOB), fusión, TCN, auto-atención
- ▶ Fundacionales: **MOMENT** (series) y **TabPFN** (tabular)

MOMENT mejora de forma monótona al adaptarlo y aun así no bate a la deriva ingenua ni a un ARIMA; su curva de escalado es **plana**.

TabPFN gana la **ordenación zero-shot** con un tercio de los datos (Spearman 0,119 frente a 0,092), pero no mejora la decisión ni la vuelve rentable.

La complejidad no se da por buena: debe ganarse su sitio.



El candidato congelado


Especialista para la ventana *prestart*, entre -60 y -45 s de la apertura. 36 características causales, sin variables de reloj.

Dos cabezas y una regla que exige ambas condiciones:


- ▶ valor esperado $> 0,75$
- ▶ probabilidad de relleno sano $\geq 0,50$

No intenta operar todo: intenta seleccionar contextos ejecutables.

Selecciona contextos ejecutables, no oportunidades en abstracto.



La fe de erratas que refuerza la tesis



En la fase final detecté que mi modelo subestimaba la comisión *taker* en un **factor ocho**, justo en la zona de precios donde opera el trabajo.

Lo declaré como fe de erratas **sellada**, y re-evalué la política congelada sin reentrenar nada:

	entrada	ida y vuelta
Todas ($n=754$)	-1,059	-3,304
Baja vol. ($n=318$)	-0,342	-2,604

La comisión media de entrada, 1,75 ticks, **supera por sí sola** el resultado bruto de la señal.

El error, declarado y sellado, confirma la tesis.


El valor no desaparece: se desplaza al otro lado del libro

La misma estructura de comisiones que mata al *taker* **retribuye** a quien provee liquidez: exento de comisión y con una parte del fondo de *rebates*.

Construí un simulador de colas y *fills* para evaluarlo sin operar. Dos hallazgos de diseño:


- ▶ la selección adversa de corto plazo es **favorable** al maker;
- ▶ el riesgo vive en el **inventario terminal**, no en el *spread*.

El vehículo viable es cobrar el *spread*, no pagarlo.



En la apertura el precio es casi una moneda al aire;
sólo en el tramo terminal se vuelve resolutivo.

Validación prospectiva pre-registrada: NO-GO



Una sola corrida sobre 35 días posteriores al sello. La política **gana dinero** —+3.408 \$ simulados— y aun así el veredicto es **NO-GO**: su peor día, -235,66 \$, cruza el umbral declarado de -150.

Y aquí está lo incómodo: esa puerta se falla el **63–87 %** de las veces *con independencia de la calidad de la política*. El sub-criterio que firmó el veredicto era el único sin potencia; el que sí la tenía se cumplía con holgura.

La ventana la cerró un fallo de hardware, no yo.

Una regla pre-registrada sólo vale si se obedece cuando incomoda.

El cuarto camino, y el que por fin tiene potencia

Capa	Corte 1	Corte 2
Histórica @0,5	-0,004	+0,075
Con comisión real	-0,770	-0,691
<i>Taker</i> entrada	-1,411	-1,334
<i>Taker</i> ida-vuelta	-3,646	-3,570

Medias en ticks · 50 y 55 días · 25.011 y 27.208 unidades

La cifra que este corte venía a contrastar —los +0,349 de junio— **nunca fue significativa**: su IC es $[-0,19; +0,89]$.

Así que no hay deterioro que explicar. Con **más de 30 veces más datos** la señal sigue sin distinguirse del azar: la capa histórica tiene el cero dentro del intervalo en los **dos** cortes, $[-0,22; +0,21]$ y $[-0,13; +0,29]$. Y la comisión vigente la vuelve decisivamente negativa en ambos.

Por fin potencia para afirmar la ausencia, no sólo para sugerirla.

¿Y si el problema era el objetivo, no la arquitectura?

Censo de las funciones de pérdida de todo el trabajo:

BCE ($\times 18$) · L1 ($\times 16$) · QLIKE ($\times 15$) ·
económicas ($\times 0$)

Todos los modelos entrenaban contra una pérdida estadística y decidían después con un umbral. La última línea entrena la **decisión** directamente contra el dinero, con el contrafactual exacto de cada acción y la puerta de riesgo escrita como función de pérdida.

El *sizing* continuo se descartó por medición: la caja no es monótona en el tamaño.

Para esta decisión, el mejor modelo resultó ser un número bien elegido.

0 de 16

puntos de la frontera aprendida
que batan a un parámetro escalar

Tras agotar los tres ejes —arquitectura, datos y objetivo— la conclusión ya no es que falte capacidad.

Los límites, declarados, son parte del resultado

- ▶ El simulador asume que los *makers* incumbentes **no reaccionan** a mis órdenes. Ningún *replay* puede medir esa respuesta.
- ▶ Dos tercios de las órdenes casadas dependen de un mecanismo declarado **optimista**.
- ▶ La malla de 2 s no permite observar el intervalo donde vive la latencia realmente medida.
- ▶ El suceso que hay que aprender a evitar —el día de pérdida severa— es tan raro que **las particiones pequeñas lo pierden**: una validación de una semana sale limpia el 43 % de las veces.
- ▶ Reproducibilidad parcial: el corpus completo no se publica por tamaño.

Por eso no se reporta ROI, sino ticks netos y soporte.

No convertir un diagnóstico retrospectivo en una promesa económica.

Aportaciones

1. Sistema de captura multifuente con control de calidad por sesión, y el corpus alineado que produce.
2. Protocolo de evaluación con costes y latencia medidos, **pre-registrado y sellado en la cadena de Bitcoin**.
3. Evidencia por **cuatro caminos independientes** de la ruptura entre predicción y ejecución.
4. Trazabilidad de los resultados negativos y de las correcciones, con la misma dignidad que los positivos.

La aportación no es «este modelo gana», sino un marco reproducible para evaluar señales de microestructura en mercados de predicción.

La metodología es el entregable.

Hay señal, pero es frágil.

La ejecución importa más que la precisión.

Cualquier afirmación económica necesita datos nuevos.

**En microestructura, una predicción sólo cuenta
si sobrevive al mercado.**

Queda sellada una confirmación prospectiva con mirada única, pendiente de ejecutarse sobre
datos que nadie ha visto.