

UNIVERSIDAD POLITÉCNICA DE MADRID
Escuela Técnica Superior de Ingeniería de Sistemas Informáticos



UNIVERSIDAD
POLITÉCNICA
DE MADRID



Máster
Deep Learning
Universidad Politécnica de Madrid

**Aprendizaje profundo aplicado a la
microestructura de mercados de predicción:
predicción de corto plazo en mercados de
Bitcoin de Polymarket**

**MÁSTER DE FORMACIÓN
PERMANENTE
EN DEEP LEARNING**

Presentado por:

Marc Maldonado Lorca

Bajo la dirección de:

Dra. María Inmaculada Santamaría Valenzuela

Madrid, 2026

Título: Aprendizaje profundo aplicado a la microestructura de mercados de predicción:
predicción de corto plazo en mercados de Bitcoin de Polymarket

Autor: Marc Maldonado Lorca

Máster de Formación Permanente en Deep Learning

Universidad Politécnica de Madrid

Dirección de Tesis:

Dra. María Inmaculada Santamaría Valenzuela, Universidad Politécnica de Madrid
(Directora)

Agradecimientos

Quiero agradecer especialmente a mi amigo Ramón, que me introdujo en este mundo y sin cuya curiosidad inicial este trabajo no habría existido. Gracias también a mi directora por su guía a lo largo del proyecto, y a mi familia y amigos por su apoyo durante el máster.

Abstract

This work studies whether deep learning can exploit market microstructure signals to anticipate the short-term price movement of binary contracts on Bitcoin traded on Polymarket, a prediction market. Unlike the literature focused on how the event finally resolves, here we target the local movements of the contract price over windows of a few seconds, combining the order book with external Bitcoin market references (spot, perpetual futures and a price oracle). The main contribution is not a single model but a reproducible methodology: a multi-source data capture system with per-session quality control, strictly temporal validation, and an evaluation that incorporates realistic execution costs and latency. The central, uncomfortable finding is that a directional classifier that is correct nearly nine out of ten times stops being profitable once a realistic two-second entry latency is introduced: what decides the outcome is cost and execution, not directional accuracy. Building on this, we evaluate a progression of models (tabular baselines, latency-aware models, and sequential and convolutional architectures over the order book) and a frozen tabular specialist. On the untouched five-day out-of-sample block, the specialist obtains a modest positive mean at the reference cost (+0.349 ticks per action, 754 actions and three out of five positive days), but turns slightly negative under the full-cost stress test. A volatility filter, whose numerical threshold came from the training period, is then explored after detecting a regime shift; it improves the result on the same block, so it is reported as a post-hoc diagnostic rather than as confirmatory evidence. We report every figure in net ticks together with its support and uncertainty, and we do not claim real profitability: the deliverable is the methodology, the evidence obtained under an auditable protocol, and the explicit delimitation of its limits.

Resumen

Este trabajo estudia si el aprendizaje profundo puede aprovechar señales de microestructura de mercado para anticipar el movimiento de corto plazo del precio de los contratos binarios sobre Bitcoin negociados en Polymarket, un mercado de predicción. A diferencia de la literatura centrada en cómo se resuelve finalmente el evento, aquí el objetivo son los movimientos locales del precio del contrato en ventanas de pocos segundos, combinando el libro de órdenes con referencias externas del mercado de Bitcoin (contado, futuros perpetuos y un oráculo de precios). La aportación principal no es un modelo concreto, sino una metodología reproducible: un sistema de captura de datos multifuente con control de calidad por sesión, una validación estrictamente temporal y una evaluación que incorpora costes de ejecución y latencia realistas. El hallazgo central, y algo incómodo, es que un clasificador direccional que acierta casi nueve de cada diez veces deja de ser rentable en cuanto se introduce una latencia de entrada realista de dos segundos: lo que decide el resultado es el coste y la ejecución, no el acierto direccional. A partir de ahí se evalúa una progresión de modelos (líneas base tabulares, modelos sensibles a la latencia y arquitecturas secuenciales y convolucionales sobre el libro de órdenes) y un especialista tabular congelado. En el bloque intacto de cinco días fuera de muestra, el especialista obtiene un promedio modestamente positivo al coste de referencia (+0,349 ticks por acción, 754 acciones y tres de cinco días positivos), pero pasa a ser ligeramente negativo bajo el coste de estrés completo. Tras detectar un cambio de régimen se explora un filtro de volatilidad cuyo umbral numérico procede del entrenamiento; como la decisión de incorporarlo se evalúa sobre ese mismo bloque, su mejora se presenta como diagnóstico *post-hoc*, no como evidencia confirmatoria. Todos los resultados se reportan en ticks netos junto a su soporte e incertidumbre, y no se afirma rentabilidad real: lo que se entrega es la metodología, la evidencia obtenida bajo un protocolo auditable y la delimitación explícita de sus límites.

Tabla de Contenido

Agradecimientos	ii
Abstract	iii
Resumen	iv
Lista de Figuras	vi
Lista de Tablas	vii
Abreviaturas y acrónimos	ix
1 Introducción	1
1.1 Introducción y definición del problema	1
1.1.1 Qué es un mercado de predicción	1
1.1.2 Qué es Polymarket	2
1.1.3 El libro de órdenes y el vocabulario de la microestructura	2
1.1.4 Definición del problema	3
1.2 Motivación	4
1.3 Objetivos	4
2 Estado de la cuestión	6
2.1 Trabajos previos y estudios relevantes	6
2.1.1 Mercados de predicción	6
2.1.2 Aprendizaje profundo sobre libros de órdenes	6
2.1.3 Microestructura, costes de ejecución y latencia	7
2.1.4 Aprendizaje automático en finanzas y validación temporal	7
2.1.5 Cambio de distribución y adaptación de dominio	8
2.2 Limitaciones en la literatura	8
3 Material y métodos	9
3.1 Descripción del dataset	9
3.1.1 Sistema de captura multifuente	9
3.1.2 Malla temporal y contrato de latencia	9
3.1.3 Controles de calidad por sesión	10
3.1.4 Composición del corpus	11
3.1.5 Análisis exploratorio del corpus	11
3.2 Resultados en modelos baseline	12
3.2.1 Línea base tabular y el impacto de la latencia	12
3.3 Metodología y entrenamiento	13
3.3.1 Definición del objetivo	13
3.3.2 Ingeniería de características	14
3.3.3 Validación temporal y prevención de fuga	15

3.3.4	Modelo de costes y latencia	15
3.3.5	Métricas de evaluación	16
3.3.6	La escalera de modelos	16
3.3.7	Especialista <i>prestart</i> H60	17
3.3.8	Filtro de volatilidad	18
3.3.9	Protocolo de congelación	18
4	Resultados y análisis	19
4.1	Resultados obtenidos	19
4.1.1	Validación fuera de muestra del especialista base	19
4.1.2	Diagnóstico <i>post-hoc</i> del régimen de volatilidad	20
4.1.3	Registro de sombra retrospectivo	21
4.2	Comparativa con otros enfoques y baseline	22
4.2.1	Especialista tabular frente a aprendizaje profundo	22
4.2.2	Experimentos de adaptación al régimen	23
5	Despliegue	24
5.1	Estrategia de despliegue y seguimiento en sombra	24
5.1.1	Por qué no se despliega	24
5.1.2	Del registro retrospectivo a la sombra prospectiva	24
5.1.3	Diseño de una hipotética API de inferencia	25
6	Aspectos éticos y limitaciones	26
6.1	Consideraciones éticas	26
6.2	Limitaciones	26
7	Reproducibilidad	28
7.1	Enlace a repositorio GitHub	28
7.1.1	Estructura del repositorio	28
7.1.2	Cómo reproducir	28
7.1.3	Datos no publicados	29
8	Conclusiones	30
	Referencias	31
	Glosario de términos	33
	Conjunto de características	35
	Hiperparámetros de los modelos	36

Lista de Figuras

1.1	El entorno del problema. El precio del contrato binario se forma en su libro de órdenes y está acoplado a referencias externas del mercado de Bitcoin. El objetivo es anticipar su movimiento de muy corto plazo.	3
3.1	Arquitectura del sistema de captura. Las cuatro fuentes se alinean sobre una malla de dos segundos, pasan un control de calidad por sesión y forman el corpus.	10
3.2	Flujo del control de calidad por sesión. Solo las sesiones que superan todos los umbrales se incorporan al corpus.	11
3.3	Partición temporal del corpus. El conjunto fuera de muestra (6–10 jun) se capturó después de congelar el candidato, lo que convierte su validación en una prueba genuina.	11
3.4	Neto medio en el test terminal frente a la latencia de entrada. La señal a latencia nula es real como <i>markout</i> desde el instante de la señal, pero no sobrevive como política ejecutable con dos segundos de latencia.	13
3.5	Modelo de dos cabezas. Un regresor predice el valor esperado de la operación y un clasificador predice si el relleno será “sano”. La política exige ambas condiciones.	14
3.6	La escalera de modelos. Cada paso debe superar al anterior bajo el mismo protocolo; si no lo hace, se descarta.	16
3.7	La ventana <i>prestart</i> del especialista: solo se opera entre −60 y −45 segundos respecto a la apertura del mercado, donde el análisis exploratorio detectó una densidad atípica de actividad del libro.	18
4.1	Fracción de sesiones de alta volatilidad por periodo. El salto del bloque nuevo motiva el análisis de régimen, pero no valida por sí mismo el filtro. .	20
4.2	Contraste <i>post-hoc</i> del neto medio entre baja y alta volatilidad. La separación es una hipótesis de política que requiere datos posteriores.	21
4.3	Sensibilidad al coste del subconjunto de baja volatilidad. Resultado exploratorio obtenido tras inspeccionar el mismo bloque.	21
4.4	Neto medio diario del subconjunto <i>post-hoc</i> de baja volatilidad.	22
4.5	Suma acumulada y drawdown diagnóstico de 318 unidades de acción. No representa una cartera con restricciones de capital o de exposición simultánea. .	22

Lista de Tablas

1.1	Ejemplo ilustrativo de un libro de órdenes (valores inventados con fines explicativos, no datos reales). El mejor <i>bid</i> es 0,52 y el mejor <i>ask</i> , 0,54; por tanto el <i>spread</i> es de 0,02 y el precio medio, 0,53. Los niveles más alejados del centro tienen, típicamente, más volumen acumulado.	2
3.1	Rendimiento en el test terminal bajo distintas latencias (ticks netos). . . .	12
3.2	Selección de horizonte (ticks netos <i>proxy</i>). Solo H60 conserva señal.	17
4.1	Validación fuera de muestra del especialista base congelado. Los valores son ticks netos por unidad de acción y no incorporan el filtro de volatilidad posterior.	19
4.2	Desglose diario del especialista base al coste de referencia.	20
4.3	Diagnóstico <i>post-hoc</i> por régimen en el bloque del 6–10 de junio (ticks por unidad de acción).	20
1	Hiperparámetros principales del especialista (HistGradientBoosting, dos cabezas).	36
2	Hiperparámetros principales de los modelos profundos (línea de exploración).	36

Abreviaturas y acrónimos

UPM Universidad Politécnica de Madrid

TFM Trabajo Fin de Máster

LOB Libro de órdenes (*Limit Order Book*)

BTC Bitcoin

AUC Área bajo la curva ROC (*Area Under the Curve*)

EV Valor esperado (*Expected Value*)

HGB *Histogram-based Gradient Boosting*

GRU Unidad recurrente con puertas (*Gated Recurrent Unit*)

LSTM Memoria larga a corto plazo (*Long Short-Term Memory*)

CNN Red neuronal convolucional (*Convolutional Neural Network*)

TCN Red convolucional temporal (*Temporal Convolutional Network*)

OOF Fuera de pliegue (*Out-Of-Fold*)

OOS Fuera de muestra (*Out-Of-Sample*)

IC Intervalo de confianza

QA Control de calidad (*Quality Assurance*)

API Interfaz de programación de aplicaciones (*Application Programming Interface*)

bps Puntos básicos (*basis points*)

Capítulo 1

Introducción

Este Trabajo Fin de Máster estudia un problema de predicción financiera de muy corto plazo en un entorno poco habitual: los mercados de predicción sobre el precio de Bitcoin de la plataforma Polymarket. El objetivo no es un sistema de trading en producción, sino una *metodología* rigurosa para responder, con honestidad estadística, a una pregunta concreta: ¿contiene el libro de órdenes de estos mercados señales que permitan anticipar el movimiento del precio en los próximos segundos y que, además, sobrevivan a los costes y a la latencia reales de operar?

Como el lector puede no estar familiarizado con el mundo de las criptomonedas ni con la microestructura de mercado, este capítulo introduce todos los conceptos desde cero antes de plantear el problema y los objetivos.

1.1 Introducción y definición del problema

Esta sección define el problema desde cero. Antes de plantear la pregunta de investigación se introducen los conceptos imprescindibles —mercado de predicción, contrato binario, libro de órdenes y señales de microestructura—, de modo que el documento resulte autocontenido también para un lector ajeno al mundo de las criptomonedas. Con ese vocabulario fijado, se enuncia el problema concreto que se aborda.

1.1.1 Qué es un mercado de predicción

Un *mercado de predicción* es un mercado en el que se compran y venden contratos cuyo valor depende del resultado de un acontecimiento futuro. El caso más sencillo es el *contrato binario*: un contrato que pagará una unidad monetaria si el acontecimiento ocurre y cero si no ocurre. Por construcción, su precio se mueve entre 0 y 1, y puede leerse directamente como la *probabilidad implícita* que el mercado asigna al suceso. Por ejemplo, un contrato “el precio de Bitcoin estará por encima de un umbral a una hora determinada” que cotiza a 0,60 indica que el mercado estima una probabilidad cercana al 60 % de que eso ocurra. Cuando el acontecimiento se resuelve, el contrato vale 1 o 0 y las posiciones se liquidan. La literatura clásica ha mostrado que estos mercados agregan información dispersa y producen previsiones razonablemente calibradas [3].

1.1.2 Qué es Polymarket

Polymarket es una plataforma de mercados de predicción descentralizada. A diferencia de una casa de apuestas, donde el operador fija las cuotas, en Polymarket son los propios participantes quienes ponen precios mediante un *libro de órdenes*: el emparejamiento de compras y ventas ocurre fuera de la cadena de bloques (de forma rápida) y la liquidación final del dinero se registra en cadena (sobre una *blockchain*) [2]. En los mercados sobre el precio de Bitcoin, cada contrato binario toma valores entre 0 y 1 y se interpreta como una probabilidad [1]. Esto convierte cada mercado en un pequeño *mercado electrónico* (*exchange*) con su propia dinámica de oferta y demanda.

1.1.3 El libro de órdenes y el vocabulario de la microestructura

El *libro de órdenes* (en inglés *limit order book*, LOB) es la lista, ordenada por precio, de todas las órdenes de compra y de venta que están a la espera de ejecutarse. Sus elementos esenciales son:

- **Bid**: el precio más alto al que alguien está dispuesto a comprar.
- **Ask**: el precio más bajo al que alguien está dispuesto a vender. Siempre es mayor o igual que el *bid*.
- **Spread**: la diferencia entre el *ask* y el *bid*. Es el primer coste de operar: quien compra al *ask* y vende al *bid* pierde el *spread*.
- **Profundidad**: el volumen disponible en cada nivel de precio. A más profundidad, más se puede operar sin mover el precio.
- **Precio medio** (*mid*): el punto medio entre *bid* y *ask*; una referencia “limpia” del precio sin el ruido del *spread*.
- **Tick**: la variación mínima de precio que admite el mercado. Es la unidad natural en la que mediremos todos los resultados de este trabajo.

La Tabla 1.1 muestra, a modo de ejemplo ilustrativo, el aspecto de un libro de órdenes con tres niveles a cada lado.

Tabla 1.1: Ejemplo ilustrativo de un libro de órdenes (valores inventados con fines explicativos, no datos reales). El mejor *bid* es 0,52 y el mejor *ask*, 0,54; por tanto el *spread* es de 0,02 y el precio medio, 0,53. Los niveles más alejados del centro tienen, típicamente, más volumen acumulado.

Compra (<i>bids</i>)		Venta (<i>asks</i>)	
Precio	Tamaño	Precio	Tamaño
0,52	120	0,54	90
0,51	200	0,55	150
0,50	340	0,56	220

La *microestructura de mercado* es la rama que estudia cómo se forman los precios a partir de estos mecanismos —órdenes, *spread*, profundidad y flujo de operaciones— a escalas de tiempo muy finas. En este contexto, se entiende por *señales de microestructura* las variables derivadas del propio libro de órdenes (por ejemplo, el desbalance entre compra y

venta, la presión del microprice o los cambios recientes del *spread*) que podrían contener información anticipatoria sobre el movimiento inmediato del precio. La Figura 1.1 resume el entorno: el precio del contrato se forma en su propio libro de órdenes, pero está acoplado a referencias externas del mercado de Bitcoin (mercado al contado, futuros perpetuos y un oráculo de precios), ya que, en última instancia, el contrato se refiere al precio de Bitcoin.

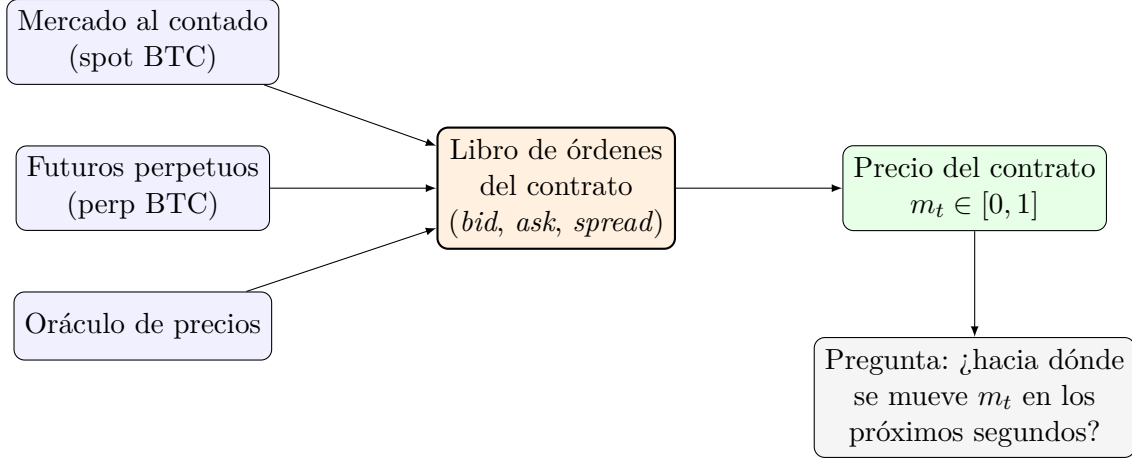


Figura 1.1: El entorno del problema. El precio del contrato binario se forma en su libro de órdenes y está acoplado a referencias externas del mercado de Bitcoin. El objetivo es anticipar su movimiento de muy corto plazo.

1.1.4 Definición del problema

El precio del contrato no es el precio de Bitcoin: es una función no lineal y dependiente del tiempo de la probabilidad de que el suceso se resuelva afirmativamente. Sin embargo, está acoplado a las referencias externas observables que se acaban de citar. Un modelo útil debe, por tanto, aprender simultáneamente dos elementos: la dinámica interna del libro de órdenes y la semántica del contrato respecto a Bitcoin.

El problema que se aborda es de microestructura y de muy corto plazo: dado el estado del mercado en un instante t (libro de órdenes y referencias externas), predecir el movimiento del precio medio del contrato en una ventana de pocas decenas de segundos. A diferencia de la mayor parte de la literatura sobre mercados de predicción, que estudia cómo se calibra el precio frente a la resolución final del evento, aquí el interés está en los movimientos locales del precio, a escala de segundos.

Conviene fijar desde el principio un matiz que vertebra todo el trabajo: una buena capacidad de *predecir la dirección* no implica una estrategia rentable. Esta distinción está bien documentada en la literatura de microestructura y de aprendizaje automático en finanzas [9, 11, 12]: una métrica de clasificación puede ser muy alta y, aun así, el sistema no ser explotable si opera con retraso, si aprende artefactos del propio conjunto de datos o si ignora el coste real de cruzar una orden. Por eso el problema no se evalúa por el acierto, sino por el resultado económico neto, una vez descontados costes y latencia realistas.

1.2 Motivación

La motivación de este trabajo es doble. Desde el punto de vista aplicado, los mercados de predicción de criptoactivos son un entorno joven, con menos competencia algorítmica que los mercados financieros tradicionales, y con datos públicos accesibles; resulta natural preguntarse si contienen señales explotables. Desde el punto de vista metodológico —que es el que da peso a una memoria de máster— el entorno es un excelente banco de pruebas para una cuestión central en el aprendizaje automático aplicado a finanzas: la distancia entre *predecir correctamente* y *obtener beneficio*.

Esa distancia es el hilo conductor. Como se mostrará, un clasificador direccional sencillo alcanza una precisión cercana al 90 % y, pese a ello, deja de ser rentable en cuanto se introduce una latencia de entrada realista de dos segundos. El coste y la ejecución, y no el acierto, determinan el resultado. Asumir lo contrario es uno de los errores más comunes y costosos en este campo, y documentarlo con evidencia cuantitativa es, en sí mismo, una aportación.

Conviene además situar las expectativas. El objetivo no es construir un sistema de trading en producción ni demostrar rentabilidad, sino algo más modesto y, a la vez, más exigente metodológicamente: determinar *si* existe señal explotable bajo condiciones realistas y, sobre todo, *cómo* evaluarla sin engañarse. En un dominio donde es fácil obtener resultados espectaculares pero ilusorios, el valor de un trabajo de máster está tanto en lo que encuentra como en el rigor con el que descarta lo que no se sostiene. Por eso, a lo largo de la memoria, los resultados negativos —modelos que parecían prometedores y no superaron la validación— se reportan con el mismo cuidado que los positivos.

1.3 Objetivos

El objetivo general es **construir y validar, con un protocolo honesto, una metodología completa para evaluar si el aprendizaje automático y profundo pueden anticipar el movimiento de corto plazo del precio de los contratos de Bitcoin de Polymarket bajo costes y latencia realistas**. De él se derivan los siguientes objetivos específicos:

1. Diseñar un sistema de captura de datos multifuente, con control de calidad por sesión, que produzca un corpus alineado temporalmente y libre de fugas.
2. Definir un protocolo de evaluación que combine validación estrictamente temporal, un modelo explícito de costes y una latencia medida empíricamente.
3. Cuantificar el impacto de la latencia sobre una señal direccional fuerte, para delimitar dónde se rompe la cadena entre predicción y ejecución.
4. Evaluar una progresión de modelos, de menor a mayor complejidad (líneas base tabulares, modelos sensibles a la latencia y arquitecturas profundas sobre el libro de órdenes), exigiendo que cada incremento de complejidad se justifique con evidencia.
5. Determinar si existe un candidato que sobreviva a una validación fuera de muestra bajo coste, y delimitar con rigor sus límites y su incertidumbre.

El presente trabajo se organiza como sigue. El Capítulo 2 revisa el estado de la cuestión. El Capítulo 3 describe los datos, las líneas base y la metodología de modelado y entrenamiento. El Capítulo 4 presenta y analiza los resultados sobre el conjunto fuera de muestra. El Capítulo 5 discute la estrategia de despliegue. El Capítulo 6 aborda los aspectos éticos

y las limitaciones. El Capítulo 7 detalla la reproducibilidad, y el Capítulo 8 recoge las conclusiones. Por último, los anexos incluyen un glosario de términos para el lector no familiarizado con las criptomonedas, el detalle de las características y los hiperparámetros de los modelos.

Capítulo 2

Estado de la cuestión

Este capítulo sitúa el trabajo en la literatura. Se organiza en cinco áreas que confluyen en el problema —mercados de predicción, aprendizaje profundo sobre libros de órdenes, microestructura y ejecución, validación temporal en finanzas, y cambio de distribución— y termina señalando el hueco concreto que este trabajo pretende cubrir.

2.1 Trabajos previos y estudios relevantes

Esta sección recorre la literatura relevante para el problema, organizada en cinco bloques temáticos. En cada bloque se resume qué proponen los trabajos de referencia y qué se toma de ellos para este trabajo. La predicción del movimiento de precios a partir de la microestructura es un campo activo, con propuestas asentadas tanto para mercados tradicionales como para criptoactivos; el interés aquí es seleccionar de esa literatura los elementos aplicables a un mercado de predicción sobre Bitcoin.

2.1.1 Mercados de predicción

Los mercados de predicción se han estudiado, sobre todo, como mecanismos de agregación de información dispersa. Wolfers y Zitzewitz [3] muestran que pueden producir previsiones notablemente precisas, si bien su interpretación depende del diseño del contrato, de la liquidez y de los incentivos de los participantes. La mayor parte de esta literatura analiza la calibración del precio frente a la resolución final del evento. El presente trabajo se sitúa un escalón por debajo, en el terreno de la microestructura: la dinámica intradía del precio del contrato a escala de segundos, donde aparecen *spreads*, profundidad limitada y desajustes transitorios respecto a las referencias externas. Conviene además precisar el mecanismo: a diferencia de los mercados de predicción basados en creadores de mercado automáticos (que fijan el precio mediante una fórmula), Polymarket emplea un libro de órdenes, lo que hace aplicable el instrumental clásico de la microestructura y justifica el enfoque de este trabajo.

2.1.2 Aprendizaje profundo sobre libros de órdenes

La predicción del movimiento de precios a partir del libro de órdenes es un problema con una literatura ya madura. El trabajo de referencia es DeepLOB [4], que representa el libro como una matriz de dos dimensiones (niveles de precio frente a tiempo) y aplica

primero módulos convolucionales —que capturan la estructura espacial entre los niveles de compra y de venta— y, a continuación, capas recurrentes que modelan la dependencia temporal; se valida sobre FI-2010 [5], un conjunto de referencia público de libros de órdenes ampliamente utilizado como banco de pruebas. En la misma línea, Tsantekidis et al. [6] comparan arquitecturas convolucionales y recurrentes para detectar cambios de precio en el libro. Sirignano y Cont [7] aportan evidencia de la existencia de características universales en la formación de precios que el aprendizaje profundo es capaz de capturar, y Jha et al. [8] trasladan estas ideas al terreno de los criptoactivos, mostrando que el enfoque no es exclusivo de los mercados tradicionales.

De esta literatura este trabajo adopta una decisión de diseño —tratar el libro de órdenes como un objeto con estructura espacio-temporal, y no como una tabla plana— y, sobre ella, introduce dos cambios. El primero es metodológico: evaluar cada modelo bajo un modelo de ejecución realista (coste y latencia), y no solo con métricas de clasificación como es habitual en estos trabajos. El segundo es de dominio: aplicar el enfoque a un mercado de predicción sobre Bitcoin —y no a un mercado de acciones—, lo que obliga a combinar el libro con referencias externas. Esa doble diferencia es, precisamente, donde este trabajo pone el acento.

2.1.3 Microestructura, costes de ejecución y latencia

La distancia entre predecir bien y obtener beneficio es uno de los temas clásicos de la microestructura de mercado. Kearns y Nevmyvaka [9] revisan el papel del aprendizaje automático en microestructura y negociación de alta frecuencia, y subrayan que la ejecución, el coste y la latencia condicionan de forma decisiva la viabilidad de una señal. Este trabajo cuantifica ese fenómeno en el contexto concreto de Polymarket: se mide la latencia real del ciclo de orden y se demuestra que una señal direccional fuerte se vuelve no rentable bajo una latencia de entrada modesta. El cambio que se introduce respecto a esta literatura es, de nuevo, metodológico: en lugar de asumir una latencia o un coste fijos, ambos se determinan a partir de los datos —la latencia, de forma empírica sobre el ciclo de orden real; el coste, de forma relativa al estado del libro en cada instante—, de modo que la evaluación económica refleje las condiciones efectivas de ejecución.

2.1.4 Aprendizaje automático en finanzas y validación temporal

El aprendizaje automático aplicado a la predicción financiera es especialmente propenso a resultados ilusorios cuando la evaluación no respeta la estructura temporal de los datos. Gu, Kelly y Xiu [10] ofrecen un marco riguroso de comparación de modelos con validación fuera de muestra. López de Prado [11] documenta los mecanismos por los que se cuela información del futuro y por los que se sobreajustan los *backtests*, y propone protocolos de validación que respetan la causalidad temporal. Bailey y López de Prado [12] advierten de un riesgo adicional: si se prueban muchos modelos y se elige el mejor, las métricas de rendimiento salen infladas casi por construcción. Estas referencias motivan tres decisiones metodológicas de este trabajo: la partición estrictamente temporal, el protocolo fuera de pliegue (*out-of-fold*) y la congelación del candidato antes de observar el conjunto de validación fuera de muestra.

2.1.5 Cambio de distribución y adaptación de dominio

Los mercados financieros no son estacionarios, por lo que la distribución de los datos cambia entre el periodo de entrenamiento y el de despliegue. Para amortiguar ese efecto existen técnicas de adaptación de dominio, como la alineación de correlaciones CORAL [13]. En el Capítulo 4 se mostrará un resultado contraintuitivo: con un horizonte de datos reducido, estas técnicas no superan a una estrategia mucho más simple, consistente en restringir la operativa al régimen en el que el modelo fue entrenado. Además de CORAL, en este trabajo se evalúan otras estrategias de adaptación habituales —filtros conformales, *ensembles* y reentrenamiento incremental con ventana móvil—, cuyos resultados se detallan en el Capítulo 4. Por último, en cuanto a arquitecturas profundas para series temporales multivariantes, trabajos como el *Temporal Fusion Transformer* [14] marcan una línea de evolución natural para cuando se disponga de muchos más datos.

2.2 Limitaciones en la literatura

Del repaso anterior se desprenden tres limitaciones recurrentes que enmarcan la aportación de este trabajo. En primer lugar, la evaluación predominante es de *clasificación* (precisión, AUC), y rara vez se traduce a un resultado económico bajo un modelo de ejecución realista; como se verá, esa traducción cambia las conclusiones por completo. En segundo lugar, gran parte de los resultados positivos se obtienen sin una latencia de entrada explícita, cuando la latencia es precisamente lo que destruye muchas señales de corto plazo. En tercer lugar, los entornos de criptoactivos jóvenes ofrecen pocos datos, lo que agrava el riesgo de sobreajuste y de resultados ilusorios si la validación no es estrictamente temporal.

El hueco que cubre este trabajo es, por tanto, metodológico: evaluar la predicción de corto plazo *bajo coste y latencia medida*, con validación estrictamente temporal y congelación previa del candidato, y reportar cada resultado en ticks netos acompañado de su soporte y su incertidumbre.

Capítulo 3

Material y métodos

Este capítulo describe el material (los datos) y los métodos (líneas base, protocolo de validación y modelos) del trabajo. Se ha organizado en tres bloques: la descripción del conjunto de datos, los resultados de las líneas base —que contienen la lección central del trabajo— y la metodología de modelado y entrenamiento.

3.1 Descripción del dataset

Esta sección describe el origen de los datos, su organización temporal y los controles de calidad que determinan qué entra en el conjunto de trabajo. Se introducen primero los conceptos necesarios —fuentes de datos, malla temporal y contrato de latencia, y datos obsoletos— y después se resume la composición del corpus y su análisis exploratorio.

3.1.1 Sistema de captura multifuente

Los datos de mercado se registran mediante una herramienta de captura propia, desarrollada específicamente para este trabajo. Por su carácter sensible, esta herramienta no se publica y aquí se describe únicamente a nivel funcional; lo que sí se publica (Capítulo 7) es el esquema de la consulta de datos, una muestra representativa y todo el código de análisis y modelado. A nivel funcional, por cada sesión de mercado la herramienta anota cuatro tipos de información: (i) el libro de órdenes del contrato de Polymarket y su flujo de operaciones; (ii) los metadatos del mercado (tamaño de tick, ventana temporal, comisiones); (iii) referencias externas del mercado de Bitcoin —el mercado al contado (*spot*) y los futuros perpetuos (*perpetual futures*)—; y (iv) un oráculo de precios que aporta el precio de referencia. La fuente de verdad es una base de datos relacional sobre la que se construyen las características; de ella se publican el esquema y una muestra representativa, pero no los datos completos. Todas las fuentes se alinean en el tiempo sobre una malla regular de dos segundos, como se detalla a continuación (Figura 3.1).

3.1.2 Malla temporal y contrato de latencia

Las observaciones se organizan sobre una malla temporal regular: una secuencia de instantes $t_0, t_1, t_2, \dots$ separados exactamente dos segundos, de modo que $t_{k+1} = t_k + 2$ segundos. En cada instante t_k se toma una “fotografía” del estado del mercado (libro de órdenes y referencias externas). La elección de este intervalo no es accesorio, porque define lo que

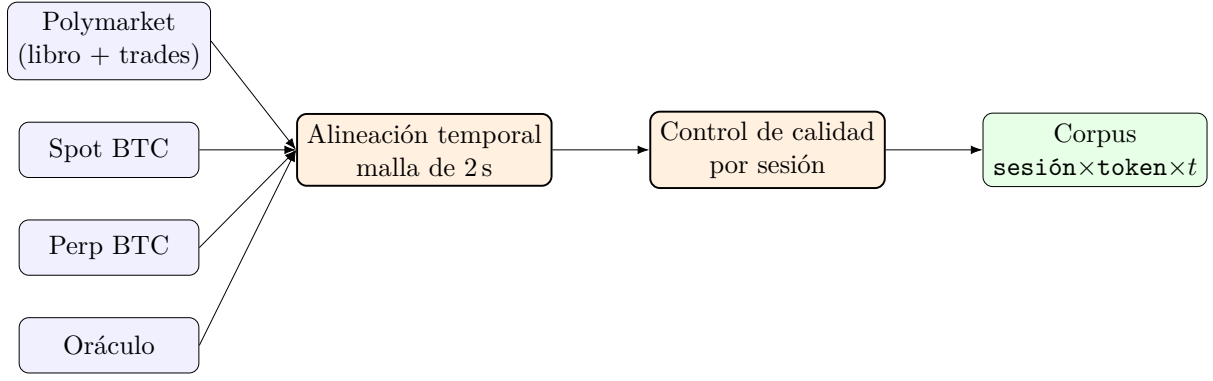


Figura 3.1: Arquitectura del sistema de captura. Las cuatro fuentes se alinean sobre una malla de dos segundos, pasan un control de calidad por sesión y forman el corpus.

en este trabajo se denomina *contrato de latencia*: el supuesto sobre cuánto tarda una decisión en poder ejecutarse. En lugar de interpolar un instante intermedio que nunca se observó, una decisión tomada con la información de t_k se evalúa contra la siguiente fotografía real, t_{k+1} ; es decir, se asume que entre observar la señal y poder operar transcurre, como mínimo, el intervalo de la malla. Este criterio hace la evaluación deliberadamente conservadora y evita el error habitual de suponer ejecución instantánea.

3.1.3 Controles de calidad por sesión

La calidad de los datos es tan crítica como el modelo: una referencia externa retrasada o incompleta puede inducir una señal que en realidad no existe. Por ello, antes de incorporarse al conjunto de trabajo, cada sesión de mercado pasa una batería de controles de calidad y se descarta por completo si no los supera (Figura 3.2). Conviene definir primero un concepto recurrente: un dato *obsoleto* (en inglés *stale*) es un valor que no se ha actualizado cuando debería haberlo hecho —por ejemplo, una cotización externa que permanece “congelada” varios instantes de la malla porque su fuente dejó de emitir—. Un dato obsoleto parece información válida, pero no lo es, y es una de las principales fuentes de señales espurias.

Los controles aplicados a cada sesión son los siguientes:

Cobertura Fracción de instantes de la malla efectivamente observados respecto a los esperados durante la sesión; una cobertura baja indica una captura incompleta.

Continuidad Ausencia de interrupciones prolongadas en el registro de las fuentes.

Obsolescencia Proporción de instantes con datos *stale*; si una referencia se queda congelada demasiado tiempo, la sesión se rechaza.

Arranque Validación de que la sesión comenzó a capturarse correctamente, sin un periodo inicial degradado.

Huecos severos Detección de saltos temporales grandes que la malla no puede rellenar de forma fiable.

Esta política es deliberadamente estricta: se prefiere reducir el tamaño de la muestra antes que contaminar el entrenamiento con ruido que el modelo podría confundir con una señal. Como consecuencia, el corpus efectivo es sensiblemente menor que el total capturado, lo que más adelante justifica la estrategia de regularización agresiva.




Figura 3.2: Flujo del control de calidad por sesión. Solo las sesiones que superan todos los umbrales se incorporan al corpus.

3.1.4 Composición del corpus

Se denomina *corpus* al conjunto de todas las sesiones aceptadas tras el control de calidad; sobre él se definen después las particiones temporales (entrenamiento, validación y test). El corpus principal abarca del 11 al 25 de mayo de 2026, con del orden de 2,6 millones de filas multifuente (*cross-venue*). Como conjunto fuera de muestra se reservó del 6 al 10 de junio de 2026, capturado con posterioridad a la congelación del candidato (Sección 3.3.9). La unidad de observación es la tupla `sesión × token × instante` sobre la malla de dos segundos. La Figura 3.3 resume la partición temporal.




Figura 3.3: Partición temporal del corpus. El conjunto fuera de muestra (6–10 jun) se capturó después de congelar el candidato, lo que convierte su validación en una prueba genuina.

3.1.5 Análisis exploratorio del corpus

El análisis exploratorio previo deja cuatro observaciones que condicionan todo el diseño posterior:

1. **Desequilibrio de clases.** La etiqueta direccional está dominada por la clase FLAT (quietud): a horizonte de 60 segundos, entre el 55 y el 65 % de las observaciones caen dentro de la banda de quietud. Esto vuelve engañosa la precisión bruta —un modelo que prediga siempre FLAT ya supera el 60 %— y obliga a usar precisión equilibrada (*balanced accuracy*) y F1 macro.
2. **Calidad de los datos.** En los tramos de alta volatilidad, los retardos de actualización de las referencias externas abarcan varios ciclos de la malla; tras el filtrado, el corpus efectivo es sensiblemente menor que el total capturado, lo que justifica una regularización agresiva.
3. **Patrón *prestart*.** La ventana inmediatamente anterior a la apertura del mercado concentra una densidad atípica de cancelaciones, modificaciones y cruces, lo que sugiere reposicionamiento de los participantes y una señal de microestructura diferenciada. Esta observación motiva el *modelo especialista* —un modelo entrenado exclusivamente para esa ventana, en lugar de uno generalista— que se describe más adelante en este capítulo.
4. **Acoplamiento con Bitcoin.** La correlación entre el precio del contrato y las referencias de Bitcoin es clara en ventanas de minutos pero se diluye en ventanas de

segundos: el arbitraje externo no es instantáneo. Esa separación de escalas justifica combinar el libro local con las referencias externas.

En conjunto, estas cuatro observaciones no son anecdóticas: determinan decisiones concretas del resto del trabajo. El desequilibrio de clases fija la elección de métricas; la calidad de los datos y su escasez efectiva imponen la regularización agresiva y la prudencia en la validación; el patrón *prestart* define la ventana del especialista; y el acoplamiento con Bitcoin justifica el bloque de características externas. Es decir, el diseño metodológico de los apartados siguientes se deriva directamente de lo que muestran los datos, y no de elecciones arbitrarias.

3.2 Resultados en modelos baseline

Antes de introducir cualquier modelo complejo conviene establecer una línea base sencilla y medir su comportamiento bajo condiciones realistas. Esta sección muestra que una línea base tabular alcanza una precisión direccional muy alta y, sin embargo, deja de ser rentable al introducir la latencia; este resultado es la observación que reorienta todo el trabajo.

3.2.1 Línea base tabular y el impacto de la latencia

La línea base son modelos sobrios y bien entendidos —una regresión logística balanceada y un *gradient boosting* pequeño, también balanceado— sobre el conjunto de características descrito antes, con la etiqueta direccional a un horizonte corto (16 segundos). Se entrena por *token-frame* y se evalúa por *market-frame*, para no contar dos veces el mismo instante del mercado. Esta línea base alcanza una precisión direccional cercana al 90 % y supera la validación temporal por bloques. Evaluada solo con métricas de clasificación, parece un modelo excelente. El problema aparece al introducir la entrada retrasada y el coste. La Tabla 3.1 y la Figura 3.4 muestran el rendimiento en el test terminal —el bloque no utilizado para seleccionar la política— en función de la latencia de entrada, en un escenario conservador con filtro de *spread*.

Tabla 3.1: Rendimiento en el test terminal bajo distintas latencias (ticks netos).

Latencia	Acciones	Acierto UP	Neto medio	Neto total
0 s	64	92,2 %	+6,79	+434,44
2 s	63	39,7 %	−1,48	−93,48
4 s	66	45,5 %	−0,74	−48,83
8 s	66	43,9 %	−0,30	−19,53

La lectura de la tabla es contundente. A latencia nula la política sería extraordinaria (+6,79 ticks de media, con un 92 % de acierto en las operaciones de subida), porque mide el *markout* desde el instante exacto de la señal. Pero a dos segundos —el primer escalón realista— el acierto se desploma al 39,7 % y el neto pasa a −1,48 ticks: la oportunidad ya se ha consumido cuando la orden podría ejecutarse. Es revelador que a 4 y 8 segundos el neto *mejore* ligeramente (hacia −0,74 y −0,30): no es que operar más tarde sea mejor, sino que a esas latencias el modelo ya ni siquiera detecta la señal efímera que lo hacía perder, de modo que sus decisiones se vuelven casi aleatorias y el daño se diluye. En otras




Figura 3.4: Neto medio en el test terminal frente a la latencia de entrada. La señal a latencia nula es real como *markout* desde el instante de la señal, pero no sobrevive como política ejecutable con dos segundos de latencia.

palabras, toda la ventaja vivía en una ventana de pocos segundos que la latencia hace inaccesible.

Este es el resultado que vertebra todo el trabajo: **acertar la dirección no equivale a obtener beneficio**. Con una latencia realista de dos segundos, el neto medio del test terminal cae a $-1,48$ ticks. El problema deja de ser de clasificación y pasa a ser de ejecución; a partir de aquí, todo modelo se evalúa por su política económica bajo coste y latencia, no por su acierto.

3.3 Metodología y entrenamiento

Esta sección detalla cómo se define el objetivo de aprendizaje, cómo se valida sin incurrir en fugas temporales, cómo se modelan los costes y la latencia, qué métricas deciden y qué progresión de modelos se evaluó hasta llegar al candidato final. El hilo conductor es que cada decisión metodológica está orientada a un objetivo: evitar resultados ilusorios y medir el rendimiento económico real.

3.3.1 Definición del objetivo

Para cada instante t se define el retorno futuro del precio medio a un horizonte H ,

$$\Delta_H(t) = \frac{m_{t+H} - m_t}{m_t}, \quad (3.1)$$

donde m_t es el precio medio del contrato. La etiqueta direccional se obtiene con un umbral θ que absorbe el *spread*, las comisiones y el ruido:

$$y_t = \begin{cases} \text{UP} & \text{si } \Delta_H(t) > \theta, \\ \text{DOWN} & \text{si } \Delta_H(t) < -\theta, \\ \text{FLAT} & \text{en otro caso.} \end{cases} \quad (3.2)$$

Esta etiqueta ternaria es útil para mirar el arco experimental en su conjunto; el especialista final, en cambio, usa los dos objetivos económicos que se definen más abajo. Las características son causales (solo usan información hasta t) y las etiquetas se calculan *a posteriori* de forma trazable, de modo que no entra información del futuro por las entradas del modelo. Todos los resultados económicos se expresan en ticks netos, que es la unidad natural del libro; no se traducen a dinero porque ello exigiría suponer un tamaño de posición y favorecería la sobreafirmación.

Los dos objetivos del especialista. El modelo final no usa la etiqueta ternaria, sino dos objetivos complementarios, porque un modelo que debe decidir si entra necesita saber algo más fino que la dirección: cuánto vale la operación y si el entorno de ejecución es favorable (Figura 3.5).




Figura 3.5: Modelo de dos cabezas. Un regresor predice el valor esperado de la operación y un clasificador predice si el relleno será “sano”. La política exige ambas condiciones.

El **regresor** predice `exec_net_cost_0p25_H60`: el neto ejecutado a 60 segundos tras descontar una fracción (0,25) del coste visible de entrada de cada operación. El **clasificador** predice `healthy_fill_proxy_0p25_H60`: una variable binaria que vale 1 cuando ese neto es positivo y la operación no cae en el peor cuartil de un grupo de operaciones comparables (mismo bloque temporal, fase, nivel de *spread*, microprice y momento del perp). La independencia entre ambas cabezas es deliberada: una operación puede tener alto valor esperado pero baja probabilidad de relleno sano si el libro está degradado.

3.3.2 Ingeniería de características

El especialista recibe un vector de 36 características, todas calculadas exclusivamente con información disponible hasta el instante t . Se agrupan en cuatro bloques con una justificación clara para cada uno:

Estado del libro Resúmenes del libro de órdenes de Polymarket: precio medio, *spread*, *microprice* (precio ponderado por volumen, que anticipa la presión de compra-venta), desbalance entre niveles, coste visible de entrada y cambios recientes del precio. Describen el estado local del mercado.

Referencias externas Retornos orientados del mercado al contado y de los futuros perpetuos a 2 y 8 segundos, junto con medidas de consenso y de actualización. Capturan el acoplamiento con Bitcoin, que el análisis exploratorio mostró relevante a escala de segundos.

Volatilidad La volatilidad realizada del perpetuo a 5 segundos, empleada posteriormente en el diagnóstico de cambio de régimen.

Contexto de ventana Posición dentro de la ventana *prestart* y *proxies* de calidad del libro (cobertura e indicadores de degradación), que informan de la ejecutabilidad.

Una decisión deliberada es excluir las variables de reloj (hora, minuto, segundo): el conjunto se denomina por ello *no_clock*. El motivo es evitar que el modelo aprenda atajos temporales triviales —por ejemplo, asociar la señal a un instante concreto del día— que no generalizarían y que, en la práctica, son una forma sutil de sobreajuste. El inventario completo se recoge en el Anexo 8.

3.3.3 Validación temporal y prevención de fuga

Una partición aleatoria por filas, habitual en problemas sin estructura temporal, sería aquí un error grave: las observaciones contiguas están autocorrelacionadas y un mismo mercado puede aparecer a ambos lados del corte, de modo que el modelo acabaría “viendo el futuro”. Por ello la partición respeta siempre el orden del tiempo: el entrenamiento utiliza las sesiones más antiguas, la validación las posteriores y el test terminal el bloque final, que permanece sellado hasta el final del proceso.

En los experimentos secuenciales se refuerza esta disciplina con un protocolo fuera de pliegue (*out-of-fold*) de tipo *walk-forward* expansivo: el conjunto de entrenamiento crece hacia delante en el tiempo y, en cada pliegue, las predicciones que consume una segunda etapa proceden siempre de un modelo que no las entrenó. A ello se añaden dos protecciones en las fronteras entre bloques. La *purga* retira del entrenamiento las observaciones cuyo horizonte de etiqueta se solapa con el bloque que se está evaluando, ya que de lo contrario una etiqueta calculada con datos del bloque evaluado contaminaría el ajuste. El *embargo* descarta además un pequeño margen temporal alrededor de cada frontera, para que el solape de las secuencias históricas tampoco introduzca fuga. La política de decisión se selecciona únicamente sobre la validación, sin observar en ningún momento el test terminal. Esta disciplina contra la fuga temporal es la principal salvaguarda frente a los resultados ilusorios que la literatura describe de forma reiterada [11, 10].

3.3.4 Modelo de costes y latencia

La latencia no se supone, se mide. En una prueba controlada del ciclo de orden de Polymarket, el tiempo entre observar la oportunidad y confirmar el emparejamiento fue de unos 0,43 segundos en el percentil 95 de la muestra válida. Aun así, por prudencia se trabaja con cifras peores: una latencia conceptual de un segundo y una latencia observable en los datos de dos segundos (la malla de captura). El coste de ejecución no se fija como un número plano de ticks, sino como una fracción del coste visible de entrada de cada operación: la mitad de ese coste como referencia, un cuarto como contraste optimista y el coste completo como prueba de estrés. Modelar el coste relativo al libro de cada instante es más fiel que asumir un coste fijo e igual para todas las operaciones. Formalmente, el neto ejecutado a horizonte H con un factor de coste $c \in \{0, 0,25, 0,5, 1\}$ es

$$\text{net}_c(t) = \left(\Delta_H^{\text{ticks}}(t) - b \right) - c \cdot \kappa_t, \quad (3.3)$$

donde $\Delta_H^{\text{ticks}}(t)$ es el *markout* en ticks desde la entrada (a dos segundos del instante de señal) hasta el horizonte, b es un *buffer* fijo y κ_t es el coste visible de entrada de esa operación. Nótese que, por construcción, un factor de coste mayor produce un neto menor

sobre la misma operación; por eso el resultado al coste de referencia ($c = 0,5$) es siempre inferior al optimista ($c = 0,25$) y superior al de estrés ($c = 1$).

3.3.5 Métricas de evaluación

La elección de métricas es deliberada y responde a las características del problema. Para la fase de clasificación no se reporta la precisión bruta (*accuracy*), porque el dominio de la clase FLAT la vuelve engañosa; en su lugar se usan la **precisión equilibrada** (*balanced accuracy*) y la **F1 macro**, que promedian por clase y no premian al modelo que siempre predice quietud. Para medir la capacidad de *ordenar* las oportunidades se emplea el **AUC** (área bajo la curva ROC), independiente del umbral.

Ahora bien, la métrica que decide es económica, no de clasificación: el **neto medio por operación** bajo el modelo de costes de la ecuación (3.3). A su alrededor se reportan siempre cuatro elementos de soporte e incertidumbre: (i) el **número de operaciones y de días**, porque un neto sin soporte no es interpretable; (ii) un **intervalo de confianza bootstrap** (5 000 remuestreos, semilla fija); (iii) la **probabilidad de neto positivo** estimada sobre esa misma distribución; y (iv) el **drawdown máximo** y el número de **días positivos**, como medidas de estabilidad. Esta batería evita confundir una señal estadística con una estrategia viable.

3.3.6 La escalera de modelos

Los modelos se evalúan en una progresión incremental, de menor a mayor complejidad, exigiendo en cada salto que la complejidad añadida se justifique con evidencia de mejora bajo el mismo protocolo de costes y validación (Figura 3.6).

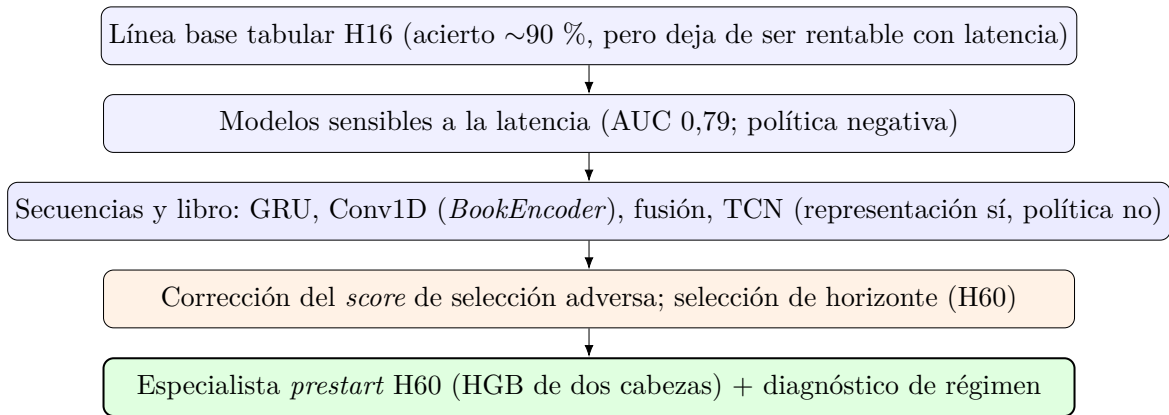


Figura 3.6: La escalera de modelos. Cada paso debe superar al anterior bajo el mismo protocolo; si no lo hace, se descarta.

Modelos sensibles a la latencia. El primer salto sobre el baseline consiste en incorporar la latencia ya en el etiquetado y en la selección, de modo que el modelo aprenda a elegir operaciones que sigan siendo rentables *tras* el retardo de entrada. Uno de estos modelos alcanza un AUC de test de 0,79 —una capacidad de clasificación notable— y, sin embargo, su política económica sigue siendo negativa. La conclusión refuerza la lección central: más capacidad de clasificación no implica una política rentable.

Modelos secuenciales y sobre el libro de órdenes. El siguiente nivel trata el libro como un objeto con estructura espacio-temporal. Se construyen secuencias de ocho fotografías consecutivas y un tensor de los diez primeros niveles del libro, y sobre esa representación se evalúan cuatro arquitecturas:

- una red recurrente **GRU** (capa oculta de dimensión 56) sobre la secuencia de características, que modela la dinámica temporal reciente;
- un codificador convolucional del libro, el **BookEncoder**, inspirado en DeepLOB [4, 6], que resume cada fotografía con dos convoluciones unidimensionales sobre la dimensión de niveles y un *pooling* dual,

$$\mathbf{h} = \left[\text{mean}_{\tau} \phi(\mathbf{B}_{\tau}) \parallel \text{max}_{\tau} \phi(\mathbf{B}_{\tau}) \right], \quad \phi = \text{ReLU} \circ \text{Conv1d} \circ \text{Dropout} \circ \text{ReLU} \circ \text{Conv1d}, \quad (3.4)$$

donde $\mathbf{B}_{\tau}$ es el libro en el paso τ y $\parallel$ denota concatenación; el *pooling* máximo capta los picos de profundidad, a menudo más informativos que la media en mercados poco líquidos;

- una **fusión** que combina la salida de la GRU y la del BookEncoder en una cabeza común, para aprovechar simultáneamente la dinámica temporal y la estructura del libro;
- una red convolucional temporal (**TCN**) orientada a clasificar el régimen de volatilidad de la sesión.

Todas estas arquitecturas aprenden representación —obtienen métricas de clasificación y de ordenación razonables, y algunas políticas *proxy* resultan positivas dentro de muestra—, pero ninguna produce una política rentable y estable cuando se exige selección causal día a día y estabilidad en todo el bloque de test. Con un horizonte de entrenamiento de unas dos semanas (unos 5 800 ejemplos) la varianza de estos modelos es demasiado alta: memorizan el periodo de entrenamiento y no generalizan al siguiente. Por eso el aprendizaje profundo se aparca a la espera de un volumen de datos sustancialmente mayor.

Durante la auditoría se detectó y corrigió un error de interpretación en el *score* de selección adversa (su orientación correcta es $1 - P(\text{adverso})$), lo que ilustra que una métrica positiva no basta sin auditar su significado económico. Por último, al comparar horizontes (Tabla 3.2), solo H60 conserva señal; H120 y H240 colapsan, por lo que H60 queda como único candidato.

Tabla 3.2: Selección de horizonte (ticks netos *proxy*). Solo H60 conserva señal.

Métrica	H60	H120
AUC test	0,565	0,495
Top 35 % test, coste 0,5	+0,426	−1,117
Top 35 % test, coste 1,0	+0,058	−1,491

3.3.7 Especialista *prestart* H60

El candidato final es un especialista para la ventana *prestart*: un modelo de *gradient boosting* sobre histogramas (HistGradientBoosting) con las dos cabezas descritas, entrenado sobre 36 características sin variables de reloj (para evitar atajos temporales triviales). La señal se restringe a la ventana de -60 a -45 segundos respecto a la apertura, con libro saludable y coste visible acotado (Figura 3.7).




Figura 3.7: La ventana *prestart* del especialista: solo se opera entre -60 y -45 segundos respecto a la apertura del mercado, donde el análisis exploratorio detectó una densidad atípica de actividad del libro.

Ambas cabezas comparten una configuración de regularización agresiva (tasa de aprendizaje 0,045, hasta 220 iteraciones con parada anticipada, máximo de 15 hojas por árbol, mínimo de 120 muestras por hoja y regularización L2 de 0,10), necesaria porque el bloque de entrenamiento del especialista tiene del orden de mil observaciones útiles. La política congelada opera cuando el valor esperado predicho supera 0,75 y la probabilidad de salud no baja de 0,50; ambos umbrales se seleccionaron sobre el conjunto de validación, nunca sobre el test terminal.

3.3.8 Filtro de volatilidad

Al inspeccionar el bloque fuera de muestra se observó un cambio de régimen: la fracción de sesiones de alta volatilidad pasó de un 18–22 % en entrenamiento a alrededor del 58 % (véase la Figura 4.1 del Capítulo 4). Como diagnóstico se separaron las acciones usando el umbral 0,6657, correspondiente al percentil 80 de la volatilidad de entrenamiento. El valor numérico procede, por tanto, de datos antiguos; sin embargo, la decisión de incorporar este filtro a la política se tomó después de observar el nuevo bloque. Por esa razón, el resultado filtrado no se considera una segunda validación fuera de muestra, sino un análisis *post-hoc* que genera una hipótesis para validación prospectiva.

3.3.9 Protocolo de congelación

El especialista base —modelo, conjunto de características y umbrales EV/salud— se congeló antes de observar el conjunto fuera de muestra del 6 al 10 de junio. Su evaluación sin filtro constituye, por ello, la prueba fuera de muestra genuina y previene el sobreajuste por selección múltiple [12]. El filtro de volatilidad queda fuera de esa afirmación de congelación: se definió como política candidata después del diagnóstico del bloque y solo podrá validarse con observaciones posteriores al 10 de junio.

Capítulo 4

Resultados y análisis

Este capítulo separa dos niveles de evidencia que no deben confundirse. Primero se presenta la evaluación confirmatoria del especialista base, congelado antes de observar el bloque del 6 al 10 de junio. Después se documenta el diagnóstico de volatilidad realizado sobre ese mismo bloque. El segundo resultado es útil para formular una política futura, pero no constituye una nueva validación fuera de muestra.

4.1 Resultados obtenidos

4.1.1 Validación fuera de muestra del especialista base

El especialista congelado selecciona 754 unidades de acción en los cinco días fuera de muestra. Sin aplicar ningún filtro decidido a partir de esos datos, obtiene un neto medio de +0,349 ticks al coste de referencia. El promedio es positivo en tres de cinco días y pasa a ser ligeramente negativo ($-0,026$ ticks) cuando se carga el coste visible completo (Tabla 4.1). Esta es la estimación limpia del rendimiento fuera de muestra.

Tabla 4.1: Validación fuera de muestra del especialista base congelado. Los valores son ticks netos por unidad de acción y no incorporan el filtro de volatilidad posterior.

Métrica	Valor
Unidades de acción (n)	754
Días de soporte	5 (3/5 positivos)
Neto medio (coste 0,25, optimista)	+0,537 ticks
Neto medio (coste 0,5, referencia)	+0,349 ticks
Neto medio (coste 1,0, estrés)	$-0,026$ ticks


El signo positivo al coste de referencia indica que el especialista conserva una señal modesta donde los modelos anteriores habían fracasado. Sin embargo, ni la estabilidad diaria ni el escenario de coste completo permiten calificarlo como una política robusta. La lectura defendible es, por tanto, *señal parcial fuera de muestra*, no rentabilidad demostrada.

Tabla 4.2: Desglose diario del especialista base al coste de referencia.

Día	n	Neto medio @0,5
6 de junio	220	+0,666
7 de junio	97	+1,342
8 de junio	241	+0,308
9 de junio	146	−0,565
10 de junio	50	−0,105

4.1.2 Diagnóstico *post-hoc* del régimen de volatilidad

La inspección del bloque reveló que la fracción de sesiones de alta volatilidad aumentó hasta aproximadamente el 58 %, frente al 18–22 % de los periodos históricos (Figura 4.1). Para estudiar ese desplazamiento se dividió la selección con el umbral 0,6657, percentil 80 de la volatilidad de entrenamiento. El umbral numérico no se ajustó al bloque nuevo, pero la decisión de usarlo como filtro sí se tomó tras observarlo; por ello, todo lo que sigue en esta subsección es diagnóstico y exploratorio.


Figura 4.1: Fracción de sesiones de alta volatilidad por periodo. El salto del bloque nuevo motiva el análisis de régimen, pero no valida por sí mismo el filtro.

La Tabla 4.3 muestra el contraste. Hay 318 acciones de baja volatilidad, 435 de alta volatilidad y una acción sin dato de volatilidad, que una regla operativa conservadora rechazaría. Las primeras son positivas y las segundas, negativas al coste de referencia.

Tabla 4.3: Diagnóstico *post-hoc* por régimen en el bloque del 6–10 de junio (ticks por unidad de acción).

Régimen	n	@0,25	@0,5	@1,0
Baja volatilidad	318	+1,258	+1,069	+0,691
Alta volatilidad	435	+0,004	−0,183	−0,558
Volatilidad ausente	1	+3,327	+3,154	+2,807
Total sin filtro	754	+0,537	+0,349	−0,026

Si se aplica retrospectivamente el filtro de baja volatilidad, el subconjunto de 318 acciones mantiene signo positivo en los tres niveles de coste (Figura 4.3) y en los cinco días




Figura 4.2: Contraste *post-hoc* del neto medio entre baja y alta volatilidad. La separación es una hipótesis de política que requiere datos posteriores.

(Figura 4.4). Su suma cronológica presenta un drawdown diagnóstico de 88,1 ticks (Figura 4.5). Estas magnitudes describen el subconjunto observado; no son PnL de una cartera ejecutada.




Figura 4.3: Sensibilidad al coste del subconjunto de baja volatilidad. Resultado exploratorio obtenido tras inspeccionar el mismo bloque.

El remuestreo independiente de las 318 acciones produce un IC90 de $[+0,472, +1,654]$ y $P = 0,998$, pero esa estimación ignora la dependencia entre señales del mismo mercado. Hay 156 mercados y hasta ocho acciones por mercado. Un *bootstrap* agrupado por mercado amplía el IC90 a $[+0,193, +2,004]$ y reduce la probabilidad estimada a 97,6 %. Ambos cálculos son descriptivos: la selección *post-hoc* impide darles una lectura confirmatoria.

4.1.3 Registro de sombra retrospectivo

Para auditar la mecánica de la política candidata se construyó un registro de sombra *offline*: conserva cada unidad de acción, su mercado, el resumen diario y las reglas de promoción. Es una reproducción retrospectiva de lo que la regla habría indicado, no una ejecución prospectiva ni un sistema activo en tiempo real. El filtro queda congelado después del 10 de junio; solo observaciones posteriores pueden contar para las puertas de promoción.

Además, varias señales pertenecen al mismo mercado y sus horizontes H60 se solapan. Por ello se denominan *unidades de acción*, no operaciones independientes, y la suma




Figura 4.4: Neto medio diario del subconjunto *post-hoc* de baja volatilidad.




Figura 4.5: Suma acumulada y drawdown diagnóstico de 318 unidades de acción. No representa una cartera con restricciones de capital o de exposición simultánea.

acumulada no incorpora una regla de exposición máxima. Una futura sombra prospectiva deberá decidir si permite apilar posiciones o admite una sola posición por mercado.

4.2 Comparativa con otros enfoques y baseline

Esta sección sitúa el resultado limpio del especialista frente a las alternativas evaluadas: las arquitecturas profundas sobre el libro de órdenes y los intentos de adaptación al cambio de régimen. La comparación justifica por qué la mejor señal disponible procede de un modelo tabular sencillo y no de una red profunda.

4.2.1 Especialista tabular frente a aprendizaje profundo

Las redes recurrentes y convolucionales sobre el libro aprenden representación —algunas políticas *proxy* resultan positivas dentro de muestra—, pero esa ventaja no sobrevive cuando se exige selección causal día a día y estabilidad en todo el bloque de test. Con

unas dos semanas de datos, la capacidad necesaria para generalizar temporalmente excede lo que las redes pueden estimar de forma fiable.

El modelo tabular con regularización agresiva opera en el extremo opuesto: aumenta su sesgo pero reduce drásticamente la varianza. Restringir la señal a la ventana *prestart* acota el espacio de hipótesis. Esa combinación conserva un promedio positivo al coste de referencia en el bloque intacto, aunque todavía no supera el coste de estrés. El resultado no descarta el aprendizaje profundo; lo sitúa como una vía a reevaluar cuando el volumen de datos crezca.

4.2.2 Experimentos de adaptación al régimen

Ante el cambio de régimen se probaron reentrenamiento incremental con ventana móvil, alineación de correlaciones CORAL [13], un filtro conformal, un *ensemble* por *bootstrap*, un filtro de volatilidad adaptativo, características normalizadas por volatilidad y *distillation* de una red convolucional temporal. Ninguna alternativa produjo evidencia prospectiva robusta con tan pocos días. Este resultado negativo sigue siendo informativo, pero no permite declarar vencedor al filtro simple sobre el mismo bloque usado para proponerlo. La comparación definitiva queda aplazada hasta disponer de nuevos datos bajo una política ya congelada.

Capítulo 5

Despliegue

Este capítulo documenta la estrategia de despliegue y, sobre todo, la decisión de no operar con capital real. El especialista base ofrece una señal fuera de muestra modesta, mientras que la mejora del filtro de volatilidad procede de un análisis *post-hoc*. El siguiente paso válido no es producción, sino una sombra prospectiva con la política ya congelada.

5.1 Estrategia de despliegue y seguimiento en sombra

5.1.1 Por qué no se despliega

El resultado limpio se apoya en cinco días, solo tres son positivos y el neto pasa a ser ligeramente negativo bajo el coste completo. El subconjunto de baja volatilidad es más prometedor, pero se identificó usando esos mismos cinco días. Desplegar en estas condiciones confundiría una hipótesis razonable con una validación. Por coherencia con la tesis del trabajo —la honestidad del protocolo prevalece sobre cualquier número concreto— el proyecto se detiene antes de operar.

5.1.2 Del registro retrospectivo a la sombra prospectiva

El registro disponible es *offline* y retrospectivo: reconstruye, unidad de acción a unidad de acción, qué habría indicado la regla de baja volatilidad sobre el bloque ya observado. Sirve para comprobar la contabilidad, el resumen diario y las guardas, pero esos cinco días no cuentan como validación de la política completa.

A partir del cierre del bloque se congela la regla candidata ($\text{volatilidad}_{5s} \leq 0,6657$, $\text{EV} > 0,75$ y probabilidad de salud $\geq 0,50$). Una sombra prospectiva deberá ejecutarla sin cambios sobre fechas posteriores, registrar también las abstenciones y resolver la exposición simultánea por mercado. Solo esa evidencia podrá alimentar las puertas de promoción:

- **Candidato a seguimiento ampliado:** neto superior a 0,5 ticks, al menos 200 unidades de acción y al menos 8 días prospectivos.
- **Candidato a despliegue:** neto superior a 0,5 ticks, al menos 400 unidades, 12 días prospectivos y una regla de exposición/fill validada.

En la fecha de corte hay cero días prospectivos de la política completa. Su estado correcto es *hipótesis congelada pendiente de validación*, no candidata a bot.

5.1.3 Diseño de una hipotética API de inferencia

Solo si se superasen las puertas anteriores, un despliegue eventual tomaría la forma de un servicio de inferencia con cuatro etapas. Primero, una etapa de ingesta que reconstruyese en tiempo real el estado del mercado sobre la malla de dos segundos. Segundo, una etapa de cálculo que generase las 36 características causales del instante actual, idéntica a la del entrenamiento para evitar discrepancias entre entrenamiento y producción (*train/serve skew*). Tercero, una etapa de decisión que consultase las dos cabezas del especialista y devolviese operar o abstenerse. Y cuarto, una capa de guardas que aplicase los filtros de entorno, volatilidad y obsolescencia, además del límite de exposición por mercado.

Por encima operaría una capa de monitorización que vigilase la deriva de distribución, registrase cada decisión para auditoría y dispusiese de un interruptor de parada inmediata. Esta arquitectura es un diseño, no una implementación.

Capítulo 6

Aspectos éticos y limitaciones

Este capítulo recoge las consideraciones éticas que han guiado el trabajo y una revisión explícita de sus limitaciones, que delimitan el alcance de cualquier conclusión.

6.1 Consideraciones éticas

El sistema estudia decisiones económicas automatizadas y es especialmente sensible al sobreajuste cuando el horizonte de datos es reducido. La actuación responsable es no operar con capital real y no convertir un diagnóstico *post-hoc* en una afirmación de rentabilidad. La política completa queda congelada para observación prospectiva, sin que los días usados para formularla cuenten de nuevo como validación.

En cuanto a los datos, se adopta un marco de confidencialidad, integridad y disponibilidad. Una referencia externa retrasada o errónea puede inducir una señal espuria; por ello el sistema se entrena solo con sesiones aceptadas, separa datos crudos, características y etiquetas, mantiene trazabilidad de los artefactos e inhibe la operativa ante datos obsoletos. El trabajo emplea datos públicos de mercado y no datos personales. El corpus completo no se distribuye por tamaño; se publican el esquema, un ledger anonimizado de acciones y el código de evaluación.

6.2 Limitaciones

Selección posterior al bloque. El especialista base sí estaba congelado y su resultado limpio es +0,349 ticks por acción al coste de referencia. El filtro de volatilidad se incorporó después de observar el cambio de régimen; por tanto, su resultado de +1,069 ticks sobre el mismo bloque es exploratorio y necesita fechas posteriores.

Soporte temporal. El conjunto fuera de muestra abarca cinco días. Tres de cinco son positivos para la política base y cinco de cinco dentro del subconjunto diagnóstico. Ninguna de las dos cifras constituye una validación definitiva.

Dependencia y solapamiento. Las 318 unidades del diagnóstico pertenecen a 156 mercados, con hasta ocho señales por mercado y horizontes H60 solapados. El *bootstrap* por filas subestima esa dependencia. Un remuestreo agrupado por mercado amplía el IC90 % a [+0,193, +2,004], pero sigue describiendo un subconjunto elegido *post-hoc*. Además, no

se ha fijado una regla de exposición simultánea; por ello la suma acumulada no es PnL de cartera.

Validación *offline*. La evaluación usa un modelo de ejecución conservador pero simplificado. No reconstruye la cola orden por orden ni incorpora rellenos parciales. El registro de sombra actual es retrospectivo; falta una ejecución prospectiva de mayor fidelidad.

Reproducibilidad parcial. El repositorio permite recalcular las tablas públicas desde el ledger anonimizado y probar la lógica compartida. La reproducción integral del entrenamiento requiere el corpus privado de gran tamaño y se documenta como limitación, no como capacidad publicada.

Patrón en U. Dentro de la baja volatilidad se observa una posible relación en forma de U entre volatilidad y resultado. Como se descubrió en los mismos cinco días, se conserva solo como hipótesis para trabajo futuro.

Capítulo 7

Reproducibilidad

7.1 Enlace a repositorio GitHub

El código, los registros de resultados y los artefactos públicos de auditoría se mantienen en un repositorio:

<https://github.com/marcmaldonadolorca/polymarket-btc-microstructure>

7.1.1 Estructura del repositorio

El repositorio se organiza en los siguientes directorios:

config/ Umbrales congelados de la política y configuraciones del arco.

docs/ Documentos canónicos del proceso, renumerados de forma secuencial.

notebooks/ Cuadernos pedagógicos ejecutados (EDA, particiones, objetivo, línea base, latencia, secuencias, corrección del *score* adverso y especialista).

scripts/ Puntos de entrada reproducibles de cada experimento.

src/ Paquete con la lógica compartida (datos, características, modelos, evaluación), con pruebas automatizadas.

results/ Tablas de resultados y ledger anonimizado de 754 unidades de acción.

sql/ Esquema de la consulta base de entrenamiento.

reports/ Esta memoria (fuente LaTeX).

7.1.2 Cómo reproducir

El entorno se prepara con un entorno virtual de Python y la instalación de las dependencias declaradas. Las pruebas automatizadas verifican la lógica de política y sus guardas. El ledger `results/final_candidate_actions_anonymized.csv` permite recalcular las tablas agregadas, los desgloses por régimen y la incertidumbre agrupada sin acceder al corpus completo. El script que lo genera queda versionado para mantener trazabilidad, aunque su ejecución integral requiere el workspace privado de investigación.

7.1.3 Datos no publicados

El conjunto completo (del orden de 2,6 millones de filas *cross-venue*, más la base de captura) no se publica por tamaño. En su lugar se incluyen el esquema SQL, un ledger anonimizado suficiente para reproducir las cifras finales y el código del *pipeline*. Esto permite una auditoría parcial, no la reproducción bit a bit del entrenamiento. Declarar esa frontera de forma explícita es parte de la trazabilidad y reduce la deuda técnica propia de estos sistemas [15].

Capítulo 8

Conclusiones

Este trabajo ha presentado una metodología de captura de datos, validación temporal y control de costes para la predicción de corto plazo en mercados de Bitcoin de Polymarket. La conclusión central es que una precisión direccional cercana al 90 % no garantiza una política económica: con una latencia de entrada realista, el coste y la ejecución dominan el resultado.

El aprendizaje profundo aplicado a secuencias y al libro de órdenes aprende representaciones útiles, pero no produce una política estable con unas dos semanas de datos. El especialista tabular congelado conserva una señal modesta en cinco días intactos fuera de muestra: +0,349 ticks por unidad al coste de referencia, 754 unidades y tres de cinco días positivos; bajo el coste completo, el promedio es $-0,026$ ticks.

El análisis posterior detecta un cambio de régimen y propone un filtro de baja volatilidad. Sobre el mismo bloque, ese subconjunto alcanza +1,069 ticks y cinco de cinco días positivos. Su valor es el de una hipótesis prometedora, no el de una validación confirmatoria: la regla se congela después del diagnóstico y queda pendiente de datos futuros.

Las aportaciones del trabajo son cuatro: un sistema de captura y control de calidad multifuente; un protocolo temporal que incorpora coste y latencia medidos; evidencia cuantitativa de la ruptura entre predicción y ejecución; y una trazabilidad que conserva tanto los resultados negativos como la corrección de errores metodológicos. No se afirma rentabilidad real ni se presenta un bot listo para desplegar.

Trabajo futuro. La prioridad es ejecutar prospectivamente la política completa sin retocar umbrales, con una sola regla de exposición por mercado y registro de fills. Solo después podrá evaluarse el filtro de volatilidad. Con un horizonte de datos sustancialmente mayor podrán reevaluarse arquitecturas como el *Temporal Fusion Transformer* [14]. La regla que guía el proyecto permanece: la complejidad y cualquier afirmación económica deben ganarse su sitio con evidencia verdaderamente nueva.

Referencias

- [1] Polymarket. (2026). *Prices & Orderbooks* [Documentación]. <https://docs.polymarket.com/polymarket-learn/trading/using-the-orderbook> (Recuperado el 14 de junio de 2026).
- [2] Polymarket. (2026). *Order Lifecycle* [Documentación]. <https://docs.polymarket.com/concepts/order-lifecycle> (Recuperado el 14 de junio de 2026).
- [3] Wolfers, J., & Zitzewitz, E. (2004). Prediction Markets. *Journal of Economic Perspectives*, 18(2), 107–126.
- [4] Zhang, Z., Zohren, S., & Roberts, S. (2019). DeepLOB: Deep Convolutional Neural Networks for Limit Order Books. *IEEE Transactions on Signal Processing*, 67(11), 3001–3012.
- [5] Ntakaris, A., Magris, M., Kannianen, J., Gabbouj, M., & Iosifidis, A. (2018). Benchmark dataset for mid-price forecasting of limit order book data with machine learning methods. *Journal of Forecasting*, 37(8), 852–866.
- [6] Tsantekidis, A., Passalis, N., Tefas, A., Kannianen, J., Gabbouj, M., & Iosifidis, A. (2017). Using deep learning to detect price change indications in financial markets. *European Signal Processing Conference (EUSIPCO)*.
- [7] Sirignano, J., & Cont, R. (2019). Universal features of price formation in financial markets: perspectives from deep learning. *Quantitative Finance*, 19(9), 1449–1459.
- [8] Jha, R., et al. (2020). Deep Learning for Digital Asset Limit Order Books. *arXiv:2010.01241*.
- [9] Kearns, M., & Nevmyvaka, Y. (2013). Machine Learning for Market Microstructure and High Frequency Trading. In *High Frequency Trading: New Realities for Traders, Markets and Regulators*.
- [10] Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *The Review of Financial Studies*, 33(5), 2223–2273.
- [11] López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- [12] Bailey, D. H., & López de Prado, M. (2014). The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality. *The Journal of Portfolio Management*, 40(5), 94–107.
- [13] Sun, B., Feng, J., & Saenko, K. (2016). Return of Frustratingly Easy Domain Adaptation. *AAAI Conference on Artificial Intelligence*.
- [14] Lim, B., Arik, S. O., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers

- for Interpretable Multi-horizon Time Series Forecasting. *International Journal of Forecasting*, 37(4), 1748–1764.
- [15] Sculley, D., et al. (2015). Hidden Technical Debt in Machine Learning Systems. *Advances in Neural Information Processing Systems (NeurIPS)*.

Glosario de términos

Glosario pensado para el lector no familiarizado con las criptomonedas ni con la microestructura de mercado. Recoge los términos empleados a lo largo de la memoria.

Mercado de predicción Mercado en el que se negocian contratos cuyo valor depende del resultado de un acontecimiento futuro.

Contrato binario Contrato que paga una unidad si el suceso ocurre y cero si no; su precio toma valores entre 0 y 1 y se interpreta como probabilidad.

Polymarket Plataforma de mercados de predicción descentralizada, con emparejamiento fuera de cadena y liquidación en cadena.

Libro de órdenes (LOB) Lista, ordenada por precio, de las órdenes de compra y venta pendientes de ejecución.

Bid / Ask Mejor precio de compra (*bid*) y mejor precio de venta (*ask*).

Spread Diferencia entre *ask* y *bid*; primer coste de cruzar el mercado.

Profundidad Volumen disponible en cada nivel de precio del libro.

Precio medio (*mid*) Punto medio entre *bid* y *ask*.

Tick Variación mínima de precio del mercado; unidad de medida de los resultados.

Microestructura Estudio de cómo se forman los precios a partir de órdenes, *spread*, profundidad y flujo, a escalas de tiempo muy finas.

Markout Movimiento del precio desde el instante de ejecución a lo largo de un horizonte; sirve para medir si una operación fue buena.

Latencia Retardo entre observar la oportunidad y ejecutar la orden.

Spot / Perpetuo Mercado de Bitcoin al contado (*spot*) y de futuros sin vencimiento (*perpetual futures*); referencias externas del contrato.

Oráculo de precios Fuente externa que aporta el precio de referencia de Bitcoin.

Volatilidad realizada Medida de cuánto se ha movido el precio recientemente.

Ventana *prestart* Intervalo inmediatamente anterior a la apertura del mercado.

Validación temporal Partición de los datos respetando el orden del tiempo (entrenar con el pasado, evaluar con el futuro).

Fuera de muestra (OOS) Datos no usados ni para entrenar ni para seleccionar.

- Fuera de pliegue (OOF)** Protocolo en el que las predicciones que consume una segunda etapa proceden siempre de un modelo que no las entrenó.
- Fuga temporal** Filtración de información del futuro hacia el entrenamiento o las características; principal fuente de resultados ilusorios.
- Congelación** Fijar el modelo y los umbrales antes de observar el conjunto fuera de muestra.
- Drawdown** Mayor caída acumulada desde un máximo previo.
- Bootstrap*** Remuestreo con reemplazo para estimar la incertidumbre de un resultado.
- Registro de sombra** Contabilidad de lo que la política habría indicado sin arriesgar capital. Puede ser retrospectivo (replay *offline*) o prospectivo; solo el segundo aporta nuevos días de validación.
- Gradient boosting** Familia de modelos que suma muchos árboles de decisión, cada uno corrigiendo los errores del anterior.

Conjunto de características

El especialista final emplea 36 características causales sin variables de reloj (*no_clock*), agrupadas por bloques:

- **Estado local del libro de Polymarket:** precio medio, *spread*, microprice, desbalance de órdenes, coste visible de entrada y deltas recientes del precio.
- **Referencias externas:** retornos orientados del mercado al contado y de los futuros perpetuos a 2 y 8 segundos; medidas de consenso y de actualización.
- **Volatilidad:** volatilidad realizada del perpetuo a 5 segundos, usada en el diagnóstico posterior de cambio de régimen.
- **Contexto de ventana:** fase de la ventana *prestart* y proxies de calidad del libro (cobertura, indicadores de degradación).

Se excluyen deliberadamente las variables de reloj (hora, minuto, segundo) para evitar que el modelo aprenda atajos temporales triviales.

Hiperparámetros de los modelos

Tabla 1: Hiperparámetros principales del especialista (HistGradientBoosting, dos cabezas).

Hiperparámetro	Valor
Tasa de aprendizaje	0,045
Iteraciones máximas	220 (con parada anticipada)
Fracción de validación interna	0,15
Máximo de hojas por árbol	15
Mínimo de muestras por hoja	120
Regularización L2	0,10

Tabla 2: Hiperparámetros principales de los modelos profundos (línea de exploración).

Hiperparámetro	Valor
Optimizador	AdamW
Tasa de aprendizaje	0,0015
Decaimiento de pesos	10^{-4}
Tamaño de lote	192
Paciencia (parada anticipada)	18 épocas
Dimensión oculta de la GRU	56
<i>Dropout</i> (<i>BookEncoder</i>)	0,08

El especialista base congelado opera con dos umbrales: valor esperado predicho superior a 0,75 y probabilidad de salud no inferior a 0,50. Tras el diagnóstico del bloque fuera de muestra se propone una política futura que exige, además, volatilidad realizada a 5 segundos no superior a 0,6657 (percentil 80 del entrenamiento). La incertidumbre exploratoria se estima con 5 000 remuestreos y semilla fija, tanto por filas como agrupando por mercado.