



UNIVERSIDAD
POLITÉCNICA
DE MADRID



Máster
Deep Learning
Universidad Politécnica de Madrid

**Aprendizaje profundo aplicado a la
microestructura de mercados de predicción:
predicción de corto plazo en mercados de
Bitcoin de Polymarket**

**MÁSTER DE FORMACIÓN
PERMANENTE
EN DEEP LEARNING**

Presentado por:

Marc Maldonado Lorca

Bajo la dirección de:

Dra. María Inmaculada Santamaría Valenzuela

Madrid, 2026

Título: Aprendizaje profundo aplicado a la microestructura de mercados de predicción:
predicción de corto plazo en mercados de Bitcoin de Polymarket

Autor: Marc Maldonado Lorca

Máster de Formación Permanente en Deep Learning

Universidad Politécnica de Madrid

Dirección de Tesis:

Dra. María Inmaculada Santamaría Valenzuela, Universidad Politécnica de Madrid
(Directora)

Agradecimientos

Quiero agradecer especialmente a mi amigo Ramón, que me introdujo en este mundo y sin cuya curiosidad inicial este trabajo no habría existido. Gracias también a mi directora por su guía a lo largo del proyecto, y a mi familia y amigos por su apoyo durante el máster.

Abstract

This work studies whether deep learning can exploit market microstructure signals to anticipate the short-term price movement of binary contracts on Bitcoin traded on Polymarket, a prediction market. Unlike the literature focused on how the event finally resolves, here we target the local movements of the contract price over windows of a few seconds, combining the order book with external Bitcoin market references (spot, perpetual futures and a price oracle). The main contribution is not a single model but a reproducible methodology: a multi-source data capture system with per-session quality control, strictly temporal validation, and an evaluation that incorporates realistic execution costs and latency. The central, uncomfortable finding is that a directional classifier that is correct nearly nine out of ten times stops being profitable once a realistic two-second entry latency is introduced: what decides the outcome is cost and execution, not directional accuracy. Building on this, we evaluate a progression of models (tabular baselines, latency-aware models, and sequential and convolutional architectures over the order book) and a frozen tabular specialist. On the untouched five-day out-of-sample block, the specialist obtains a modest positive mean at the reference cost (+0.349 ticks per action, 754 actions and three out of five positive days), but turns slightly negative under the full-cost stress test. A volatility filter, whose numerical threshold came from the training period, is then explored after detecting a regime shift; it improves the result on the same block, so it is reported as a post-hoc diagnostic rather than as confirmatory evidence. Two further results complete the arc. First, a correction of the cost model (documented and registered with a cryptographic timestamp) shows that under Polymarket’s official 2026 fee schedule no taker cut remains profitable, which confirms the thesis structurally and shifts the viable economic vehicle to the maker side: the same fee structure that taxes the taker pays the passive liquidity provider, whose economics are quantified with a queue-and-fill simulator over the captured L2 book. Second, a ladder of reference models shows that a time-series foundation model (MOMENT) improves monotonically with adaptation yet never beats naive drift or ARIMA, with a flat data-scaling curve: the ceiling is set by the data regime, not by model capacity. The evaluation protocol—frozen candidate, pre-committed regime-filter variants and a taker expectation declared negative in advance—is pre-registered and timestamped on the Bitcoin blockchain, making its priority over the evaluation window independently verifiable. We report every figure in net ticks together with its support and uncertainty, and we do not claim real profitability: the deliverable is the methodology, the evidence obtained under an auditable protocol, and the explicit delimitation of its limits.

Resumen

Este trabajo estudia si el aprendizaje profundo puede aprovechar señales de microestructura de mercado para anticipar el movimiento de corto plazo del precio de los contratos binarios sobre Bitcoin negociados en Polymarket, un mercado de predicción. A diferencia de la literatura centrada en cómo se resuelve finalmente el evento, aquí el objetivo son los movimientos locales del precio del contrato en ventanas de pocos segundos, combinando el libro de órdenes con referencias externas del mercado de Bitcoin (contado, futuros perpetuos y un oráculo de precios). La aportación principal no es un modelo concreto, sino una metodología reproducible: un sistema de captura de datos multifuente con control de calidad por sesión, una validación estrictamente temporal y una evaluación que incorpora costes de ejecución y latencia realistas. El hallazgo central, y algo incómodo, es que un clasificador direccional que acierta casi nueve de cada diez veces deja de ser rentable en cuanto se introduce una latencia de entrada realista de dos segundos: lo que decide el resultado es el coste y la ejecución, no el acierto direccional. A partir de ahí se evalúa una progresión de modelos (líneas base tabulares, modelos sensibles a la latencia y arquitecturas secuenciales y convolucionales sobre el libro de órdenes) y un especialista tabular congelado. En el bloque intacto de cinco días fuera de muestra, el especialista obtiene un promedio modestamente positivo al coste de referencia (+0,349 ticks por acción, 754 acciones y tres de cinco días positivos), pero pasa a ser ligeramente negativo bajo el coste de estrés completo. Tras detectar un cambio de régimen se explora un filtro de volatilidad cuyo umbral numérico procede del entrenamiento; como la decisión de incorporarlo se evalúa sobre ese mismo bloque, su mejora se presenta como diagnóstico *post-hoc*, no como evidencia confirmatoria. Dos resultados adicionales completan el arco. Primero, una corrección del modelo de costes (documentada y registrada con sello criptográfico de tiempo) muestra que, bajo el régimen oficial de comisiones de 2026 de Polymarket, ningún corte *taker* es rentable, lo que confirma estructuralmente la tesis y desplaza el vehículo económico viable al lado *maker*: la misma estructura de comisiones que grava al *taker* paga al proveedor pasivo de liquidez, cuya economía se cuantifica con un simulador de colas y *fills* sobre el libro L2 capturado. Segundo, una escalera de modelos de referencia muestra que un modelo fundacional de series temporales (MOMENT) mejora de forma monótona al adaptarse pero nunca supera a la deriva simple ni a un ARIMA, con una curva de escalado plana: el techo lo pone el régimen de datos, no la capacidad del modelo. El protocolo de evaluación (candidato congelado, variantes de filtro de régimen comprometidas por adelantado y expectativa *taker* declarada negativa antes de mirar los datos) queda pre-registrado y sellado en la cadena de Bitcoin, de modo que su anterioridad a la ventana de evaluación es verificable de forma independiente. Todos los resultados se reportan en ticks netos junto a su soporte e incertidumbre, y no se afirma rentabilidad real: lo que se entrega es la metodología, la evidencia obtenida bajo un protocolo auditable y la delimitación explícita de sus límites.

Tabla de Contenido

Agradecimientos	ii
Abstract	iii
Resumen	iv
Lista de Figuras	vii
Lista de Tablas	x
Abreviaturas y acrónimos	xiii
Glosario de términos	xv
1 Introducción	1
1.1 Introducción y definición del problema	1
1.1.1 Qué es un mercado de predicción	1
1.1.2 Qué es Polymarket	2
1.1.3 El libro de órdenes y el vocabulario de la microestructura	2
1.1.4 Definición del problema	3
1.2 Motivación	4
1.3 Objetivos	5
2 Estado de la cuestión	7
2.1 Trabajos previos y estudios relevantes	7
2.1.1 Mercados de predicción	7
2.1.2 Polymarket como objeto de estudio académico	7
2.1.3 Aprendizaje profundo sobre libros de órdenes	9
2.1.4 Modelos fundacionales de series temporales y aprendizaje auto-supervisado	10
2.1.5 Microestructura, costes de ejecución y latencia	11
2.1.6 Aprendizaje automático en finanzas y validación temporal	11
2.1.7 Cambio de distribución y adaptación de dominio	12
2.1.8 Rigor de validación: pre-registro y control del sesgo de selección	12
2.2 Limitaciones en la literatura	13
3 Material y métodos	14
3.1 Descripción del dataset	14
3.1.1 Sistema de captura multifuente	14
3.1.2 Malla temporal y contrato de latencia	15
3.1.3 El grano del precio: un mercado casi siempre inmóvil	15
3.1.4 Controles de calidad por sesión	16
3.1.5 Composición del corpus	18
3.1.6 Análisis exploratorio del corpus	18

3.2	Análisis exploratorio de series temporales	19
3.3	Resultados en modelos base	22
3.3.1	Modelos base tabulares y el impacto de la latencia	22
	Qué es exactamente el escalón de dos segundos	24
3.4	Metodología y entrenamiento	25
3.4.1	Definición del objetivo	26
3.4.2	Ingeniería de características	27
3.4.3	Validación temporal y prevención de fuga	28
3.4.4	Modelo de costes y latencia	28
3.4.5	Corrección del modelo de costes: el régimen de comisiones de 2026 .	29
3.4.6	Métricas de evaluación	31
3.4.7	La escalera de modelos	31
3.4.8	Especialista <i>prestart</i> H60	35
3.4.9	Filtro de volatilidad	36
3.4.10	Variantes de filtro de régimen pre-registradas: estática, GARCH y clustering de regímenes	36
3.4.11	Protocolo de congelación	37
3.4.12	Entrenar contra el dinero: política de parada con contrafactual exacto	37
4	Resultados y análisis	39
4.1	Resultados obtenidos	39
4.1.1	Validación fuera de muestra del especialista base	39
4.1.2	Diagnóstico <i>post-hoc</i> del régimen de volatilidad	40
4.1.3	Resultados con la comisión oficial de 2026 (nivel de coste taker-real)	41
4.1.4	Validación prospectiva pre-registrada	42
	Cadena de compromiso	42
	Ventana de evaluación	42
	Variantes evaluadas y métricas	43
	Reglas de decisión, declaradas antes de mirar	43
	Lectura del corte	43
	Niveles de reporte del protocolo general	47
	Segundo corte, justo antes de la entrega	49
4.2	Comparativa con otros enfoques y baseline	50
4.2.1	Especialista tabular frente a aprendizaje profundo	50
4.2.2	Modelos de referencia de series temporales: baselines clásicos, kNN- DTW y MOMENT	50
4.2.3	Un fundacional tabular: TabPFN <i>zero-shot</i>	52
4.2.4	Experimentos de adaptación al régimen	53
4.2.5	Por qué falla fuera de muestra la cabeza de salud	53
4.2.6	Curva de escalado de datos: tabular frente a aprendizaje profundo .	53
4.2.7	Adenda C: la curva de escalado sobre trayectorias independientes .	54
	Un hallazgo no buscado: la tarea excluye los mercados cortos	54
4.2.8	Adenda D: entrenar contra el objetivo económico	55
5	Despliegue	57
5.1	Estrategia de despliegue y seguimiento en sombra	57
5.1.1	Por qué no se despliega	57
5.1.2	Del registro retrospectivo a la sombra prospectiva	57

5.1.3	Diseño de una hipotética API de inferencia	58
5.2	Economía de la ejecución bajo el régimen de comisiones de 2026	58
5.2.1	Economía del lado maker y tamaño del premio	58
5.2.2	El simulador de colas y <i>fills</i>	59
5.2.3	El tramo terminal: cuándo el precio se vuelve informativo	60
6	Aspectos éticos y limitaciones	63
6.1	Consideraciones éticas	63
6.2	Limitaciones	63
7	Reproducibilidad	67
7.1	Enlace a repositorio GitHub	67
7.1.1	Estructura del repositorio	67
7.1.2	Cómo reproducir	67
7.1.3	El recolector, y por qué no se publica	68
7.1.4	Datos no publicados	68
8	Conclusiones	69
8.1	La conclusión central, alcanzada por cuatro caminos	69
8.2	Qué hizo y qué no hizo el aprendizaje profundo	70
8.3	La validación prospectiva	71
8.4	Aportaciones	71
8.5	Lecciones metodológicas	72
8.6	Trabajo futuro	73
	Referencias	74
	Conjunto de características	78
	Hiperparámetros de los modelos	79
	Pre-registro v2 y verificación del sello	81
	Auditoría del ledger público	83
	Análisis de soporte de los resultados	85
.1	Diagnóstico del fallo fuera de muestra	85
.2	Adenda C: tabla completa del escalado sobre trayectorias	86
.3	Ampliación del triaje de arquitecturas	87
.4	Figuras del diagnóstico <i>post-hoc</i> de régimen	88
.5	Registro de sombra retrospectivo	88

Lista de Figuras

1.1	El entorno del problema. El precio del contrato binario se forma en su libro de órdenes y está acoplado a referencias externas del mercado de Bitcoin. El objetivo es anticipar su movimiento de muy corto plazo.	3
2.1	La literatura académica sobre Polymarket surgida en la primera mitad de 2026 y la posición de este trabajo. Los cinco estudios describen la plataforma (elecciones, arbitraje, flujo, archivos on-chain o tick-level); este trabajo se distingue por añadir el libro L2 sincronizado con referencias externas y un contrato de latencia, lo que habilita la evaluación económica de la ejecución que ninguno aborda.	8
2.2	La “lectura visual” del libro de órdenes	10
2.3	Familias de modelos consideradas (fundacionales de series, auto-supervisados y el fundacional tabular) y su papel como peldaños de la escalera comparativa frente al especialista tabular, que es el vehículo finalmente elegido de la señal. Las estrellas marcan los modelos efectivamente evaluados en este trabajo (MOMENT y TabPFN).	11
3.1	Arquitectura del sistema de captura	15
3.2	Flujo del control de calidad por sesión. Solo las sesiones que superan todos los umbrales se incorporan al corpus.	17
3.3	Partición temporal del corpus. El conjunto fuera de muestra (6–10 jun) se capturó después de congelar el candidato, lo que convierte su validación en una prueba genuina.	18
3.4	Contrastes de estacionariedad ADF y KPSS sobre niveles y primeras diferencias del precio medio (muestra de 285 series). El patrón conjunto (raíz unitaria en niveles, estacionariedad en diferencias) es consistente en todo el corpus.	19
3.5	Funciones de autocorrelación medias: retornos, retornos absolutos y desequilibrio de profundidad. La señal lineal está en el estado del libro, no en el retorno retardado.	20
3.6	Descomposición STL de la actividad agregada del corpus. La estacionalidad diaria explica el 19,4% de la varianza.	20
3.7	Espectro de la actividad agregada y perfil intrahora. Picos en 24 h y 1 h; el minuto 50 es el más activo del ciclo horario.	21
3.8	Distribución de la cobertura de la malla de 2 s por serie. La densidad del corpus permite una política de imputación conservadora.	21

3.9	Neto medio en el test terminal frente a la latencia de entrada. La señal a latencia nula es real como <i>markout</i> desde el instante de la señal, pero no sobrevive como política ejecutable con dos segundos de latencia.	23
3.10	Índice general del proceso	26
3.11	Modelo de dos cabezas. Un regresor predice el valor esperado de la operación y un clasificador predice si el relleno será “sano”. La política exige ambas condiciones.	27
3.12	Corrección de la función de costes para su adaptación al modelo oficial de costes de 2026. Izquierda: comisión oficial de 2026 ($rp(1-p)$, $r = 0,07$) frente a la función de costes anterior, en ticks por contrato; en $p = 0,5$ la diferencia es de un factor ocho (1,75 frente a $\sim 0,22$). Derecha: distribución del precio de entrada del corpus operable de la ventana fuera de muestra ($n=6.010$ operaciones candidatas) superpuesta a la curva oficial: las operaciones se concentran precisamente donde la comisión es máxima, con un coste de entrada medio de 1,75 ticks por contrato.	30
3.13	La escalera de modelos. Cada paso debe superar al anterior bajo el mismo protocolo; si no lo hace, se descarta.	31
3.14	La ventana <i>prestart</i> del especialista: solo se opera entre -60 y -45 segundos respecto a la apertura del mercado, donde el análisis exploratorio detectó una densidad atípica de actividad del libro.	36
4.1	Fracción de sesiones de alta volatilidad por periodo. El salto del bloque nuevo motiva el análisis de régimen, pero no valida por sí mismo el filtro. .	40
4.2	Suma acumulada y drawdown diagnóstico de 318 unidades de acción. No representa una cartera con restricciones de capital o de exposición simultánea.	41
4.3	Corte prospectivo pre-registrado nº 1	45
4.4	La puerta B3 vista desde la dispersión	46
4.5	Curva de escalado del fine-tuning de MOMENT (linear-probing) frente al número de ventanas de entrenamiento, evaluada sobre los 906 casos congelados. Más datos no cierran la brecha con la deriva simple: el techo lo marca el régimen de datos, no el tamaño de la muestra.	52
4.6	Curva de escalado sobre la misma tarea (dirección H60, 906 casos congelados): la vía tabular (<i>gradient boosting</i>) supera a la profunda (MOMENT) en todo el presupuesto de datos, y la distancia se mantiene o crece al aumentar el número de ventanas de entrenamiento. Con este horizonte de datos, más muestras no hacen que el aprendizaje profundo alcance al tabular.	55
5.1	El peso $p(1-p)$ que gobierna la comisión taker y el reparto de <i>rebates</i> al maker: máximo en $p = 0,5$ y nulo en los extremos. La economía maker es más densa precisamente en la zona de precios intermedios donde opera el trabajo.	59
5.2	Informatividad del precio medio sobre el settlement. Izquierda: puntuación de Brier por tiempo a expiración; el precio es casi una moneda al aire en la apertura y solo se vuelve informativo en el tramo terminal. Derecha: curvas de fiabilidad lejos (30–60 min) y cerca (1–5 min) del cierre; el precio está bien calibrado en ambos cortes, pero su masa se polariza al acercarse la expiración.	61

1	Diagnóstico del fallo fuera de muestra de la cabeza de salud. Izquierda: el AUC se desploma de entrenamiento a test con una dispersión mínima entre las diez réplicas (barras de error) y un desacuerdo entre réplicas plano (línea naranja) (el fallo es estable y no es epistémico). Derecha: un clasificador de dominio separa mayo de junio con AUC 0,90, señal de un fuerte desplazamiento de covariables encabezado por la base del perpetuo.	86
2	Sensibilidad al coste del subconjunto de baja volatilidad. Resultado exploratorio obtenido tras inspeccionar el mismo bloque.	88
3	Neto medio diario del subconjunto <i>post-hoc</i> de baja volatilidad.	89

Lista de Tablas

1.1	Ejemplo ilustrativo de un libro de órdenes (valores inventados con fines explicativos, no datos reales). El mejor <i>bid</i> es 0,52 y el mejor <i>ask</i> , 0,54; por tanto el <i>spread</i> es de 0,02 y el precio medio, 0,53. Los niveles más alejados del centro tienen, típicamente, más volumen acumulado.	3
2.1	Balance de las familias de modelos revisadas	13
3.1	Grano temporal del punto medio según la ventana de observación	16
3.2	Los dos modelos base en el bloque de test	22
3.3	Rendimiento de la política del modelo base bajo distintas latencias de entrada	23
3.4	Re-evaluación de la política congelada con la comisión oficial de 2026. Ticks netos medios por operación; “solo entrada” es la cota optimista que omite la comisión de salida.	30
3.5	Triage diagnóstico de las arquitecturas profundas	33
3.6	Selección de horizonte (ticks netos <i>proxy</i>). Solo H60 conserva señal.	35
4.1	Validación fuera de muestra del especialista base congelado. Los valores son ticks netos por unidad de acción y no incorporan el filtro de volatilidad posterior.	39
4.2	Desglose diario del especialista base al coste de referencia.	40
4.3	Diagnóstico <i>post-hoc</i> por régimen en el bloque del 6–10 de junio (ticks por unidad de acción). Las columnas @0,25, @0,5 y @1,0 son el neto al factor de coste c correspondiente de la ecuación (3.3): la fracción del coste visible de entrada que se descuenta (optimista, referencia y estrés).	40
4.4	Política congelada re-evaluada con la comisión oficial de 2026. Ticks netos medios por acción; “solo entrada” es la cota optimista que omite la comisión de salida, “ida y vuelta” carga ambas. Las comisiones medias medidas son de 1,75 ticks a la entrada y 1,71 a la salida.	42
4.5	Puertas de decisión pre-declaradas	43
4.6	Resultado del corte prospectivo por variante	44
4.7	Corte prospectivo del pre-registro general	48
4.8	Segundo corte prospectivo del pre-registro general	49
4.9	Escalera de modelos de referencia	51
1	Hiperparámetros principales del especialista (HistGradientBoosting, dos cabezas).	79
2	Hiperparámetros principales de los modelos profundos (línea de exploración).	79
3	Hiperparámetros de los modelos fundacionales evaluados.	79

4	Escalado sobre trayectorias independientes	87
5	Ampliación del triaje con cinco semillas	88

Abreviaturas y acrónimos

UPM	Universidad Politécnica de Madrid
TFM	Trabajo Fin de Máster
LOB	Libro de órdenes (<i>Limit Order Book</i>)
BTC	Bitcoin
AUC	Área bajo la curva ROC (<i>Area Under the Curve</i>)
EV	Valor esperado (<i>Expected Value</i>)
HGB	<i>Histogram-based Gradient Boosting</i>
GRU	Unidad recurrente con puertas (<i>Gated Recurrent Unit</i>)
LSTM	Memoria larga a corto plazo (<i>Long Short-Term Memory</i>)
CNN	Red neuronal convolucional (<i>Convolutional Neural Network</i>)
TCN	Red convolucional temporal (<i>Temporal Convolutional Network</i>)
OOF	Fuera de pliegue (<i>Out-Of-Fold</i>)
OOS	Fuera de muestra (<i>Out-Of-Sample</i>)
IC	Intervalo de confianza
QA	Control de calidad (<i>Quality Assurance</i>)
API	Interfaz de programación de aplicaciones (<i>Application Programming Interface</i>)
bps	Puntos básicos (<i>basis points</i>)
ADF	Contraste de raíz unitaria de Dickey-Fuller aumentado (<i>Augmented Dickey-Fuller</i>)
KPSS	Contraste de estacionariedad de Kwiatkowski-Phillips-Schmidt-Shin
ACF	Función de autocorrelación (<i>AutoCorrelation Function</i>)
PACF	Función de autocorrelación parcial (<i>Partial AutoCorrelation Function</i>)
STL	Descomposición estacional-tendencia mediante Loess (<i>Seasonal-Trend decomposition using Loess</i>)
ARIMA	Modelo autorregresivo integrado de media móvil (<i>AutoRegressive Integrated Moving Average</i>)
DTW	Alineamiento temporal dinámico (<i>Dynamic Time Warping</i>)

GARCH Heterocedasticidad condicional autorregresiva generalizada (*Generalized AutoRegressive Conditional Heteroskedasticity*)

PnL Pérdidas y ganancias (*Profit and Loss*)

SHA-256 Función resumen criptográfica de 256 bits (*Secure Hash Algorithm*)

Glosario de términos

Glosario pensado para el lector no familiarizado con las criptomonedas ni con la microestructura de mercado. Recoge los términos empleados a lo largo de la memoria.

Mercado de predicción Mercado en el que se negocian contratos cuyo valor depende del resultado de un acontecimiento futuro.

Contrato binario Contrato que paga una unidad si el suceso ocurre y cero si no; su precio toma valores entre 0 y 1 y se interpreta como probabilidad.

Polymarket Plataforma de mercados de predicción descentralizada, con emparejamiento fuera de cadena y liquidación en cadena.

Libro de órdenes (LOB) Lista, ordenada por precio, de las órdenes de compra y venta pendientes de ejecución.

Bid / Ask Mejor precio de compra (*bid*) y mejor precio de venta (*ask*).

Spread Diferencia entre *ask* y *bid*; primer coste de cruzar el mercado.

Profundidad Volumen disponible en cada nivel de precio del libro.

Precio medio (*mid*) Punto medio entre *bid* y *ask*.

Tick Variación mínima de precio del mercado; unidad de medida de los resultados.

Microestructura Estudio de cómo se forman los precios a partir de órdenes, *spread*, profundidad y flujo, a escalas de tiempo muy finas.

Markout Movimiento del precio desde el instante de ejecución a lo largo de un horizonte; sirve para medir si una operación fue buena.

Latencia Retardo entre observar la oportunidad y ejecutar la orden.

Spot / Perpetuo Mercado de Bitcoin al contado (*spot*) y de futuros sin vencimiento (*perpetual futures*); referencias externas del contrato.

Oráculo de precios Fuente externa que aporta el precio de referencia de Bitcoin.

Volatilidad realizada Medida de cuánto se ha movido el precio recientemente.

Ventana *prestart* Intervalo inmediatamente anterior a la apertura del mercado.

Validación temporal Partición de los datos respetando el orden del tiempo (entrenar con el pasado, evaluar con el futuro).

Fuera de muestra (OOS) Datos no usados ni para entrenar ni para seleccionar.

Fuera de pliegue (OOF) Protocolo en el que las predicciones que consume una segunda etapa proceden siempre de un modelo que no las entrenó.

Fuga temporal Filtración de información del futuro hacia el entrenamiento o las características; principal fuente de resultados ilusorios.

Congelación	Fijar el modelo y los umbrales antes de observar el conjunto fuera de muestra.
Drawdown	Mayor caída acumulada desde un máximo previo.
<i>Bootstrap</i>	Remuestreo con reemplazo para estimar la incertidumbre de un resultado.
Registro de sombra	Contabilidad de lo que la política habría indicado sin arriesgar capital. Puede ser retrospectivo (<i>replay offline</i>) o prospectivo; solo el segundo aporta nuevos días de validación.
Gradient boosting	Familia de modelos que suma muchos árboles de decisión, cada uno corrigiendo los errores del anterior.
Taker / Maker	Quien cruza el libro y ejecuta contra órdenes existentes (<i>taker</i> , paga la comisión) frente a quien aporta liquidez con órdenes limitadas (<i>maker</i> , exento de comisión y receptor de <i>rebates</i>).
Selección adversa	Riesgo del <i>maker</i> de ser ejecutado precisamente cuando el precio va a moverse en su contra.
Riesgo terminal	En un contrato binario, el riesgo del inventario que llega vivo a la resolución: el contrato liquida a 0 o a 1, de modo que una posición sin cerrar se enfrenta a la varianza estructural del desenlace.
Modelo fundacional	Modelo pre-entrenado sobre colecciones masivas y heterogéneas de datos (series temporales, tablas) pensado para aplicarse a tareas nuevas sin entrenamiento o con una adaptación ligera.
Zero-shot / linear-probing / fine-tuning	Regímenes de adaptación crecientes de un modelo pre-entrenado: usarlo tal cual, entrenar solo su cabeza de salida, o re-entrenar todos sus parámetros.
Puntuación de Brier	Métrica de calidad de una probabilidad (<i>proper scoring</i>): error cuadrático medio entre la probabilidad emitida y el desenlace; 0,25 equivale a una moneda al aire.
Pre-registro	Compromiso público de hipótesis, protocolo y criterios de éxito anterior a la observación de los datos de evaluación.
Sello de tiempo (OpenTimestamps)	Atestación criptográfica sobre la cadena de Bitcoin de que un documento existía antes de cierto bloque; permite verificar la anterioridad de un compromiso sin confiar en el autor.
<i>Rebate</i> de liquidez	Devolución que la plataforma reparte entre quienes publican órdenes en el libro, financiada con las comisiones que pagan quienes las cruzan. Es la razón por la que el mismo régimen de comisiones que arruina al <i>taker</i> retribuye al <i>maker</i> .
AUC	Área bajo la curva ROC: probabilidad de que el modelo puntúe más alto un caso positivo que uno negativo tomados al azar. 0,5 es no distinguir

nada; 1,0 es separación perfecta.

Ratio de Sharpe deflactada Corrección de la ratio de Sharpe que descuenta cuántas estrategias se probaron antes de quedarse con una; sin ella, buscar lo suficiente garantiza encontrar un resultado bueno por azar.

Adenda Ampliación de un pre-registro, sellada con el mismo procedimiento y antes de observar sus propios datos, para cubrir un experimento que el compromiso original no contemplaba.

Capítulo 1

Introducción

Este Trabajo Fin de Máster estudia un problema de predicción financiera de muy corto plazo en un entorno poco habitual: los mercados de predicción sobre el precio de Bitcoin de la plataforma Polymarket. El objetivo no es un sistema de trading en producción, sino una *metodología* rigurosa para responder, con honestidad estadística, a una pregunta concreta: ¿contiene el libro de órdenes de estos mercados señales que permitan anticipar el movimiento del precio en los próximos segundos y que, además, sobrevivan a los costes y a la latencia reales de operar?

Como el lector puede no estar familiarizado con el mundo de las criptomonedas ni con la microestructura de mercado, este capítulo introduce todos los conceptos desde cero antes de plantear el problema y los objetivos.

1.1 Introducción y definición del problema

Esta sección define el problema desde cero. Antes de plantear la pregunta de investigación se introducen los conceptos imprescindibles (mercado de predicción, contrato binario, libro de órdenes y señales de microestructura), de modo que el documento resulte autocontenido también para un lector ajeno al mundo de las criptomonedas. Con ese vocabulario fijado, se enuncia el problema concreto que se aborda.

1.1.1 Qué es un mercado de predicción

Un *mercado de predicción* es un mercado en el que se compran y venden contratos cuyo valor depende del resultado de un acontecimiento futuro. El caso más sencillo es el *contrato binario*: un contrato que pagará una unidad monetaria si el acontecimiento ocurre y cero si no ocurre. Por construcción, su precio se mueve entre 0 y 1, y puede leerse directamente como la *probabilidad implícita* que el mercado asigna al suceso. Por ejemplo, un contrato “el precio de Bitcoin estará por encima de un umbral a una hora determinada” que cotiza a 0,60 indica que el mercado estima una probabilidad cercana al 60 % de que eso ocurra. Cuando el acontecimiento se resuelve, el contrato vale 1 o 0 y las posiciones se liquidan. La literatura clásica ha mostrado que estos mercados agregan información dispersa y producen previsiones razonablemente calibradas [4].

1.1.2 Qué es Polymarket

Polymarket es una plataforma de mercados de predicción descentralizada. A diferencia de una casa de apuestas, donde el operador fija las cuotas, en Polymarket son los propios participantes quienes ponen precios mediante un *libro de órdenes* central (*Central Limit Order Book*, CLOB): el emparejamiento de compras y ventas ocurre fuera de la cadena de bloques (de forma rápida) y la liquidación final del dinero se registra en cadena (sobre una *blockchain*) [2]. En los mercados sobre el precio de Bitcoin, cada contrato binario toma valores entre 0 y 1 y se interpreta como una probabilidad [1]. Esto convierte cada mercado en un pequeño *mercado electrónico* (*exchange*) con su propia dinámica de oferta y demanda.

Que la liquidación viva en una cadena de bloques tiene una consecuencia directa para un trabajo de datos: nada se borra. Cada operación liquidada queda registrada de forma permanente y pública; si una posición se deshace, no se elimina el apunte original, sino que se añade otro en sentido contrario. Esa propiedad es la que hace posible la auditoría del registro público de operaciones del Anexo D (reproducir las cifras del trabajo desde un dato que nadie puede reescribir) y la que garantiza que el flujo de operaciones capturado no depende de la buena voluntad del operador de la plataforma. El libro de órdenes en sí, en cambio, vive fuera de cadena por velocidad, y por eso su captura continua (Capítulo 3) es aportación de este trabajo: es la parte del sistema que no deja huella permanente.

1.1.3 El libro de órdenes y el vocabulario de la microestructura

El *libro de órdenes* (en inglés *limit order book*, LOB) es la lista, ordenada por precio, de todas las órdenes de compra y de venta que están a la espera de ejecutarse. Sus elementos esenciales son:

- **Bid**: el precio más alto al que alguien está dispuesto a comprar.
- **Ask**: el precio más bajo al que alguien está dispuesto a vender. Siempre es mayor o igual que el *bid*.
- **Spread**: la diferencia entre el *ask* y el *bid*. Es el primer coste de operar: quien compra al *ask* y vende al *bid* pierde el *spread*.
- **Profundidad**: el volumen disponible en cada nivel de precio. A más profundidad, más se puede operar sin mover el precio.
- **Precio medio** (*mid*): el punto medio entre *bid* y *ask*; una referencia “limpia” del precio sin el ruido del *spread*.
- **Tick**: la variación mínima de precio que admite el mercado. Es la unidad natural en la que mediremos todos los resultados de este trabajo.
- **Taker**: quien cruza el *spread* con una orden inmediata contra el libro. Obtiene ejecución al instante y, en los mercados de criptomonedas de 2026, paga la comisión.
- **Maker** (creador de mercado): quien publica órdenes límite y espera a que otro las cruce. Provee liquidez, cobra el *spread* y una parte de las comisiones de los *takers* (*rebate*), y a cambio asume el riesgo de quedarse con inventario cuando el mercado se mueve en su contra. La distinción *maker/taker* vertebró la segunda mitad de este trabajo.

La Tabla 1.1 muestra, a modo de ejemplo ilustrativo, el aspecto de un libro de órdenes con tres niveles a cada lado.

Tabla 1.1: Ejemplo ilustrativo de un libro de órdenes (valores inventados con fines explicativos, no datos reales). El mejor *bid* es 0,52 y el mejor *ask*, 0,54; por tanto el *spread* es de 0,02 y el precio medio, 0,53. Los niveles más alejados del centro tienen, típicamente, más volumen acumulado.

Compra (<i>bids</i>)		Venta (<i>asks</i>)	
Precio	Tamaño	Precio	Tamaño
0,52	120	0,54	90
0,51	200	0,55	150
0,50	340	0,56	220

La *microestructura de mercado* es la rama que estudia cómo se forman los precios a partir de estos mecanismos (órdenes, *spread*, profundidad y flujo de operaciones) a escalas de tiempo muy finas. En este contexto, se entiende por *señales de microestructura* las variables derivadas del propio libro de órdenes (por ejemplo, el desbalance entre compra y venta, la presión del microprice o los cambios recientes del *spread*) que podrían contener información anticipatoria sobre el movimiento inmediato del precio. La Figura 1.1 resume el entorno: el precio del contrato se forma en su propio libro de órdenes, pero está acoplado a referencias externas del mercado de Bitcoin (mercado al contado, futuros perpetuos y un oráculo de precios), ya que, en última instancia, el contrato se refiere al precio de Bitcoin.




Figura 1.1: El entorno del problema. El precio del contrato binario se forma en su libro de órdenes y está acoplado a referencias externas del mercado de Bitcoin. El objetivo es anticipar su movimiento de muy corto plazo.

1.1.4 Definición del problema

El precio del contrato no es el precio de Bitcoin: es una función no lineal y dependiente del tiempo de la probabilidad de que el suceso se resuelva afirmativamente. Sin embargo, está acoplado a las referencias externas observables que se acaban de citar. Un modelo útil debe, por tanto, aprender simultáneamente dos elementos: la dinámica interna del libro de órdenes y la semántica del contrato respecto a Bitcoin.

El problema que se aborda es de microestructura y de muy corto plazo: dado el estado del mercado en un instante t (libro de órdenes y referencias externas), predecir el movimiento del precio medio del contrato en una ventana de pocas decenas de segundos. A diferencia de la mayor parte de la literatura sobre mercados de predicción, que estudia cómo se calibra el precio frente a la resolución final del evento, aquí el interés está en los movimientos locales del precio, a escala de segundos.

Conviene fijar desde el principio un matiz que vertebra todo el trabajo: una buena capacidad de *predecir la dirección* no implica una estrategia rentable. Esta distinción está bien documentada en la literatura de microestructura y de aprendizaje automático en finanzas [10, 12, 13]: una métrica de clasificación puede ser muy alta y, aun así, el sistema no ser explotable si opera con retraso, si aprende artefactos del propio conjunto de datos o si ignora el coste real de cruzar una orden. Por eso el problema no se evalúa por el acierto, sino por el resultado económico neto, una vez descontados costes y latencia realistas.

1.2 Motivación

La motivación de este trabajo es doble. Desde el punto de vista aplicado, los mercados de predicción de criptoactivos son un entorno joven, con menos competencia algorítmica que los mercados financieros tradicionales, y con datos públicos accesibles; resulta natural preguntarse si contienen señales explotables. Desde el punto de vista metodológico (que es el que da peso a una memoria de máster) el entorno es un excelente banco de pruebas para una cuestión central en el aprendizaje automático aplicado a finanzas: la distancia entre *predecir correctamente* y *obtener beneficio*.

El trabajo previo existe y deja un hueco preciso: los estudios académicos sobre Polymarket aparecidos en 2026 describen la plataforma (archivos de eventos, arbitraje, composición del flujo) pero ninguno evalúa económicamente una política de negociación bajo coste, latencia y comisiones medidos, ni valida prospectivamente sus resultados (Capítulo 2); y la literatura de aprendizaje profundo sobre libros de órdenes rara vez cruza sus métricas de clasificación con un modelo de ejecución realista. Ahí es donde este trabajo puede mejorar lo existente, y ahí se juega su respuesta a “¿qué se gana?”: no una estrategia rentable (el resultado económico final es negativo y se reporta íntegro), sino la cuantificación, por varias vías independientes, de cuánta de la capacidad predictiva sobrevive a la ejecución, junto con el protocolo sellado que hace creíble esa cuantificación.

Esa distancia es el hilo conductor. Como se mostrará, un clasificador direccional sencillo alcanza una precisión cercana al 90 % medida como *markout* instantáneo y, pese a ello, no sobrevive al primer escalón de latencia que el instrumento de captura permite resolver. El coste y la ejecución, y no el acierto, determinan el resultado. Asumir lo contrario es uno de los errores más comunes y costosos en este campo, y documentarlo con evidencia cuantitativa es, en sí mismo, una aportación.

El argumento no descansa sobre una única medición. A lo largo del trabajo, la misma conclusión se alcanza por cuatro caminos: el efecto de la latencia sobre la señal direccional, la estructura oficial de comisiones (que, una vez corregido un error en el modelo de costes, resulta suficiente por sí sola para agotar el resultado bruto), la ausencia de cualquier retardo explotable en la incorporación de la información externa, y una validación prospectiva pre-registrada, ejecutada dos veces sobre una ventana sellada de antemano y con potencia suficiente para afirmar la ausencia en lugar de sugerirla. Que varias vías

converjan es lo que convierte una observación en una conclusión.

Conviene además situar las expectativas. El objetivo no es construir un sistema de trading en producción ni demostrar rentabilidad, sino algo más modesto y, a la vez, más exigente metodológicamente: determinar *si* existe señal explotable bajo condiciones realistas y, sobre todo, *cómo* evaluarla sin engañarse. En un dominio donde es fácil obtener resultados espectaculares pero ilusorios, el valor de un trabajo de máster está tanto en lo que encuentra como en el rigor con el que descarta lo que no se sostiene. Por eso, a lo largo de la memoria, los resultados negativos (modelos que parecían prometedores y no superaron la validación) se reportan con el mismo cuidado que los positivos.

1.3 Objetivos

El objetivo general es **construir y validar, con un protocolo honesto, una metodología completa para evaluar si el aprendizaje automático y profundo pueden anticipar el movimiento de corto plazo del precio de los contratos de Bitcoin de Polymarket bajo costes y latencia realistas**. De él se derivan los siguientes objetivos específicos:

1. Diseñar un sistema de captura de datos multifuente, con control de calidad por sesión, que produzca un corpus alineado temporalmente y libre de fugas.
2. Definir un protocolo de evaluación que combine validación estrictamente temporal, un modelo explícito de costes y una latencia de ejecución medida contra el mercado real, declarando con precisión qué parte de ella es medición y qué parte es la resolución del instrumento.
3. Cuantificar el impacto de la latencia sobre una señal direccional fuerte, para delimitar dónde se rompe la cadena entre predicción y ejecución.
4. Evaluar una progresión de modelos, de menor a mayor complejidad (líneas base tabulares, modelos sensibles a la latencia y arquitecturas profundas sobre el libro de órdenes), exigiendo que cada incremento de complejidad se justifique con evidencia.
5. Determinar si existe un candidato que sobreviva a una validación fuera de muestra bajo coste, y delimitar con rigor sus límites y su incertidumbre.
6. Auditar el propio modelo de costes hasta sus fuentes primarias y, si resultara erróneo, corregirlo, documentar la corrección con marca de tiempo verificable y reevaluar sin reentrenar nada, extrayendo las consecuencias sobre qué lado del libro es económicamente viable.
7. Someter la política resultante a una **validación prospectiva pre-registrada**: fijar por escrito y sellar criptográficamente, antes de observar los datos, el universo, las variantes, las métricas y las reglas de decisión; ejecutar una única evaluación sobre una ventana posterior al sellado; y reportar el resultado con independencia de su signo.

Los dos últimos objetivos no figuraban en el planteamiento inicial y se incorporaron durante el desarrollo: el sexto, al detectarse que el modelo de comisiones empleado no correspondía con la tarifa oficial vigente; el séptimo, como consecuencia natural de que toda la evidencia acumulada hasta ese punto era retrospectiva. Se declaran aquí como objetivos, y no como incidencias, porque acabaron aportando más al trabajo que varios de los previstos desde el principio.

Estructura del documento. El presente trabajo se organiza como sigue:

- **Capítulo 2:** Estado de la cuestión: literatura de microestructura y aprendizaje profundo sobre libros de órdenes, y sus limitaciones.
- **Capítulo 3:** Material y métodos: el sistema de captura, el corpus y su análisis exploratorio, las líneas base y la metodología de modelado, validación y costes.
- **Capítulo 4:** Resultados y análisis: la evaluación fuera de muestra, la corrección del modelo de comisiones, el giro al lado *maker* y la validación prospectiva pre-registrada.
- **Capítulo 5:** Despliegue: arquitectura del sistema y condiciones bajo las que tendría sentido operarlo.
- **Capítulo 6:** Aspectos éticos y limitaciones.
- **Capítulo 7:** Reproducibilidad: qué se publica y cómo reproducir las cifras.
- **Capítulo 8:** Conclusiones y trabajo futuro.
- **Anexos:** detalle de características e hiperparámetros, el pre-registro completo con el procedimiento de verificación del sello temporal, y una auditoría del registro público de operaciones desde el dato anonimizado.

En los preliminares se incluye además un glosario para el lector no familiarizado con las criptomonedas.

Una advertencia sobre la lectura. La memoria no describe un plan ejecutado sin sobresaltos, porque el trabajo no fue así. Recoge un itinerario en el que una señal aparentemente excelente resultó no ser explotable, un modelo de costes tuvo que corregirse a mitad de camino, el vehículo económico se desplazó de un lado del libro al contrario, y la validación final (pre-registrada y sellada) arrojó un resultado negativo que se reporta íntegro. Ese itinerario, y no un modelo concreto, es la aportación.

Capítulo 2

Estado de la cuestión

Este capítulo sitúa el trabajo en la literatura. Se organiza en las áreas que confluyen en el problema (mercados de predicción y el estudio académico reciente de Polymarket, aprendizaje profundo sobre libros de órdenes, modelos fundacionales y auto-supervisados de series temporales, microestructura y ejecución, validación temporal en finanzas, y cambio de distribución) y termina señalando el hueco concreto que este trabajo pretende cubrir.

2.1 Trabajos previos y estudios relevantes

Esta sección recorre la literatura relevante para el problema, organizada en bloques temáticos. En cada bloque se resume qué proponen los trabajos de referencia y qué se toma de ellos para este trabajo. La predicción del movimiento de precios a partir de la microestructura es un campo activo, con propuestas asentadas tanto para mercados tradicionales como para criptoactivos; el interés aquí es seleccionar de esa literatura los elementos aplicables a un mercado de predicción sobre Bitcoin.

2.1.1 Mercados de predicción

Los mercados de predicción se han estudiado, sobre todo, como mecanismos de agregación de información dispersa. Wolfers y Zitzewitz [4] muestran que pueden producir previsiones notablemente precisas, si bien su interpretación depende del diseño del contrato, de la liquidez y de los incentivos de los participantes. La mayor parte de esta literatura analiza la calibración del precio frente a la resolución final del evento. El presente trabajo se sitúa un escalón por debajo, en el terreno de la microestructura: la dinámica intradía del precio del contrato a escala de segundos, donde aparecen *spreads*, profundidad limitada y desajustes transitorios respecto a las referencias externas. Conviene además precisar el mecanismo: a diferencia de los mercados de predicción basados en creadores de mercado automáticos (que fijan el precio mediante una fórmula), Polymarket emplea un libro de órdenes, lo que hace aplicable el instrumental clásico de la microestructura y justifica el enfoque de este trabajo.

2.1.2 Polymarket como objeto de estudio académico

Hasta 2025, Polymarket apenas contaba con literatura académica propia; en la primera mitad de 2026 han aparecido cinco estudios que lo convierten en objeto de análisis directo,

y que delimitan con precisión el hueco que ocupa este trabajo (véase la Figura 2.1).

La literatura académica de Polymarket en 2026 y la posición de este trabajo




Figura 2.1: La literatura académica sobre Polymarket surgida en la primera mitad de 2026 y la posición de este trabajo. Los cinco estudios describen la plataforma (elecciones, arbitraje, flujo, archivos on-chain o tick-level); este trabajo se distingue por añadir el libro L2 sincronizado con referencias externas y un contrato de latencia, lo que habilita la evaluación económica de la ejecución que ninguno aborda.

Dubach [17] construye un archivo *tick-level* del canal público del libro de órdenes (30 mil millones de eventos a lo largo de 52 días) y extrae de él ocho hechos estilizados de la microestructura de Polymarket: concentración de la actividad en pocos mercados, *spreads* dependientes del nivel de precio, actividad de cancelación dominante y ciclos intradía marcados, entre otros. Es el trabajo más cercano al presente en objeto y escala temporal, y sirve aquí como referencia de contraste para el análisis exploratorio del Capítulo 3: los hechos estilizados que aquel archivo documenta sobre el conjunto de la plataforma se comparan con lo observado en el corpus propio de mercados horarios de Bitcoin. Tsang y Yang [18] analizan el mercado de la elección presidencial estadounidense de 2024 con datos de la cadena Polygon y un marco contable a nivel de transacción, incluyendo la detección de *wash trading*; su interés es forense y agregado, no operativo. Cheng, Yang y Zou [19] buscan oportunidades de arbitraje en los mercados de baloncesto y encuentran que las anomalías de mercado único son rarísimas y de vida mediana de pocos segundos: una advertencia empírica directa contra las estrategias *taker* de latencia que este trabajo confirma por otra vía. Ese hallazgo acota también la alternativa práctica más visible fuera de la literatura académica: los *bots* de arbitraje de código abierto que circulan en repositorios públicos, que cruzan desajustes elementales (los dos lados de un mercado sumando menos de uno, o el mismo suceso cotizado distinto en dos mercados) sin modelo alguno. De ellos este trabajo aprovecha la lección de ingeniería (la conexión continua a la API y la contabilidad de costes por operación son la mitad del problema) y se diferencia en el objetivo: no ejecutar la anomalía obvia, que la evidencia muestra escasa y efímera, sino medir si existe señal explotable bajo costes y latencia reales. Nechepurenko [20] estudia la composición del flujo ejecutado y muestra que la liquidez de Polymarket descansa en niveles de participantes no minoristas con firmas de microestructura diferenciadas; para este trabajo, ese resultado describe al adversario contra el que compite cualquier política

maker. Por último, Qin y Yang [21] publican la base Polymarket-v1, el archivo on-chain completo de la primera generación del protocolo (1,2 mil millones de operaciones entre 2022 y 2026), orientada a la historia larga de operaciones liquidadas.

La posición de este trabajo frente a esa literatura se resume en dos diferencias. La primera es el dato: los archivos citados capturan operaciones on-chain o el canal público de eventos, mientras que el corpus propio sincroniza el libro L2 completo a malla fija de 2 segundos con referencias externas simultáneas (*spot*, perpetuos y oráculo) y con un contrato de latencia medido sobre el ciclo real de órdenes (es decir, contiene exactamente la información que hace falta para simular ejecución, no solo para describir actividad). La segunda es la pregunta: ninguno de los cinco estudios evalúa económicamente una política de negociación congelada bajo coste, latencia y régimen de comisiones medidos, ni valida prospectivamente sus resultados; ese es el terreno de este trabajo.

2.1.3 Aprendizaje profundo sobre libros de órdenes

La predicción del movimiento de precios a partir del libro de órdenes es un problema con una literatura ya madura. El trabajo de referencia es DeepLOB [5], que representa el libro como una matriz de dos dimensiones (niveles de precio frente a tiempo) y aplica primero módulos convolucionales (que capturan la estructura espacial entre los niveles de compra y de venta) y, a continuación, capas recurrentes que modelan la dependencia temporal; se valida sobre FI-2010 [6], un conjunto de referencia público de libros de órdenes ampliamente utilizado como banco de pruebas. En la misma línea, Tsantekidis et al. [7] comparan arquitecturas convolucionales y recurrentes para detectar cambios de precio en el libro. Sirignano y Cont [8] aportan evidencia de la existencia de características universales en la formación de precios que el aprendizaje profundo es capaz de capturar, y Jha et al. [9] trasladan estas ideas al terreno de los criptoactivos, mostrando que el enfoque no es exclusivo de los mercados tradicionales. La línea sigue activa: TLOB [23] sustituye el par convolucional-recurrente por un transformador con doble atención (espacial sobre los niveles del libro y temporal sobre la secuencia) y documenta, además, que el rendimiento de todos estos modelos se degrada al acercarse a condiciones de mercado realistas (observación que anticipa el resultado central de este trabajo).

La Figura 2.2 ilustra la idea que da nombre a la “lectura visual” del libro: el estado del mercado en cada instante se apila como una columna (precios y volúmenes de los mejores niveles de compra y de venta) y la sucesión de instantes forma una matriz que la convolución recorre igual que recorrería una imagen, buscando motivos locales (desequilibrios entre lados, escalones de profundidad) que la recurrencia integra después a lo largo del tiempo.

De esta literatura este trabajo adopta una decisión de diseño (tratar el libro de órdenes como un objeto con estructura espacio-temporal, y no como una tabla plana) y, sobre ella, introduce dos cambios. El primero es metodológico: evaluar cada modelo bajo un modelo de ejecución realista (coste y latencia), y no solo con métricas de clasificación como es habitual en estos trabajos. El segundo es de dominio: aplicar el enfoque a un mercado de predicción sobre Bitcoin (y no a un mercado de acciones), lo que obliga a combinar el libro con referencias externas. Esa doble diferencia es, precisamente, donde este trabajo pone el acento.




Figura 2.2: Esquema de la familia DeepLOB: el libro se representa como una matriz niveles×tiempo (cada celda, un precio o volumen) que los módulos convolucionales procesan como una imagen antes de que la parte recurrente (o de atención) integre la evolución temporal. El BookEncoder del Capítulo 3 es la adaptación de esta idea al libro de Polymarket.

2.1.4 Modelos fundacionales de series temporales y aprendizaje auto-supervisado

Una segunda corriente reciente propone trasladar a las series temporales la receta de los grandes modelos de lenguaje: pre-entrenar un modelo genérico sobre colecciones masivas y heterogéneas de series y aplicarlo después a tareas nuevas sin entrenamiento (*zero-shot*) o con una adaptación ligera (*fine-tuning*). MOMENT [24] es el representante que este trabajo adopta como peldaño de su escalera de modelos: una familia abierta de transformadores pre-entrenados por reconstrucción enmascarada, con variantes que caben en hardware modesto. En la misma familia, Chronos [25] discretiza los valores de la serie y los trata literalmente como *tokens* de un modelo de lenguaje; TimesFM [26] es el fundacional de predicción de Google entrenado sobre cientos de miles de millones de puntos reales, y la línea Moirai [27] (ya en su segunda versión, con predicción cuantílica) representa el estado del arte de los fundacionales universales de predicción. Fuera de las series, TabPFN [28] lleva la misma idea al dato tabular: una red pre-entrenada sobre el prior de millones de conjuntos sintéticos que clasifica conjuntos pequeños por inferencia en contexto, sin entrenar. Su inclusión en la escalera de este trabajo permite formular la pregunta simétrica (¿qué aporta un fundacional *del tipo de dato que ganó*, el tabular, y no solo del tipo de dato aparente, la serie temporal?), cuyos resultados se presentan en la Sección 4.2.3.

El pre-entrenamiento auto-supervisado es el mecanismo que sostiene a estos modelos y una línea propia de literatura. Las estrategias dominantes son la reconstrucción de tramos enmascarados (SimMTM [29] la formula como suma ponderada de series vecinas fuera de la variedad de la serie original), el contraste jerárquico entre vistas aumentadas (TS2Vec [30], generalizado por SoftCLT [31] con asignaciones blandas que respetan la cercanía temporal) y los objetivos híbridos: TimeSiam [32] empareja subseries pasadas y presentes con codificadores siameses, y TimeDART [33] combina difusión y auto-regresión para capturar a la vez la dinámica global y los patrones locales. Para este trabajo, esta literatura cumple dos papeles: motiva el peldaño auto-supervisado de la escalera (un codificador convolucional-temporal pre-entrenado por reconstrucción sobre el propio corpus) y aporta la advertencia, repetida en sus propias evaluaciones, de que la ventaja del pre-entrenamiento depende críticamente del volumen y de la afinidad de dominio de los datos (condición que un mercado joven, con semanas de historia, no cumple de partida). La Figura 2.3 resume las familias evaluadas y su relación con el especialista tabular que este

trabajo acaba eligiendo.




Figura 2.3: Familias de modelos consideradas (fundacionales de series, auto-supervisados y el fundacional tabular) y su papel como peldaños de la escalera comparativa frente al especialista tabular, que es el vehículo finalmente elegido de la señal. Las estrellas marcan los modelos efectivamente evaluados en este trabajo (MOMENT y TabPFN).

2.1.5 Microestructura, costes de ejecución y latencia

La distancia entre predecir bien y obtener beneficio es uno de los temas clásicos de la microestructura de mercado. Kearns y Nevmyvaka [10] revisan el papel del aprendizaje automático en microestructura y negociación de alta frecuencia, y subrayan que la ejecución, el coste y la latencia condicionan de forma decisiva la viabilidad de una señal. Este trabajo cuantifica ese fenómeno en el contexto concreto de Polymarket: se mide la latencia real del ciclo de orden y se demuestra que una señal direccional fuerte se vuelve no rentable bajo una latencia de entrada modesta. El cambio que se introduce respecto a esta literatura es, de nuevo, metodológico: en lugar de asumir una latencia o un coste fijos, ambos se determinan a partir de los datos (la latencia, de forma empírica sobre el ciclo de orden real; el coste, de forma relativa al estado del libro en cada instante), de modo que la evaluación económica refleje las condiciones efectivas de ejecución.

2.1.6 Aprendizaje automático en finanzas y validación temporal

El aprendizaje automático aplicado a la predicción financiera es especialmente propenso a resultados ilusorios cuando la evaluación no respeta la estructura temporal de los datos. Gu, Kelly y Xiu [11] ofrecen un marco riguroso de comparación de modelos con validación fuera de muestra. López de Prado [12] documenta los mecanismos por los que se cuela información del futuro y por los que se sobreajustan los *backtests*, y propone protocolos de validación que respetan la causalidad temporal. Bailey y López de Prado [13] advierten

de un riesgo adicional: si se prueban muchos modelos y se elige el mejor, las métricas de rendimiento salen infladas casi por construcción. Estas referencias motivan tres decisiones metodológicas de este trabajo: la partición estrictamente temporal, el protocolo fuera de pliegue (*out-of-fold*) y la congelación del candidato antes de observar el conjunto de validación fuera de muestra.

2.1.7 Cambio de distribución y adaptación de dominio

Los mercados financieros no son estacionarios, por lo que la distribución de los datos cambia entre el periodo de entrenamiento y el de despliegue. Para amortiguar ese efecto existen técnicas de adaptación de dominio, como la alineación de correlaciones CORAL [14]. En el Capítulo 4 se mostrará un resultado contraintuitivo: con un horizonte de datos reducido, estas técnicas no superan a una estrategia mucho más simple, consistente en restringir la operativa al régimen en el que el modelo fue entrenado. Además de CORAL, en este trabajo se evalúan otras estrategias de adaptación habituales (filtros conformales, *ensembles* y reentrenamiento incremental con ventana móvil), cuyos resultados se detallan en el Capítulo 4. Por último, en cuanto a arquitecturas profundas para series temporales multivariantes, trabajos como el *Temporal Fusion Transformer* [15] marcan una línea de evolución natural para cuando se disponga de muchos más datos.

2.1.8 Rigor de validación: pre-registro y control del sesgo de selección

Las referencias de validación temporal citadas más arriba comparten un diagnóstico: el riesgo dominante en la investigación financiera empírica no es el error del modelo, sino el del investigador que prueba muchas variantes y reporta la mejor. Harvey, Liu y Zhu [34] cuantifican el problema en la literatura de factores (la mayoría de los resultados publicados no sobreviviría umbrales de contraste múltiple) y Bailey y López de Prado [13] ofrecen la corrección correspondiente para estrategias de negociación, la ratio de Sharpe deflactada, que penaliza explícitamente el número de ensayos. Ambas líneas atacan el sesgo *a posteriori*, corrigiendo la métrica una vez cometido el pecado.

La respuesta *a priori* es el pre-registro: comprometer hipótesis, protocolo y criterios de éxito antes de observar los datos de evaluación, práctica hoy estándar en las ciencias experimentales [35]. Su punto débil clásico es la verificabilidad: nada impide redactar el “pre”-registro después. Este trabajo lo resuelve con un sello criptográfico de tiempo: el documento de pre-registro y la política congelada se atestan con OpenTimestamps [36] sobre la cadena de Bitcoin, de modo que cualquier lector puede verificar la fecha del compromiso frente a las fechas de la ventana de evaluación, sin confiar en el autor ni en un tercero. Una precisión que conviene dejar escrita: el sello garantiza que el compromiso precede a la *observación* de los datos, no a su existencia (al sellarse el protocolo general ya se habían capturado los primeros días de su ventana). Para ese tramo inicial la garantía es la declaración del propio documento sellado, que fija el compromiso “antes de mirar cualquier dato”, y la frontera entre la garantía criptográfica y la procedimental se declara aquí en lugar de dejarla implícita. La combinación (candidato congelado con hashes verificables, ventana de evaluación prospectiva intocada hasta un corte fijado de antemano, y reporte de todas las variantes comprometidas, favorables o no) es, hasta donde alcanza la revisión de este capítulo, inédita en la literatura de mercados de predicción, y constituye la aportación metodológica central del trabajo (el protocolo se detalla en el Capítulo 3).

La Tabla 2.1 condensa el balance de las familias revisadas: qué fortaleza motiva incluir cada una, qué debilidad documenta la literatura o anticipa este corpus, y qué se adopta de ella en el trabajo.

Tabla 2.1: Puntos fuertes y débiles de cada familia revisada y qué adopta este trabajo de cada una.

Familia	Punto fuerte	Punto débil	Qué se adopta
CNN/LSTM sobre el libro (DeepLOB, TLOB)	Estructura espacial del libro; F1 ~ 83 % en FI-2010	Exige subyacente en movimiento continuo; frágil ante coste y latencia	Representación matriz niveles $\times$ tiempo (BookEncoder)
Fundacionales de series (MOMENT, Chronos, TimesFM)	<i>Zero-shot</i> y ajuste barato; contexto largo	No baten a baselines simples en régimen casi inmóvil; contexto de 512 no cabe en mercados cortos	MOMENT como peldaño profundo de la escalera
Fundacional tabular (TabPFN)	Ordenación <i>zero-shot</i> competitiva con un tercio de los datos	Tope de contexto; no mejora la cabeza de decisión	Pregunta simétrica de la escalera (Sección 4.2.3)
Auto-supervisión (TS2Vec, TCN propio)	Aprovecha datos sin etiquetar; regulariza	Sin etiqueta económica, la representación no encuentra señal que no exista	Encoder TCN auto-supervisado como peldaño
Tabulares con regularización (HGB)	Varianza baja con pocos casos; robustos a escala y ruido	Sesgo alto; no capturan estructura secuencial fina	Especialista de dos cabezas (el modelo final)

2.2 Limitaciones en la literatura

Del repaso anterior se desprenden tres limitaciones recurrentes que enmarcan la aportación de este trabajo. En primer lugar, la evaluación predominante es de *clasificación* (precisión, AUC), y rara vez se traduce a un resultado económico bajo un modelo de ejecución realista; como se verá, esa traducción cambia las conclusiones por completo. En segundo lugar, gran parte de los resultados positivos se obtienen sin una latencia de entrada explícita, cuando la latencia es precisamente lo que destruye muchas señales de corto plazo. En tercer lugar, los entornos de criptoactivos jóvenes ofrecen pocos datos, lo que agrava el riesgo de sobreajuste y de resultados ilusorios si la validación no es estrictamente temporal.

El hueco que cubre este trabajo es, por tanto, metodológico: evaluar la predicción de corto plazo *bajo coste y latencia medida*, con validación estrictamente temporal y congelación previa del candidato, y reportar cada resultado en ticks netos acompañado de su soporte y su incertidumbre.

Capítulo 3

Material y métodos

Este capítulo describe el material (los datos) y los métodos (líneas base, protocolo de validación y modelos) del trabajo. Se ha organizado en cuatro bloques: la descripción del conjunto de datos, el análisis exploratorio de series temporales, los resultados de los modelos base (que contienen la lección central del trabajo) y la metodología de modelado y entrenamiento.

3.1 Descripción del dataset

Esta sección describe el origen de los datos, su organización temporal y los controles de calidad que determinan qué entra en el conjunto de trabajo. Se introducen primero los conceptos necesarios (fuentes de datos, malla temporal y contrato de latencia, y datos obsoletos) y después se resume la composición del corpus y su análisis exploratorio.

3.1.1 Sistema de captura multifuente

El conjunto de datos es íntegramente **real**, no sintético ni simulado: se captura en vivo del mercado en producción, y todas las operaciones y niveles de libro registrados corresponden a órdenes reales de participantes reales.

Los datos de mercado se registran mediante una herramienta de captura propia, desarrollada específicamente para este trabajo. Esta herramienta no se publica porque está acoplada a la infraestructura privada en la que se ejecuta (el motivo se detalla en la Sección 7.1.3); aquí se describe únicamente a nivel funcional, y lo que sí se publica (Capítulo 7) es el esquema de la consulta de datos, una muestra representativa y todo el código de análisis y modelado. A nivel funcional, por cada sesión de mercado la herramienta anota cuatro tipos de información: (i) el libro de órdenes del contrato de Polymarket y su flujo de operaciones; (ii) los metadatos del mercado (tamaño de tick, ventana temporal, comisiones); (iii) referencias externas del mercado de Bitcoin (el mercado al contado, *spot*, y los futuros perpetuos, *perpetual futures*); y (iv) un oráculo de precios que aporta el precio de referencia. La fuente de verdad es una base de datos relacional sobre la que se construyen las características; de ella se publican el esquema y una muestra representativa, pero no los datos completos. Todas las fuentes se alinean en el tiempo sobre una malla regular de dos segundos, como se detalla a continuación (véase la Figura 3.1).

Qué permite hacer la API pública y qué se usa de ella. Polymarket expone dos servicios públicos de solo lectura que bastan para toda la recolección. El primero es la API de catálogo (`gamma-api.polymarket.com`), que enumera los mercados activos con sus metadatos: identificadores de mercado y de *token*, pregunta, ventana temporal de la sesión, tamaño de *tick* y régimen de comisiones. De ella la herramienta obtiene, en cada ciclo, qué contratos de Bitcoin están vivos y cuándo vencen. El segundo es la API del libro de órdenes (`clob.polymarket.com`), que para cada *token* devuelve la fotografía completa del libro (todos los niveles de compra y de venta con sus precios y volúmenes) y el flujo de operaciones ejecutadas (precio, volumen y lado agresor). La herramienta consulta ambas de forma periódica y sella cada respuesta con dos marcas de tiempo, la del servidor y la local de recepción, que es lo que después permite medir la latencia (Sección 3.3.1) y detectar datos obsoletos. Ninguna de las dos API exige autenticación para lectura, de modo que la captura no depende de una cuenta ni mueve fondos.




Figura 3.1: Arquitectura del sistema de captura. Las cuatro fuentes se alinean sobre una malla de dos segundos, pasan un control de calidad por sesión y forman el corpus.

3.1.2 Malla temporal y contrato de latencia

Las observaciones se organizan sobre una malla temporal regular: una secuencia de instantes $t_0, t_1, t_2, \dots$ separados exactamente dos segundos, de modo que $t_{k+1} = t_k + 2$ segundos. En cada instante t_k se toma una “fotografía” del estado del mercado (libro de órdenes y referencias externas). La elección de este intervalo no es accesorio, porque define lo que en este trabajo se denomina *contrato de latencia*: el supuesto sobre cuánto tarda una decisión en poder ejecutarse. En lugar de interpolar un instante intermedio que nunca se observó, una decisión tomada con la información de t_k se evalúa contra la siguiente fotografía real, t_{k+1} ; es decir, se asume que entre observar la señal y poder operar transcurre, como mínimo, el intervalo de la malla. Este criterio hace la evaluación deliberadamente conservadora y evita el error habitual de suponer ejecución instantánea.

3.1.3 El grano del precio: un mercado casi siempre inmóvil

La malla de dos segundos fija el ritmo de observación, pero no garantiza que el mercado tenga algo nuevo que contar en cada fotografía. Medido sobre el corpus horario, la respuesta es contundente: **el 89,8 % de los incrementos del punto medio entre fotografías consecutivas es exactamente cero**. El precio no se mueve casi nunca a esa escala. Ampliar la ventana de observación atenúa el efecto, pero no lo elimina en ningún punto razonable (Tabla 3.1).

Tabla 3.1: Grano temporal del punto medio: proporción de intervalos sin ningún cambio de precio y observaciones disponibles por mercado, según la ventana de observación. La columna $|\Delta|$ p90 es el percentil 90 del valor absoluto del cambio del punto medio entre dos observaciones consecutivas de esa ventana, en céntimos de probabilidad.

Ventana	Intervalos sin cambio	$ \Delta $ p90 (céntimos)	Obs./mercado
2 s	89,8 %	0,05	2204
30 s	60,7 %	4	134
60 s	53,7 %	6	60
120 s	47,7 %	8	24
300 s	36,5 %	15	9,5
600 s	29,6 %	21	4,5

La causa es estructural y no accidental: el *tick* de estos contratos vale un céntimo de probabilidad y la horquilla media mide **3,8 ticks**, de modo que el punto medio solo se desplaza cuando uno de los dos lados del libro salta de verdad. Conviene además descartar la explicación alternativa (que la inmovilidad la produjera el sistema de captura y no el mercado), y cuatro comprobaciones independientes la descartan: en el 33,8 % de las fotografías con el precio inmóvil *sí* cambia la profundidad disponible en el toque, luego el capturador observa el libro y registra sus cambios; la proporción de intervalos inmóviles es homogénea entre mercados (del 84,3 % al 95,0 % entre los percentiles 10 y 90) y no se concentra en los menos líquidos; y, como referencia externa, el activo subyacente se mueve **2,3 veces más** en los intervalos en que nuestro precio sí cambia que en los que permanece quieto, es decir, la relación con el subyacente existe y apunta en el sentido correcto.

Para dimensionar el fenómeno con justicia conviene añadir que *tampoco* el mercado al contado de Bitcoin (uno de los más líquidos que existen) registra un cambio mediano de su punto medio en intervalos de dos segundos dentro de esta misma captura. El grano no es, por tanto, una patología de la plataforma estudiada, sino un recordatorio de que dos segundos es un intervalo muy fino para observar precios medios en cualquier mercado.

Esta caracterización tiene una consecuencia metodológica de primer orden, y explica decisiones que se toman más adelante en este trabajo. Toda la familia de modelos de tiempo continuo (difusiones con saltos, cotización óptima al estilo Avellaneda-Stoikov y sus derivados) presupone un precio que evoluciona sin interrupción; aplicada a una serie inmóvil nueve de cada diez instantes, su estimación degenera. Cuando la observación tiene un grano tan grueso, el análisis en clave de tiempo continuo debe realizarse en la banda de **60 a 120 segundos**, donde alrededor de la mitad de los intervalos ya presentan movimiento real y todavía quedan entre 24 y 60 observaciones por mercado; por debajo se mide el *tick* y por encima se agota la muestra, porque estos contratos viven únicamente una hora.

3.1.4 Controles de calidad por sesión

La calidad de los datos es tan crítica como el modelo: una referencia externa retrasada o incompleta puede inducir una señal que en realidad no existe. Por ello, antes de incorporarse al conjunto de trabajo, cada sesión de mercado pasa una batería de controles de calidad y se descarta por completo si no los supera (véase la Figura 3.2). Conviene definir primero un concepto recurrente: un dato *obsoleto* (en inglés *stale*) es un valor que no se

ha actualizado cuando debería haberlo hecho (por ejemplo, una cotización externa que permanece “congelada” varios instantes de la malla porque su fuente dejó de emitir). Un dato obsoleto parece información válida, pero no lo es, y es una de las principales fuentes de señales espurias.

Los controles aplicados a cada sesión son los siguientes:

Cobertura Fracción de instantes de la malla efectivamente observados respecto a los esperados durante la sesión; una cobertura baja indica una captura incompleta.

Continuidad Ausencia de interrupciones prolongadas en el registro de las fuentes.

Obsolescencia Proporción de instantes con datos *stale*; si una referencia se queda congelada demasiado tiempo, la sesión se rechaza.

Arranque Validación de que la sesión comenzó a capturarse correctamente, sin un periodo inicial degradado.

Huecos severos Detección de saltos temporales grandes que la malla no puede rellenar de forma fiable.

Existe además una distinción en la propia estructura del registro que condiciona qué puede usarse como característica y que conviene dejar explícita, porque no es evidente al inspeccionar los datos. No todas las columnas capturadas son series temporales: unas se observan en *cada* instante de la malla (el punto medio, las mejores posturas de compra y venta, la profundidad disponible en cada lado, la horquilla y el último precio operado) mientras que otras son *agregados de ventana*, es decir, un único valor calculado para toda la sesión y repetido idéntico en cada una de sus fotografías; es el caso de los volúmenes y recuentos de operaciones y de las altas y bajas de órdenes. La comprobación es inmediata (basta contar valores distintos dentro de cada sesión) y el resultado es inequívoco: las columnas del segundo grupo presentan un valor único en la totalidad de las sesiones examinadas.

La distinción importa porque una columna agregada es indistinguible de una serie al inspeccionar el conjunto: tiene un valor en cada fila, del tipo correcto y sin ausencias. Usarla como si midiera actividad instantánea introduce dos errores a la vez (sobreestima enormemente el número de observaciones independientes y solapa el predictor con el intervalo que pretende anticipar), sin que ninguna comprobación de software lo delate. Por ese motivo las características construidas en este trabajo se restringen al primer grupo.




Figura 3.2: Flujo del control de calidad por sesión. Solo las sesiones que superan todos los umbrales se incorporan al corpus.

Esta política es deliberadamente estricta: se prefiere reducir el tamaño de la muestra antes que contaminar el entrenamiento con ruido que el modelo podría confundir con una señal. Como consecuencia, el corpus efectivo es sensiblemente menor que el total capturado, lo

que más adelante justifica la estrategia de regularización agresiva.

3.1.5 Composición del corpus

Se denomina *corpus* al conjunto de todas las sesiones aceptadas tras el control de calidad; sobre él se definen después las particiones temporales (entrenamiento, validación y test). El corpus principal abarca del 11 al 25 de mayo de 2026, con del orden de 2,5 millones de filas multifuente (*cross-venue*). Como conjunto fuera de muestra se reservó del 6 al 10 de junio de 2026, capturado con posterioridad a la congelación del candidato (Sección 3.4.11). La unidad de observación es la tupla **sesión** $\times$ **token** $\times$ **instante** sobre la malla de dos segundos. La Figura 3.3 resume la partición temporal.




Figura 3.3: Partición temporal del corpus. El conjunto fuera de muestra (6–10 jun) se capturó después de congelar el candidato, lo que convierte su validación en una prueba genuina.

3.1.6 Análisis exploratorio del corpus

El análisis exploratorio previo deja cuatro observaciones que condicionan todo el diseño posterior:

1. **Desequilibrio de clases.** La etiqueta direccional está dominada por la clase FLAT (quietud): a horizonte H60, y midiendo sobre los 2,2 millones de pasos del corpus horario, el 52,9 % de las observaciones se mueve menos de un tick y el 64,0 %, menos de dos (el rango que cubre los umbrales θ que absorben *spread* y comisión). Esto vuelve engañosa la precisión bruta (un modelo que prediga siempre FLAT acierta ya más de la mitad de las veces) y obliga a usar precisión equilibrada (*balanced accuracy*) y F1 macro.
2. **Calidad de los datos.** En los tramos de alta volatilidad, los retardos de actualización de las referencias externas abarcan varios ciclos de la malla; tras el filtrado, el corpus efectivo es sensiblemente menor que el total capturado, lo que justifica una regularización agresiva.
3. **Patrón prestart.** La ventana inmediatamente anterior a la apertura del mercado concentra una densidad atípica de cancelaciones, modificaciones y cruces, lo que sugiere reposicionamiento de los participantes y una señal de microestructura diferenciada. Esta observación motiva el *modelo especialista* (un modelo entrenado exclusivamente para esa ventana, en lugar de uno generalista) que se describe más adelante en este capítulo.
4. **Acoplamiento con Bitcoin.** La correlación entre el precio del contrato y las referencias de Bitcoin es clara en ventanas de minutos pero se diluye en ventanas de segundos: el arbitraje externo no es instantáneo. Esa separación de escalas justifica combinar el libro local con las referencias externas.

En conjunto, estas cuatro observaciones no son anecdóticas: determinan decisiones concretas del resto del trabajo. El desequilibrio de clases fija la elección de métricas; la calidad de los datos y su escasez efectiva imponen la regularización agresiva y la prudencia en

la validación; el patrón *prestart* define la ventana del especialista; y el acoplamiento con Bitcoin justifica el bloque de características externas. Es decir, el diseño metodológico de los apartados siguientes se deriva directamente de lo que muestran los datos, y no de elecciones arbitrarias.

3.2 Análisis exploratorio de series temporales

Antes de modelar, el corpus se somete a un análisis exploratorio formal de series temporales. Cada análisis de esta sección responde una pregunta concreta de diseño y termina en una decisión; el material es una muestra de 285–300 series mercado–contrato del corpus completo (2,3 millones de filas de la malla horaria de Polymarket (no confundir con los 2,5 millones de filas multifuente, que incluyen las referencias externas), 1.018 series).

Estacionariedad (ADF/KPSS). Como se muestra en la Figura 3.4, al analizar los niveles del precio medio el contraste ADF solo rechaza la raíz unitaria en el 6,3 % de las series. Además, el KPSS rechaza la estacionariedad en el 99,3 %. Sobre las primeras diferencias ocurre lo contrario: el ADF rechaza en el 100 % y el KPSS solo en el 12,6 %. Ambos contrastes coinciden: el precio medio es integrado de orden uno y los retornos son estacionarios. La decisión derivada es modelar siempre sobre diferencias o retornos, nunca sobre niveles.




Figura 3.4: Contrastes de estacionariedad ADF y KPSS sobre niveles y primeras diferencias del precio medio (muestra de 285 series). El patrón conjunto (raíz unitaria en niveles, estacionariedad en diferencias) es consistente en todo el corpus.

Autocorrelación (ACF/PACF). Como se muestra en la Figura 3.5, los retornos a 2 segundos presentan una autocorrelación de primer orden media de 0,07, con cero retardos significativos de los diez primeros en la serie mediana: apenas hay estructura lineal exploitable en el retorno puro. En cambio, los retornos absolutos muestran los diez primeros retardos significativos (agrupamiento de volatilidad) y el desequilibrio de profundidad del libro es extremadamente persistente (autocorrelación de primer orden 0,99). La decisión derivada es doble: las características del modelo deben buscar la señal en el estado del libro y en la volatilidad (no en el retorno retardado) y la persistencia del desequilibrio valida su uso como característica lenta.




Figura 3.5: Funciones de autocorrelación medias: retornos, retornos absolutos y desequilibrio de profundidad. La señal lineal está en el estado del libro, no en el retorno retardado.

Descomposición STL de la actividad. Como se muestra en la Figura 3.6, la serie agregada de actividad (eventos por cubo temporal) se descompone en tendencia, estacionalidad diaria y residuo; la componente estacional explica el 19,4 % de la varianza. Existe un ciclo diario real pero moderado: la actividad no es reducible a su patrón horario.




Figura 3.6: Descomposición STL de la actividad agregada del corpus. La estacionalidad diaria explica el 19,4 % de la varianza.

Espectro de Fourier y ciclo intrahora. Como se muestra en la Figura 3.7, el espectro de la actividad presenta picos nítidos en los periodos de 24 horas y de 1 hora (230 y 225 veces la potencia mediana, respectivamente): el ciclo de vida horario de los mercados estudiados imprime su firma en la actividad global. Dentro de la hora, el perfil medio no es plano (la razón entre el minuto más y menos activo es 2,3) y el minuto más activo es el **minuto 50**, coherente con la concentración de actividad en el tramo final de la vida del contrato que motiva el análisis del riesgo terminal del Capítulo 5.




Figura 3.7: Espectro de la actividad agregada y perfil intrahora. Picos en 24 h y 1 h; el minuto 50 es el más activo del ciclo horario.

Calidad por sesión e imputación. Como se muestra en la Figura 3.8, la cobertura mediana de la malla de 2 segundos es del 100 % y el 99,8 % de las series supera el 99 % de cobertura. Con esta densidad, la política de imputación puede ser conservadora: arrastre del último valor observado marcando el dato como *stale*, sin interpolar (interpolar inventaría microestructura precisamente donde el modelo la busca), y exclusión de la sesión cuando la cobertura cae por debajo del umbral de calidad.




Figura 3.8: Distribución de la cobertura de la malla de 2s por serie. La densidad del corpus permite una política de imputación conservadora.

Contraste con los hechos estilizados de la literatura. Los resultados anteriores se alinean con los hechos estilizados que Dubach [17] documenta sobre el archivo *tick-level* de toda la plataforma: ciclos de actividad intradía marcados, retornos sin estructura lineal apreciable pero con volatilidad agrupada, y estado del libro persistente. La diferencia es de resolución y de alcance: aquel archivo describe la plataforma completa a nivel de evento, y este corpus añade las referencias externas sincronizadas y el contrato de latencia que permiten pasar de la descripción a la evaluación económica.

3.3 Resultados en modelos base

Antes de introducir cualquier modelo complejo conviene establecer modelos base sencillos y medir su comportamiento bajo condiciones realistas. Esta sección muestra el análisis de los resultados de los modelos base, que sirven de referencia para las comparaciones posteriores: el mejor de ellos alcanza una precisión direccional muy alta en las operaciones que selecciona y, sin embargo, deja de ser rentable al introducir la latencia de entrada. Ese resultado es la observación que reorienta todo el trabajo.

3.3.1 Modelos base tabulares y el impacto de la latencia

Modelos base. Se han seleccionado dos modelos base *tabulares*, es decir, modelos que reciben en cada instante un vector de características ya calculadas (no la secuencia ni el libro completo): una regresión logística balanceada y un *gradient boosting* ligero, también balanceado (la implementación `HistGradientBoostingClassifier` de scikit-learn, con 90 iteraciones, 15 hojas por árbol y regularización ℓ_2). Ambos se entrenan sobre un conjunto de características de las mismas familias que las de la Sección 3.4.2 (estado del libro, referencias externas, volatilidad y contexto de ventana), en su versión previa al especialista, que todavía incluía las variables de reloj de la ventana; la variante del *gradient boosting* seleccionada en validación prescinde del *microprice*. La etiqueta es la direccional a un horizonte corto de 16 segundos.

En ambos casos se entrena por *token-frame* y se evalúa por *market-frame*, para no contar dos veces el mismo instante del mercado, con la validación temporal por bloques de la Sección 3.4.3.

Métrica de clasificación y primera comparación. La Tabla 3.2 compara los dos modelos en el bloque de test del experimento de referencia (el último tramo temporal del corpus, reservado), a latencia nula y con la regla de decisión seleccionada en validación. El *gradient boosting* es el mejor de los dos en las tres métricas y la regresión logística el peor: con una precisión equilibrada similar (0,577 frente a 0,571), el primero acierta la subida en el 75,9 % de las operaciones que selecciona, frente al 55,2 % de la segunda, y triplica su neto visible medio. Por eso el resto de la sección usa el *gradient boosting*. En un escenario conservador (filtro de horquilla, margen de medio tick y umbral de decisión alto, el de la Tabla 3.3) su precisión direccional se acerca al 90 % y supera la validación temporal por bloques.

Tabla 3.2: Los dos modelos base en el bloque de test (horizonte de 16 segundos, latencia nula, una acción por *market-frame*). Acierto UP: porcentaje de acciones cuyo precio medio subió al menos un tick a los 16 segundos. Neto visible medio: *markout* a 16 segundos menos el coste visible de entrada, promediado por acción, en ticks.

Modelo	Precisión equilibrada	Acciones (núm.)	Acierto UP (%)	Neto visible medio (ticks)
Regresión logística balanceada	0,571	1.336	55,2	+1,14
<i>Gradient boosting</i> ligero	0,577	1.371	75,9	+3,51

Evaluación económica de los modelos base. Evaluado solo por su acierto direccional en las operaciones que selecciona, el mejor modelo base parece excelente. Por los

motivos metodológicos que se exponen a continuación, esa métrica no basta, y se añade una evaluación del beneficio obtenido bajo condiciones de ejecución realistas. Para ello se define una *política*: entrar solo cuando la diferencia entre la probabilidad de subida y la de bajada que estima el modelo alcanza o supera 0,65, con una acción por *market-frame* y en un escenario conservador (horquilla de entrada de un tick como máximo, margen adicional de medio tick, 16 segundos de espera entre acciones del mismo mercado y límites de 50 acciones por día y 3 por sesión). Esa política se evalúa en el **test terminal**, que es el último bloque temporal del corpus, reservado y no utilizado para seleccionar ni la política ni sus umbrales. Sobre él se aplica una prueba de estrés de latencia: la fila de entrada se desplaza 0, 2, 4 u 8 segundos después del instante de la señal y el resultado se mide desde ahí. La Tabla 3.3 y la Figura 3.9 recogen el resultado.

Tabla 3.3: Rendimiento de la política del mejor modelo base (el *gradient boosting*) en el test terminal bajo distintas latencias de entrada. Latencia: retraso entre el instante de la señal y la fila de entrada (0 s es la señal instantánea; 2 s es el primer escalón que la malla de captura puede representar, como se precisa en el apartado siguiente). Acierto UP: porcentaje de acciones cuyo precio medio subió al menos un tick a los 16 segundos de la entrada. Neto medio: *markout* a 16 segundos menos el coste visible de entrada y el margen de medio tick, promediado por acción, en ticks; Neto total: suma de ese neto sobre todas las acciones. Ambos pueden ser negativos. Ninguna cifra incluye la comisión oficial de 206 (Sección 3.4.5).

Latencia (s)	Acciones (núm.)	Acierto UP (%)	Neto medio (ticks)	Neto total (ticks)
0	64	92,2	+6,79	+434,44
2	63	39,7	-1,48	-93,48
4	66	45,5	-0,74	-48,83
8	66	43,9	-0,30	-19,53




Figura 3.9: Neto medio en el test terminal frente a la latencia de entrada. La señal a latencia nula es real como *markout* desde el instante de la señal, pero no sobrevive como política ejecutable con dos segundos de latencia.

La Tabla 3.3 muestra el rendimiento de la política en función de la latencia de entrada. Cuando la latencia es nula, la política funciona de manera extraordinaria, con +6,79 ticks

netos de media y un 92 % de acierto en las operaciones de subida, porque mide el *markout* desde el instante exacto de la señal. Con una latencia de 2 segundos, el primer escalón que el instrumento puede resolver, el acierto cae al 39,7 % y el neto medio pasa a $-1,48$ ticks: la oportunidad ya se ha consumido cuando la orden podría ejecutarse. Con 4 y 8 segundos el neto mejora ligeramente (hacia $-0,74$ y $-0,30$), y no porque operar más tarde sea mejor, sino porque a esas latencias el modelo ya ni siquiera detecta la señal efímera que lo hacía perder, de modo que sus decisiones se vuelven casi aleatorias y el daño se diluye.

Reflexión. El mejor resultado (latencia nula) y el peor (dos segundos) delimitan la lectura: toda la ventaja vivía en una ventana de pocos segundos, y la métrica de clasificación, por sí sola, no la habría detectado. La sección siguiente precisa qué significa exactamente ese escalón de dos segundos.

Qué es exactamente el escalón de dos segundos

Conviene precisar el significado de la columna de latencia de la Tabla 3.3, porque de ello depende el alcance de la conclusión y porque la cifra se presta a una lectura más fuerte de la que los datos sostienen. **Los dos segundos no son la latencia medida del sistema, sino la resolución de la rejilla de captura**, y ambas cosas difieren en casi un orden de magnitud.

La cadena de ejecución se instrumentó extremo a extremo y se midió contra el mercado real, incluyendo una orden efectivamente casada. El tiempo desde que el dato se observa hasta que el CLOB reconoce y casa la orden resultó ser de **429,7 ms** en percentil 95, con un *fill* real medido en **426,7 ms**; la firma en caliente cuesta unos 7 ms y el envío hasta el acuse, 144 ms. La conclusión operativa que se registró entonces fue fijar $L = 1$ s como contrato de modelado y reservar $L = 2$ s como escenario de estrés, dejando constancia expresa de que la latencia real no debía asumirse en dos segundos.

Lo que impide usar esa cifra es el propio muestreo: la captura se realiza en una malla de dos segundos, de modo que un escalón de un segundo no tiene ninguna fila que lo soporte. El valor que aparece en la tabla es, por tanto, el mínimo que el instrumento puede representar, y sobreestima la latencia real por un factor cercano a cinco. Entre cero y dos segundos (justamente el rango donde vive la latencia efectivamente medida) **no existe ninguna observación**, y la forma que la señal tenga ahí no puede deducirse de estos datos.

A ello se añade que el bloque terminal sobre el que se mide es pequeño: con 63 acciones, el error estándar del acierto ronda los 6,3 puntos porcentuales, de modo que el 39,7 % del escalón de dos segundos no es estadísticamente distinguible del azar. La cifra sólida de la tabla es la de latencia nula.

La afirmación defendible es entonces más matizada, y también más útil: la ventaja medida como *markout* instantáneo es real y grande, pero **no se ha demostrado que sobreviva a la latencia de ejecución, ni se ha demostrado que no lo haga**, porque el experimento carece de resolución en el intervalo relevante. Lo que el escenario de estrés sí establece es una cota: si la ventaja se agota antes de dos segundos, la política no es ejecutable. Zanzar la cuestión exigiría capturar el libro a una frecuencia sensiblemente mayor, lo que se recoge como línea futura en el Capítulo 8.

Existe, no obstante, una vía independiente para acotar el problema, y conviene recogerla porque apunta en la misma dirección sin depender del escalón de latencia. Si el mercado de predicción tardase varios segundos en incorporar los movimientos del subyacente, una latencia de ejecución inferior al segundo sería irrelevante y quedaría margen explotable. Puede comprobarse midiendo la correlación cruzada entre el retorno del futuro perpetuo de Bitcoin y la variación posterior del precio medio del contrato, a distintos desfases. Aplicada sobre los 841 mercados independientes de la ventana prospectiva y quince desfases entre -8 y $+20$ segundos, ninguna correlación supera 0,004 en valor absoluto y prácticamente todos los intervalos de confianza contienen el cero. Un único desfase resulta marginalmente significativo, a los catorce segundos, pero no se interpreta como hallazgo: con quince contrastes cabía esperar por azar en torno a un falso positivo, su magnitud es económicamente nula y no existe mecanismo que justifique un retardo de esa duración.

La lectura es que el contrato incorpora la información del subyacente dentro del mismo intervalo de dos segundos, de modo que **no se observa ninguna ventana explotable por encima de la resolución del instrumento**. Ello refuerza la conclusión por un camino que no depende de la latencia asumida: no es solo que la ventaja propia se agote deprisa, es que el mercado digiere la información externa más rápido de lo que este montaje permite observar.

Este es, con esa matización, el resultado que vertebra el trabajo: **acertar la dirección no equivale a obtener beneficio**. El problema deja de ser de clasificación y pasa a ser de ejecución; a partir de aquí, todo modelo se evalúa por su política económica bajo coste y latencia, no por su acierto. Los modelos base ya se han evaluado con ese criterio (su neto visible en la Tabla 3.2 y, para el mejor de ellos, la prueba de estrés de latencia de la Tabla 3.3), y sus cifras netas no incluyen todavía la comisión oficial de 2026, que las haría aún más negativas. Conviene subrayar, además, que esta conclusión no depende en exclusiva del argumento de latencia: la corrección del modelo de costes de la Sección 3.4.5 la sostiene por una vía independiente, al mostrar que con la tarifa oficial la comisión de entrada agota por sí sola el resultado bruto.

3.4 Metodología y entrenamiento

Esta sección detalla cómo se define el objetivo de aprendizaje, cómo se valida sin incurrir en fugas temporales, cómo se modelan los costes y la latencia, qué métricas deciden y qué progresión de modelos se evaluó hasta llegar al candidato final. El hilo conductor es que cada decisión metodológica está orientada a un objetivo: evitar resultados ilusorios y medir el rendimiento económico real.

La Figura 3.10 sirve de índice general del proceso: encadena las etapas que las secciones siguientes desarrollan, de la captura al corte prospectivo.

Preprocesado. Antes de cualquier modelo, el corpus pasa por cuatro transformaciones, ya introducidas en las secciones anteriores y resumidas aquí en un solo lugar: (i) filtrado de calidad por sesión según los controles de la Sección 3.1.4; (ii) imputación por arrastre del último valor observado, sin interpolación, con cada valor arrastrado marcado como obsoleto para que los filtros puedan excluirlo; (iii) exclusión de las columnas agregadas de ventana que incorporarían información futura; y (iv) sin normalización para los modelos de árboles (invariantes a transformaciones monótonas) y con estandarización robusta por




Figura 3.10: Las ocho etapas del proceso, en orden. Los recuadros de trazo grueso marcan los dos puntos de no retorno: la congelación del especialista antes del bloque fuera de muestra y el sellado criptográfico del pre-registro antes de la ventana prospectiva.

característica en los modelos profundos.

Funciones de pérdida. Cada familia entrena contra la pérdida estándar de su tarea: entropía cruzada binaria con *logits* para las cabezas de clasificación (salud, signo, riesgo terminal), error absoluto o cuadrático para las cabezas de regresión de valor esperado, y QLIKE para la predicción de volatilidad (Sección 3.4.6). Son, deliberadamente, pérdidas estadísticas; la única excepción, motivada al final del capítulo, es la política de parada de la Sección 3.4.12, que entrena directamente contra el objetivo económico.

Hardware y tiempos. Todo el trabajo corre en una estación de consumo: los modelos de árboles y los análisis, en CPU; los modelos profundos, en una única GPU (Radeon RX 6800 XT, 16 GB) mediante ROCm. Como referencia de coste, el *linear probe* de MOMENT sobre 40.758 ventanas tarda unos 16 segundos por época en la GPU (la primera sube a 38 por el calentamiento) frente a unos 700 en CPU, es decir un factor cercano a cuarenta; el ajuste completo de todas las capas ronda los 58 segundos por época. Ningún experimento del trabajo exige más de unas horas de cómputo, lo que acota también su coste de reproducción (Capítulo 7).

3.4.1 Definición del objetivo

Para cada instante t se define el retorno futuro del precio medio a un horizonte H ,

$$\Delta_H(t) = \frac{m_{t+H} - m_t}{m_t}, \quad (3.1)$$

donde m_t es el precio medio del contrato. La etiqueta direccional se obtiene con un umbral $\theta \ll 1$ (en unidades de retorno relativo) que absorbe el *spread*, las comisiones y el ruido. Su valor depende del experimento: en la etiqueta de referencia del corpus θ vale 5 puntos básicos (0,0005), unos 0,025 ticks en la mediana de los precios, y su variante económica, que le suma la media horquilla y un margen de 2 puntos básicos, ronda el medio tick; en los experimentos a horizonte H60 los umbrales equivalen a uno o dos ticks (Sección 3.1.6):

$$y_t = \begin{cases} \text{UP} & \text{si } \Delta_H(t) > \theta, \\ \text{DOWN} & \text{si } \Delta_H(t) < -\theta, \\ \text{FLAT} & \text{en otro caso.} \end{cases} \quad (3.2)$$

Esta etiqueta ternaria es útil para mirar el arco experimental en su conjunto; el especialista final, en cambio, usa los dos objetivos económicos que se definen más abajo. Las características son causales (solo usan información hasta t) y las etiquetas se calculan *a posteriori* de forma trazable, de modo que no entra información del futuro por las entradas del modelo. Todos los resultados económicos se expresan en ticks netos, que es la unidad natural del libro; no se traducen a dinero porque ello exigiría suponer un tamaño de posición y favorecería la sobreafirmación.

Los dos objetivos del especialista. El modelo final no usa la etiqueta ternaria, sino dos objetivos complementarios, porque un modelo que debe decidir si entra necesita saber algo más fino que la dirección: cuánto vale la operación y si el entorno de ejecución es favorable (véase la Figura 3.11).




Figura 3.11: Modelo de dos cabezas. Un regresor predice el valor esperado de la operación y un clasificador predice si el relleno será “sano”. La política exige ambas condiciones.

El **regresor** predice `exec_net_cost_0p25_H60`: el neto ejecutado a 60 segundos tras descontar una fracción (0,25) del coste visible de entrada de cada operación. El **clasificador** predice `healthy_fill_proxy_0p25_H60`: una variable binaria que vale 1 cuando ese neto es positivo *y* la operación no cae en el peor cuartil de un grupo de operaciones comparables (mismo bloque temporal, fase, nivel de *spread*, microprice y momento del perp). La independencia entre ambas cabezas es deliberada: una operación puede tener alto valor esperado pero baja probabilidad de relleno sano si el libro está degradado.

3.4.2 Ingeniería de características

El especialista recibe un vector de 36 características, todas calculadas exclusivamente con información disponible hasta el instante t . Se agrupan en cuatro bloques con una justificación clara para cada uno:

Estado del libro Resúmenes del libro de órdenes de Polymarket: precio medio, *spread*, *microprice* (precio ponderado por volumen, que anticipa la presión de compra-venta), desbalance entre niveles, coste visible de entrada y cambios recientes del precio. Describen el estado local del mercado.

Referencias externas Retornos orientados del mercado al contado y de los futuros perpetuos a 2 y 8 segundos, junto con medidas de consenso y de actualización. Capturan el acoplamiento con Bitcoin, que el análisis exploratorio mostró relevante a escala de segundos.

Volatilidad La volatilidad realizada del perpetuo a 5 segundos, empleada posteriormente en el diagnóstico de cambio de régimen.

Contexto de ventana Posición dentro de la ventana *prestart* y *proxies* de calidad del libro (cobertura e indicadores de degradación), que informan de la ejecutabilidad.

Una decisión deliberada es excluir las variables de reloj (hora, minuto, segundo): el conjunto se denomina por ello *no_clock*. El motivo es evitar que el modelo aprenda atajos temporales triviales (por ejemplo, asociar la señal a un instante concreto del día) que no generalizarían y que, en la práctica, son una forma sutil de sobreajuste. El inventario completo se recoge en el Anexo 8.6.

3.4.3 Validación temporal y prevención de fuga

Una partición aleatoria por filas, habitual en problemas sin estructura temporal, sería aquí un error grave: las observaciones contiguas están autocorrelacionadas y un mismo mercado puede aparecer a ambos lados del corte, de modo que el modelo acabaría “viendo el futuro”. Por ello la partición respeta siempre el orden del tiempo: el entrenamiento utiliza las sesiones más antiguas, la validación las posteriores y el test terminal el bloque final, que permanece sellado hasta el final del proceso.

En los experimentos secuenciales se refuerza esta disciplina con un protocolo fuera de pliegue (*out-of-fold*) de tipo *walk-forward* expansivo: el conjunto de entrenamiento crece hacia delante en el tiempo y, en cada pliegue, las predicciones que consume una segunda etapa proceden siempre de un modelo que no las entrenó. A ello se añaden dos protecciones en las fronteras entre bloques. La *purga* retira del entrenamiento las observaciones cuyo horizonte de etiqueta se solapa con el bloque que se está evaluando, ya que de lo contrario una etiqueta calculada con datos del bloque evaluado contaminaría el ajuste. El *embargo* descarta además un pequeño margen temporal alrededor de cada frontera, para que el solape de las secuencias históricas tampoco introduzca fuga. La política de decisión se selecciona únicamente sobre la validación, sin observar en ningún momento el test terminal. Esta disciplina contra la fuga temporal es la principal salvaguarda frente a los resultados ilusorios que la literatura describe de forma reiterada [12, 11].

3.4.4 Modelo de costes y latencia

La latencia no se supone, se mide. En una prueba controlada del ciclo de orden de Polymarket, el tiempo entre observar la oportunidad y confirmar el emparejamiento fue de unos 0,43 segundos en el percentil 95 de la muestra válida. Aun así, por prudencia se trabaja con cifras peores: una latencia conceptual de un segundo y una latencia observable en los datos de dos segundos (la malla de captura). Conviene precisar *dónde* reside esa latencia, porque determina qué mejoras son posibles. El cómputo local (desde observar el dato hasta emitir la decisión: cálculo de características e inferencia del modelo) se midió en torno a 25 milisegundos en el percentil 95, una fracción despreciable del ciclo. El grueso lo consumen etapas que no dependen del lenguaje de implementación: la construcción y la firma criptográfica de la orden, su envío por la red hasta el emparejador de Polymarket y la confirmación del emparejamiento. La latencia que anula la señal es, por tanto, un límite de red y de microestructura, no de software: reescribir el cálculo en un lenguaje más rápido reduciría esos 25 milisegundos a unos pocos, pero dejaría intacto el resto del ciclo (de cientos de milisegundos a segundos) sin rescatar la rentabilidad del lado *taker*. Esta observación es, además, una de las razones estructurales del giro al lado *maker* (Ca-

pítulo 5): el creador de mercado pasivo no compite en esta carrera de latencia. El coste de ejecución no se fija como un número plano de ticks, sino como una fracción del coste visible de entrada de cada operación: la mitad de ese coste como referencia, un cuarto como contraste optimista y el coste completo como prueba de estrés. Modelar el coste relativo al libro de cada instante es más fiel que asumir un coste fijo e igual para todas las operaciones. Formalmente, el neto ejecutado a horizonte H con un factor de coste $c \in \{0, 0,25, 0,5, 1\}$ es

$$\text{net}_c(t) = \left(\Delta_H^{\text{ticks}}(t) - b \right) - c \cdot \kappa_t, \quad (3.3)$$

donde $\Delta_H^{\text{ticks}}(t)$ es el *markout* en ticks desde la entrada (a dos segundos del instante de señal) hasta el horizonte, b es un *buffer* fijo y κ_t es el coste visible de entrada de esa operación. Nótese que, por construcción, un factor de coste mayor produce un neto menor sobre la misma operación; por eso el resultado al coste de referencia ($c = 0,5$) es siempre inferior al optimista ($c = 0,25$) y superior al de estrés ($c = 1$).

3.4.5 Corrección del modelo de costes: el régimen de comisiones de 2026

Durante la fase final del trabajo se detectó un error en el modelo de costes que merece documentarse como corrección metodológica explícita, porque su arreglo cambia positivamente las conclusiones económicas.

Desde 2026 Polymarket aplica a los mercados de criptomonedas una comisión sobre el lado *taker* de la operación, definida en su documentación oficial [3] como

$$\text{comisión}(C, p) = C \cdot r \cdot p(1 - p), \quad (3.4)$$

donde C es el número de contratos, p el precio de ejecución y $r = 0,07$ la tasa vigente para crypto. La forma $p(1 - p)$ hace que la comisión sea máxima en torno a $p = 0,5$ (justo la zona de precios donde opera la mayor parte de este trabajo) y decrezca hacia los extremos.

La versión implementada originalmente en el código calculaba $p \cdot r \cdot (p(1 - p))^2$: elevaba al cuadrado el término $p(1 - p)$ y arrastraba además un factor p adicional, lo que en torno al precio medio subestima el coste real en un factor de aproximadamente ocho. Como se muestra en la Figura 3.12, en $p = 0,5$ la comisión oficial es de 1,75 ticks por contrato frente a los $\sim 0,22$ ticks de la función de costes anterior.

Detectado el error, se corrigió la fórmula en todos los repositorios afectados y se re-evaluó la política congelada del especialista (sin reentrenamiento de los modelos) sobre la misma ventana fuera de muestra. Primero se reprodujeron, como control de integridad, las cifras reportadas inicialmente en el repositorio con la función de costes anterior ($n=754$, $+0,349$ ticks netos; corte de baja volatilidad $n=318$, $+1,069$), y después se aplicó la comisión oficial. El resultado se resume en la Tabla 3.4: con el régimen de comisiones de 2026, ningún corte *taker* es positivo, ni siquiera en la cota optimista que solo carga la comisión de entrada. Las comisiones medias medidas sobre el corpus (1,75 ticks la entrada, 1,71 la salida) superan por sí solas el edge bruto de la señal.

La lección es estructural, no incidental: el lado *taker* de este mercado no es económico para una señal de la magnitud encontrada, y ninguna mejora razonable del modelo lo compensa. La misma estructura de comisiones señala la salida: el programa de reembolsos al creador




Figura 3.12: Corrección de la función de costes para su adaptación al modelo oficial de costes de 2026. Izquierda: comisión oficial de 2026 ($rp(1-p)$, $r = 0,07$) frente a la función de costes anterior, en ticks por contrato; en $p = 0,5$ la diferencia es de un factor ocho (1,75 frente a $\sim 0,22$). Derecha: distribución del precio de entrada del corpus operable de la ventana fuera de muestra ($n=6.010$ operaciones candidatas) superpuesta a la curva oficial: las operaciones se concentran precisamente donde la comisión es máxima, con un coste de entrada medio de 1,75 ticks por contrato.

Tabla 3.4: Re-evaluación de la política congelada con la comisión oficial de 2026. Ticks netos medios por operación; “solo entrada” es la cota optimista que omite la comisión de salida.

Corte	Función de costes	Función de costes oficial 2026	
	anterior	solo entrada	ida y vuelta
Todos ($n=754$)	+0,349	-1,059	-3,304
Baja volatilidad ($n=318$)	+1,069	-0,342	-2,604

de mercado (*maker rebates*) reparte el 20 % del fondo de comisiones de cada mercado entre quienes aportan liquidez, con el mismo peso $p(1 - p)$. La consecuencia para el diseño del trabajo es el giro al lado maker que articula el Capítulo 5: la señal predictiva conserva su valor, pero el vehículo económico viable es cobrar el *spread* y el reembolso, no pagarlos. Esta corrección quedó registrada en el repositorio público, con su propio sello de tiempo, antes de la evaluación prospectiva (Capítulo 7).

3.4.6 Métricas de evaluación

La elección de métricas es deliberada y responde a las características del problema. Para la fase de clasificación no se reporta la precisión bruta (*accuracy*), porque el dominio de la clase FLAT la vuelve engañosa; en su lugar se usan la **precisión equilibrada** (*balanced accuracy*) y la **F1 macro**, que promedian por clase y no premian al modelo que siempre predice quietud. Para medir la capacidad de *ordenar* las oportunidades se emplea el **AUC** (área bajo la curva ROC), independiente del umbral.

Ahora bien, la métrica que decide es económica, no de clasificación: el **neto medio por operación** bajo el modelo de costes de la ecuación (3.3). A su alrededor se reportan siempre cuatro elementos de soporte e incertidumbre: (i) el **número de operaciones y de días**, porque un neto sin soporte no es interpretable; (ii) un **intervalo de confianza bootstrap** (5 000 remuestreos, semilla fija); (iii) la **probabilidad de neto positivo** estimada sobre esa misma distribución; y (iv) el **drawdown máximo** y el número de **días positivos**, como medidas de estabilidad. Esta batería evita confundir una señal estadística con una estrategia viable.

3.4.7 La escalera de modelos

Los modelos se evalúan en una progresión incremental, de menor a mayor complejidad, exigiendo en cada salto que la complejidad añadida se justifique con evidencia de mejora bajo el mismo protocolo de costes y validación (véase la Figura 3.13).




Figura 3.13: La escalera de modelos. Cada paso debe superar al anterior bajo el mismo protocolo; si no lo hace, se descarta.

Modelos sensibles a la latencia. El primer salto sobre el baseline consiste en incorporar la latencia ya en el etiquetado y en la selección, de modo que el modelo aprenda a elegir operaciones que sigan siendo rentables *tras* el retardo de entrada. Uno de estos modelos alcanza un AUC de test de 0,79 (una capacidad de clasificación notable) y, sin

embargo, su política económica sigue siendo negativa. La conclusión refuerza la lección central: más capacidad de clasificación no implica una política rentable.

Modelos secuenciales y sobre el libro de órdenes. El siguiente nivel trata el libro como un objeto con estructura espacio-temporal. Se construyen secuencias de ocho fotografías consecutivas y un tensor de los diez primeros niveles del libro, y sobre esa representación se evalúan cinco arquitecturas:

- una red recurrente **GRU** [45] (capa oculta de dimensión 56) sobre la secuencia de características, que modela la dinámica temporal reciente. La GRU es la variante recurrente con dos puertas (actualización y reinicio) que deciden cuánto del estado anterior se conserva en cada paso, lo que mitiga el desvanecimiento del gradiente de las recurrentes simples; se prefiere aquí a la LSTM porque logra una capacidad comparable con menos parámetros, algo relevante con los pocos miles de casos etiquetados disponibles;
- un codificador convolucional del libro, el **BookEncoder**, inspirado en DeepLOB [5, 7], que resume cada fotografía con dos convoluciones unidimensionales sobre la dimensión de niveles y un *pooling* dual,

$$\mathbf{h} = \left[\text{mean}_{\tau} \phi(\mathbf{B}_{\tau}) \parallel \text{max}_{\tau} \phi(\mathbf{B}_{\tau}) \right], \quad \phi = \text{ReLU} \circ \text{Conv1d} \circ \text{Dropout} \circ \text{ReLU} \circ \text{Conv1d}, \quad (3.5)$$

donde $\mathbf{B}_{\tau}$ es el libro en el paso τ y $\parallel$ denota concatenación; el *pooling* máximo capta los picos de profundidad, a menudo más informativos que la media en mercados poco líquidos;

- una **fusión** que combina la salida de la GRU y la del BookEncoder en una cabeza común, para aprovechar simultáneamente la dinámica temporal y la estructura del libro;
- una red convolucional temporal (**TCN**) [46] orientada a clasificar el régimen de volatilidad de la sesión. Una TCN sustituye la recurrencia por convoluciones *causales* (cada salida solo ve el pasado) con dilatación creciente: al duplicar el salto entre entradas consecutivas en cada capa, el campo receptivo crece de forma exponencial con la profundidad, lo que permite cubrir sesiones largas con pocos parámetros y entrenar en paralelo, sin la dependencia secuencial de una recurrente;
- un codificador con **auto-atención** [49] sobre esa misma representación, en dos variantes (atención sobre la última fotografía del libro y sobre la secuencia completa), incorporado para comprobar si el mecanismo que domina la literatura reciente de modelos de secuencia cambia el diagnóstico. En la auto-atención cada posición de la entrada emite una consulta que se compara con las claves de todas las demás, y su representación de salida es la media de los valores ponderada por esa afinidad; el mecanismo aprende así qué partes del libro o de la secuencia son relevantes entre sí sin imponer una estructura de vecindad fija, a costa de muchos más parámetros (el motivo, como se verá, de su sobreajuste aquí).

Todas estas arquitecturas aprenden representación (obtienen métricas de clasificación y de ordenación razonables, y algunas políticas *proxy* resultan positivas dentro de muestra), pero ninguna produce una política rentable y estable cuando se exige selección causal día a día y estabilidad en todo el bloque de test. La Tabla 3.5 recoge el triaje completo sobre el mismo tensor y el mismo protocolo, con las siete variantes entrenadas.

La tabla dice dos cosas que una cifra suelta no diría. La primera es que **el AUC de**

Tabla 3.5: Triage diagnóstico de las arquitecturas sobre el libro. Todas comparten tensor, protocolo y partición. ρ es la correlación de Spearman sobre el bloque terminal. Las dos últimas columnas corresponden a la política seleccionada en validación de cada experimento, evaluada sobre los tres días del bloque terminal. **Es triaje exploratorio, no evidencia confirmatoria:** véase el apartado “Límites del triaje original” más abajo.

Variante	Par.	AUC val	AUC test	ρ test	Neto test	Días < 0
Atención, última foto	22.106	0,569	0,514	+0,020	-1,99	3/3
Atención, secuencia	53.890	0,567	0,531	+0,065	—	—
BookEncoder Conv1d	9.986	0,560	0,528	+0,024	-1,08	2/3
BookEncoder + GRU	29.946	0,561	0,543	+0,048	—	—
Fusión, concatenación	42.874	0,568	0,552	+0,133	+0,54	0/3
Fusión, dual	34.190	0,562	0,552	+0,127	—	—
Control tabular	18.186	0,568	0,553	+0,134	+0,59	1/3

validación no separa a estas arquitecturas (las siete caen entre 0,560 y 0,569) mientras que el bloque terminal sí las ordena. La ordenación *fin*a dentro de las variantes que solo ven el libro no debe leerse de esta tabla: la ampliación con cinco semillas que sigue muestra que se invierte.

La segunda es la que decide la elección del candidato final. **El control tabular, con 18.186 parámetros, iguala o supera a todas las variantes que incorporan el libro**, incluida la fusión de 42.874. La diferencia no está en el AUC, donde el margen es estrecho, sino en la correlación de rangos sobre el bloque terminal: +0,134 del control frente a +0,020 y +0,065 de las dos variantes de atención, entre dos y seis veces más. Añadir el libro de órdenes como representación profunda no aporta ordenación por encima de la que ya extraen las características tabulares. Ese es el motivo medido, y no una preferencia por la simplicidad, de que el candidato de la Sección 3.4.8 sea un modelo tabular.

Límites del triaje original. La tabla anterior es **exploratoria y así debe leerse**, por cuatro razones que conviene declarar antes de que se conviertan en una objeción. Primera: el bloque terminal de este triaje tiene **tres días**, y las políticas evaluadas seleccionan entre 50 y 321 acciones, de modo que la diferencia entre “tres días negativos” y “dos” es de un solo día y no soporta ninguna lectura fina. Segunda: esa partición se ha reutilizado entre experimentos de esta fase, así que no es evidencia fresca en el sentido en que sí lo son los cortes pre-registrados del Capítulo 4. Tercera: cada variante se entrenó con **una sola semilla** y una única configuración de hiperparámetros, sin búsqueda, y la LSTM, la arquitectura recurrente de referencia, no estaba en la comparación. Cuarta: el contexto es de ocho fotogramas, dieciséis segundos, que para un mecanismo de atención o una convolución dilatada es un régimen muy corto. Los dos primeros límites son del diseño y se aceptan; el tercero (semilla única y ausencia de la LSTM) se cerró con la ampliación que se describe a continuación; el cuarto (el contexto corto) queda abierto aquí y lo mide por su cuenta la Adenda C del Capítulo 4.

Control de reproducción: el triaje no reproduce entre plataformas. El punto de partida de la ampliación, y su motivo principal, fue un control previo: antes de añadir

nada se re-ejecutó el experimento de auto-atención con su *semilla original* en el entorno actual. No reproduce: con idénticos datos, código, semilla e hiperparámetros, y cambiando solo la plataforma de cómputo, la correlación de rangos de la variante principal pasa de 0,020 a 0,058 y su AUC de test de 0,514 a 0,522. **El ruido de plataforma es, por tanto, del mismo orden que las diferencias que separan a estas arquitecturas entre sí**, lo que obliga a leer la Tabla 3.5 como una foto de su entorno y no como una medición transportable. Ese resultado fija el diseño de la ampliación: cada variante se entrena con **cinco semillas**, íntegramente en un solo entorno, y se interpreta solo dentro de él, con la comparación pareada por semilla como instrumento. El protocolo (etapas, métricas de cabecera y, sobre todo, *qué se escribiría en la memoria para cada resultado posible*) se selló con OpenTimestamps **antes** de ejecutar nada, con la cláusula expresa de que el candidato congelado no se cambiaría ganase lo que ganase cualquier modelo nuevo.

Ampliación: semillas, LSTM y *forecasting* moderno. Se añaden tres arquitecturas: la **LSTM**, que sustituye la celda recurrente del control tabular y cierra el hueco declarado; **DLinear**, que descompone la serie en tendencia y residuo y proyecta cada componente con una capa lineal [47]; y **PatchTST-lite**, parches temporales con atención e independencia de canal [48]. Las dos últimas son adaptaciones pequeñas al tensor y al volumen disponibles, no reproducciones fieles de sus artículos. La Tabla 5 del Anexo 8.6 recoge las diez variantes con su dispersión entre semillas; aquí se resume lo que decide.

Lo que confirma. La separación entre las dos familias es **total**: la peor de las treinta corridas que incorporan características tabulares ($\rho = 0,119$) queda por encima de la mejor de las veinte que solo ven el libro ($\rho = 0,066$). En comparación pareada por semilla, las cuatro variantes del libro pierden contra el control tabular en las **cinco de cinco** semillas, con diferencias de $-0,082$ a $-0,106$ frente a errores estándar de $0,004$ a $0,007$. La conclusión que sostenía el triaje original (que añadir el libro como representación profunda no aporta ordenación sobre las características tabulares) queda confirmada con un margen que la varianza de inicialización no explica.

Lo que corrige. La ordenación *dentro* de la familia del libro se invierte. El triaje original leía la auto-atención como el caso más nítido de sobreajuste por capacidad; con cinco semillas, la atención queda **por encima** de la convolución en las cinco ($+0,024$ de diferencia media). Esa lectura se retira. Lo que sí sobrevive, y en el eje correcto, es el patrón de fondo: la columna “Caída” ordena a las arquitecturas casi exactamente como la tesis predice (las dos de atención pierden $0,050$ de AUC al pasar de validación a test, **cinco veces más que el control tabular**, que pierde $0,010$). La capacidad compra ordenación dentro de muestra y la paga fuera de ella; simplemente, la comparación que lo demuestra no era la que el triaje original eligió.

Lo que añade. Las tres arquitecturas nuevas resultan **indistinguibles** del control tabular en comparación pareada: LSTM $+0,0001$, PatchTST-lite $+0,0000$ y DLinear $+0,0033$, todas por debajo de dos errores estándar. De ahí se siguen tres cosas. La elección de la GRU frente a la LSTM, que hasta aquí se justificaba solo a priori, era **indiferente**, y ahora está medida. La familia moderna de *forecasting* tampoco aporta en este régimen. Y el resultado más informativo de toda la ampliación no es que algo gane, sino **con cuánto se iguala**: DLinear alcanza el rendimiento del control con **1.364 parámetros frente a 18.186**, trece veces menos, y con el segundo AUC de validación más alto de la tabla.

Que un modelo esencialmente lineal empate con todo lo demás es la forma más fuerte del hallazgo de este capítulo: en este problema, y a este volumen de datos, **la capacidad no es el factor limitante**. Coincide con lo que Zeng *et al.* [47] documentan para predicción de series temporales, y refuerza, por una vía distinta a las del Capítulo 4, la conclusión económica del trabajo: si la capacidad no limita, un modelo mejor no habría cambiado el resultado, porque lo que decide es el coste de ejecución y no la calidad de la predicción.

Lo que este trabajo sostiene. La afirmación que se defiende no es que el aprendizaje profundo no sirva en este problema, sino la más estrecha y la única que la evidencia respalda: **en este régimen de datos, con este contexto y este presupuesto de cómputo, ninguna de las familias evaluadas, ni en el triaje original ni en su ampliación, se separó del ruido ni superó al control tabular**. La distinción importa porque la conclusión económica del trabajo no depende de ella: como se verá, la política muere por la estructura de costes y por la latencia, no por falta de capacidad predictiva, de modo que un modelo mejor elevaría el AUC pero no el resultado. Por eso el aprendizaje profundo se aparca a la espera de un volumen de datos sustancialmente mayor, y la Adenda C del Capítulo 4 mide por su cuenta cuánto haría falta.

Ninguna de estas corridas modifica el candidato congelado, que estaba sellado antes de que existieran, ni ninguna cifra del Capítulo 4. La cláusula estaba escrita en el protocolo antes de conocer los resultados.

Durante la auditoría se detectó y corrigió un error de interpretación en el *score* de selección adversa (su orientación correcta es $1 - P(\text{adverso})$), lo que ilustra que una métrica positiva no basta sin auditar su significado económico. Por último, al comparar horizontes (Tabla 3.6), solo H60 conserva señal; H120 y H240 colapsan, por lo que H60 queda como único candidato.

Tabla 3.6: Selección de horizonte (ticks netos *proxy*). Solo H60 conserva señal.

Métrica	H60	H120
AUC test	0,565	0,495
Top 35 % test, coste 0,5	+0,426	−1,117
Top 35 % test, coste 1,0	+0,058	−1,491

3.4.8 Especialista *prestart* H60

El candidato final es un especialista para la ventana *prestart*: un modelo de *gradient boosting* sobre histogramas (HistGradientBoosting) con las dos cabezas descritas, entrenado sobre 36 características sin variables de reloj (para evitar atajos temporales triviales). La señal se restringe a la ventana de -60 a -45 segundos respecto a la apertura, con libro saludable y coste visible acotado (véase la Figura 3.14).

Ambas cabezas comparten una configuración de regularización agresiva (tasa de aprendizaje 0,045, hasta 220 iteraciones con parada anticipada, máximo de 15 hojas por árbol, mínimo de 120 muestras por hoja y regularización L2 de 0,10), necesaria porque, aunque el bloque de entrenamiento del especialista tiene 28.095 filas, estas pertenecen a solo unas 1.400 sesiones independientes, y es ese número (no el de filas) el que gobierna la varianza efectiva. La política congelada opera cuando el valor esperado predicho supera 0,75 y la




Figura 3.14: La ventana *prestart* del especialista: solo se opera entre -60 y -45 segundos respecto a la apertura del mercado, donde el análisis exploratorio detectó una densidad atípica de actividad del libro.

probabilidad de salud no baja de 0,50; ambos umbrales se seleccionaron sobre el conjunto de validación, nunca sobre el test terminal.

3.4.9 Filtro de volatilidad

Al inspeccionar el bloque fuera de muestra se observó un cambio de régimen: la fracción de sesiones de alta volatilidad pasó de un 18-22 % en entrenamiento a alrededor del 58 % (véase la Figura 4.1 del Capítulo 4). Como diagnóstico se separaron las acciones usando el umbral 0,6657, correspondiente al percentil 80 de la volatilidad de entrenamiento. El valor numérico procede, por tanto, de datos antiguos; sin embargo, la decisión de incorporar este filtro a la política se tomó después de observar el nuevo bloque. Por esa razón, el resultado filtrado no se considera una segunda validación fuera de muestra, sino un análisis *post-hoc* que genera una hipótesis para validación prospectiva.

3.4.10 Variantes de filtro de régimen pre-registradas: estática, GARCH y clustering de regímenes

El filtro de volatilidad anterior es una hipótesis *post-hoc*, y como tal no puede validarse sobre los mismos días que la inspiraron. Para convertirla en una prueba honesta, el pre-registro compromete por adelantado *tres* variantes de filtro de régimen, cada una con sus parámetros fijados antes de mirar la ventana de evaluación, que se evalúan en paralelo sobre la misma selección de señales. Las tres atacan la misma pregunta (operar solo cuando el régimen se parece a aquel en el que el modelo fue entrenado) por vías de sofisticación creciente.

Variante estática. El filtro heredado: operar solo si la volatilidad realizada del perpetuo a 5 segundos no supera 0,6657, el percentil 80 de la volatilidad de entrenamiento. Es un umbral fijo sobre una única variable; su versión de junio se reporta como diagnóstico, nunca como confirmación.

Variante GARCH. Un modelo GARCH(1,1) con media constante sobre los retornos logarítmicos a un minuto del precio del perpetuo (en puntos básicos), ajustado *exclusivamente* con datos hasta el 31 de mayo (13.036 observaciones). El filtro de régimen opera cuando la volatilidad condicional a un paso $\hat{\sigma}_t$ no supera 4,531 puntos básicos, el percentil 80 dentro de muestra. Los parámetros quedaron congelados ($\mu = 0,0358$, $\omega = 0,391$, $\alpha_1 = 0,0908$, $\beta_1 = 0,892$) con su resumen SHA-256 en el pre-registro. Frente a la variante estática, el GARCH sustituye un umbral fijo por una estimación dinámica de la volatilidad que se actualiza sesión a sesión, pero sin reajustar nada tras el corte de mayo.

Variante de clustering de regímenes. Un modelo no supervisado (KMeans con k elegido por silueta, sobre características causales del tramo pre-apertura (volatilidad realizada, volumen, *spread*, actividad y rango) normalizadas de forma robusta) entrenado solo con datos anteriores a julio. La solución retenida es $k = 2$ (silueta 0,31): un régimen “tranquilo” (volatilidad $\approx 5,8$ bps) y otro “agitado” ($\approx 13,0$ bps, con más *spread* y volumen). A diferencia de los dos anteriores, no impone un umbral sobre una variable elegida a mano, sino que deja que los datos definan los regímenes; su artefacto se sella como adenda del pre-registro antes del primer corte prospectivo. Un hallazgo del cruce con la vía maker matiza su interpretación: el régimen agitado, que perjudica al lado taker, resulta *más* rentable para el maker (el mismo flujo que estorbaba a uno alimenta al otro), lo que lo señala como candidato a filtro de régimen de la política maker, no solo de la taker.

Niveles de coste. Sobre la selección de cada variante se reportan, declarados por adelantado, los niveles de coste de la Sección 3.4.5: la comparabilidad histórica (net@0,5), el nivel *taker* con la comisión oficial de 2026 (cuya expectativa negativa se compromete antes de mirar los datos) y el nivel *maker* simulado, cuando el simulador de colas y fills lo produzca. La combinación de tres variantes pre-comprometidas y tres niveles publicados en su totalidad es lo que impide que la elección *a posteriori* del mejor resultado infle las conclusiones.

3.4.11 Protocolo de congelación

El especialista base (modelo, conjunto de características y umbrales EV/salud) se congeló antes de observar el conjunto fuera de muestra del 6 al 10 de junio. Su evaluación sin filtro constituye, por ello, la prueba fuera de muestra genuina y previene el sobreajuste por selección múltiple [13]. El filtro de volatilidad queda fuera de esa afirmación de congelación: se definió como política candidata después del diagnóstico del bloque y solo podrá validarse con observaciones posteriores al 10 de junio.

3.4.12 Entrenar contra el dinero: política de parada con contra-factual exacto

Un censo de las funciones de pérdida empleadas a lo largo de este trabajo revela un patrón que ningún experimento aislado hacía visible: entropía cruzada binaria, error absoluto y QLIKE (todas pérdidas estadísticas). En los veintiséis programas que entrenan un modelo profundo, la decisión económica se tomó siempre *después*, aplicando un umbral sobre una probabilidad. Nunca se entrenó nada directamente contra el dinero, pese a que el planteamiento inicial del trabajo contemplaba funciones de pérdida que penalizasen la volatilidad negativa durante el entrenamiento, al estilo del ratio de Sharpe.

La última línea experimental cierra ese hueco. La regresión del tamaño de la posición se descartó primero por medición directa: con el tope de inventario de la política maker, duplicar el tamaño de orden de 50 a 100 acciones solo multiplica el volumen casado por 1,50, y la caja ni siquiera es monótona en el tamaño (22.390, 26.939 y 25.826 \$ para 50, 100 y 200 acciones), de modo que el beneficio no es una función tratable del tamaño y una política de *sizing* exigiría un simulador diferenciable. La decisión de *retirada*, en cambio, sí lo es, y de forma exacta: el parámetro de aplanado (“dejar de cotizar en los últimos k fotogramas”) se simuló para ocho valores de k , de modo que se conoce el

contrafactual completo de cada sesión: cuánto habría ganado con cada acción posible. El beneficio esperado de una política estocástica π_θ es entonces $\mathbb{E}[\text{P\&L}] = \sum_k \pi_k(\theta) e_k$, exacto y diferenciable, sin estimadores *off-policy*.

La política se implementa como parada secuencial causal: en cada punto de decisión, de más lejano a más cercano al cierre, la red observa la trayectoria disponible hasta ese instante y emite la probabilidad de retirarse. Como función de pérdida se emplea la propia puerta de riesgo del pre-registro escrita como objetivo: maximizar la media diaria menos λ veces la desviación a la baja (Sortino), agregada por día. Se comparan una variante tabular (resúmenes de la trayectoria) y una secuencial (codificador convolucional dilatado), con λ elegido en validación. El carácter de esta línea es exploratorio (los treinta y cinco días del corte ya habían sido observados por los barridos previos) y sus resultados se reportan en el Capítulo 4 con esa etiqueta.

Capítulo 4

Resultados y análisis

Este capítulo separa dos niveles de evidencia que no deben confundirse. Primero se presenta la evaluación confirmatoria del especialista base, congelado antes de observar el bloque del 6 al 10 de junio. Después se documenta el diagnóstico de volatilidad realizado sobre ese mismo bloque con el fin de formular una política futura, pero no constituye una nueva validación fuera de muestra.

4.1 Resultados obtenidos

4.1.1 Validación fuera de muestra del especialista base

El especialista congelado selecciona 754 unidades de acción en los cinco días fuera de muestra. Sin aplicar ningún filtro decidido a partir de esos datos, obtiene un neto medio de +0,349 ticks al coste de referencia. El promedio es positivo en tres de cinco días (Tabla 4.2) y pasa a ser ligeramente negativo (−0,026 ticks) cuando se carga el coste visible completo (Tabla 4.1). Esta es la estimación limpia del rendimiento fuera de muestra.

Tabla 4.1: Validación fuera de muestra del especialista base congelado. Los valores son ticks netos por unidad de acción y no incorporan el filtro de volatilidad posterior.

Métrica	Valor
Unidades de acción (n)	754
Días de soporte	5 (3/5 positivos)
Neto medio (coste 0,25, optimista)	+0,537 ticks
Neto medio (coste 0,5, referencia)	+0,349 ticks
Neto medio (coste 1,0, estrés)	−0,026 ticks


El signo positivo al coste de referencia indica que el especialista conserva una señal modesta donde los modelos anteriores habían fracasado. Sin embargo, ni la estabilidad diaria ni el escenario de coste completo permiten calificarlo como una política robusta. La lectura defendible es, por tanto, *señal parcial fuera de muestra*, no rentabilidad demostrada.

Tabla 4.2: Desglose diario del especialista base al coste de referencia.

Día	n	Neto medio @0,5
6 de junio	220	+0,666
7 de junio	97	+1,342
8 de junio	241	+0,308
9 de junio	146	−0,565
10 de junio	50	−0,105

4.1.2 Diagnóstico *post-hoc* del régimen de volatilidad

La inspección del bloque reveló que la fracción de sesiones de alta volatilidad aumentó hasta aproximadamente el 58 %, frente al 18–22 % de los periodos históricos (véase la Figura 4.1). Para estudiar ese desplazamiento se dividió la selección con el umbral 0,6657, percentil 80 de la volatilidad de entrenamiento. El umbral numérico no se ajustó al bloque nuevo, pero la decisión de usarlo como filtro sí se tomó tras observarlo; por ello, todo lo que sigue en esta subsección es diagnóstico y exploratorio.


Figura 4.1: Fracción de sesiones de alta volatilidad por periodo. El salto del bloque nuevo motiva el análisis de régimen, pero no valida por sí mismo el filtro.

La Tabla 4.3 muestra el contraste. Hay 318 acciones de baja volatilidad, 435 de alta volatilidad y una acción sin dato de volatilidad, que una regla operativa conservadora rechazaría. Las primeras son positivas y las segundas, negativas al coste de referencia.

Tabla 4.3: Diagnóstico *post-hoc* por régimen en el bloque del 6–10 de junio (ticks por unidad de acción). Las columnas @0,25, @0,5 y @1,0 son el neto al factor de coste c correspondiente de la ecuación (3.3): la fracción del coste visible de entrada que se descuenta (optimista, referencia y estrés).

Régimen	n	@0,25	@0,5	@1,0
Baja volatilidad	318	+1,258	+1,069	+0,691
Alta volatilidad	435	+0,004	−0,183	−0,558
Volatilidad ausente	1	+3,327	+3,154	+2,807
Total sin filtro	754	+0,537	+0,349	−0,026

Si se aplica retrospectivamente el filtro de baja volatilidad, el subconjunto de 318 acciones

mantiene signo positivo en los tres niveles de coste (Figura 2) y en los cinco días (Figura 3), ambas en el Anexo 8.6. Su suma cronológica presenta un drawdown diagnóstico de 88,1 ticks (véase la Figura 4.2). Estas magnitudes describen el subconjunto observado; no son PnL de una cartera ejecutada.




Figura 4.2: Suma acumulada y drawdown diagnóstico de 318 unidades de acción. No representa una cartera con restricciones de capital o de exposición simultánea.

El remuestreo independiente de las 318 acciones produce un IC90 de $[+0,472, +1,654]$ y $P = 0,998$, pero esa estimación ignora la dependencia entre señales del mismo mercado. Hay 156 mercados y hasta ocho acciones por mercado. Un *bootstrap* agrupado por mercado amplía el IC90 a $[+0,193, +2,004]$ y reduce la probabilidad estimada a 97,6 %. Ambos cálculos son descriptivos: la selección *post-hoc* impide darles una lectura confirmatoria.

4.1.3 Resultados con la comisión oficial de 2026 (nivel de coste taker-real)

La corrección del modelo de costes (Sección 3.4.5) obliga a re-evaluar la política congelada con la comisión oficial de 2026. La operación se hizo sin reentrenar nada: los mismos artefactos sellados, la misma selección de acciones, y como control de integridad se reprodujeron primero las cifras reportadas inicialmente (la política $ev > 0,75$, $healthy \geq 0,5$ da $n = 754$ y $+0,349$ ticks netos al coste de referencia; el corte de baja volatilidad, $n = 318$ y $+1,069$). Después se aplicó la comisión real. La Tabla 4.4 resume el resultado.

El resultado es inequívoco: *ningún corte taker es positivo* bajo el régimen de comisiones vigente, ni siquiera en la cota optimista que solo carga la comisión de entrada. La comisión media de entrada (1,75 ticks) supera por sí sola el resultado bruto de la señal. Este número negativo no es un fracaso del trabajo, sino su lección central confirmada estructuralmente: una precisión direccional cercana al 90 %, que se muestra en los capítulos anteriores, no se traduce en beneficio cuando el coste de ejecución la domina. “Acertar no es ganar” deja de ser una advertencia metodológica y pasa a ser una consecuencia medida del régimen de comisiones. La política congelada se reporta, por tanto, tal cual: negativa en el nivel taker, lo que motiva el giro al lado maker del Capítulo 5 y no una búsqueda de umbrales que la rescaten.

Tabla 4.4: Política congelada re-evaluada con la comisión oficial de 2026. Ticks netos medios por acción; “solo entrada” es la cota optimista que omite la comisión de salida, “ida y vuelta” carga ambas. Las comisiones medias medidas son de 1,75 ticks a la entrada y 1,71 a la salida.

Corte	Función de costes	Función de costes oficial 2026	
	anterior	solo entrada	ida y vuelta
Todas las acciones ($n = 754$)	+0,349	−1,059	−3,304
Baja volatilidad ($n = 318$)	+1,069	−0,342	−2,604

4.1.4 Validación prospectiva pre-registrada

Todo lo anterior en este capítulo comparte una debilidad que ninguna técnica estadística puede reparar: se mide sobre datos que ya existían cuando se diseñó la política. Por cuidadosa que sea la separación entre entrenamiento y prueba, el analista ha visto el periodo, ha iterado sobre él y ha tomado decisiones informadas por lo que allí ocurría. La única refutación limpia de esa objeción es evaluar sobre datos que todavía no existían cuando la política quedó congelada. Esta sección recoge esa evaluación.

Cadena de compromiso

El procedimiento se diseñó para que el autor no pudiera ajustarlo después de ver los resultados, y para que un tercero pueda comprobarlo sin tener que fiarse de su palabra. Antes de que existiera un solo día completo de la ventana (el sello es de la tarde del primer día) y sin haber observado ningún dato de ella, se fijaron por escrito y se sellaron: el universo de mercados, los filtros, la configuración exacta del simulador, las variantes que se ejecutarían, las métricas que se reportarían y las reglas de decisión, junto con las huellas criptográficas de los cinco artefactos ejecutables. El documento se registró además en la cadena de bloques de Bitcoin mediante OpenTimestamps [36], de modo que su fecha es verificable con independencia del repositorio y del autor. El Anexo 8.6 reproduce el pre-registro y el procedimiento de verificación del sello.

La cadena tiene una divergencia deliberada que conviene declarar aquí y no en una nota al pie: la huella del motor de simulación que consta en el pre-registro no es la del motor que se ejecutó. El 13 de julio de 2026 se detectó y corrigió un error que impedía ejecutar la variante base, y la corrección se selló a su vez con su propia marca de tiempo. Revertir al artefacto originalmente sellado no habría hecho el experimento más honesto: lo habría hecho imposible, porque la variante de referencia no llegaba a completar una corrida. Se conserva por tanto la cadena completa (sello original, corrección, sello de la corrección) y se reporta la divergencia como parte del resultado.

Ventana de evaluación

La ventana comprende **35 días completos, del 10 de julio al 13 de agosto de 2026**, ambos incluidos. Su comienzo está determinado por el pre-registro, que excluye explícitamente los días 6 a 9 de julio por haberse empleado en el desarrollo del simulador. Su final no lo decidió el autor: el 14 de agosto la captura se interrumpió por una desconexión física del almacenamiento del recolector, descrita en el Capítulo 6. El último día íntegro es el 13 de agosto.

Esa circunstancia, que operativamente fue un contratiempo, refuerza metodológicamente el resultado. La objeción más natural a cualquier evaluación prospectiva es que el analista elija cuándo parar, y que esa elección dependa de lo que va viendo. Aquí el punto de corte lo fijó un fallo de hardware tres días antes de que se ejecutara la primera evaluación, y la cobertura se verificó sobre el registro de sesiones del recolector (unas 225 sesiones diarias, sin un solo día incompleto dentro de la ventana) antes de calcular ninguna métrica de resultado. El mínimo declarado en el pre-registro era de 25 días evaluados; la ventana disponible lo supera en un 40 %.

Variantes evaluadas y métricas

Se ejecutan las **tres variantes declaradas**, y las tres se reportan con independencia de su signo. La variante *base* es la configuración congelada operando sin señal. La variante *suppress_ask* suprime durante 240 segundos la cotización de venta del token favorecido por la señal H60. La variante *tight_risk* activa, en los mercados señalados, un régimen de riesgo estricto que reduce a la mitad el límite de inventario y el sesgo de inventario y duplica el número de fotogramas en plano. La partición por el filtro de regímenes congelado descrito en la Sección 3.4.10 se reporta como análisis secundario, con su hipótesis registrada de antemano.

Las métricas son las del pre-registro, sin añadidos: equity neta (caja más inventario valorado a resolución más *rebates*), su descomposición en las tres partidas, *markout* a corto plazo, peor día y porcentaje de mercados con resultado positivo.

Reglas de decisión, declaradas antes de mirar

La Tabla 4.5 recoge las tres condiciones que el pre-registro declara para promover la política a operación en sombra, y la regla de sustitución entre variantes. Se rellenan y se obedecen sin interpretación. Conviene subrayar que un resultado negativo no es un fracaso del trabajo ni obliga a reescribir nada: el pre-registro declara explícitamente que el experimento es informativo en cualquier dirección y que todo corte se reporta completo. La contribución de esta sección es el procedimiento y su ejecución honesta, no el signo del número que produzca.

Tabla 4.5: Puertas de decisión pre-declaradas para el corte prospectivo nº 1, sobre la variante base. Las tres condiciones deben cumplirse simultáneamente.

Condición	Valor medido	¿Cumple?
Equity neta > 0	+3.408,11 \$	Sí
Peor día > -150 \$ simulados	-235,66 \$ (5-ago)	No
Días evaluados ≥ 25	35	Sí
Resultado: NO-GO		

Lectura del corte

La política congelada gana dinero y aun así no pasa la puerta. La Tabla 4.6 desglosa las tres variantes y la Figura 4.3 muestra su evolución diaria. La variante base acumula +3.408,11 \$ simulados en 35 días (una media de 97,4 \$ diarios) con 10 días negativos y un 50,4 % de pares mercado-token en positivo. Pero su peor día es -235,66 \$, y

Tabla 4.6: Resultado del corte prospectivo n° 1 por variante, con la descomposición declarada en el pre-registro. Valores en dólares simulados sobre los 35 días de la ventana y 1.684 pares mercado-token.

Variante	Equity neta	Caja	Terminal	Rebates	Peor día
Base	+3.408,11	+9.425,06	−6.712,95	+696,00	−235,66
<i>suppress_ask</i>	+3.397,73	+9.139,05	−6.430,98	+689,66	−241,43
<i>tight_risk</i>	+2.925,10	+8.372,26	−6.103,28	+656,12	−233,26

la regla pre-declarada exigía no bajar de -150 \$. Falla una de las tres condiciones y, por tanto, el veredicto es **NO-GO**: la política no se promueve a operación en sombra.

Conviene detenerse en esto, porque es el resultado más informativo del capítulo. La puerta no rechazó una estrategia que perdiera dinero: rechazó una rentable, y lo hizo por la única de las tres condiciones que mide riesgo y no retorno. Un criterio pre-registrado que solo aprueba no demuestra nada; este tenía dientes, y los enseñó contra un resultado económicamente favorable.

Interesa precisar contra qué se compara ese rendimiento, porque la elección del punto de referencia puede hacerlo parecer mejor o peor de lo que es. La media de $97,4$ \$ diarios queda *entre* las dos referencias previas de la misma configuración: los ~ 112 \$ diarios del ajuste sobre mayo-junio, que es una cifra dentro de muestra, y los ~ 40 \$ de la validación única de julio, que era fuera de muestra pero se apoyaba en solo cuatro días, el primero de ellos parcial. El retorno medio, por tanto, no mejora ni empeora de forma concluyente: se mantiene dentro de la banda ya conocida.

Lo que sí cambia es la dispersión, y conviene decirlo con precisión porque la lectura inmediata (“la cola izquierda se ha duplicado”) no resiste el contraste. El peor día pasa de $-118,46$ a $-235,66$ \$, pero **ocupa la misma posición relativa dentro de su propia ventana**: su distancia a la media, medida en desviaciones típicas diarias, es de $-2,15$ en desarrollo y $-2,13$ en la ventana prospectiva. No es un día más extremo: es el mínimo de una distribución más ancha.

Lo que se ensancha es medible y tiene dos componentes. La desviación típica de la equity *por par mercado-token* crece de $19,11$ a $21,45$ \$ (un 12 %, con un contraste de Brown-Forsythe que da $p = 1,7 \cdot 10^{-9}$), y el número de pares simultáneos por día sube de $42,4$ a $48,1$. Ambos efectos se componen: la desviación típica *diaria* pasa de $106,88$ a $156,25$ \$, un factor $1,46$ cuyo contraste F queda en $p = 0,060$, marginal por el escaso número de días. El retorno medio, en cambio, no se mueve de forma detectable ($111,53$ frente a $97,37$ \$ diarios, $p = 0,681$). El valor terminal del inventario aporta el $70,8$ % de la varianza de la equity medido como cuota de covarianza, esto es, $\text{cov}(\text{terminal}, \text{equity}) / \text{var}(\text{equity})$, que es la descomposición aditiva pertinente cuando las partidas suman exactamente la magnitud descompuesta; conviene precisarlo porque el coeficiente de determinación de una regresión simple entre ambas series es bastante menor ($R^2 = 0,28$), y confundir ambas cifras exageraría el poder predictivo del terminal. La partida dominante de la varianza es, en todo caso, precisamente aquella sobre la que actúan las variantes de señal.

Esto obliga a una observación crítica sobre el propio diseño de la puerta, que se hace aquí como limitación y no como atenuante: **el umbral se declaró como una cantidad absoluta, sin análisis de potencia**. Se fijó en -150 \$ contra el peor día de la validación de julio, -120 \$, con un margen del 25 %. Pero un umbral absoluto codifica implícitamente




Figura 4.3: Corte prospectivo pre-registrado nº 1. Arriba, equity neta acumulada por variante sobre los 35 días de la ventana. Abajo, equity diaria de la variante base con el umbral pre-declarado de -150 \$: el corte no falla por rentabilidad (la curva acumulada termina en $+3.408$ \$) sino por la profundidad de un único día, el 5 de agosto.

una hipótesis sobre la dispersión: con la desviación por par del desarrollo equivale a unas 1,2 desviaciones típicas diarias, mientras que con la de la ventana prospectiva ($21,45 \times \sqrt{48} \approx 148,6$) cae prácticamente sobre una sola. La probabilidad de fallar la puerta no era la misma en los dos escenarios, y el pre-registro no distinguía entre ellos. Un diseño más exigente habría declarado el umbral en unidades de dispersión, o habría acompañado la regla de la potencia estadística que le correspondía.

La objeción admite además una formulación cuantitativa que conviene hacer explícita, porque responde a la pregunta de si el umbral era siquiera alcanzable. Dada la dispersión diaria efectivamente observada, ¿cuál era el peor día *esperado* en una ventana de 35 días? Simulando 50.000 ventanas con la media y la desviación medidas, el mínimo esperado es de $-231,8$ \$ (frente a los $-235,66$ que se observaron) y la probabilidad de cruzar el umbral de -150 \$ alcanza el 87 %. Un remuestreo *bootstrap* de los propios días observados, que no supone normalidad, da $-199,9$ \$ y un 64 %; conviene señalar que esta segunda cifra es una cota inferior por construcción, ya que el *bootstrap* del mínimo no puede generar ningún día peor que el peor efectivamente observado y por tanto subestima cualquier probabilidad de cola. Las dos estimaciones coinciden en lo esencial: **era más probable fallar la puerta que superarla, y el día que la hizo fallar no fue un suceso extraordinario sino el mínimo ordinario de una ventana de ese tamaño y esa dispersión** (Figura 4.4, izquierda).




Figura 4.4: Izquierda: distribución simulada del peor día en una ventana de 35 días bajo la dispersión medida. El día observado ($-235,66$ \$) cae junto a la moda de lo esperado, y el umbral pre-declarado queda holgadamente dentro de la región que la distribución cruza. Derecha: techo de oráculo del riesgo terminal (qué ocurriría si se retirase el percentil peor de pares). Retirar solo el 5 % bastaría para que la puerta se superase, lo que acota el valor máximo de un modelo de riesgo terminal.

Esa misma descomposición permite acotar, por el otro extremo, cuánto valdría acertar el riesgo terminal, que es la línea que el resultado sugiere. Si se retirase con información perfecta el 5 % peor de los pares (85 de 1.684) la equity ascendería a $+6.789$ \$ y el peor día quedaría en $-125,4$ \$: la puerta se superaría. Retirando el decil, la equity llega a $+9.221$ \$ y el peor día a $-70,2$. No es una política, porque exige conocer el futuro, sino la cota superior de lo que un modelo de riesgo terminal podría aportar, y justifica que sea esa (y no la predicción direccional) la dirección de trabajo que este resultado deja abierta.

Nada de esto altera el veredicto. La regla estaba escrita, es la que se aplica y el resultado es NO-GO. Lo que cambia es la explicación de *por qué* se falla: no porque aparezca un riesgo de cola nuevo, sino porque cada operación se volvió un 12 % más dispersa y se ejecutaron más operaciones simultáneas, de modo que la distribución diaria se ensanchó lo suficiente para que su mínimo ordinario cruzara una línea fijada sobre una distribución más estrecha.

Ninguna variante de señal sustituye a la base. La regla de sustitución exigía mejorar simultáneamente la equity neta y el valor terminal. Las dos variantes mejoran el terminal (*suppress_ask* lo lleva de $-6.712,95$ a $-6.430,98$ y *tight_risk* hasta $-6.103,28$) pero ninguna mejora la neta. Se documentan y se descartan, como estaba escrito.

El detalle importa más que el agregado, porque las variantes solo actúan sobre los 208 pares que la señal toca. Restringiendo la comparación a ese subconjunto, el efecto es inequívoco: *tight_risk* reduce el inventario terminal de $-1.565,57$ a $-955,91$ (un 39 % menos) mientras la equity neta cae de $+841,44$ a $+358,44$, es decir, un 57 %. La señal H60 hace exactamente lo que el diagnóstico del Capítulo 5 anticipaba: incide sobre el inventario terminal, que era la palanca identificada. Lo que el corte añade es el precio de accionarla, y ese precio no estaba medido: controlar el riesgo terminal cuesta más de la mitad del beneficio en caja. La hipótesis era correcta y la palanca funciona; simplemente no compensa.

El *markout* confirma que la ejecución maker captura spread, pero poco. Las

tres variantes quedan en torno a +0,011 ticks a 30 y 60 segundos. El signo es el esperado para un proveedor de liquidez, la magnitud es marginal.

Análisis secundario por régimen: la hipótesis registrada se cumple. Aplicando el filtro de régimen congelado de la adenda A (entrenado únicamente con datos de mayo y junio, y por tanto sin haber visto un solo frame de la ventana) las 1.673 series se reparten en dos regímenes, siendo el agitado el de mayor volatilidad realizada (11,5 frente a 6,2). Sobre la variante base y descartando los terminales ambiguos ($n = 1.316$), el régimen agitado rinde +4,06 \$ de equity media por serie frente a +3,12 \$ del tranquilo, y concentra además un inventario terminal menos negativo. La hipótesis declarada de antemano (que el régimen agitado favorece el neto maker) queda confirmada prospectivamente, lo que respalda la observación de desarrollo recogida en el Capítulo 3.

Qué se lleva el trabajo de aquí. Un NO-GO pre-registrado no invalida la vía maker: la sitúa. La economía del lado maker es positiva y medible donde la del lado *taker* era estructuralmente negativa, que es el giro que motiva el Capítulo 5; pero su perfil de riesgo diario, con la configuración congelada y sin respuesta competitiva del mercado, excede el umbral que este trabajo se fijó antes de mirar. La consecuencia práctica no es abandonar la línea sino que cualquier continuación debe atacar la cola izquierda (no el retorno medio) y volver a someterse a una puerta declarada de antemano.

Niveles de reporte del protocolo general

El pre-registro general contempla, además de la adenda del simulador, dos niveles de reporte sobre la política congelada del lado *taker*: el histórico a 0,5 y el de comisión oficial. Su corte prospectivo tiene fecha propia y posterior (el 24 de agosto de 2026) y se reporta aquí en un segundo bloque. Que las dos fechas sean distintas no es un descuido sino la consecuencia de que son dos experimentos encadenados: el del simulador maker no podía pre-registrarse hasta que el simulador existió, y por eso tiene su propia ventana, más corta y posterior. Ninguna de las dos fechas se ha movido respecto a lo sellado.

El corte se ejecutó una sola vez sobre la ventana elegible, del 2 de julio al 23 de agosto de 2026. De sus 53 días hay captura efectiva en 50. Falta el 2 de julio, porque la reanudación real no se confirmó hasta el día 3 a las 08:42 UTC, y faltan el 15 y el 16 de agosto por el incidente de almacenamiento del recolector. Las tres ausencias caen bajo la única excepción que el protocolo admite, el fallo de captura documentado, y ninguna se decidió después de ver resultado alguno. La política congelada selecciona 25.011 unidades de acción.

La Tabla 4.7 recoge el resultado, cuya lectura tiene dos partes que conviene no confundir. En el nivel histórico (el que existe únicamente para ser comparable con lo reportado inicialmente) el resultado es **indistinguible de cero**: -0,004 ticks con un intervalo que contiene holgadamente el cero y 23 días positivos de 50. El filtro de volatilidad no lo cambia. En los niveles que cobran la comisión oficial, en cambio, el signo es inequívoco y el intervalo excluye el cero por amplio margen en las tres, hasta los -3,65 ticks de la operación completa, que no tiene un solo día positivo en toda la ventana.

Una precisión que altera el marco de la comparación y que solo apareció al calcular los intervalos de la referencia. La cifra que este corte venía a contrastar (los +0,349 ticks del bloque de junio, reproducidos aquí dígito a dígito como control del instrumento) **nunca fue estadísticamente significativa**: su intervalo al 95 % es [-0,194; +0,892] por filas y

Tabla 4.7: Corte prospectivo del pre-registro general (50 días, 25.011 unidades de acción). Los intervalos se calculan por *bootstrap* agrupando por mercado, que es el pertinente: varias unidades del mismo mercado comparten horizonte y el remuestreo por filas las trataría como independientes.

Nivel	Filtro	Media (ticks)	IC 95 %	Días > 0
Histórica @0,5	ninguno	-0,004	[-0,223; +0,212]	23/50
Histórica @0,5	estático	+0,009	[-0,233; +0,257]	25/50
Histórica, fee real	ninguno	-0,770	[-0,989; -0,554]	10/50
<i>Taker</i> entrada	ninguno	-1,411	[-1,631; -1,195]	3/50
<i>Taker</i> ida-vuelta	ninguno	-3,646	[-3,866; -3,431]	0/50

[-0,655; +1,337] agrupando por mercado. Hablar de deterioro, por tanto, sería impreciso: lo que muestra el corte es que con treinta y tres veces más datos la señal sigue sin distinguirse del azar, y que la comisión vigente la vuelve decisivamente negativa. Es el mismo desenlace al que llegan las otras vías del trabajo, alcanzado ahora con la potencia que a la validación original le faltaba.

Una contradicción interna del pre-registro, y cómo se resolvió. El protocolo declara que el filtro de tradabilidad debe aplicarse con la definición histórica de la columna de coste, esto es, con la fórmula de comisión anterior y “para no des-congelar el filtro”, mientras los niveles de reporte usan la comisión real. Ocurre que el propio acto de sellado incorporó al control de versiones el módulo que calcula esa columna *ya con la fórmula corregida*, de modo que el texto sellado y el código sellado se contradicen. Reconstruido el conjunto con el código actual, el filtro dejaba 42 unidades de 2.837.137, y ninguna tras aplicar la ventana temporal. No porque la política no seleccionase nada, sino porque el umbral se estaba comparando contra una escala ocho veces mayor que la suya. Se restauró la definición histórica, con una comprobación que exige reproducir la columna almacenada al aplicarle la fórmula vigente. Debe decirse con claridad que esa decisión se tomó *después* de observar que la vía literal no producía datos: es un grado de libertad ejercido con conocimiento de un resultado intermedio, y por eso se declara aquí como desviación documentada y no como continuidad silenciosa.

Dos variantes que no se ejecutaron. De los tres filtros de régimen pre-registrados solo el estático pudo evaluarse. La variante GARCH resultó **inejecutable en el punto de decisión**: su especificación exige sesenta barras de un minuto por sesión, y el tramo previo a la apertura, que es el único disponible cuando la política decide, tiene una mediana de cuatro barras y un máximo de seis. Ninguna sesión alcanza el mínimo. No es que el filtro de régimen no funcione: es que la historia intra-sesión que necesita no existe. La variante de regímenes sí pudo aplicarse, pero el agrupamiento congelado se entrenó sobre la malla del lado *maker* y solo cubre el 4,9 % de las unidades de este corte, así que se reporta como no concluyente en lugar de extrapolarla. Ambos casos se documentan porque una variante comprometida que no se reporta es información perdida, y la tentación de sustituirla por un sucedáneo (que en una primera versión de este análisis llegó a materializarse) produce cifras que parecen resultados sin serlo.

Segundo corte, justo antes de la entrega

El protocolo general contempla un segundo corte “justo antes de la entrega de septiembre”, sobre la misma ventana acumulativa y el mismo *pipeline* congelado. Se ejecutó el 29 de agosto de 2026 con la regla derivada que fija el cierre en el último día UTC completo anterior a la ejecución (el 28 de agosto), valor escrito en los guiones antes de lanzarlos. La ventana elegible pasa así del 2 de julio al 28 de agosto: 58 días, con captura efectiva en 55. Las tres ausencias son las mismas de antes y por la misma causa documentada. La política congelada selecciona ahora 27.208 unidades de acción.

Tabla 4.8: Segundo corte prospectivo del pre-registro general (55 días, 27.208 unidades de acción). Mismos niveles, misma política congelada y mismo *bootstrap* agrupado por mercado que la Tabla 4.7.

Nivel	Filtro	Media (ticks)	IC 95 %	Días > 0
Histórica @0,5	ninguno	+0,075	[−0,132; +0,286]	28/55
Histórica @0,5	estático	+0,039	[−0,202; +0,278]	29/55
Histórica, fee real	ninguno	−0,691	[−0,898; −0,480]	13/55
<i>Taker</i> entrada	ninguno	−1,334	[−1,541; −1,122]	5/55
<i>Taker</i> ida-vuelta	ninguno	−3,570	[−3,776; −3,359]	0/55

El control que hace comparable este corte con el anterior es la reutilización. La extracción fue incremental: solo se extrajeron los cinco días nuevos y los cincuenta anteriores se reaprovecharon. Recalculada la serie diaria completa dentro del conjunto ampliado, esos cincuenta días devuelven las mismas 25.011 unidades y valores idénticos a los del primer corte en los cuatro niveles y en el recuento diario (doscientas cincuenta celdas sin una sola diferencia), incluida la media de $-0,004$ ticks.

La conclusión que recoge la Tabla 4.8 no cambia, pero el aspecto de su primera fila sí, y hay que explicar por qué. En el nivel histórico la media pasa de $-0,004$ a $+0,075$ ticks y los días positivos de 23 de 50 a 28 de 55. Todo ese movimiento cabe en los cinco días nuevos: aportan el 8,1 % de las unidades, los cinco salen positivos y esas 2.197 unidades promedian $+0,97$ ticks. Con cinco días no hay forma de separar una racha del principio de otra cosa, y sobre la serie diaria no se ha ejecutado ningún contraste de ruptura; lo que decide, en cambio, sigue en su sitio. El intervalo contiene el cero con holgura, $[-0,132; +0,286]$ agrupando por mercado, y el *deflated Sharpe* de la serie diaria queda en 0,14, muy por debajo del 95 % de confianza con que Bailey y López de Prado [13] identifican habilidad. Que cinco días de cincuenta y cinco muevan la media casi ocho centésimas de tick ilustra por qué aquí manda el intervalo y no el punto.

En los niveles que cobran la comisión oficial el signo vuelve a ser inequívoco. El intervalo excluye el cero en las tres, hasta los $-3,57$ ticks de la operación completa, que no tiene un solo día positivo en los cincuenta y cinco. Las dos variantes que no se ejecutaron en el primer corte siguen sin ejecutarse por las mismas razones (la GARCH por falta de barras en el punto de decisión, la de regímenes por cobertura insuficiente, ahora del 4,5 %) y se reportan como tales.

Qué queda observado y qué sigue sin mirarse. Este corte observa el lado *taker* hasta el 28 de agosto. La ventana del lado *maker* posterior a la de la adenda del simulador

sigue sin observarse: sus mallas no se han regenerado y su corte está pre-registrado para después de la entrega. La separación entre ambas se mantiene en los términos en que se selló.

4.2 Comparativa con otros enfoques y baseline

Esta sección sitúa el resultado limpio del especialista frente a las alternativas evaluadas: las arquitecturas profundas sobre el libro de órdenes, los modelos de referencia de series temporales (baselines clásicos, kNN-DTW y el fundacional MOMENT), un fundacional tabular y los intentos de adaptación al cambio de régimen. La comparación justifica por qué la mejor señal disponible procede de un modelo tabular sencillo y no de una red profunda ni de un modelo fundacional.

4.2.1 Especialista tabular frente a aprendizaje profundo

Las redes recurrentes y convolucionales sobre el libro aprenden representación (algunas políticas *proxy* resultan positivas dentro de muestra), pero esa ventaja no sobrevive cuando se exige selección causal día a día y estabilidad en todo el bloque de test. Con unas dos semanas de datos, la capacidad necesaria para generalizar temporalmente excede lo que las redes pueden estimar de forma fiable.

El modelo tabular con regularización agresiva opera en el extremo opuesto: aumenta su sesgo pero reduce drásticamente la varianza. Restringir la señal a la ventana *prestart* acota el espacio de hipótesis. Esa combinación conserva un promedio positivo al coste de referencia en el bloque intacto, aunque todavía no supera el coste de estrés. El resultado no descarta el aprendizaje profundo; lo sitúa como una vía a reevaluar cuando el volumen de datos crezca.

4.2.2 Modelos de referencia de series temporales: baselines clásicos, kNN-DTW y MOMENT

Para situar al especialista frente a los métodos clásicos y fundacionales de series temporales, se evalúa una escalera de modelos de referencia sobre un mismo problema controlado: predecir la dirección del precio medio a horizonte H60 (60 pasos de 2s) en la foto de apertura—45s de cada mercado, con el mismo nivel de coste (comisión taker oficial). El conjunto de evaluación son 906 casos congelados; cada modelo produce una señal de signo y se reporta su acierto direccional y su resultado bruto en ticks. Conviene subrayar que estos baselines usan un universo más amplio que el especialista final (no aplican su filtro estricto de tradabilidad), de modo que la comparación con la cifra sellada del especialista es de contexto, no cabeza a cabeza.

Qué declaran estos métodos en sus *benchmarks* y qué se obtiene aquí. La comparación con las cifras que sus autores reportan en los artículos originales es parte de la pregunta. DeepLOB declara un F1 del 83,4 % prediciendo la dirección a horizonte corto en FI-2010, un conjunto de acciones nórdicas de alta liquidez [5]; MOMENT declara resultados *zero-shot* competitivos con modelos ajustados en sus colecciones de series de largo horizonte [24]. Nada de eso se reproduce en este corpus, y la diferencia no es un fallo de implementación sino de régimen: FI-2010 etiqueta movimientos sobre un subyacente

que se mueve casi siempre, mientras que aquí el precio queda inmóvil en la mayoría de los pasos de dos segundos (Sección 3.1.3), la señal útil vive a horizontes donde la comisión oficial de 2026 consume el margen, y la geometría contexto–horizonte excluye a la mayor parte de los mercados cortos. Este contraste (métodos que rinden donde fueron diseñados y no aquí) es precisamente lo que la comparación debe hacer visible, y anticipa la conclusión económica de la Sección 4.1.3.

Los baselines clásicos se ajustan por serie sobre el tramo pre-señal, sin información futura. El **naive-drift** (signo de la deriva reciente) y el **ARIMA(1,1,1)** son los más informativos; el **suavizado exponencial de Holt** queda por detrás, y el **kNN con distancia DTW** (biblioteca de mayo, consultas de junio, con separación temporal estricta) no supera a la deriva simple. Como demostración de forecasting estacional donde tiene sentido, un modelo de Holt-Winters sobre la actividad agregada mejora un 2,7 % el error del persistente; a horizonte de segundos sobre el precio, en cambio, el componente estacional no aporta.

El modelo fundacional de referencia es **MOMENT-1-small**, evaluado en tres regímenes de adaptación crecientes: *zero-shot* (reconstrucción con la cola enmascarada, sin entrenar), *linear-probing* (solo la cabeza de predicción, backbone congelado) y *fine-tuning completo* (todo el modelo, entrenado en GPU). El entrenamiento usa ventanas del propio corpus muestreadas fuera de los casos de evaluación (con un margen de exclusión que garantiza que entrenamiento y evaluación no comparten ni un frame) y restringidas al mismo régimen de actividad que el corte de evaluación (Sección 3.2). La Tabla 4.9 recoge el resultado.

Tabla 4.9: Escalera de modelos de referencia sobre el conjunto de 906 casos congelados (H60, comisión taker oficial). La columna n es el soporte real de cada modelo: los baselines clásicos solo emiten señal donde su criterio interno lo permite, de modo que sus aciertos *no* son comparables cabeza a cabeza entre sí ni con MOMENT (que responde en los 906); el ejemplo extremo es ARIMA, cuyo 56,5 % descansa en el 18 % de los casos. El neto taker es negativo en todos los casos por el régimen de comisiones de 2026.

Modelo	n	Acuerdo direccional	Bruto (ticks)
ARIMA(1,1,1)	161	56,5 %	+0,621
naive-drift	467	53,1 %	+1,186
Holt (suavizado exponencial)	902	48,4 %	+0,516
MOMENT fine-tuning completo	906	47,3 %	+0,082
MOMENT linear-probing	906	46,6 %	−0,175
MOMENT zero-shot	906	45,5 %	−0,585
kNN-DTW	232	45,3 %	−0,209

De esta escalera se extraen dos lecturas. La primera es que la adaptación del fundacional *ayuda de forma monótona*: cada régimen mejora al anterior, tanto en acierto como en resultado bruto (zero-shot → linear-probing → fine-tuning completo), lo que confirma que el modelo capta algo de la estructura local al especializarse; los tres regímenes responden sobre los mismos 906 casos, así que esta comparación sí es cabeza a cabeza. La segunda, más importante, es que *ni siquiera el fine-tuning completo supera a los baselines clásicos*: Holt, que responde en 902 de los 906 casos (soporte casi idéntico), lo supera ligeramente con una fracción del coste computacional, y naive-drift y ARIMA se sitúan por encima aunque sobre soportes menores (467 y 161 casos donde su criterio interno emite señal), de

modo que su ventaja debe leerse con la cautela que la columna n impone. El fundacional de series temporales, la herramienta más sofisticada de la escalera, no es en ningún caso la más precisa.

Cabe preguntarse si el fundacional mejoraría con más datos. La Figura 4.5 responde con una curva de escalado: se re-entrena el linear-probing sobre subconjuntos crecientes de ventanas (de 2.700 a 40.500) y se evalúa cada uno sobre los mismos casos congelados. La curva es esencialmente plana (el acierto oscila entre el 43,9 y el 46,8 % sin tendencia clara al alza) y se mantiene por debajo del baseline clásico en todo el rango. La conclusión es que el cuello de botella no es la cantidad de datos de entrenamiento ni la capacidad del modelo, sino el régimen de datos: sobre una malla de 2 segundos, el precio medio de estos mercados apenas contiene estructura direccional explotable a este horizonte por encima de la deriva, con independencia de la sofisticación del modelo. Es la misma lección que atraviesa el trabajo (predecir es difícil, y donde se puede, no basta) reforzada ahora desde el lado del modelado.




Figura 4.5: Curva de escalado del fine-tuning de MOMENT (linear-probing) frente al número de ventanas de entrenamiento, evaluada sobre los 906 casos congelados. Más datos no cierran la brecha con la deriva simple: el techo lo marca el régimen de datos, no el tamaño de la muestra.

4.2.3 Un fundacional tabular: TabPFN *zero-shot*

El Capítulo 2 anunciaba la evaluación de TabPFN [28], el modelo fundacional para dato tabular que predice sin entrenar (el conjunto de entrenamiento se le pasa como contexto). Se evaluó sobre el universo del especialista sin el filtro de coste, con las dos particiones habituales (validación inicial y test terminal), limitado a 10.000 de las 28.095 filas de entrenamiento por su ventana de contexto: aproximadamente un tercio de los datos que ve el *gradient boosting*.

El resultado tiene dos caras. En el *ranking* del valor esperado, TabPFN gana a ambos competidores en las dos particiones sin haber entrenado: Spearman 0,115 y 0,120 frente a 0,092 del *gradient boosting* fresco y 0,098/0,096 del especialista congelado, y es el único cuyo R^2 es positivo en ambas particiones. En la cabeza de salud, en cambio, no domina: su AUC (0,550) queda por debajo del *gradient boosting* en validación (0,585), y en el test terminal la ordenación se invierte (0,549 frente a 0,535) sin que ninguno de los dos

se despegue del azar. Y la traducción económica repite la lección del resto del capítulo: ninguna de esas diferencias de ordenación convierte la política en rentable bajo la comisión oficial. El interés del resultado es metodológico (un fundacional tabular alcanza *zero-shot*, con un tercio de los datos, la calidad de ordenación de un modelo ajustado) y delimita dónde rinde esta familia: en ordenar candidatos, no en decidir operaciones.

4.2.4 Experimentos de adaptación al régimen

Ante el cambio de régimen se probaron reentrenamiento incremental con ventana móvil, alineación de correlaciones CORAL [14], un filtro conformal, un *ensemble* por *bootstrap*, un filtro de volatilidad adaptativo, características normalizadas por volatilidad y *distillation* de una red convolucional temporal. Ninguna alternativa produjo evidencia prospectiva robusta con tan pocos días. Este resultado negativo sigue siendo informativo, pero no permite declarar vencedor al filtro simple sobre el mismo bloque usado para proponerlo. La comparación definitiva queda aplazada hasta disponer de nuevos datos bajo una política ya congelada.

4.2.5 Por qué falla fuera de muestra la cabeza de salud

La debilidad conocida de la pieza sellada es la cabeza de salud, cuya discriminación cae de 0,79 a 0,56 entre entrenamiento y validación. Un ensemble de diez réplicas con semillas distintas permite atribuir esa caída: es estable entre réplicas (de modo que no es suerte de inicialización), el desacuerdo entre ellas no aumenta fuera de muestra (de modo que no es incertidumbre epistémica) y un clasificador de dominio separa mayo de junio con AUC 0,90, lo que sí identifica un desplazamiento acusado de covariables. La consecuencia práctica acota cualquier iteración futura: reentrenar con más datos del mismo periodo tiene techo, porque el obstáculo no es el tamaño de la muestra sino la cobertura del régimen. El diagnóstico completo, con sus figuras, está en el Anexo 8.6.

4.2.6 Curva de escalado de datos: tabular frente a aprendizaje profundo

La conclusión anterior (el tabular sencillo bate a la red profunda con pocos datos) invita a una objeción natural: ¿no ganaría la vía profunda con más datos, dada su mayor capacidad? Se responde empíricamente con una curva de escalado que enfrenta a ambas vías sobre la *misma* tarea y evaluación. Se predice la dirección del tramo H60 en los 906 casos congelados a partir de ventanas de contexto régimen-ajustadas y sin fuga; la vía profunda es el fine-tuning de MOMENT (Sección 4.2.2) y la tabular un *gradient boosting* sobre características clásicas derivadas de la misma ventana (retornos a varios rezagos, momentum, volatilidad realizada y distancia a 0,5). Ambas se entrenan sobre subconjuntos crecientes del mismo corpus (de 3.000 a algo más de 41.000 ventanas) y se evalúan sobre los mismos casos (véase la Figura 4.6).

El resultado es inequívoco: la vía tabular domina a la profunda *en todo el rango de datos*. Con el corpus mínimo, la tabular acierta un 48,2 % frente al 46,0 % de MOMENT; con el corpus completo, la tabular sube hasta el 50,3 % mientras que la profunda se estanca en torno al 46,8 %. Es decir, la vía tabular no solo parte de un nivel más alto, sino que además escala al menos tan bien: la brecha no se cierra al añadir datos, se ensancha. La objeción queda respondida en negativo (al menos en este régimen de tamaño de corpus)

y refuerza la elección del modelo tabular como vehículo de la señal. La lección para el proyecto es coherente con el resto del trabajo: la complejidad del modelo no es el cuello de botella, de modo que no compra rendimiento; con dos semanas de datos, la capacidad de una red profunda es una desventaja, no una ventaja.

Conviene delimitar con exactitud qué eje recorre esta curva, porque de ello depende el alcance de la conclusión. El presupuesto de datos se varió aumentando el número de *ventanas* de entrenamiento sobre un corpus fijo de 509 mercados (1.018 pares mercado-token) pertenecientes todos a la temporalidad horaria. Como las ventanas se solapan casi por completo (en un 98 %: paso de 10 sobre ventanas de 512 fotogramas), lo que crece a lo largo del eje es la densidad de muestreo, no el número de trayectorias independientes, que permanece constante. Y la temporalidad horaria es solo una de las tres capturadas: un día cualquiera del corpus contiene 24 mercados a una hora, 96 a quince minutos y 284 a cinco, de modo que la curva se apoya en torno al 6 % de los mercados disponibles. La conclusión que sostiene, por tanto, es que *más muestras solapadas del mismo conjunto de trayectorias* no cierran la brecha; no llega a afirmar que no la cerraría un corpus con un orden de magnitud más de trayectorias independientes. Ese experimento sí se ha realizado, después de detectar la limitación, y se recoge a continuación.

4.2.7 Adenda C: la curva de escalado sobre trayectorias independientes

La curva de escalado publicada tenía una limitación de diseño que se detectó después: hacía crecer el número de ventanas de entrenamiento sobre un conjunto fijo de trayectorias, de modo que medía densidad de muestreo y no diversidad. La adenda C, pre-registrada y sellada antes de entrenar nada, repite el experimento ampliando el corpus a las tres temporalidades capturadas y llevando el eje hasta agotar los datos: 7.784 mercados frente a 509, y hasta 1,88 veces las ventanas que la curva original llegó a explorar. El resultado sostiene la conclusión previa por el eje correcto: en el punto máximo del eje ninguna de las dos vías se despega del azar, con intervalos que contienen el 50 % y sin ningún contraste por debajo de $p = 0,25$. La regla de decisión pedía un punto porcentual de separación y la brecha observada fue de 0,87, por debajo del umbral (y, como se documenta en el Capítulo 8, también por debajo del ruido del propio conjunto de evaluación). La tabla completa y el protocolo de sellado están en el Anexo 8.6.

Un hallazgo no buscado: la tarea excluye los mercados cortos

El diseño pretendía multiplicar las trayectorias por quince y solo consiguió multiplicarlas por menos de tres. El motivo no es de disponibilidad de datos, y merece quedar escrito porque reencuadra la conclusión anterior.

Cada par requiere, para producir una sola ventana válida, 128 fotogramas de contexto, 60 de horizonte y un margen de seguridad anti-fuga de 188 fotogramas alrededor del corte de evaluación, con el muestreo comenzando a mitad de sesión: del orden de 376 fotogramas como mínimo. La longitud mediana de un mercado de cinco minutos es de **160 fotogramas**, menos que el propio margen de seguridad. De sus 10.812 pares, 7.116 no ofrecen ningún rango utilizable y otros 3.662 quedan anulados por el margen; sobreviven 34, que aportan 332 de las 97.752 ventanas totales. El corpus ampliado resulta ser, en la práctica, un 87 % de ventanas horarias.

La consecuencia es metodológica y no menor: lo que limita el aprendizaje aquí no es solo el régimen de los datos, sino **la geometría de la tarea**, que descarta el 94 % de los mercados capturados antes de que empiece el entrenamiento. La elección de operar solo con mercados horarios, que en la curva original podía parecer una simplificación, resulta ser una consecuencia forzada del horizonte elegido. Una línea futura que quiera aprovechar los mercados de horizonte corto (que son los más numerosos con diferencia) no necesita más datos: necesita redefinir el horizonte de predicción.




Figura 4.6: Curva de escalado sobre la misma tarea (dirección H60, 906 casos congelados): la vía tabular (*gradient boosting*) supera a la profunda (MOMENT) en todo el presupuesto de datos, y la distancia se mantiene o crece al aumentar el número de ventanas de entrenamiento. Con este horizonte de datos, más muestras no hacen que el aprendizaje profundo alcance al tabular.

4.2.8 Adenda D: entrenar contra el objetivo económico

La última línea experimental del trabajo (metodología en la Sección 3.4.12) ataca el eje que ningún experimento anterior había tocado: en lugar de predecir mejor y decidir después, entrenar la decisión directamente contra el dinero. Su carácter es **exploratorio** (los treinta y cinco días del corte ya habían sido observados por los barridos de política), de modo que nada de esta sección constituye validación prospectiva.

La política colapsa a la constante, por razones correctas. Entrenada sobre mayo–junio y evaluada sobre la ventana del corte, la política de parada elige “no retirarse nunca” en las 1.323 sesiones de test, con las dos arquitecturas, y ni siquiera supera a la mejor acción constante en el propio conjunto de ajuste. El análisis de la causa resultó más informativo que el resultado: en el periodo de entrenamiento la acción de no retirarse *domina estrictamente*: tiene el mejor total (+3.523,9\$) y además la mejor cola (peor día −20,9\$) de las ocho acciones, de modo que no existe compromiso que aprender y la constante es la respuesta óptima. El suceso que la política debía aprender a evitar (el día de pérdida severa) sencillamente no está en sus datos: mayo–junio contiene un único día en pérdida (de veinticuatro) y ninguno por debajo de −100\$, mientras que la ventana del corte contiene cuatro y dos, respectivamente, bajo la configuración de esta adenda. Conviene precisar la comparación: esas cifras proceden del contrafactual sin aplanado de

la adenda, no de la variante base del corte reportado más arriba, que sobre la misma ventana registra diez días negativos y seis por debajo de ese umbral. Son dos simulaciones distintas del mismo periodo (difieren en tamaño de orden y en el conjunto de pares) y lo que interesa aquí es la comparación interna entre entrenamiento y prueba dentro de una misma configuración, no el nivel absoluto.

La frontera aprendida queda dominada por el parámetro. Sobre una partición donde el compromiso media–cola sí existe, la política entrenada con aversión creciente al riesgo (λ de 0 a 32) recorre las ocho acciones y traza una frontera riesgo–rendimiento real. Comparada punto a punto contra la frontera de las ocho acciones constantes (para cada nivel de protección de cola, la mejor acción fija que protege al menos igual), ninguno de los dieciséis puntos evaluados bate a la frontera fija. En ocho de ellos la política ni siquiera se diferencia: con aversión al riesgo baja colapsa a la acción constante y empata con ella por construcción. En los ocho restantes, donde sí elige, pierde: 9,6\$ diarios menos que el escalar equivalente en el mejor caso y 119,9\$ menos en el peor. Para esta decisión, el mejor modelo resultó ser un parámetro escalar bien elegido, un resultado coherente con la curva de escalado plana y con el empate entre el codificador secuencial y el tabular en la predicción del riesgo terminal.

Dos defectos propios, corregidos y documentados. La primera versión del experimento producía dieciséis puntos idénticos hasta el último decimal; la instrumentación reveló *logits* saturados en torno a -12 , donde el gradiente del sigmoide ($\approx 6 \cdot 10^{-6}$) congela la política con independencia de lo que pida la pérdida (se corrigió acotando los *logits* y manteniendo exploración con un premio de entropía decreciente). La segunda corrección fue conceptual: la regla de un *token* por mercado, correcta para contar muestras independientes en un contraste de AUC, falsea la evaluación económica (en la operativa se cotizan los dos *tokens* y el umbral de riesgo del pre-registro se calibró sobre el libro completo), y al deshacerla desapareció un aparente cumplimiento de la puerta de riesgo que era un artefacto de la partición.

Capítulo 5

Despliegue

Este capítulo documenta la estrategia de despliegue y, sobre todo, la decisión de no operar con capital real. El especialista base ofrece una señal fuera de muestra modesta, mientras que la mejora del filtro de volatilidad procede de un análisis *post-hoc*. El siguiente paso válido no es producción, sino una sombra prospectiva con la política ya congelada.

5.1 Estrategia de despliegue y seguimiento en sombra

5.1.1 Por qué no se despliega

El resultado limpio se apoya en cinco días, solo tres son positivos y el neto pasa a ser ligeramente negativo bajo el coste completo. El subconjunto de baja volatilidad es más prometedor, pero se identificó usando esos mismos cinco días. Desplegar en estas condiciones confundiría una hipótesis razonable con una validación. Por coherencia con la tesis del trabajo (la honestidad del protocolo prevalece sobre cualquier número concreto) el proyecto se detiene antes de operar.

5.1.2 Del registro retrospectivo a la sombra prospectiva

El registro disponible es *offline* y retrospectivo: reconstruye, unidad de acción a unidad de acción, qué habría indicado la regla de baja volatilidad sobre el bloque ya observado. Sirve para comprobar la contabilidad, el resumen diario y las guardas, pero esos cinco días no cuentan como validación de la política completa.

A partir del cierre del bloque se congela la regla candidata ($\text{volatilidad}_{5s} \leq 0,6657$, $\text{EV} > 0,75$ y probabilidad de salud $\geq 0,50$). Una sombra prospectiva deberá ejecutarla sin cambios sobre fechas posteriores, registrar también las abstenciones y resolver la exposición simultánea por mercado. Solo esa evidencia podrá alimentar las puertas de promoción:

- **Candidato a seguimiento ampliado:** neto superior a 0,5 ticks, al menos 200 unidades de acción y al menos 8 días prospectivos.
- **Candidato a despliegue:** neto superior a 0,5 ticks, al menos 400 unidades, 12 días prospectivos y una regla de exposición/fill validada.

Cuando se congeló la regla no existía ningún día prospectivo de la política completa, y su estado era el de *hipótesis pendiente de validación*. Los cortes del protocolo general del

Capítulo 4 llenaron después esa casilla, y conviene actualizar aquí el veredicto en lugar de dejar la promesa congelada: hay 50 y 55 días prospectivos (muy por encima de los 12 que exige la puerta más alta) y el nivel con el filtro de volatilidad rinde +0,009 y +0,039 ticks en los dos cortes, lejos del umbral de 0,5 y con intervalos que contienen el cero. El estado correcto de la regla es, por tanto, *hipótesis contrastada y no confirmada*: las puertas de promoción se fallan por rentabilidad, no por falta de datos, y no hay candidata a bot.

5.1.3 Diseño de una hipotética API de inferencia

Solo si se superasen las puertas anteriores, un despliegue eventual tomaría la forma de un servicio de inferencia con cuatro etapas. Primero, una etapa de ingesta que reconstruyese en tiempo real el estado del mercado sobre la malla de dos segundos. Segundo, una etapa de cálculo que generase las 36 características causales del instante actual, idéntica a la del entrenamiento para evitar discrepancias entre entrenamiento y producción (*train/serve skew*). Tercero, una etapa de decisión que consultase las dos cabezas del especialista y devolviese operar o abstenerse. Y cuarto, una capa de guardas que aplicase los filtros de entorno, volatilidad y obsolescencia, además del límite de exposición por mercado.

Por encima operaría una capa de monitorización que vigilase la deriva de distribución, registrase cada decisión para auditoría y dispusiese de un interruptor de parada inmediata. Esta arquitectura es un diseño, no una implementación.

5.2 Economía de la ejecución bajo el régimen de comisiones de 2026

La corrección del modelo de costes (Sección 3.4.5) dejó una conclusión estructural: el lado *taker* de este mercado no es económico para una señal de la magnitud encontrada. Pero la misma estructura de comisiones que cierra una puerta abre otra. Esta sección desarrolla la economía del lado *maker* y el simulador construido para evaluarla, que es la aportación diferencial del trabajo en el plano del despliegue.

5.2.1 Economía del lado maker y tamaño del premio

Quien cruza el mercado (*taker*) paga una comisión $C \cdot r \cdot p(1 - p)$; quien aporta liquidez (*maker*) está exento y, además, recibe una parte del fondo de comisiones en forma de *rebate*, aproximadamente el 20 % del fondo repartido con el mismo peso $p(1 - p)$. Ese peso (Figura 5.1) concentra tanto la comisión como el reparto en torno a $p = 0,5$ (la zona de precios donde opera este trabajo) y se anula en los extremos, cerca de la resolución. El vehículo económico se invierte respecto al *taker*: donde uno paga el *spread* y la comisión, el otro los cobra.

El tamaño del premio se midió sobre la copia histórica (solo lectura) antes de construir nada. El universo de mercados horarios de Bitcoin mueve del orden de \$310.000 de notional al día (\$434.000 contando todas las temporalidades), con una concentración baja (el 10 % de mercados más grandes reúne solo el 23 % del volumen) y una distribución horaria plana: no hay “mercado estrella” ni “hora mágica” por los que competir, de modo que la ventaja está en la presencia continua, que la infraestructura 24/7 del proyecto ya proporciona. El fondo de *rebates* resultante se estima entre \$1.100 y \$3.000 al día, entre diez y veinte veces




Figura 5.1: El peso $p(1-p)$ que gobierna la comisión taker y el reparto de *rebates* al maker: máximo en $p = 0,5$ y nulo en los extremos. La economía maker es más densa precisamente en la zona de precios intermedios donde opera el trabajo.

por encima del umbral por debajo del cual la vía se habría descartado por insignificante. La puerta económica del lado maker, por tanto, se pasa con holgura (a diferencia de la taker).

5.2.2 El simulador de colas y *fills*

Para evaluar la vía maker sin operar con dinero se construyó un simulador de ejecución sobre el libro L2 agregado a 2 segundos y la cinta de operaciones capturada, con las reglas del *venue* separadas del motor para poder auditarlas y reutilizarlas. La estrategia base se une al mejor precio de compra y de venta sin mejorarlo, con tamaño fijo, solo cuando el *spread* alcanza un mínimo, y con un tope de inventario; recotiza cuando el mejor nivel se mueve, perdiendo su lugar en la cola.

El modelo de *fill* es deliberadamente conservador donde puede y explícito en sus sesgos donde no. La cola por delante al colocar una orden se fija en todo el tamaño visible del nivel (se asume que todos los demás llegaron antes); el flujo *taker* de cada frame consume cola cuando la última operación ocurrió a nuestro precio, y un barrido más allá del precio produce ejecución completa. Sin datos de nivel 3 no existe una verdad de cola, por lo que el simulador se declara una *cota*, no una medida: su sesgo optimista (atribuir todo el flujo del frame a nuestro nivel) y su sesgo pesimista (no adelantar a nadie tras recotizar) se netean en la calibración pendiente contra la cinta fresca. La economía por sesión se contabiliza como caja más inventario valorado a la resolución más *rebates*; el **riesgo terminal binario** está incluido: el inventario que queda al expirar liquida a 0 o a 1 según el desenlace del mercado.

El resultado más informativo del simulador no es el número (una banda de entre \$25 y \$200 diarios de beneficio bruto simulado según régimen y configuración, cuyo signo sobrevive a los ajustes estrictos) sino la *descomposición* del riesgo. La selección adversa medida por el *markout* a corto plazo es **favorable** (alrededor de +1 tick): estos libros revierten a pocos segundos, y esa misma predictibilidad de corto plazo que el taker no podía pagar por culpa de la comisión es la que cobra el maker pasivo. El coste no está ahí, sino en el **inventario retenido hasta la expiración**, que resuelve en contra (la selección adversa vive en el tramo terminal, no en el *markout* corto). La consecuencia de

diseño es directa y conecta con la Sección 5.2.3: la palanca dominante es el control de inventario (aplanar la posición antes del tramo en que el precio se decide), no la captura de *spread* en sí. Introducir una zona plana en los últimos minutos, cotizando solo el lado que reduce inventario, es lo que separa un simulador que pierde en el terminal de uno que conserva el signo.

Las reservas de esta evaluación se declaran sin adornos. El modelo de *fill* es una cota superior; los lados SÍ y NO del mismo mercado se tratan como riesgos independientes cuando en realidad están correlacionados; el corpus es de mayo a junio, sin validación prospectiva; y, sobre todo, ningún *replay* histórico puede capturar la respuesta competitiva de los creadores de mercado incumbentes (Capítulo 6), lo que sitúa la banda simulada como optimista. Es evidencia suficiente para justificar la validación prospectiva pre-registrada, no para afirmar rentabilidad.

Cotización óptima como línea de trabajo futuro. La estrategia base de este simulador cotiza de forma pasiva y controla el inventario terminal con una regla heurística (la zona plana). El paso natural es sustituir esa heurística por la teoría canónica de *market making* óptimo: el modelo de Avellaneda y Stoikov [41], cuyo *precio de reserva* sesga las cotizaciones en proporción al inventario y al tiempo restante hasta la resolución, y sus extensiones al control de riesgo de inventario [42]. Una exploración preliminar sobre el mismo corpus (fuera del pre-registro) indica que este sesgo, adaptado a la varianza de *settlement* binario $p(1-p)$, reduce la pérdida terminal que penaliza a la estrategia pasiva. Esa adaptación, construida aquí de forma heurística, coincide además con la teoría publicada casi en paralelo: la derivación por control estocástico de la cotización óptima en mercados de predicción obtiene como condición terminal de su ecuación de Hamilton-Jacobi-Bellman precisamente la varianza del *settlement* binario, $-\gamma_T q^2 p(1-p)$ con q el inventario [43], lo que respalda de forma independiente la forma funcional empleada. Su magnitud, sin embargo, resultó depender por completo del modelo de *fill*: bajo el supuesto más generoso, en el que una orden alcanzada por un barrido se ejecuta íntegra, la pérdida terminal llega a neutralizarse y la mejora neta es del orden del tres por ciento; bajo el supuesto conservador que fija el propio pre-registro (ejecución de la mitad del tamaño en los barridos) la pérdida terminal solo se atenúa y la mejora neta desaparece. Esta sensibilidad no es exclusiva de la cotización óptima: afecta al orden de mérito de cualquier política que cotice alejada del mejor precio, porque el grueso de sus ejecuciones procede precisamente de barridos. Junto con la ausencia de respuesta competitiva ya señalada, su validación real exige el simulador reactivo antes descrito. La reciente sistematización de la microestructura de los mercados de predicción descentralizados [44] enmarca esta línea dentro de un campo en rápida consolidación.

5.2.3 El tramo terminal: cuándo el precio se vuelve informativo

El riesgo central de un creador de mercado en estos contratos no está en el *spread* que cobra, sino en el inventario que le queda cuando el mercado resuelve: un contrato binario liquida a 0 o a 1, de modo que una posición sin cerrar a la expiración se enfrenta a una varianza estructural de *settlement*. Para dimensionar ese riesgo hace falta saber *cuándo* el precio deja de ser una moneda al aire sobre el desenlace. Se mide de forma directa (sin entrenar ningún modelo, como baseline previo a cualquier modelo secuencial) tratando el precio medio como estimador de la probabilidad de *settlement* y evaluando su calibración a lo largo de la vida del mercado con *proper scoring* (puntuación de Brier) por tiempo a

expiración. La etiqueta es el settlement real, aproximado por el precio medio del último frame observado cuando este cae a menos de cinco minutos del cierre y ha convergido a 0 o 1; las series cuyo último frame queda lejos del cierre se censuran. El universo etiquetado (310 series, con balance exacto entre desenlaces) es un subconjunto sesgado del corpus (el observado cerca del cierre), lo que se declara como limitación.

El resultado (Figura 5.2, panel izquierdo) es una caída suave y monótona de la puntuación de Brier: en la apertura del mercado (50–60 minutos a expiración) vale 0,234, apenas por debajo del 0,25 de la moneda al aire, y el acierto direccional sobre el desenlace es del 58 %; el precio no se vuelve claramente informativo hasta los últimos quince a veinte minutos, donde la puntuación cae por debajo de 0,10 (acierto del 90 % o más) y, en el último minuto, converge al settlement. Dicho de otro modo, durante la mayor parte de la vida del contrato el precio medio de Polymarket es honesto pero poco resolutivo, y toda la información se concentra en el tramo final.

El panel derecho matiza el diagnóstico con curvas de fiabilidad en dos cortes. Lejos del cierre, el precio está *bien calibrado* (un precio de 0,25 resuelve a favor en un 31 % de los casos y uno de 0,75 en un 69 %, cerca de la diagonal) pero con casi toda su masa concentrada en torno a 0,5: el mercado dice correctamente “no lo sé”. Al acercarse el cierre, la distribución se polariza hacia 0 y 1 conforme llega la información, manteniendo la calibración en los extremos. La consecuencia para el diseño maker es inmediata: el precio sirve como probabilidad (no hay que corregir su sesgo), pero la ventana en la que el inventario deja de ser una apuesta y pasa a estar decidido es estrecha y tardía, lo que convierte el aplanado de inventario *antes* de ese tramo en la palanca de riesgo dominante del simulador, coherente con la concentración de actividad en el minuto 50 detectada en el análisis exploratorio (Sección 3.2).




Figura 5.2: Informatividad del precio medio sobre el settlement. Izquierda: puntuación de Brier por tiempo a expiración; el precio es casi una moneda al aire en la apertura y solo se vuelve informativo en el tramo terminal. Derecha: curvas de fiabilidad lejos (30–60 min) y cerca (1–5 min) del cierre; el precio está bien calibrado en ambos cortes, pero su masa se polariza al acercarse la expiración.

Cabe preguntarse si un modelo aprendido extraería la señal del desenlace *antes* que el precio, a partir de la microestructura (*imbalance*, flujo de órdenes, presión del libro). Se

comprobó de forma directa, como paso previo a cualquier modelo secuencial: un *gradient boosting* sobre esas características, con partición temporal estricta (entrenamiento en mayo, prueba en junio, agrupando por mercado), no mejora la puntuación de Brier del propio precio (0,141 frente a 0,140) en ningún tramo de tiempo a expiración; usando *solo* el flujo, sin el precio, la puntuación es peor (0,20) y a tiempo a expiración grande cae al azar. La microestructura no aporta información sobre el settlement que el precio no capture ya: a este horizonte, el precio es prácticamente un estadístico suficiente. En consecuencia no se entrena un modelo secuencial dedicado (sobre apenas un centenar de desenlaces independientes solo añadiría riesgo de sobreajuste), y la curva de Brier por tiempo a expiración se emplea directamente como cronograma de aplanado de inventario en el simulador.

Capítulo 6

Aspectos éticos y limitaciones

Este capítulo recoge las consideraciones éticas que han guiado el trabajo y una revisión explícita de sus limitaciones, que delimitan el alcance de cualquier conclusión.

6.1 Consideraciones éticas

El sistema estudia decisiones económicas automatizadas y es especialmente sensible al sobreajuste cuando el horizonte de datos es reducido. La actuación responsable es no operar con capital real y no convertir un diagnóstico *post-hoc* en una afirmación de rentabilidad. La política completa queda congelada para observación prospectiva, sin que los días usados para formularla cuenten de nuevo como validación.

En cuanto a los datos, se adopta un marco de confidencialidad, integridad y disponibilidad. Una referencia externa retrasada o errónea puede inducir una señal espuria; por ello el sistema se entrena solo con sesiones aceptadas, separa datos crudos, características y etiquetas, mantiene trazabilidad de los artefactos e inhibe la operativa ante datos obsoletos. El trabajo emplea datos públicos de mercado y no datos personales. El corpus completo no se distribuye por tamaño; se publican el esquema, un ledger anonimizado de acciones y el código de evaluación.

6.2 Limitaciones

Selección posterior al bloque. El especialista base sí estaba congelado y su resultado limpio es +0,349 ticks por acción al coste de referencia. El filtro de volatilidad se incorporó después de observar el cambio de régimen; por tanto, su resultado de +1,069 ticks sobre el mismo bloque es exploratorio y necesita fechas posteriores.

Soporte temporal. El conjunto fuera de muestra abarca cinco días. Tres de cinco son positivos para la política base y cinco de cinco dentro del subconjunto diagnóstico. Ninguna de las dos cifras constituye una validación definitiva.

Ausencia del suceso de cola en particiones pequeñas. La línea de la adenda D (Sección 4.2.8) reveló una limitación estructural que afecta a cualquier intento de *aprender* gestión del riesgo con pocos meses de datos: el suceso que la política debe evitar, el día de pérdida severa, es tan infrecuente (cuatro días de treinta y cinco en la configuración

de la adenda, diez en la variante base del corte) que las particiones pequeñas lo pierden con alta probabilidad. El periodo de entrenamiento de mayo-junio no contiene ni un solo día por debajo de -100 \$, y un conjunto de validación de una semana sale sin ningún día en pérdida el 43 % de las veces. Cuando eso ocurre, el término de aversión al riesgo de la función de pérdida vale cero por construcción y el hiperparámetro que la gobierna no puede seleccionarse: no es un fallo del modelo sino del diseño experimental, y solo lo resuelven ventanas más largas o la simulación de escenarios de cola.

Continuidad de la captura. El recolector no operó de forma ininterrumpida durante todo el periodo del proyecto: hay un hueco documentado entre el 14 de junio y la reanudación real, confirmada el 3 de julio de 2026 a las 08:42 UTC. El hueco no afecta a ninguna cifra reportada en este trabajo (tanto el corpus principal de entrenamiento, del 11 al 25 de mayo, como el bloque fuera de muestra confirmatorio, del 6 al 10 de junio, se capturaron antes de que se abriera), pero delimita el origen real de la ventana de captura continua sobre la que se apoyará la validación prospectiva (Capítulo 4).

Resolución temporal del instrumento. La captura opera en una malla de dos segundos, y esa granularidad limita una de las conclusiones centrales más de lo que su enunciado sugiere. La latencia de ejecución se midió extremo a extremo contra el mercado real (429,7 ms en percentil 95 hasta el acuse del CLOB, con un *fill* efectivamente casado en 426,7 ms) y la decisión operativa registrada fue emplear un segundo como contrato de modelado, reservando los dos segundos para el escenario de estrés. Sin embargo, un escalón de un segundo no tiene ninguna observación que lo soporte en una malla de dos, de modo que la tabla de latencias salta de cero a dos segundos sin ningún punto intermedio. El intervalo donde vive la latencia realmente medida queda, por tanto, sin observar, y la conclusión correcta es que no se ha demostrado que la ventaja sobreviva a la latencia de ejecución ni que deje de hacerlo (Sección 3.3.1). Resolverlo exige capturar a una frecuencia sensiblemente mayor, con el coste de almacenamiento y de proceso que ello implica; queda como línea futura. Conviene recordar que la conclusión de fondo se apoya además en un argumento independiente de la latencia, el de la estructura de comisiones.

Cierre de la ventana prospectiva. La ventana de evaluación prospectiva no la cerró una decisión metodológica sino un fallo de hardware: el 14 de agosto de 2026 a las 11:05 UTC el disco de almacenamiento del recolector se desconectó del bus USB de la Raspberry Pi y la captura se detuvo, reanudándose el 17 de agosto a las 09:23 UTC. El último día completo capturado es el 13 de agosto, y esa es la fecha de cierre de la ventana. La integridad de lo capturado se verificó antes de evaluar nada: el sistema de ficheros se recuperó mediante la reejecución de su diario, el medio no presentó errores de lectura ni antes ni después del incidente, y la cobertura diaria se comprobó una a una sobre el registro de sesiones del propio recolector. Resultan 35 días completos e ininterrumpidos, del 10 de julio al 13 de agosto, por encima del mínimo de 25 días declarado en el pre-registro. La circunstancia tiene una consecuencia metodológica favorable que conviene explicitar: el final de la ventana quedó determinado por una causa externa y ajena al experimento, y quedó determinado *antes* de que se observara ningún resultado, de modo que la elección del punto de corte no pudo verse influida por los datos que ese corte iba a revelar. El hueco posterior al 14 de agosto queda documentado en el monitor del recolector, tal y como exige el propio pre-registro para cualquier exclusión de días por fallo de captura.

Dependencia y solapamiento. Las 318 unidades del diagnóstico pertenecen a 156 mercados, con hasta ocho señales por mercado y horizontes H60 solapados. El *bootstrap* por

filas subestima esa dependencia. Un remuestreo agrupado por mercado amplía el IC90 % a $[+0,193, +2,004]$, pero sigue describiendo un subconjunto elegido *post-hoc*. Además, no se ha fijado una regla de exposición simultánea; por ello la suma acumulada no es PnL de cartera.

Validación *offline*. La evaluación usa un modelo de ejecución simplificado: no reconstruye la cola orden por orden, y su supuesto central (en un barrido, la orden ejecuta la mitad de lo pendiente) sostiene cerca de dos tercios de las órdenes casadas del simulador *maker*. Ese supuesto, no obstante, ya no está sin contrastar. Sobre 1,1 millones de eventos de barrido observados en la ventana de desarrollo, el flujo agresor consume en media el 47,6 % del tamaño visible del nivel cruzado, frente al 50 % supuesto, y el 98 % del volumen que desaparece en el cruce corresponde a consumo negociado, no a cancelaciones. La calibración no sustituye a una ejecución real: la malla de dos segundos agrega el detalle *intra-frame* y la posición en cola de una orden concreta sigue sin modelar. Acota, eso sí, el supuesto en el rango correcto en lugar de darlo por bueno sin medirlo. El registro de sombra actual es retrospectivo; falta una ejecución prospectiva de mayor fidelidad.

Respuesta competitiva del mercado. Más allá de la fidelidad de la cola, el simulador *maker* hereda una limitación estructural de todo *backtest* basado en reproducción histórica: asume que el resto del mercado (y en particular los creadores de mercado incumbentes) no reacciona a las órdenes propias. En un régimen de recompensas por liquidez, esa hipótesis es optimista, porque una orden *maker* nueva compite por la cola y por el reparto de *rebates* con participantes que ajustarían su comportamiento. Ningún *replay* puede medir esa reacción; hacerlo exige un simulador reactivo, lo que se plantea como línea de trabajo futuro (Capítulo 8).

Manipulación de *settlement*. Dai, Jia y Yu [22] documentan, tras el lanzamiento del contrato de Bitcoin a cinco minutos de Polymarket, que el flujo del mercado al contado se dispara en el instante de resolución y provoca reversiones de precio posteriores, un fenómeno que desaparece en gran medida en los contratos de quince minutos. Como la vía *maker* de este trabajo se concentra por tamaño en los horizontes de una hora y de quince minutos, se auditó si ese patrón aparece en el corpus propio, comparando la reversión del precio de Bitcoin en los instantes de *settlement* frente a instantes placebo emparejados por hora. El patrón direccional aparece con el signo que describe ese trabajo, pero es minúsculo (los contrastes más fuertes quedan entre $-0,2$ y $-0,8$ puntos básicos, con $|t|$ entre 2,1 y 2,3) y ninguno de los seis contrastes sobre el mercado al contado sobrevive la corrección por comparaciones múltiples de Benjamini-Hochberg al 5 %; en los futuros perpetuos la dirección coincide con estadísticos aún menores. El componente de flujo del mecanismo no es medible con esta captura (sus volúmenes son agregados móviles de varios minutos, no cinta instante a instante) y el diseño solo detecta coincidencia temporal, no atribución causal: un efecto genérico de las marcas redondas de tiempo produciría el mismo contraste. La auditoría se queda, por tanto, en una comprobación de robustez favorable a los horizontes empleados, no en una confirmación ni una refutación del mecanismo.

Reproducibilidad parcial. El repositorio permite recalcular las tablas públicas desde el ledger anonimizado y probar la lógica compartida. La reproducción integral del entrenamiento requiere el corpus privado de gran tamaño y se documenta como limitación, no como capacidad publicada.

Patrón en U. Dentro de la baja volatilidad se observa una posible relación en forma de U entre volatilidad y resultado. Como se descubrió en los mismos cinco días, se conserva

solo como hipótesis para trabajo futuro.

Capítulo 7

Reproducibilidad

7.1 Enlace a repositorio GitHub

El código, los registros de resultados y los artefactos públicos de auditoría se mantienen en un repositorio:

<https://github.com/marcmaldonadolorca/polymarket-btc-microstructure>

7.1.1 Estructura del repositorio

El repositorio se organiza en los siguientes directorios:

config/ Umbrales congelados de la política y configuraciones del arco.

docs/ Documentos canónicos del proceso, renumerados de forma secuencial.

notebooks/ Catorce cuadernos pedagógicos (00–13): el arco ejecutado (EDA, particiones, objetivo, línea base, latencia, secuencias, corrección del *score* adverso, especialista y auditoría del ledger) más los cuadernos autocontenidos sobre CSV públicos (EDA de series temporales, baselines clásicos, regímenes, economía maker y fundacionales); cada uno declara qué pregunta responde, qué entradas usa, qué produce y su conclusión, y enlaza su fila de **results/key_results.csv**.

scripts/ Puntos de entrada reproducibles de cada experimento.

src/ Paquete con la lógica compartida (datos, características, modelos, evaluación), con pruebas automatizadas.

results/ Tablas de resultados y ledger anonimizado de 754 unidades de acción.

sql/ Esquema de la consulta base de entrenamiento.

reports/ Esta memoria (fuente LaTeX).

7.1.2 Cómo reproducir

El entorno se prepara con un entorno virtual de Python y la instalación de las dependencias declaradas. Las pruebas automatizadas verifican la lógica de política y sus guardas. El ledger **results/final_candidate_actions_anonymized.csv** permite recalcular las tablas agregadas, los desgloses por régimen y la incertidumbre agrupada sin acceder al

corpus completo. El script que lo genera queda versionado para mantener trazabilidad, aunque su ejecución integral requiere el workspace privado de investigación.

7.1.3 El recolector, y por qué no se publica

Conviene decirlo con claridad porque es el artefacto más sustancial de ingeniería del trabajo y el único que estuvo en producción: el sistema desplegado no fue nunca la política, fue el **recolector**. Un servicio que corrió de forma continua durante meses sobre un ordenador de placa reducida, alineando cuatro fuentes (libro y operaciones del contrato, *spot*, futuro perpetuo y oráculo) sobre una malla fija de dos segundos, con control de calidad por sesión y rechazo de las que no lo superan. Todo lo que este trabajo puede afirmar descansa en él, y las incidencias que acotaron sus ventanas (una reanudación tardía, una desconexión del disco de almacenamiento) están reportadas en el Capítulo 6 precisamente porque son propiedades del instrumento y no del análisis.

Su código **no se publica**, y el motivo no es el tamaño. Está acoplado a la infraestructura privada donde vive (rutas, servicio, almacenamiento y la máquina concreta que lo aloja) y publicarlo exigiría un trabajo de saneamiento que no se ha hecho: separar la lógica de captura de la configuración del entorno y auditar que no arrastra nada del sistema que lo hospeda. Publicar sin ese paso sería peor que no publicar.

Lo que sí se publica es lo que hace falta para reconstruirlo: el **esquema SQL** de la base de captura, que define exactamente qué se guarda y con qué granularidad, y el *pipeline* de procesamiento posterior. Con eso, y con las dos APIs públicas de solo lectura que el recolector consume (el catálogo de contratos y el libro de órdenes), un tercero puede escribir su propio recolector equivalente. No es lo mismo que entregar el binario, y esa diferencia se declara aquí en vez de dejarla implícita: la reproducción posible es la del *método*, no la del *corpus*.

7.1.4 Datos no publicados

El conjunto completo (del orden de 2,5 millones de filas *cross-venue*, más la base de captura) no se publica por tamaño. Tampoco existe un script de descarga que lo sustituya, y el motivo es de naturaleza de los datos: el corpus no procede de una descarga, sino de una captura en tiempo real. La API del libro de órdenes que consume el recolector devuelve la fotografía presente del libro, no su historia, de modo que la serie de libros solo puede obtenerse observándola en el momento; las referencias externas y el flujo de operaciones sí tienen histórico, pero sin el libro alineado no reconstruyen el corpus. Quien quiera un corpus equivalente tiene que capturar una ventana nueva con un recolector como el descrito en la Sección 3.1.1, y esa ventana será otra. En su lugar se incluyen el esquema SQL, un ledger anonimizado suficiente para reproducir las cifras finales y el código del *pipeline*. Esto permite una auditoría parcial, no la reproducción bit a bit del entrenamiento. Declarar esa frontera de forma explícita es parte de la trazabilidad y reduce la deuda técnica propia de estos sistemas [16].

Capítulo 8

Conclusiones

Este trabajo se planteó averiguar si el aprendizaje profundo puede anticipar el movimiento de corto plazo del precio de los contratos binarios sobre Bitcoin de Polymarket y si esa capacidad, en caso de existir, sobrevive a los costes y a la latencia de operar. La respuesta a la primera pregunta es que sí, parcialmente y con matices; la respuesta a la segunda es que no. Lo que da cuerpo a la memoria es el detalle de cómo se ha establecido cada una de esas dos respuestas.

8.1 La conclusión central, alcanzada por cuatro caminos

Una precisión direccional cercana al 90 % no garantiza una política económica. Esta afirmación, que vertebra el trabajo, no descansa sobre una única medición, y su solidez proviene precisamente de que cuatro vías independientes convergen en ella.

La primera es la latencia. Medida como *markout* desde el instante exacto de la señal, la política produce +6,79 ticks de media; en el primer escalón que la malla de captura permite resolver (dos segundos) el resultado ya es negativo. Conviene ser preciso sobre el alcance de este argumento, y el Capítulo 3 lo es: la latencia de ejecución se midió contra el mercado real en unos 430 ms, incluida una orden efectivamente casada, mientras que el escalón de dos segundos es la resolución del instrumento y no una latencia observada. Entre ambos valores no existe ninguna observación, de modo que lo demostrado es que la ventaja no sobrevive a dos segundos, no que muera a los cuatrocientos milisegundos.

La segunda vía es la estructura de comisiones, y es independiente de la anterior. La auditoría del modelo de costes hasta las fuentes primarias reveló un error en la tarifa empleada. Corregido y documentado con marca de tiempo verificable, el resultado es inequívoco: con la tarifa oficial vigente, la comisión media de entrada agota por sí sola el resultado bruto de la señal, sin que la latencia intervenga en el argumento. Ninguna política del lado agresivo del libro es viable bajo ese régimen de costes.

La tercera es la ausencia de retardo explotable en la incorporación de información externa. Si el contrato tardase varios segundos en reflejar los movimientos del subyacente, una latencia inferior al segundo dejaría margen. La correlación cruzada entre el retorno del futuro perpetuo de Bitcoin y la variación posterior del precio del contrato, medida

sobre 841 mercados independientes y quince desfases, no supera 0,004 en ningún caso. El mercado digiere la información más rápido de lo que este montaje permite observar.

La cuarta es la única que llegó por validación prospectiva del lado *taker*, y es la que cierra el argumento con la potencia que a las demás les faltaba. El corte del protocolo general se ejecutó dos veces, cada una sobre la ventana sellada de antemano: la primera hasta el 23 de agosto, sobre cincuenta días y 25.011 unidades de acción; la segunda hasta el 28, sobre cincuenta y cinco días y 27.208. El nivel histórico queda en $-0,004$ y en $+0,075$ ticks respectivamente, con un intervalo que contiene el cero en los dos casos y la deja por tanto indistinguible del azar. Los niveles que cobran la comisión oficial caen entre $-0,69$ y $-3,65$ ticks según el corte, con intervalos que lo excluyen holgadamente en ambos. Su valor no está solo en el signo. Al calcular el intervalo de la cifra de referencia contra la que se iba a comparar, los $+0,349$ ticks de la validación de junio, resultó que **aquella nunca había sido significativa**: $[-0,194; +0,892]$ por filas y $[-0,655; +1,337]$ por mercado. Entre junio y agosto, por tanto, no hay deterioro que explicar: hay una ausencia que antes no podía afirmarse y ahora sí, con más de treinta veces más datos detrás. Lo que el corte aporta es lo que a la validación original le faltaba: potencia suficiente para afirmar la ausencia en lugar de sugerirla.

8.2 Qué hizo y qué no hizo el aprendizaje profundo

La progresión de modelos profundos (arquitecturas recurrentes y convolucionales sobre el libro, auto-atención, y un modelo fundacional de series temporales) aprende representaciones útiles pero no produce una política estable. El modelo fundacional mejora de forma monótona con la adaptación y aun así no alcanza a la deriva ingenua ni a un ARIMA, y la curva de escalado de datos es plana.

Esa conclusión se sometió después a una prueba más exigente que la original, motivada por una limitación detectada en el propio diseño: la curva publicada hacía crecer el número de ventanas de entrenamiento sobre un conjunto fijo de trayectorias, de modo que medía densidad de muestreo y no diversidad. Ampliando el corpus a las tres temporalidades capturadas y llevando el eje hasta agotar los datos disponibles (casi el doble de ventanas de las exploradas originalmente y casi el triple de trayectorias) ninguna de las dos vías, tabular o profunda, se despegaba del azar en la predicción del signo.

De ese experimento surgió además un hallazgo que no se buscaba y que acota el problema mejor que el resultado principal: la definición de la tarea excluye estructuralmente a la mayoría de los mercados capturados. Entre contexto, horizonte y margen de seguridad, cada serie requiere del orden de 376 fotogramas, y la longitud mediana de un mercado de cinco minutos es de 160. Lo que limita el aprendizaje aquí no es solo el régimen de los datos: es la geometría de la tarea, que descarta el 94 % de los mercados antes de que empiece el entrenamiento. Una continuación que quiera aprovechar los mercados de horizonte corto no necesita más datos, necesita redefinir el horizonte de predicción.

Quedaba un eje sin explorar, y cerró el argumento. Todos los modelos anteriores entrenaron contra pérdidas estadísticas y decidieron después con un umbral; la última línea (adenda D, Sección 4.2.8) entrenó por fin la decisión directamente contra el objetivo económico, con el contrafactual exacto de cada acción posible y la propia puerta de riesgo del pre-registro escrita como función de pérdida. El resultado completa la respuesta sobre el aprendizaje profundo por una vía independiente de la arquitectura y de la escala: la

frontera riesgo–rendimiento aprendida queda dominada en sus dieciséis puntos por la de un parámetro escalar bien elegido. El eje de la arquitectura se amplió después con tres modelos más (una LSTM, que cierra la única ablación que faltaba, y las dos familias dominantes hoy en predicción de series temporales) y con cinco semillas por variante: las tres resultan indistinguibles del control tabular, y la mejor de ellas iguala su rendimiento con **trece veces menos parámetros**. Tras agotar los tres ejes (arquitectura, datos y objetivo), la conclusión ya no es que falte capacidad, sino que en este mercado y a esta resolución no hay estructura explotable que una red pueda capturar y un escalar no; que el modelo más pequeño de todos los probados empate con los demás es la forma más directa de decirlo.

8.3 La validación prospectiva

El giro al lado pasivo del libro (motivado por que la misma estructura de comisiones que penaliza a quien cruza el *spread* retribuye a quien provee liquidez) condujo a una política candidata que se sometió a validación prospectiva pre-registrada.

El protocolo se selló criptográficamente antes de observar los datos, con las huellas de los cinco artefactos ejecutables, y se ejecutó una sola vez sobre una ventana de 35 días fijada en el propio sello (que es de la tarde del primer día de esa ventana) y no observada hasta el corte. El resultado es **NO-GO**: la política acumula +3.408\$ simulados, pero su peor día desciende por debajo del umbral de riesgo declarado de antemano, y la regla se aplica sin interpretación.

Conviene precisar qué demuestra y qué no. Lo que demuestra es disciplina: un criterio pre-registrado que solo aprueba no prueba nada, y este rechazó una estrategia económicamente favorable porque violaba una condición escrita antes de mirar. Lo que no demuestra es que la política careciera de valor, y el análisis posterior obliga a decirlo sin rodeos: la puerta estaba prácticamente condenada de antemano. Bajo la dispersión efectivamente observada, el peor día esperado en una ventana de ese tamaño era de −232\$ frente a un umbral de −150, de modo que la probabilidad de fallarla superaba el 60 % *con independencia de la calidad de la política*. Dicho de otro modo: el sub-criterio que firmó el veredicto era el único de los tres que carecía de potencia para distinguir una política buena de una mala, mientras el que sí la tenía (equity neta positiva) se cumplía con holgura. El NO-GO es un resultado sobre el procedimiento, no una medición del valor económico de la estrategia, y presentarlo como lo segundo sería justamente el tipo de confusión que este trabajo intenta evitar.

Una circunstancia externa reforzó involuntariamente la validez del ejercicio: la ventana no se cerró por decisión del autor sino por una desconexión física del almacenamiento del recolector, tres días antes de que se calculara la primera métrica. El punto de corte, por tanto, no pudo verse influido por los datos que iba a revelar.

8.4 Aportaciones

Las aportaciones de este trabajo son metodológicas antes que predictivas.

1. Un sistema de captura multifuente con control de calidad por sesión, operando de forma continua, y el corpus alineado que produce.

2. Un protocolo de evaluación que combina validación estrictamente temporal, un modelo explícito de costes con la tarifa oficial y una latencia medida contra el mercado real, distinguiendo qué parte de ella es medición y cuál es resolución del instrumento.
3. Evidencia cuantitativa, por cuatro caminos independientes, de la ruptura entre predicción y ejecución, incluida una validación prospectiva del lado agresivo con potencia suficiente para afirmar la ausencia de señal, y no solo para sugerirla.
4. Una validación prospectiva pre-registrada y sellada, con resultado negativo reportado íntegro.
5. Una trazabilidad que conserva los resultados negativos y las correcciones de error con la misma dignidad que los positivos, incluida una corrección del modelo de costes documentada con marca de tiempo verificable.

No se afirma rentabilidad real ni se presenta un sistema listo para desplegar.

8.5 Lecciones metodológicas

Un trabajo cuyo objeto es la honestidad estadística debe reportar también dónde falló su propia disciplina. Cinco patrones se repitieron lo suficiente como para merecer mención.

El primero es la fijación de umbrales de decisión sin análisis de potencia. Ocurrió dos veces: el umbral de peor día del pre-registro se declaró en cantidad absoluta, sin advertir que codifica implícitamente una hipótesis sobre la dispersión; y el criterio de separación entre arquitecturas se fijó por debajo del error estándar del propio conjunto de evaluación, de modo que ninguna de sus dos ramas podía establecerse. En ambos casos el umbral se eligió por analogía con una magnitud observada antes, en lugar de derivarlo de la dispersión del estadístico que iba a contrastar. La lección es que el pre-registro es condición necesaria para la honestidad de un experimento, pero no suficiente para su potencia.

El segundo es la confusión entre un oráculo y una política. En dos ocasiones un análisis sugirió un margen de mejora considerable que, examinado, resultaba proceder de conocer por anticipado qué operaciones perderían dinero y evitarlas. Un techo calculado con información del futuro no acota lo que un modelo puede lograr; solo acota lo que lograría alguien que ya conoce el resultado.

El tercero es que un resultado nulo puede estar midiendo el instrumento y no el fenómeno. La primera frontera riesgo–rendimiento de la adenda D devolvió dieciséis puntos idénticos hasta el último decimal; la reacción correcta no fue aceptar el “no aporta” (que era la conclusión cómoda y esperada) sino instrumentar el optimizador, que reveló *logits* saturados con gradiente del orden de 10^{-6} : la política no elegía la constante, estaba congelada en ella. Solo tras corregirlo y comprobar que la política se movía, el mismo veredicto negativo pasó a ser evidencia. Un resultado demasiado exacto es una alarma, no una confirmación.

El cuarto es que la unidad de análisis correcta depende de la pregunta. La regla de un *token* por mercado es obligada al contar muestras independientes en un contraste estadístico, y esa misma regla, trasladada a una evaluación económica, fabricó un falso cumplimiento de la puerta de riesgo: en la operativa se cotizan los dos *tokens* y el umbral se calibró sobre el libro completo, de modo que evaluar con medio libro reducía el peor día por construcción. La regla no era incorrecta; estaba aplicada a la pregunta equivocada.

El quinto afecta al cruce entre fuentes de datos. Los fallos de alineación temporal no producen errores: producen tablas vacías, o casi vacías, que superficialmente parecen re-

sultados. En este trabajo un desajuste entre dos relojes con precisiones distintas devolvió una tabla completa de correlaciones que no significaba nada, y su única señal de alarma fue que los valores eran demasiado exactos. Todo cruce entre fuentes debe asertarse, nunca suponerse.

8.6 Trabajo futuro

La continuación inmediata es la validación de las conclusiones de política sobre la ventana de captura posterior al corte, que permanece sin observar y crece cada día.

Una segunda línea, más ambiciosa, ataca la limitación estructural del simulador *maker*: su incapacidad para medir la respuesta competitiva del mercado (Capítulo 6). La reproducción histórica trata el libro como un decorado inerte; capturar cómo reaccionarían los creadores de mercado incumbentes a las órdenes propias exige un simulador *reactivo*. La línea de simuladores generativos de libros de órdenes de los últimos años ofrece el instrumental: modelos de “agente mundo” que aprenden de datos históricos una dinámica del libro capaz de reproducir cierto impacto de mercado [37], modelos generativos autorregresivos del flujo de mensajes a nivel de *token* [38] y, más recientemente, modelos de difusión para la simulación y predicción del libro [39]; una revisión reciente sistematiza el campo [40]. Integrar uno de estos simuladores con la política congelada de este trabajo permitiría estimar la selección adversa y el reparto de *rebates* bajo competencia, y no bajo el supuesto optimista de la reproducción histórica. Tiene además una motivación cuantificada: el supuesto de ejecución sostiene cerca de dos tercios de las órdenes casadas del simulador y hoy no puede contrastarse contra nada.

Finalmente, la limitación de resolución temporal del instrumento sugiere una tercera línea: capturar el libro a una frecuencia sensiblemente mayor permitiría observar el intervalo entre cero y dos segundos, donde vive la latencia de ejecución realmente medida y que este trabajo no ha podido explorar. Esa línea exigiría además migrar el camino caliente de la captura y de la ejecución de Python a un lenguaje compilado como C++ o Rust. La ventaja no es genérica sino específica de este cuello: sin recolector de basura ni bloqueo global del intérprete, las colas de mensajes se procesan con latencias del orden de microsegundos y, sobre todo, *predecibles* (en el camino medido aquí, la varianza de la latencia importa tanto como su media). No haría falta partir de cero: existen conectores y motores de libro de órdenes maduros en ambos lenguajes (el ecosistema de *trading* cuantitativo de código abierto en Rust es hoy notablemente activo), de modo que el trabajo propio se concentraría en el cliente de la API de Polymarket y en la lógica de decisión, manteniendo en Python el análisis y el entrenamiento, donde la latencia no manda.

La regla que guió el proyecto permanece: la complejidad y cualquier afirmación económica deben ganarse su sitio con evidencia verdaderamente nueva.

Referencias

- [1] Polymarket. (2026). *Prices & Orderbooks* [Documentación]. <https://docs.polymarket.com/polymarket-learn/trading/using-the-orderbook> (Recuperado el 14 de junio de 2026).
- [2] Polymarket. (2026). *Order Lifecycle* [Documentación]. <https://docs.polymarket.com/concepts/order-lifecycle> (Recuperado el 14 de junio de 2026).
- [3] Polymarket. (2026). *Trading Fees* [Documentación]. <https://docs.polymarket.com/trading/fees> (Recuperado el 18 de julio de 2026; recoge la fórmula oficial $\text{fee} = r p (1 - p) \cdot \text{shares}$ con $r = 0,07$ y el reparto del 20 % a proveedores de liquidez.)
- [4] Wolfers, J., & Zitzewitz, E. (2004). Prediction Markets. *Journal of Economic Perspectives*, 18(2), 107–126.
- [5] Zhang, Z., Zohren, S., & Roberts, S. (2019). DeepLOB: Deep Convolutional Neural Networks for Limit Order Books. *IEEE Transactions on Signal Processing*, 67(11), 3001–3012.
- [6] Ntakaris, A., Magris, M., Kannianen, J., Gabbouj, M., & Iosifidis, A. (2018). Benchmark dataset for mid-price forecasting of limit order book data with machine learning methods. *Journal of Forecasting*, 37(8), 852–866.
- [7] Tsantekidis, A., Passalis, N., Tefas, A., Kannianen, J., Gabbouj, M., & Iosifidis, A. (2017). Using deep learning to detect price change indications in financial markets. *European Signal Processing Conference (EUSIPCO)*.
- [8] Sirignano, J., & Cont, R. (2019). Universal features of price formation in financial markets: perspectives from deep learning. *Quantitative Finance*, 19(9), 1449–1459.
- [9] Jha, R., et al. (2020). Deep Learning for Digital Asset Limit Order Books. *arXiv:2010.01241*.
- [10] Kearns, M., & Nevmyvaka, Y. (2013). Machine Learning for Market Microstructure and High Frequency Trading. In *High Frequency Trading: New Realities for Traders, Markets and Regulators*.
- [11] Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *The Review of Financial Studies*, 33(5), 2223–2273.
- [12] López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- [13] Bailey, D. H., & López de Prado, M. (2014). The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality. *The Journal of Portfolio Management*, 40(5), 94–107.

-
- [14] Sun, B., Feng, J., & Saenko, K. (2016). Return of Frustratingly Easy Domain Adaptation. *AAAI Conference on Artificial Intelligence*.
 - [15] Lim, B., Arik, S. O., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting. *International Journal of Forecasting*, 37(4), 1748–1764.
 - [16] Sculley, D., et al. (2015). Hidden Technical Debt in Machine Learning Systems. *Advances in Neural Information Processing Systems (NeurIPS)*.
 - [17] Dubach, P. D. (2026). The Anatomy of a Decentralized Prediction Market: Microstructure Evidence from the Polymarket Order Book. *arXiv:2604.24366*.
 - [18] Tsang, K. P., & Yang, Z. (2026). The Anatomy of a Blockchain Prediction Market: Polymarket in the 2024 U.S. Presidential Election. *arXiv:2603.03136*.
 - [19] Cheng, G., Yang, J., & Zou, H. (2026). Arbitrage Analysis in Polymarket NBA Markets. *arXiv:2605.00864*.
 - [20] Nechepurenko, M. (2026). Fill-Side Behavioral Concentration on Polymarket: Identification Limits under Record-Level Attribution. *arXiv:2605.11640*. (Título de la revisión v2, consultada el 30 de julio de 2026.)
 - [21] Qin, B., & Yang, R. (2026). Polymarket-v1 Database. *arXiv:2606.04217*.
 - [22] Dai, D., Jia, R., & Yu, S. (2026). Settlement Manipulation in Prediction Markets. *arXiv:2606.31675*.
 - [23] Berti, L., & Kasneci, G. (2025). TLOB: A Novel Transformer Model with Dual Attention for Price Trend Prediction with Limit Order Book Data. *arXiv:2502.15757*.
 - [24] Goswami, M., Szafer, K., Choudhry, A., Cai, Y., Li, S., & Dubrawski, A. (2024). MOMENT: A Family of Open Time-series Foundation Models. *International Conference on Machine Learning (ICML)*.
 - [25] Ansari, A. F., et al. (2024). Chronos: Learning the Language of Time Series. *Transactions on Machine Learning Research*.
 - [26] Das, A., Kong, W., Sen, R., & Zhou, Y. (2024). A Decoder-only Foundation Model for Time-series Forecasting. *International Conference on Machine Learning (ICML)*.
 - [27] Liu, C., Aksu, T., Liu, J., Liu, X., Yan, H., Pham, Q., Savarese, S., Sahoo, D., Xiong, C., & Li, J. (2025). Moirai 2.0: When Less Is More for Time Series Forecasting. *arXiv:2511.11698*.
 - [28] Hollmann, N., Müller, S., Purucker, L., Krishnakumar, A., Körfer, M., Hoo, S. B., Schirrmeister, R. T., & Hutter, F. (2025). Accurate predictions on small data with a tabular foundation model. *Nature*, 637, 319–326.
 - [29] Dong, J., Wu, H., Zhang, H., Zhang, L., Wang, J., & Long, M. (2023). SimMTM: A Simple Pre-Training Framework for Masked Time-Series Modeling. *Advances in Neural Information Processing Systems (NeurIPS)*.
 - [30] Yue, Z., Wang, Y., Duan, J., Yang, T., Huang, C., Tong, Y., & Xu, B. (2022). TS2Vec: Towards Universal Representation of Time Series. *AAAI Conference on Artificial Intelligence*.

-
- [31] Lee, S., Park, T., & Lee, K. (2024). Soft Contrastive Learning for Time Series. *International Conference on Learning Representations (ICLR)*.
 - [32] Dong, J., Wu, H., Wang, Y., Qiu, Y., Zhang, L., Wang, J., & Long, M. (2024). TimeSiam: A Pre-Training Framework for Siamese Time-Series Modeling. *International Conference on Machine Learning (ICML)*.
 - [33] Wang, D., Cheng, M., Liu, Z., & Liu, Q. (2025). TimeDART: A Diffusion Autoregressive Transformer for Self-Supervised Time Series Representation. *International Conference on Machine Learning (ICML)*.
 - [34] Harvey, C. R., Liu, Y., & Zhu, H. (2016). ...and the Cross-Section of Expected Returns. *The Review of Financial Studies*, 29(1), 5–68.
 - [35] Nosek, B. A., Ebersole, C. R., DeHaven, A. C., & Mellor, D. T. (2018). The pre-registration revolution. *Proceedings of the National Academy of Sciences*, 115(11), 2600–2606.
 - [36] Todd, P. (2016). *OpenTimestamps: Scalable, Trust-Minimized, Distributed Timestamping with Bitcoin* [Documentación]. <https://opentimestamps.org> (Recuperado el 13 de julio de 2026).
 - [37] Coletta, A., Moulin, A., Vyetrenko, S., & Balch, T. (2022). Learning to Simulate Realistic Limit Order Book Markets from Data as a World Agent. *3rd ACM International Conference on AI in Finance (ICAIF)*. *arXiv:2210.09897*.
 - [38] Nagy, P., Frey, S., Sapora, S., Li, K., Calinescu, A., Zohren, S., & Foerster, J. (2023). Generative AI for End-to-End Limit Order Book Modelling: A Token-Level Autoregressive Generative Model of Message Flow Using a Deep State Space Network. *arXiv:2309.00638*.
 - [39] Backhouse, A., Li, K., Foerster, J., Calinescu, A., & Zohren, S. (2025). Painting the Market: Generative Diffusion Models for Financial Limit Order Book Simulation and Forecasting. *arXiv:2509.05107*.
 - [40] Jain, K., Firoozye, N., Kochems, J., & Treleaven, P. (2024). Limit Order Book Simulations: A Review. *arXiv:2402.17359*.
 - [41] Avellaneda, M., & Stoikov, S. (2008). High-frequency Trading in a Limit Order Book. *Quantitative Finance*, 8(3), 217–224.
 - [42] Guéant, O., Lehalle, C.-A., & Fernandez-Tapia, J. (2013). Dealing with the Inventory Risk: A Solution to the Market Making Problem. *Mathematics and Financial Economics*, 7(4), 477–507.
 - [43] Feil, D., & Nendel, M. (2026). Optimal Market Making in Prediction Markets. *arXiv:2607.17991*.
 - [44] Rahman, N., Al-Chami, J., & Clark, J. (2026). SoK: Market Microstructure for Decentralized Prediction Markets (DePMs). *arXiv:2510.15612*.
 - [45] Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation. *Proceedings of EMNLP 2014*, 1724–1734.
 - [46] Bai, S., Kolter, J. Z., & Koltun, V. (2018). An Empirical Evaluation of Generic

- Convolutional and Recurrent Networks for Sequence Modeling. *arXiv:1803.01271*.
- [47] Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). Are Transformers Effective for Time Series Forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(9), 11121–11128.
- [48] Nie, Y., Nguyen, N. H., Sinthong, P., & Kalagnanam, J. (2023). A Time Series is Worth 64 Words: Long-term Forecasting with Transformers. *International Conference on Learning Representations (ICLR)*.
- [49] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30, 5998–6008.

Conjunto de características

El especialista final emplea 36 características causales sin variables de reloj (*no_clock*), agrupadas por bloques:

- **Estado local del libro de Polymarket:** precio medio, *spread*, microprice, desbalance de órdenes, coste visible de entrada y deltas recientes del precio.
- **Referencias externas:** retornos orientados del mercado al contado y de los futuros perpetuos a 2 y 8 segundos; medidas de consenso y de actualización.
- **Volatilidad:** volatilidad realizada del perpetuo a 5 segundos, usada en el diagnóstico posterior de cambio de régimen.
- **Contexto de ventana:** fase de la ventana *prestart* y proxies de calidad del libro (cobertura, indicadores de degradación).

Se excluyen deliberadamente las variables de reloj (hora, minuto, segundo) para evitar que el modelo aprenda atajos temporales triviales.

Hiperparámetros de los modelos

Tabla 1: Hiperparámetros principales del especialista (HistGradientBoosting, dos cabezas).

Hiperparámetro	Valor
Tasa de aprendizaje	0,045
Iteraciones máximas	220 (con parada anticipada)
Fracción de validación interna	0,15
Máximo de hojas por árbol	15
Mínimo de muestras por hoja	120
Regularización L2	0,10

Tabla 2: Hiperparámetros principales de los modelos profundos (línea de exploración).

Hiperparámetro	Valor
Optimizador	AdamW
Tasa de aprendizaje	0,0015
Decaimiento de pesos	10^{-4}
Tamaño de lote	192
Paciencia (parada anticipada)	18 épocas
Dimensión oculta de la GRU	56
<i>Dropout (BookEncoder)</i>	0,08

Tabla 3: Hiperparámetros de los modelos fundacionales evaluados.

Hiperparámetro	MOMENT (ajuste)	TabPFN (<i>zero-shot</i>)
Modelo base	MOMENT-1-small	TabPFN v2
Modo	<i>linear probe</i>	sin entrenamiento
Ventana de contexto	512 pasos	10.000 filas (tope)
Optimizador	AdamW	—
Épocas	15	—
Ventanas de entrenamiento	40.758	—
Semilla	20260714	20260713

El especialista base congelado opera con dos umbrales: valor esperado predicho superior a 0,75 y probabilidad de salud no inferior a 0,50. Tras el diagnóstico del bloque fuera de muestra se propone una política futura que exige, además, volatilidad realizada a 5

segundos no superior a 0,6657 (percentil 80 del entrenamiento). La incertidumbre exploratoria se estima con 5 000 remuestreos y semilla fija, tanto por filas como agrupando por mercado.

Pre-registro v2 y verificación del sello

Este anexo reproduce el compromiso de pre-registro que sostiene la validación prospectiva del Capítulo 4 y detalla cómo verificarlo de forma independiente. El documento íntegro vive en el repositorio (`docs/PREREGISTRO_V2.md`); aquí se resume su contenido comprobable.

Política congelada

La señal y la política se fijaron en el entrenamiento de mayo y no se han modificado desde entonces: universo *prestart* estricto (-60 a -45 s respecto a la apertura, $spread \leq 2$ ticks, libro saludable, coste visible acotado), dos cabezas de *gradient boosting* sobre el conjunto de características *no_clock*, y regla de operación “valor esperado $> 0,75$ y salud $\geq 0,5$ ”. La integridad de los artefactos se ancla con sus resúmenes SHA-256, incluidos literalmente en el pre-registro (modelos de valor esperado y de salud, manifiesto de características y filtro de régimen GARCH congelado).

Variantes de filtro de régimen y niveles de reporte

Se comprometieron por adelantado tres variantes de filtro de régimen (la estática heredada, un GARCH(1,1) ajustado solo con datos anteriores a junio y el clustering de regímenes de la adenda A) y tres niveles de reporte que se publican todos: `net@0,5` histórica, `taker` con comisión oficial (con expectativa *declarada como negativa* antes de mirar los datos) y `maker` simulado. Declarar la expectativa negativa por adelantado es lo que convierte el resultado `taker` en una confirmación y no en una racionalización *a posteriori*.

Cortes prospectivos

Los datos elegibles son la captura de la P_i posterior a la reanudación del recolector, procesados con el mismo *pipeline* congelado. Se fijaron dos cortes (el primero a finales de agosto, el segundo justo antes de la entrega) sin ningún vistazo intermedio a las métricas de resultado.

Verificación independiente del sello temporal

El compromiso se ancla en la cadena de Bitcoin mediante OpenTimestamps [36]. Para verificarlo sin confiar en el autor:

1. Obtener el *commit* del repositorio que introduce el pre-registro y su prueba *.ots* asociada (`docs/prereg_v2_commit.ots`).
2. Ejecutar `ots verify docs/prereg_v2_commit.ots`: la herramienta consulta un nodo de Bitcoin y confirma el bloque (y por tanto la fecha) en que quedó atestado el resumen del documento.
3. Comprobar que esa fecha es anterior al primer dato de la ventana de evaluación prospectiva. Como la atestación de Bitcoin no puede retro-fecharse, la anterioridad del compromiso queda demostrada sin necesidad de confiar en la palabra del autor ni en un sello privado.

Una corrección posterior (la del modelo de comisiones, Sección 3.4.5) se selló con el mismo procedimiento, de modo que la cadena de compromisos es completa y auditable.

Auditoría del ledger público

Las cifras económicas centrales del trabajo pueden recalcularse de forma independiente sin acceso al corpus privado ni a los modelos entrenados, a partir de un único fichero anonimizado que se publica con el código: el ledger de acciones candidatas (`results/final_candidate_actions_anonymized.csv`). Este anexo describe su contenido y el procedimiento de auditoría.

Contenido del ledger

El ledger contiene una fila por unidad de acción del bloque fuera de muestra (754 filas). Cada fila registra un identificador de acción, el día de sesión, los identificadores de mercado y de contrato *anonimizados* mediante *hash* (de modo que no se pueda reconstruir la identidad del mercado), el instante relativo a la apertura, el régimen de volatilidad (*high/low*) y el resultado neto en ticks a tres niveles de coste de ejecución (medio tick de referencia, y las variantes de un cuarto y de un tick completo). No incluye características del modelo ni datos crudos: es exactamente la información necesaria para auditar el resultado, y nada más.

Procedimiento de reproducción

Con solo ese fichero y una utilidad de análisis de datos, la auditoría reproduce las tres cifras que sostienen las conclusiones económicas:

1. **Resultado confirmatorio.** La media del resultado neto al coste de referencia sobre las 754 acciones (241 mercados, cinco días) es de +0,349 ticks por acción, idéntica a la cifra publicada. Bajo el coste conservador de un tick completo el promedio cae a -0,026: la señal no sobrevive al coste de estrés.
2. **Diagnóstico *post-hoc* de baja volatilidad.** Restringiendo a las 318 acciones de régimen de baja volatilidad (156 mercados), la media asciende a +1,069 ticks. Se recuerda que esta separación se decidió tras inspeccionar el bloque, por lo que es una hipótesis, no una segunda validación.
3. **Incertidumbre agrupada por mercado.** Un *bootstrap* que remuestrea mercados enteros (para no tratar como independientes las hasta ocho señales solapadas de un mismo mercado) sitúa el intervalo de confianza del 90 % del corte de baja volatilidad en [+0,193, +2,004] ticks: positivo pero ancho, coherente con el escaso soporte temporal.

El cuaderno `08_auditoria_final_ledger` ejecuta estos tres cálculos paso a paso y constituye la vía pública más directa para verificar el resultado final del trabajo con indepen-

dencia del autor.

Análisis de soporte de los resultados

Este anexo recoge dos análisis que sostienen conclusiones del Capítulo 4 pero cuyo detalle no pertenece al hilo principal: el diagnóstico del fallo fuera de muestra de la cabeza de salud y la tabla completa de la adenda C.

.1 Diagnóstico del fallo fuera de muestra

La debilidad conocida de la pieza sellada es la cabeza de salud (*healthy*): su capacidad de discriminación cae del entrenamiento a la validación de forma acusada (AUC $0,79 \rightarrow 0,56$). Conviene explicar *por qué*, porque la causa determina si un reentrenamiento con más datos tiene techo. Se descompone la incertidumbre con un ensemble de semillas (la técnica que en redes profundas se conoce como *deep ensemble*, aplicada aquí a la cabeza de *gradient boosting*): diez réplicas de la misma cabeza entrenadas con semillas distintas, midiendo tanto su rendimiento por partición como su desacuerdo mutuo (véase la Figura 1).

El diagnóstico es inequívoco en tres puntos. Primero, la caída fuera de muestra es *estable entre semillas* (la desviación del AUC entre réplicas es de apenas $\pm 0,005$), de modo que no es un artefacto de suerte en la inicialización: todas las réplicas coinciden en que la cabeza falla en junio. Segundo, el desacuerdo entre réplicas es *prácticamente constante* entre entrenamiento y test ($\approx 0,03$ en ambos): la incertidumbre epistémica no aumenta fuera de muestra, así que las réplicas no extrapolan de forma dispersa, sino que convergen con confianza a una función que simplemente no separa las clases en junio; promediarlas apenas mueve el AUC ($0,544 \rightarrow 0,547$), lo que descarta que el problema sea de varianza. Tercero, un clasificador de dominio entrenado para distinguir mayo de junio a partir de las mismas características lo consigue con AUC 0,90: las distribuciones de entrada se desplazan de forma marcada entre los dos periodos, encabezadas por la base del perpetuo (*perp_basis*) y la estructura de diferencias al contado-perpetuo.

La conclusión es que el fallo de la cabeza de salud no es ruido irreducible ni un problema de capacidad del modelo, sino *concept drift* inducido por un cambio de régimen en las variables externas de Bitcoin. Esto tiene una consecuencia práctica directa para la iteración v2: reentrenar con dos o tres veces más datos del mismo periodo tiene techo, porque el obstáculo no es el tamaño de la muestra sino la cobertura del régimen; solo datos que abarquen el régimen de junio mejorarían la generalización. Es la misma lección que ya apuntaba el fracaso de las técnicas de adaptación de dominio: contra un cambio de régimen con pocos días, restringir la operativa al régimen conocido es más honesto que pretender corregirlo.




Figura 1: Diagnóstico del fallo fuera de muestra de la cabeza de salud. Izquierda: el AUC se desploma de entrenamiento a test con una dispersión mínima entre las diez réplicas (barras de error) y un desacuerdo entre réplicas plano (línea naranja) (el fallo es estable y no es epistémico). Derecha: un clasificador de dominio separa mayo de junio con AUC 0,90, señal de un fuerte desplazamiento de covariables encabezado por la base del perpetuo.

.2 Adenda C: tabla completa del escalado sobre trayectorias

La Tabla 4 recoge los ocho puntos del experimento.

Detectada la limitación anterior, se diseñó y **pre-registró** un experimento que varía exactamente el eje que faltaba y ningún otro. El protocolo se selló antes de entrenar ningún modelo, con las huellas criptográficas de los tres artefactos ejecutables y una marca de tiempo de OpenTimestamps, y con las dos redacciones posibles del resultado escritas de antemano para que ninguna rama pudiera elegir la narración.

El corpus se amplió a las tres temporalidades capturadas sobre *los mismos 24 días*: 7.784 mercados y 15.568 pares mercado-token, frente a los 509 y 1.018 originales. Una restricción física obliga a un cambio: la rejilla es de dos segundos, de modo que un mercado de cinco minutos apenas alcanza los 150 fotogramas y el contexto de 512 de la curva publicada no cabe en él. Se fijó por tanto un contexto de **128 fotogramas en todas las variantes**, incluida la de una hora; reducirlo solo en la variante ampliada habría confundido longitud de contexto con número de trayectorias. Las cuatro variantes (tabular y profundo, con y sin temporalidades cortas) se evalúan sobre *los mismos* 916 casos held-out de mercados horarios, que es la comparación conservadora: la variante ampliada no puede beneficiarse de un conjunto de prueba más benévolo. (Este conjunto pertenece al corpus reconstruido para la adenda y no coincide con los 906 casos congelados de la escalera; por eso sus cifras no son comparables celda a celda con las de aquella.)

Aplicada literalmente, la regla pre-registrada activa la rama principal: la variante profunda no supera al tabular por más de un punto porcentual en ningún punto del eje, de modo que la conclusión publicada no queda declarada artefacto del diseño muestral.

Pero la lectura honesta del experimento es más severa que su propia regla, y conviene decirlo con claridad: **ninguno de los ocho puntos se distingue del azar**. Todos los

Tabla 4: Curva de escalado sobre trayectorias independientes. Acierto sobre los mismos 916 casos held-out para las cuatro variantes, con intervalo de confianza binomial al 95 %. El punto inferior de cada bloque agota el *pool* disponible y llega a 1,65–1,88 veces el máximo que la curva publicada había explorado.

Variante	n_{train}	Trayect.	Acierto	IC 95 %
Tabular, solo 1h	45.000	950	50,55 %	[47,26; 53,83]
Profundo, solo 1h	45.000	950	49,56 %	[46,28; 52,85]
Tabular, 1h+15m+5m	45.000	2.685	50,87 %	[47,58; 54,16]
Profundo, 1h+15m+5m	45.000	2.685	49,45 %	[46,17; 52,74]
Tabular, solo 1h	74.218	952	49,45 %	[46,17; 52,74]
Profundo, solo 1h	74.218	952	48,03 %	[44,76; 51,33]
Tabular, 1h+15m+5m	84.438	2.834	49,78 %	[46,49; 53,07]
Profundo, 1h+15m+5m	84.438	2.834	48,91 %	[45,62; 52,20]

intervalos de confianza contienen el 50 % y el contraste binomial frente a esa hipótesis no baja de $p = 0,25$ en ningún caso. La regla de decisión exigía separar las variantes por un punto porcentual cuando el error estándar del acierto sobre 916 casos es de 1,65 puntos y el intervalo de una diferencia entre dos variantes alcanza los 4,6: el umbral se declaró *por debajo del suelo de ruido* del propio conjunto de evaluación. Ninguna de las dos ramas del pre-registro podía, por tanto, quedar establecida con estos datos.

Es la segunda vez en este trabajo que un criterio de decisión se declara en unidades absolutas sin el análisis de potencia que le corresponde (la primera fue el umbral de peor día de la Sección 4.1.4) y la coincidencia no es casual: en ambos casos el umbral se fijó por analogía con una magnitud observada antes, y no derivándolo de la dispersión del estadístico que iba a contrastar. Queda como advertencia metodológica para cualquier continuación, y explica por qué el pre-registro, siendo condición necesaria para la honestidad de un experimento, no es condición suficiente para su poder.

Lo que sí puede afirmarse sin ambigüedad es lo negativo, y no es poco: llevando el eje hasta agotar el *pool* (1,88 veces más ventanas de las que la curva publicada llegó a explorar, y casi el triple de trayectorias independientes) **ninguna de las dos vías consigue despegarse del azar en la predicción del signo a H60**. El resultado es coherente con el diagnóstico independiente del Capítulo 3, donde se estableció que el precio medio es esencialmente una moneda al aire en la apertura de la ventana. La comparación entre arquitecturas se estaba dirimiendo, en realidad, entre dos modelos que no resuelven la tarea.

.3 Ampliación del triaje de arquitecturas

La Sección 3.4.7 resume el resultado; aquí va la tabla completa. Diez variantes por cinco semillas, todas en un único entorno de cómputo (el control de reproducción descrito allí obliga a no mezclar plataformas). Las corridas y su protocolo sellado están en ‘data/experiments/triaje_ampliado_v1/’.

Tabla 5: Ampliación del triaje: diez variantes $\times$ cinco semillas en un único entorno. ρ es la correlación de Spearman sobre el bloque terminal, con su desviación entre semillas. “Caída” es la pérdida de AUC de validación a test. Las tres últimas filas del primer bloque son las arquitecturas nuevas.

Variante	Par.	AUC val	AUC test	Caída	ρ test
<i>Con características tabulares</i>					
DLinear (<i>nuevo</i>)	1.364	0,571	0,552	0,019	0,135 $\pm$ 0,004
LSTM (<i>nuevo</i>)	23.618	0,563	0,554	0,009	0,132 $\pm$ 0,006
PatchTST-lite (<i>nuevo</i>)	10.243	0,567	0,549	0,018	0,132 $\pm$ 0,006
Control tabular (GRU)	18.186	0,564	0,555	0,010	0,132 $\pm$ 0,002
Fusión, concatenación	42.874	0,561	0,551	0,010	0,128 $\pm$ 0,007
Fusión, dual	34.190	0,564	0,551	0,013	0,126 $\pm$ 0,006
<i>Solo libro de órdenes</i>					
Atención, última foto	22.106	0,573	0,523	0,050	0,050 $\pm$ 0,013
Atención, secuencia	53.890	0,569	0,518	0,050	0,041 $\pm$ 0,014
BookEncoder + GRU	29.946	0,555	0,529	0,026	0,032 $\pm$ 0,009
BookEncoder Conv1d	9.986	0,559	0,526	0,033	0,026 $\pm$ 0,010

.4 Figuras del diagnóstico *post-hoc* de régimen

Sensibilidad al coste y desglose diario del subconjunto de baja volatilidad. Ambas describen un subconjunto elegido tras observar el bloque, de modo que su lectura es diagnóstica y no confirmatoria.




Figura 2: Sensibilidad al coste del subconjunto de baja volatilidad. Resultado exploratorio obtenido tras inspeccionar el mismo bloque.

.5 Registro de sombra retrospectivo

Para auditar la mecánica de la política candidata se construyó un registro de sombra *offline*: conserva cada unidad de acción, su mercado, el resumen diario y las reglas de promoción. Es una reproducción retrospectiva de lo que la regla habría indicado, no una ejecución prospectiva ni un sistema activo en tiempo real. El filtro queda congelado después del 10 de junio; solo observaciones posteriores pueden contar para las puertas de promoción.

Además, varias señales pertenecen al mismo mercado y sus horizontes H60 se solapan. Por ello se denominan *unidades de acción*, no operaciones independientes, y la suma




Figura 3: Neto medio diario del subconjunto *post-hoc* de baja volatilidad.

acumulada no incorpora una regla de exposición máxima. Una futura sombra prospectiva deberá decidir si permite apilar posiciones o admite una sola posición por mercado.