



UNIVERSIDAD
POLITÉCNICA
DE MADRID



Máster
Deep Learning
Universidad Politécnica de Madrid

**Aprendizaje profundo aplicado a la
microestructura de mercados de predicción:
predicción de corto plazo en mercados de
Bitcoin de Polymarket**

**MÁSTER DE FORMACIÓN
PERMANENTE
EN DEEP LEARNING**

Presentado por:

Marc Maldonado Lorca

Bajo la dirección de:

Dra. María Inmaculada Santamaría Valenzuela

Madrid, 2026

Título: Aprendizaje profundo aplicado a la microestructura de mercados de predicción:
predicción de corto plazo en mercados de Bitcoin de Polymarket

Autor: Marc Maldonado Lorca

Máster de Formación Permanente en Deep Learning

Universidad Politécnica de Madrid

Dirección de Tesis:

Dra. María Inmaculada Santamaría Valenzuela, Universidad Politécnica de Madrid
(Directora)

Agradecimientos

Quiero agradecer especialmente a mi amigo Ramón, que me introdujo en este mundo y sin cuya curiosidad inicial este trabajo no habría existido. Gracias también a mi directora por su guía a lo largo del proyecto, y a mi familia y amigos por su apoyo durante el máster.

Abstract

This work studies whether deep learning can exploit market microstructure signals to anticipate the short-term price movement of binary contracts on Bitcoin traded on Polymarket, a prediction market. Unlike the literature focused on how the event finally resolves, here we target the local movements of the contract price over windows of a few seconds, combining the order book with external Bitcoin market references (spot, perpetual futures and a price oracle). The main contribution is not a single model but a reproducible methodology: a multi-source data capture system with per-session quality control, strictly temporal validation, and an evaluation that incorporates realistic execution costs and latency. The central, uncomfortable finding is that a directional classifier that is correct nearly nine out of ten times stops being profitable once a realistic two-second entry latency is introduced: what decides the outcome is cost and execution, not directional accuracy. Building on this, we evaluate a progression of models (tabular baselines, latency-aware models, and sequential and convolutional architectures over the order book) and a frozen tabular specialist. On the untouched five-day out-of-sample block, the specialist obtains a modest positive mean at the reference cost (+0.349 ticks per action, 754 actions and three out of five positive days), but turns slightly negative under the full-cost stress test. A volatility filter, whose numerical threshold came from the training period, is then explored after detecting a regime shift; it improves the result on the same block, so it is reported as a post-hoc diagnostic rather than as confirmatory evidence. Two further results complete the arc. First, a correction of the cost model—documented as a cryptographically timestamped erratum—shows that under Polymarket’s official 2026 fee schedule no taker cut remains profitable, which confirms the thesis structurally and shifts the viable economic vehicle to the maker side: the same fee structure that taxes the taker pays the passive liquidity provider, whose economics are quantified with a queue-and-fill simulator over the captured L2 book. Second, a ladder of reference models shows that a time-series foundation model (MOMENT) improves monotonically with adaptation yet never beats naive drift or ARIMA, with a flat data-scaling curve: the ceiling is set by the data regime, not by model capacity. The evaluation protocol—frozen candidate, pre-committed gate arms and a taker expectation declared negative in advance—is pre-registered and timestamped on the Bitcoin blockchain, making its priority over the evaluation window independently verifiable. We report every figure in net ticks together with its support and uncertainty, and we do not claim real profitability: the deliverable is the methodology, the evidence obtained under an auditable protocol, and the explicit delimitation of its limits.

Resumen

Este trabajo estudia si el aprendizaje profundo puede aprovechar señales de microestructura de mercado para anticipar el movimiento de corto plazo del precio de los contratos binarios sobre Bitcoin negociados en Polymarket, un mercado de predicción. A diferencia de la literatura centrada en cómo se resuelve finalmente el evento, aquí el objetivo son los movimientos locales del precio del contrato en ventanas de pocos segundos, combinando el libro de órdenes con referencias externas del mercado de Bitcoin (contado, futuros perpetuos y un oráculo de precios). La aportación principal no es un modelo concreto, sino una metodología reproducible: un sistema de captura de datos multifuente con control de calidad por sesión, una validación estrictamente temporal y una evaluación que incorpora costes de ejecución y latencia realistas. El hallazgo central, y algo incómodo, es que un clasificador direccional que acierta casi nueve de cada diez veces deja de ser rentable en cuanto se introduce una latencia de entrada realista de dos segundos: lo que decide el resultado es el coste y la ejecución, no el acierto direccional. A partir de ahí se evalúa una progresión de modelos (líneas base tabulares, modelos sensibles a la latencia y arquitecturas secuenciales y convolucionales sobre el libro de órdenes) y un especialista tabular congelado. En el bloque intacto de cinco días fuera de muestra, el especialista obtiene un promedio modestamente positivo al coste de referencia (+0,349 ticks por acción, 754 acciones y tres de cinco días positivos), pero pasa a ser ligeramente negativo bajo el coste de estrés completo. Tras detectar un cambio de régimen se explora un filtro de volatilidad cuyo umbral numérico procede del entrenamiento; como la decisión de incorporarlo se evalúa sobre ese mismo bloque, su mejora se presenta como diagnóstico *post-hoc*, no como evidencia confirmatoria. Dos resultados adicionales completan el arco. Primero, una corrección del modelo de costes —documentada como fe de erratas con sello criptográfico de tiempo— muestra que, bajo el régimen oficial de comisiones de 2026 de Polymarket, ningún corte *taker* es rentable, lo que confirma estructuralmente la tesis y desplaza el vehículo económico viable al lado *maker*: la misma estructura de comisiones que grava al *taker* paga al proveedor pasivo de liquidez, cuya economía se cuantifica con un simulador de colas y *fills* sobre el libro L2 capturado. Segundo, una escalera de modelos de referencia muestra que un modelo fundacional de series temporales (MOMENT) mejora de forma monótona al adaptarse pero nunca supera a la deriva simple ni a un ARIMA, con una curva de escalado plana: el techo lo pone el régimen de datos, no la capacidad del modelo. El protocolo de evaluación —candidato congelado, brazos de *gate* comprometidos por adelantado y expectativa *taker* declarada negativa antes de mirar los datos— queda pre-registrado y sellado en la cadena de Bitcoin, de modo que su anterioridad a la ventana de evaluación es verificable de forma independiente. Todos los resultados se reportan en ticks netos junto a su soporte e incertidumbre, y no se afirma rentabilidad real: lo que se entrega es la metodología, la evidencia obtenida bajo un protocolo auditable y la delimitación explícita de sus límites.

Tabla de Contenido

Agradecimientos	ii
Abstract	iii
Resumen	iv
Lista de Figuras	vii
Lista de Tablas	x
Abreviaturas y acrónimos	xii
Glosario de términos	xiv
1 Introducción	1
1.1 Introducción y definición del problema	1
1.1.1 Qué es un mercado de predicción	1
1.1.2 Qué es Polymarket	2
1.1.3 El libro de órdenes y el vocabulario de la microestructura	2
1.1.4 Definición del problema	3
1.2 Motivación	4
1.3 Objetivos	4
2 Estado de la cuestión	6
2.1 Trabajos previos y estudios relevantes	6
2.1.1 Mercados de predicción	6
2.1.2 Polymarket como objeto de estudio académico	7
2.1.3 Aprendizaje profundo sobre libros de órdenes	8
2.1.4 Modelos fundacionales de series temporales y aprendizaje auto-supervisado	8
2.1.5 Microestructura, costes de ejecución y latencia	9
2.1.6 Aprendizaje automático en finanzas y validación temporal	9
2.1.7 Cambio de distribución y adaptación de dominio	10
2.1.8 Rigor de validación: pre-registro y control del sesgo de selección	11
2.2 Limitaciones en la literatura	11
3 Material y métodos	12
3.1 Descripción del dataset	12
3.1.1 Sistema de captura multifuente	12
3.1.2 Malla temporal y contrato de latencia	12
3.1.3 El grano del precio: un mercado casi siempre inmóvil	13
3.1.4 Controles de calidad por sesión	14
3.1.5 Composición del corpus	15
3.1.6 Análisis exploratorio del corpus	15

3.2	Análisis exploratorio de series temporales	16
3.3	Resultados en modelos baseline	19
3.3.1	Línea base tabular y el impacto de la latencia	19
3.4	Metodología y entrenamiento	21
3.4.1	Definición del objetivo	21
3.4.2	Ingeniería de características	22
3.4.3	Validación temporal y prevención de fuga	22
3.4.4	Modelo de costes y latencia	23
3.4.5	Fe de erratas: el régimen de comisiones de 2026	23
3.4.6	Métricas de evaluación	25
3.4.7	La escalera de modelos	25
3.4.8	Peldaños de la asignatura: baselines clásicos, kNN-DTW y MOMENT	27
3.4.9	Especialista <i>prestart</i> H60	28
3.4.10	Filtro de volatilidad	29
3.4.11	Brazos de <i>gate</i> pre-registrados: estático, GARCH y clustering de regímenes	29
3.4.12	Protocolo de congelación	30
4	Resultados y análisis	31
4.1	Resultados obtenidos	31
4.1.1	Validación fuera de muestra del especialista base	31
4.1.2	Diagnóstico <i>post-hoc</i> del régimen de volatilidad	32
4.1.3	Registro de sombra retrospectivo	33
4.1.4	Resultados con la comisión oficial de 2026 (capa taker-real)	34
4.1.5	Validación prospectiva pre-registrada	35
	Cadena de compromiso	35
	Ventana de evaluación	36
	Brazos y capas	36
	Reglas de decisión, declaradas antes de mirar	36
	Lectura del corte	36
	Capas de reporte del protocolo general	40
4.2	Comparativa con otros enfoques y baseline	40
4.2.1	Especialista tabular frente a aprendizaje profundo	41
4.2.2	Experimentos de adaptación al régimen	41
4.2.3	Diagnóstico del fallo fuera de muestra: <i>deep ensembles</i> y drift	41
4.2.4	Curva de escalado de datos: tabular frente a aprendizaje profundo	42
4.2.5	Adenda C: la curva de escalado sobre trayectorias independientes	43
	Un hallazgo no buscado: la tarea excluye los mercados cortos	44
5	Despliegue	46
5.1	Estrategia de despliegue y seguimiento en sombra	46
5.1.1	Por qué no se despliega	46
5.1.2	Del registro retrospectivo a la sombra prospectiva	46
5.1.3	Diseño de una hipotética API de inferencia	47
5.2	Economía de la ejecución bajo el régimen de comisiones de 2026	47
5.2.1	Economía del lado maker y tamaño del premio	47
5.2.2	El simulador de colas y <i>fills</i>	47
5.2.3	El tramo terminal: cuándo el precio se vuelve informativo	49

6 Aspectos éticos y limitaciones	51
6.1 Consideraciones éticas	51
6.2 Limitaciones	51
7 Reproducibilidad	54
7.1 Enlace a repositorio GitHub	54
7.1.1 Estructura del repositorio	54
7.1.2 Cómo reproducir	54
7.1.3 Datos no publicados	55
8 Conclusiones	56
Referencias	58
Conjunto de características	61
Hiperparámetros de los modelos	62
Pre-registro v2 y verificación del sello	63
Auditoría del ledger público	65

Lista de Figuras

1.1	El entorno del problema. El precio del contrato binario se forma en su libro de órdenes y está acoplado a referencias externas del mercado de Bitcoin. El objetivo es anticipar su movimiento de muy corto plazo.	3
2.1	La literatura académica sobre Polymarket surgida en la primera mitad de 2026 y la posición de este trabajo. Los cinco estudios describen la plataforma (elecciones, arbitraje, flujo, archivos on-chain o tick-level); este trabajo se distingue por añadir el libro L2 sincronizado con referencias externas y un contrato de latencia, lo que habilita la evaluación económica de la ejecución que ninguno aborda.	7
2.2	Familias de modelos consideradas —fundacionales de series, auto-supervisados y el fundacional tabular— y su papel como peldaños de la escalera comparativa frente al especialista tabular, que es el vehículo finalmente elegido de la señal. Las estrellas marcan los modelos efectivamente evaluados en este trabajo (MOMENT y TabPFN).	10
3.1	Arquitectura del sistema de captura	13
3.2	Flujo del control de calidad por sesión. Solo las sesiones que superan todos los umbrales se incorporan al corpus.	15
3.3	Partición temporal del corpus. El conjunto fuera de muestra (6–10 jun) se capturó después de congelar el candidato, lo que convierte su validación en una prueba genuina.	15
3.4	Contrastes de estacionariedad ADF y KPSS sobre niveles y primeras diferencias del precio medio (muestra de 285 series). El patrón conjunto —raíz unitaria en niveles, estacionariedad en diferencias— es consistente en todo el corpus.	17
3.5	Funciones de autocorrelación medias: retornos, retornos absolutos y desequilibrio de profundidad. La señal lineal está en el estado del libro, no en el retorno retardado.	17
3.6	Descomposición STL de la actividad agregada del corpus. La estacionalidad diaria explica el 19,4 % de la varianza.	18
3.7	Espectro de la actividad agregada y perfil intrahora. Picos en 24 h y 1 h; el minuto 50 es el más activo del ciclo horario.	18
3.8	Distribución de la cobertura de la malla de 2 s por serie. La densidad del corpus permite una política de imputación conservadora.	19
3.9	Neto medio en el test terminal frente a la latencia de entrada. La señal a latencia nula es real como <i>markout</i> desde el instante de la señal, pero no sobrevive como política ejecutable con dos segundos de latencia.	20

3.10	Modelo de dos cabezas. Un regresor predice el valor esperado de la operación y un clasificador predice si el relleno será “sano”. La política exige ambas condiciones.	21
3.11	Fe de erratas del modelo de costes. Izquierda: comisión oficial de 2026 ($rp(1-p)$, $r = 0,07$) frente a la fórmula implementada originalmente, en ticks por contrato; en $p = 0,5$ la diferencia es de un factor ocho (1,75 frente a $\sim 0,22$). Derecha: distribución del precio de entrada del corpus operable de la ventana fuera de muestra ($n=6.010$ operaciones candidatas) superpuesta a la curva oficial: las operaciones se concentran precisamente donde la comisión es máxima, con un coste de entrada medio de 1,75 ticks por contrato.	24
3.12	La escalera de modelos. Cada paso debe superar al anterior bajo el mismo protocolo; si no lo hace, se descarta.	25
3.13	Curva de escalado del fine-tuning de MOMENT (linear-probing) frente al número de ventanas de entrenamiento, evaluada sobre los 906 casos congelados. Más datos no cierran la brecha con la deriva simple: el techo lo marca el régimen de datos, no el tamaño de la muestra.	28
3.14	La ventana <i>prestart</i> del especialista: solo se opera entre -60 y -45 segundos respecto a la apertura del mercado, donde el análisis exploratorio detectó una densidad atípica de actividad del libro.	29
4.1	Fracción de sesiones de alta volatilidad por periodo. El salto del bloque nuevo motiva el análisis de régimen, pero no valida por sí mismo el filtro. .	32
4.2	Contraste <i>post-hoc</i> del neto medio entre baja y alta volatilidad. La separación es una hipótesis de política que requiere datos posteriores.	33
4.3	Sensibilidad al coste del subconjunto de baja volatilidad. Resultado exploratorio obtenido tras inspeccionar el mismo bloque.	33
4.4	Neto medio diario del subconjunto <i>post-hoc</i> de baja volatilidad.	34
4.5	Suma acumulada y drawdown diagnóstico de 318 unidades de acción. No representa una cartera con restricciones de capital o de exposición simultánea. .	34
4.6	Corte prospectivo pre-registrado nº 1	38
4.7	La puerta B3 vista desde la dispersión	39
4.8	Diagnóstico del fallo fuera de muestra de la cabeza de salud. Izquierda: el AUC se desploma de entrenamiento a test con una dispersión mínima entre las diez réplicas (barras de error) y un desacuerdo entre réplicas plano (línea naranja) —el fallo es estable y no es epistémico. Derecha: un clasificador de dominio separa mayo de junio con AUC 0,90, señal de un fuerte desplazamiento de covariables encabezado por la base del perpetuo. .	42
4.9	Curva de escalado sobre la misma tarea (dirección H60, 906 casos congelados): la vía tabular (<i>gradient boosting</i>) supera a la profunda (MOMENT) en todo el presupuesto de datos, y la distancia se mantiene o crece al aumentar el número de ventanas de entrenamiento. Con este horizonte de datos, más muestras no hacen que el aprendizaje profundo alcance al tabular. .	45
5.1	El peso $p(1-p)$ que gobierna la comisión taker y el reparto de <i>rebates</i> al maker: máximo en $p = 0,5$ y nulo en los extremos. La economía maker es más densa precisamente en la zona de precios intermedios donde opera el trabajo.	48

5.2	Informatividad del precio medio sobre el settlement. Izquierda: puntuación de Brier por tiempo a expiración; el precio es casi una moneda al aire en la apertura y solo se vuelve informativo en el tramo terminal. Derecha: curvas de fiabilidad lejos (30–60 min) y cerca (1–5 min) del cierre; el precio está bien calibrado en ambos cortes, pero su masa se polariza al acercarse la expiración.	50
-----	---	----

Lista de Tablas

1.1	Ejemplo ilustrativo de un libro de órdenes (valores inventados con fines explicativos, no datos reales). El mejor <i>bid</i> es 0,52 y el mejor <i>ask</i> , 0,54; por tanto el <i>spread</i> es de 0,02 y el precio medio, 0,53. Los niveles más alejados del centro tienen, típicamente, más volumen acumulado.	2
3.1	Grano temporal del punto medio: proporción de intervalos sin ningún cambio de precio y observaciones disponibles por mercado, según la ventana de observación.	13
3.2	Rendimiento en el test terminal bajo distintas latencias (ticks netos). . . .	20
3.3	Re-evaluación de la política congelada con la comisión oficial de 2026. Ticks netos medios por operación; «solo entrada» es la cota optimista que omite la comisión de salida.	24
3.4	Selección de horizonte (ticks netos <i>proxy</i>). Solo H60 conserva señal. . . .	26
3.5	Escalera de modelos de referencia sobre los 906 casos congelados (H60, comisión taker oficial). Acierto direccional y resultado bruto medio en ticks; el neto taker es negativo en todos los casos por el régimen de comisiones de 2026.	27
4.1	Validación fuera de muestra del especialista base congelado. Los valores son ticks netos por unidad de acción y no incorporan el filtro de volatilidad posterior.	31
4.2	Desglose diario del especialista base al coste de referencia.	32
4.3	Diagnóstico <i>post-hoc</i> por régimen en el bloque del 6–10 de junio (ticks por unidad de acción).	32
4.4	Política congelada re-evaluada con la comisión oficial de 2026. Ticks netos medios por acción; «solo entrada» es la cota optimista que omite la comisión de salida, «ida y vuelta» carga ambas. Las comisiones medias medidas son de 1,75 ticks a la entrada y 1,71 a la salida.	35
4.5	Puertas de decisión pre-declaradas	37
4.6	Resultado del corte prospectivo por brazo	37
4.7	Escalado sobre trayectorias independientes	44
1	Hiperparámetros principales del especialista (HistGradientBoosting, dos cabezas).	62
2	Hiperparámetros principales de los modelos profundos (línea de exploración).	62

Abreviaturas y acrónimos

UPM	Universidad Politécnica de Madrid
TFM	Trabajo Fin de Máster
LOB	Libro de órdenes (<i>Limit Order Book</i>)
BTC	Bitcoin
AUC	Área bajo la curva ROC (<i>Area Under the Curve</i>)
EV	Valor esperado (<i>Expected Value</i>)
HGB	<i>Histogram-based Gradient Boosting</i>
GRU	Unidad recurrente con puertas (<i>Gated Recurrent Unit</i>)
LSTM	Memoria larga a corto plazo (<i>Long Short-Term Memory</i>)
CNN	Red neuronal convolucional (<i>Convolutional Neural Network</i>)
TCN	Red convolucional temporal (<i>Temporal Convolutional Network</i>)
OOF	Fuera de pliegue (<i>Out-Of-Fold</i>)
OOS	Fuera de muestra (<i>Out-Of-Sample</i>)
IC	Intervalo de confianza
QA	Control de calidad (<i>Quality Assurance</i>)
API	Interfaz de programación de aplicaciones (<i>Application Programming Interface</i>)
bps	Puntos básicos (<i>basis points</i>)
ADF	Contraste de raíz unitaria de Dickey-Fuller aumentado (<i>Augmented Dickey-Fuller</i>)
KPSS	Contraste de estacionariedad de Kwiatkowski-Phillips-Schmidt-Shin
ACF	Función de autocorrelación (<i>AutoCorrelation Function</i>)
PACF	Función de autocorrelación parcial (<i>Partial AutoCorrelation Function</i>)
STL	Descomposición estacional-tendencia mediante Loess (<i>Seasonal-Trend decomposition using Loess</i>)
ARIMA	Modelo autorregresivo integrado de media móvil (<i>AutoRegressive Integrated Moving Average</i>)
DTW	Alineamiento temporal dinámico (<i>Dynamic Time Warping</i>)

GARCH Heterocedasticidad condicional autorregresiva generalizada (*Generalized AutoRegressive Conditional Heteroskedasticity*)

PnL Pérdidas y ganancias (*Profit and Loss*)

SHA-256 Función resumen criptográfica de 256 bits (*Secure Hash Algorithm*)

Glosario de términos

Glosario pensado para el lector no familiarizado con las criptomonedas ni con la microestructura de mercado. Recoge los términos empleados a lo largo de la memoria.

Mercado de predicción Mercado en el que se negocian contratos cuyo valor depende del resultado de un acontecimiento futuro.

Contrato binario Contrato que paga una unidad si el suceso ocurre y cero si no; su precio toma valores entre 0 y 1 y se interpreta como probabilidad.

Polymarket Plataforma de mercados de predicción descentralizada, con emparejamiento fuera de cadena y liquidación en cadena.

Libro de órdenes (LOB) Lista, ordenada por precio, de las órdenes de compra y venta pendientes de ejecución.

Bid / Ask Mejor precio de compra (*bid*) y mejor precio de venta (*ask*).

Spread Diferencia entre *ask* y *bid*; primer coste de cruzar el mercado.

Profundidad Volumen disponible en cada nivel de precio del libro.

Precio medio (*mid*) Punto medio entre *bid* y *ask*.

Tick Variación mínima de precio del mercado; unidad de medida de los resultados.

Microestructura Estudio de cómo se forman los precios a partir de órdenes, *spread*, profundidad y flujo, a escalas de tiempo muy finas.

Markout Movimiento del precio desde el instante de ejecución a lo largo de un horizonte; sirve para medir si una operación fue buena.

Latencia Retardo entre observar la oportunidad y ejecutar la orden.

Spot / Perpetuo Mercado de Bitcoin al contado (*spot*) y de futuros sin vencimiento (*perpetual futures*); referencias externas del contrato.

Oráculo de precios Fuente externa que aporta el precio de referencia de Bitcoin.

Volatilidad realizada Medida de cuánto se ha movido el precio recientemente.

Ventana *prestart* Intervalo inmediatamente anterior a la apertura del mercado.

Validación temporal Partición de los datos respetando el orden del tiempo (entrenar con el pasado, evaluar con el futuro).

Fuera de muestra (OOS) Datos no usados ni para entrenar ni para seleccionar.

Fuera de pliegue (OOF) Protocolo en el que las predicciones que consume una segunda etapa proceden siempre de un modelo que no las entrenó.

Fuga temporal Filtración de información del futuro hacia el entrenamiento o las características; principal fuente de resultados ilusorios.

Congelación	Fijar el modelo y los umbrales antes de observar el conjunto fuera de muestra.
Drawdown	Mayor caída acumulada desde un máximo previo.
<i>Bootstrap</i>	Remuestreo con reemplazo para estimar la incertidumbre de un resultado.
Registro de sombra	Contabilidad de lo que la política habría indicado sin arriesgar capital. Puede ser retrospectivo (<i>replay offline</i>) o prospectivo; solo el segundo aporta nuevos días de validación.
Gradient boosting	Familia de modelos que suma muchos árboles de decisión, cada uno corrigiendo los errores del anterior.
Taker / Maker	Quien cruza el libro y ejecuta contra órdenes existentes (<i>taker</i> , paga la comisión) frente a quien aporta liquidez con órdenes limitadas (<i>maker</i> , exento de comisión y receptor de <i>rebates</i>).
Selección adversa	Riesgo del <i>maker</i> de ser ejecutado precisamente cuando el precio va a moverse en su contra.
Riesgo terminal	En un contrato binario, el riesgo del inventario que llega vivo a la resolución: el contrato liquida a 0 o a 1, de modo que una posición sin cerrar se enfrenta a la varianza estructural del desenlace.
Modelo fundacional	Modelo pre-entrenado sobre colecciones masivas y heterogéneas de datos (series temporales, tablas) pensado para aplicarse a tareas nuevas sin entrenamiento o con una adaptación ligera.
Zero-shot / linear-probing / fine-tuning	Regímenes de adaptación crecientes de un modelo pre-entrenado: usarlo tal cual, entrenar solo su cabeza de salida, o re-entrenar todos sus parámetros.
Puntuación de Brier	Métrica de calidad de una probabilidad (<i>proper scoring</i>): error cuadrático medio entre la probabilidad emitida y el desenlace; 0,25 equivale a una moneda al aire.
Pre-registro	Compromiso público de hipótesis, protocolo y criterios de éxito anterior a la observación de los datos de evaluación.
Sello de tiempo (OpenTimestamps)	Atestación criptográfica sobre la cadena de Bitcoin de que un documento existía antes de cierto bloque; permite verificar la anterioridad de un compromiso sin confiar en el autor.

Capítulo 1

Introducción

Este Trabajo Fin de Máster estudia un problema de predicción financiera de muy corto plazo en un entorno poco habitual: los mercados de predicción sobre el precio de Bitcoin de la plataforma Polymarket. El objetivo no es un sistema de trading en producción, sino una *metodología* rigurosa para responder, con honestidad estadística, a una pregunta concreta: ¿contiene el libro de órdenes de estos mercados señales que permitan anticipar el movimiento del precio en los próximos segundos y que, además, sobrevivan a los costes y a la latencia reales de operar?

Como el lector puede no estar familiarizado con el mundo de las criptomonedas ni con la microestructura de mercado, este capítulo introduce todos los conceptos desde cero antes de plantear el problema y los objetivos.

1.1 Introducción y definición del problema

Esta sección define el problema desde cero. Antes de plantear la pregunta de investigación se introducen los conceptos imprescindibles —mercado de predicción, contrato binario, libro de órdenes y señales de microestructura—, de modo que el documento resulte autocontenido también para un lector ajeno al mundo de las criptomonedas. Con ese vocabulario fijado, se enuncia el problema concreto que se aborda.

1.1.1 Qué es un mercado de predicción

Un *mercado de predicción* es un mercado en el que se compran y venden contratos cuyo valor depende del resultado de un acontecimiento futuro. El caso más sencillo es el *contrato binario*: un contrato que pagará una unidad monetaria si el acontecimiento ocurre y cero si no ocurre. Por construcción, su precio se mueve entre 0 y 1, y puede leerse directamente como la *probabilidad implícita* que el mercado asigna al suceso. Por ejemplo, un contrato “el precio de Bitcoin estará por encima de un umbral a una hora determinada” que cotiza a 0,60 indica que el mercado estima una probabilidad cercana al 60 % de que eso ocurra. Cuando el acontecimiento se resuelve, el contrato vale 1 o 0 y las posiciones se liquidan. La literatura clásica ha mostrado que estos mercados agregan información dispersa y producen previsiones razonablemente calibradas [3].

1.1.2 Qué es Polymarket

Polymarket es una plataforma de mercados de predicción descentralizada. A diferencia de una casa de apuestas, donde el operador fija las cuotas, en Polymarket son los propios participantes quienes ponen precios mediante un *libro de órdenes*: el emparejamiento de compras y ventas ocurre fuera de la cadena de bloques (de forma rápida) y la liquidación final del dinero se registra en cadena (sobre una *blockchain*) [2]. En los mercados sobre el precio de Bitcoin, cada contrato binario toma valores entre 0 y 1 y se interpreta como una probabilidad [1]. Esto convierte cada mercado en un pequeño *mercado electrónico* (*exchange*) con su propia dinámica de oferta y demanda.

1.1.3 El libro de órdenes y el vocabulario de la microestructura

El *libro de órdenes* (en inglés *limit order book*, LOB) es la lista, ordenada por precio, de todas las órdenes de compra y de venta que están a la espera de ejecutarse. Sus elementos esenciales son:

- **Bid**: el precio más alto al que alguien está dispuesto a comprar.
- **Ask**: el precio más bajo al que alguien está dispuesto a vender. Siempre es mayor o igual que el *bid*.
- **Spread**: la diferencia entre el *ask* y el *bid*. Es el primer coste de operar: quien compra al *ask* y vende al *bid* pierde el *spread*.
- **Profundidad**: el volumen disponible en cada nivel de precio. A más profundidad, más se puede operar sin mover el precio.
- **Precio medio** (*mid*): el punto medio entre *bid* y *ask*; una referencia “limpia” del precio sin el ruido del *spread*.
- **Tick**: la variación mínima de precio que admite el mercado. Es la unidad natural en la que mediremos todos los resultados de este trabajo.

La Tabla 1.1 muestra, a modo de ejemplo ilustrativo, el aspecto de un libro de órdenes con tres niveles a cada lado.

Tabla 1.1: Ejemplo ilustrativo de un libro de órdenes (valores inventados con fines explicativos, no datos reales). El mejor *bid* es 0,52 y el mejor *ask*, 0,54; por tanto el *spread* es de 0,02 y el precio medio, 0,53. Los niveles más alejados del centro tienen, típicamente, más volumen acumulado.

Compra (<i>bids</i>)		Venta (<i>asks</i>)	
Precio	Tamaño	Precio	Tamaño
0,52	120	0,54	90
0,51	200	0,55	150
0,50	340	0,56	220

La *microestructura de mercado* es la rama que estudia cómo se forman los precios a partir de estos mecanismos —órdenes, *spread*, profundidad y flujo de operaciones— a escalas de tiempo muy finas. En este contexto, se entiende por *señales de microestructura* las variables derivadas del propio libro de órdenes (por ejemplo, el desbalance entre compra y

venta, la presión del microprice o los cambios recientes del *spread*) que podrían contener información anticipatoria sobre el movimiento inmediato del precio. La Figura 1.1 resume el entorno: el precio del contrato se forma en su propio libro de órdenes, pero está acoplado a referencias externas del mercado de Bitcoin (mercado al contado, futuros perpetuos y un oráculo de precios), ya que, en última instancia, el contrato se refiere al precio de Bitcoin.




Figura 1.1: El entorno del problema. El precio del contrato binario se forma en su libro de órdenes y está acoplado a referencias externas del mercado de Bitcoin. El objetivo es anticipar su movimiento de muy corto plazo.

1.1.4 Definición del problema

El precio del contrato no es el precio de Bitcoin: es una función no lineal y dependiente del tiempo de la probabilidad de que el suceso se resuelva afirmativamente. Sin embargo, está acoplado a las referencias externas observables que se acaban de citar. Un modelo útil debe, por tanto, aprender simultáneamente dos elementos: la dinámica interna del libro de órdenes y la semántica del contrato respecto a Bitcoin.

El problema que se aborda es de microestructura y de muy corto plazo: dado el estado del mercado en un instante t (libro de órdenes y referencias externas), predecir el movimiento del precio medio del contrato en una ventana de pocas decenas de segundos. A diferencia de la mayor parte de la literatura sobre mercados de predicción, que estudia cómo se calibra el precio frente a la resolución final del evento, aquí el interés está en los movimientos locales del precio, a escala de segundos.

Conviene fijar desde el principio un matiz que vertebra todo el trabajo: una buena capacidad de *predecir la dirección* no implica una estrategia rentable. Esta distinción está bien documentada en la literatura de microestructura y de aprendizaje automático en finanzas [9, 11, 12]: una métrica de clasificación puede ser muy alta y, aun así, el sistema no ser explotable si opera con retraso, si aprende artefactos del propio conjunto de datos o si ignora el coste real de cruzar una orden. Por eso el problema no se evalúa por el acierto, sino por el resultado económico neto, una vez descontados costes y latencia realistas.

1.2 Motivación

La motivación de este trabajo es doble. Desde el punto de vista aplicado, los mercados de predicción de criptoactivos son un entorno joven, con menos competencia algorítmica que los mercados financieros tradicionales, y con datos públicos accesibles; resulta natural preguntarse si contienen señales explotables. Desde el punto de vista metodológico —que es el que da peso a una memoria de máster— el entorno es un excelente banco de pruebas para una cuestión central en el aprendizaje automático aplicado a finanzas: la distancia entre *predecir correctamente* y *obtener beneficio*.

Esa distancia es el hilo conductor. Como se mostrará, un clasificador direccional sencillo alcanza una precisión cercana al 90 % y, pese a ello, deja de ser rentable en cuanto se introduce una latencia de entrada realista de dos segundos. El coste y la ejecución, y no el acierto, determinan el resultado. Asumir lo contrario es uno de los errores más comunes y costosos en este campo, y documentarlo con evidencia cuantitativa es, en sí mismo, una aportación.

Conviene además situar las expectativas. El objetivo no es construir un sistema de trading en producción ni demostrar rentabilidad, sino algo más modesto y, a la vez, más exigente metodológicamente: determinar *si* existe señal explotable bajo condiciones realistas y, sobre todo, *cómo* evaluarla sin engañarse. En un dominio donde es fácil obtener resultados espectaculares pero ilusorios, el valor de un trabajo de máster está tanto en lo que encuentra como en el rigor con el que descarta lo que no se sostiene. Por eso, a lo largo de la memoria, los resultados negativos —modelos que parecían prometedores y no superaron la validación— se reportan con el mismo cuidado que los positivos.

1.3 Objetivos

El objetivo general es **construir y validar, con un protocolo honesto, una metodología completa para evaluar si el aprendizaje automático y profundo pueden anticipar el movimiento de corto plazo del precio de los contratos de Bitcoin de Polymarket bajo costes y latencia realistas**. De él se derivan los siguientes objetivos específicos:

1. Diseñar un sistema de captura de datos multifuente, con control de calidad por sesión, que produzca un corpus alineado temporalmente y libre de fugas.
2. Definir un protocolo de evaluación que combine validación estrictamente temporal, un modelo explícito de costes y una latencia medida empíricamente.
3. Cuantificar el impacto de la latencia sobre una señal direccional fuerte, para delimitar dónde se rompe la cadena entre predicción y ejecución.
4. Evaluar una progresión de modelos, de menor a mayor complejidad (líneas base tabulares, modelos sensibles a la latencia y arquitecturas profundas sobre el libro de órdenes), exigiendo que cada incremento de complejidad se justifique con evidencia.
5. Determinar si existe un candidato que sobreviva a una validación fuera de muestra bajo coste, y delimitar con rigor sus límites y su incertidumbre.

El presente trabajo se organiza como sigue. El Capítulo 2 revisa el estado de la cuestión. El Capítulo 3 describe los datos, las líneas base y la metodología de modelado y entrenamiento. El Capítulo 4 presenta y analiza los resultados sobre el conjunto fuera de muestra. El Capítulo 5 discute la estrategia de despliegue. El Capítulo 6 aborda los aspectos éticos

y las limitaciones. El Capítulo 7 detalla la reproducibilidad, y el Capítulo 8 recoge las conclusiones. Por último, los anexos incluyen un glosario de términos para el lector no familiarizado con las criptomonedas, el detalle de las características y los hiperparámetros de los modelos.

Capítulo 2

Estado de la cuestión

Este capítulo sitúa el trabajo en la literatura. Se organiza en las áreas que confluyen en el problema —mercados de predicción y el estudio académico reciente de Polymarket, aprendizaje profundo sobre libros de órdenes, modelos fundacionales y auto-supervisados de series temporales, microestructura y ejecución, validación temporal en finanzas, y cambio de distribución— y termina señalando el hueco concreto que este trabajo pretende cubrir.

2.1 Trabajos previos y estudios relevantes

Esta sección recorre la literatura relevante para el problema, organizada en bloques temáticos. En cada bloque se resume qué proponen los trabajos de referencia y qué se toma de ellos para este trabajo. La predicción del movimiento de precios a partir de la microestructura es un campo activo, con propuestas asentadas tanto para mercados tradicionales como para criptoactivos; el interés aquí es seleccionar de esa literatura los elementos aplicables a un mercado de predicción sobre Bitcoin.

2.1.1 Mercados de predicción

Los mercados de predicción se han estudiado, sobre todo, como mecanismos de agregación de información dispersa. Wolfers y Zitzewitz [3] muestran que pueden producir previsiones notablemente precisas, si bien su interpretación depende del diseño del contrato, de la liquidez y de los incentivos de los participantes. La mayor parte de esta literatura analiza la calibración del precio frente a la resolución final del evento. El presente trabajo se sitúa un escalón por debajo, en el terreno de la microestructura: la dinámica intradía del precio del contrato a escala de segundos, donde aparecen *spreads*, profundidad limitada y desajustes transitorios respecto a las referencias externas. Conviene además precisar el mecanismo: a diferencia de los mercados de predicción basados en creadores de mercado automáticos (que fijan el precio mediante una fórmula), Polymarket emplea un libro de órdenes, lo que hace aplicable el instrumental clásico de la microestructura y justifica el enfoque de este trabajo.

2.1.2 Polymarket como objeto de estudio académico

Hasta 2025, Polymarket apenas contaba con literatura académica propia; en la primera mitad de 2026 han aparecido cinco estudios que lo convierten en objeto de análisis directo, y que delimitan con precisión el hueco que ocupa este trabajo (Figura 2.1).

La literatura académica de Polymarket en 2026 y la posición de este trabajo




Figura 2.1: La literatura académica sobre Polymarket surgida en la primera mitad de 2026 y la posición de este trabajo. Los cinco estudios describen la plataforma (elecciones, arbitraje, flujo, archivos on-chain o tick-level); este trabajo se distingue por añadir el libro L2 sincronizado con referencias externas y un contrato de latencia, lo que habilita la evaluación económica de la ejecución que ninguno aborda.

Dubach [16] construye un archivo *tick-level* del canal público del libro de órdenes (30 mil millones de eventos a lo largo de 52 días) y extrae de él ocho hechos estilizados de la microestructura de Polymarket: concentración de la actividad en pocos mercados, *spreads* dependientes del nivel de precio, actividad de cancelación dominante y ciclos intradía marcados, entre otros. Es el trabajo más cercano al presente en objeto y escala temporal, y sirve aquí como referencia de contraste para el análisis exploratorio del Capítulo 3: los hechos estilizados que aquel archivo documenta sobre el conjunto de la plataforma se comparan con lo observado en el corpus propio de mercados horarios de Bitcoin. Tsang y Yang [17] analizan el mercado de la elección presidencial estadounidense de 2024 con datos de la cadena Polygon y un marco contable a nivel de transacción, incluyendo la detección de *wash trading*; su interés es forense y agregado, no operativo. Cheng, Yang y Zou [18] buscan oportunidades de arbitraje en los mercados de baloncesto y encuentran que las anomalías de mercado único son rarísimas y de vida mediana de pocos segundos — una advertencia empírica directa contra las estrategias *taker* de latencia que este trabajo confirma por otra vía. Nechepurenko [19] estudia la composición del flujo ejecutado y muestra que la liquidez de Polymarket descansa en niveles de participantes no minoristas con firmas de microestructura diferenciadas; para este trabajo, ese resultado describe al adversario contra el que compite cualquier política *maker*. Por último, Qin y Yang [20] publican la base Polymarket-v1, el archivo on-chain completo de la primera generación del protocolo (1,2 mil millones de operaciones entre 2022 y 2026), orientada a la historia larga de operaciones liquidadas.

La posición de este trabajo frente a esa literatura se resume en dos diferencias. La primera es el dato: los archivos citados capturan operaciones on-chain o el canal público de eventos, mientras que el corpus propio sincroniza el libro L2 completo a malla fija de 2 segundos con referencias externas simultáneas (*spot*, perpetuos y oráculo) y con un contrato de latencia medido sobre el ciclo real de órdenes — es decir, contiene exactamente la información que hace falta para simular ejecución, no solo para describir actividad. La segunda es la pregunta: ninguno de los cinco estudios evalúa económicamente una política de negociación congelada bajo coste, latencia y régimen de comisiones medidos, ni valida prospectivamente sus resultados; ese es el terreno de este trabajo.

2.1.3 Aprendizaje profundo sobre libros de órdenes

La predicción del movimiento de precios a partir del libro de órdenes es un problema con una literatura ya madura. El trabajo de referencia es DeepLOB [4], que representa el libro como una matriz de dos dimensiones (niveles de precio frente a tiempo) y aplica primero módulos convolucionales —que capturan la estructura espacial entre los niveles de compra y de venta— y, a continuación, capas recurrentes que modelan la dependencia temporal; se valida sobre FI-2010 [5], un conjunto de referencia público de libros de órdenes ampliamente utilizado como banco de pruebas. En la misma línea, Tsantekidis et al. [6] comparan arquitecturas convolucionales y recurrentes para detectar cambios de precio en el libro. Sirignano y Cont [7] aportan evidencia de la existencia de características universales en la formación de precios que el aprendizaje profundo es capaz de capturar, y Jha et al. [8] trasladan estas ideas al terreno de los criptoactivos, mostrando que el enfoque no es exclusivo de los mercados tradicionales. La línea sigue activa: TLOB [22] sustituye el par convolucional-recurrente por un transformador con doble atención (espacial sobre los niveles del libro y temporal sobre la secuencia) y documenta, además, que el rendimiento de todos estos modelos se degrada al acercarse a condiciones de mercado realistas — observación que anticipa el resultado central de este trabajo.

De esta literatura este trabajo adopta una decisión de diseño —tratar el libro de órdenes como un objeto con estructura espacio-temporal, y no como una tabla plana— y, sobre ella, introduce dos cambios. El primero es metodológico: evaluar cada modelo bajo un modelo de ejecución realista (coste y latencia), y no solo con métricas de clasificación como es habitual en estos trabajos. El segundo es de dominio: aplicar el enfoque a un mercado de predicción sobre Bitcoin —y no a un mercado de acciones—, lo que obliga a combinar el libro con referencias externas. Esa doble diferencia es, precisamente, donde este trabajo pone el acento.

2.1.4 Modelos fundacionales de series temporales y aprendizaje auto-supervisado

Una segunda corriente reciente propone trasladar a las series temporales la receta de los grandes modelos de lenguaje: pre-entrenar un modelo genérico sobre colecciones masivas y heterogéneas de series y aplicarlo después a tareas nuevas sin entrenamiento (*zero-shot*) o con una adaptación ligera (*fine-tuning*). MOMENT [23] es el representante que este trabajo adopta como peldaño de su escalera de modelos: una familia abierta de transformadores pre-entrenados por reconstrucción enmascarada, con variantes que caben en hardware modesto. En la misma familia, Chronos [24] discretiza los valores de la serie y los trata literalmente como *tokens* de un modelo de lenguaje; TimesFM [25] es

el fundacional de predicción de Google entrenado sobre cientos de miles de millones de puntos reales, y la línea Moirai [26] —ya en su segunda versión, con predicción cuantílica— representa el estado del arte de los fundacionales universales de predicción. Fuera de las series, TabPFN [27] lleva la misma idea al dato tabular: una red pre-entrenada sobre el prior de millones de conjuntos sintéticos que clasifica conjuntos pequeños por inferencia en contexto, sin entrenar. Su inclusión en la escalera de este trabajo permite formular la pregunta simétrica —¿qué aporta un fundacional *del tipo de dato que ganó* (tabular), y no solo del tipo de dato aparente (serie temporal)?— cuyos resultados se presentan en el Capítulo 4.

El pre-entrenamiento auto-supervisado es el mecanismo que sostiene a estos modelos y una línea propia de literatura. Las estrategias dominantes son la reconstrucción de tramos enmascarados —SimMTM [28] la formula como suma ponderada de series vecinas fuera de la variedad de la serie original—, el contraste jerárquico entre vistas aumentadas —TS2Vec [29], generalizado por SoftCLT [30] con asignaciones blandas que respetan la cercanía temporal— y los objetivos híbridos: TimeSiam [31] empareja subseries pasadas y presentes con codificadores siameses, y TimeDART [32] combina difusión y auto-regresión para capturar a la vez la dinámica global y los patrones locales. Para este trabajo, esta literatura cumple dos papeles: motiva el peldaño auto-supervisado de la escalera (un codificador convolucional-temporal pre-entrenado por reconstrucción sobre el propio corpus) y aporta la advertencia, repetida en sus propias evaluaciones, de que la ventaja del pre-entrenamiento depende críticamente del volumen y de la afinidad de dominio de los datos — condición que un mercado joven, con semanas de historia, no cumple de partida. La Figura 2.2 resume las familias evaluadas y su relación con el especialista tabular que este trabajo acaba eligiendo.

2.1.5 Microestructura, costes de ejecución y latencia

La distancia entre predecir bien y obtener beneficio es uno de los temas clásicos de la microestructura de mercado. Kearns y Nevmyvaka [9] revisan el papel del aprendizaje automático en microestructura y negociación de alta frecuencia, y subrayan que la ejecución, el coste y la latencia condicionan de forma decisiva la viabilidad de una señal. Este trabajo cuantifica ese fenómeno en el contexto concreto de Polymarket: se mide la latencia real del ciclo de orden y se demuestra que una señal direccional fuerte se vuelve no rentable bajo una latencia de entrada modesta. El cambio que se introduce respecto a esta literatura es, de nuevo, metodológico: en lugar de asumir una latencia o un coste fijos, ambos se determinan a partir de los datos —la latencia, de forma empírica sobre el ciclo de orden real; el coste, de forma relativa al estado del libro en cada instante—, de modo que la evaluación económica refleje las condiciones efectivas de ejecución.

2.1.6 Aprendizaje automático en finanzas y validación temporal

El aprendizaje automático aplicado a la predicción financiera es especialmente propenso a resultados ilusorios cuando la evaluación no respeta la estructura temporal de los datos. Gu, Kelly y Xiu [10] ofrecen un marco riguroso de comparación de modelos con validación fuera de muestra. López de Prado [11] documenta los mecanismos por los que se cuela información del futuro y por los que se sobreajustan los *backtests*, y propone protocolos de validación que respetan la causalidad temporal. Bailey y López de Prado [12] advierten de un riesgo adicional: si se prueban muchos modelos y se elige el mejor, las métricas de




Figura 2.2: Familias de modelos consideradas —fundacionales de series, auto-supervisados y el fundacional tabular— y su papel como peldaños de la escalera comparativa frente al especialista tabular, que es el vehículo finalmente elegido de la señal. Las estrellas marcan los modelos efectivamente evaluados en este trabajo (MOMENT y TabPFN).

rendimiento salen infladas casi por construcción. Estas referencias motivan tres decisiones metodológicas de este trabajo: la partición estrictamente temporal, el protocolo fuera de pliegue (*out-of-fold*) y la congelación del candidato antes de observar el conjunto de validación fuera de muestra.

2.1.7 Cambio de distribución y adaptación de dominio

Los mercados financieros no son estacionarios, por lo que la distribución de los datos cambia entre el periodo de entrenamiento y el de despliegue. Para amortiguar ese efecto existen técnicas de adaptación de dominio, como la alineación de correlaciones CORAL [13]. En el Capítulo 4 se mostrará un resultado contraintuitivo: con un horizonte de datos reducido, estas técnicas no superan a una estrategia mucho más simple, consistente en restringir la operativa al régimen en el que el modelo fue entrenado. Además de CORAL, en este trabajo se evalúan otras estrategias de adaptación habituales —filtros conformales, *ensembles* y reentrenamiento incremental con ventana móvil—, cuyos resultados se detallan en el Capítulo 4. Por último, en cuanto a arquitecturas profundas para series temporales multivariantes, trabajos como el *Temporal Fusion Transformer* [14] marcan una línea de evolución natural para cuando se disponga de muchos más datos.

2.1.8 Rigor de validación: pre-registro y control del sesgo de selección

Las referencias de validación temporal citadas más arriba comparten un diagnóstico: el riesgo dominante en la investigación financiera empírica no es el error del modelo, sino el del investigador que prueba muchas variantes y reporta la mejor. Harvey, Liu y Zhu [33] cuantifican el problema en la literatura de factores —la mayoría de los resultados publicados no sobreviviría umbrales de contraste múltiple— y Bailey y López de Prado [12] ofrecen la corrección correspondiente para estrategias de negociación, la ratio de Sharpe deflactada, que penaliza explícitamente el número de ensayos. Ambas líneas atacan el sesgo *a posteriori*, corrigiendo la métrica una vez cometido el pecado.

La respuesta *a priori* es el pre-registro: comprometer hipótesis, protocolo y criterios de éxito antes de observar los datos de evaluación, práctica hoy estándar en las ciencias experimentales [34]. Su punto débil clásico es la verificabilidad — nada impide redactar el «pre»-registro después. Este trabajo lo resuelve con un sello criptográfico de tiempo: el documento de pre-registro y la política congelada se atestan con OpenTimestamps [35] sobre la cadena de Bitcoin, de modo que cualquier lector puede verificar que el compromiso es anterior a los datos de la ventana de evaluación, sin confiar en el autor ni en un tercero. La combinación —candidato congelado con hashes verificables, ventana de evaluación prospectiva intocada hasta un corte fijado de antemano, y reporte de todos los brazos comprometidos, favorables o no— es, hasta donde alcanza la revisión de este capítulo, inédita en la literatura de mercados de predicción, y constituye la aportación metodológica central del trabajo (el protocolo se detalla en el Capítulo 3).

2.2 Limitaciones en la literatura

Del repaso anterior se desprenden tres limitaciones recurrentes que enmarcan la aportación de este trabajo. En primer lugar, la evaluación predominante es de *clasificación* (precisión, AUC), y rara vez se traduce a un resultado económico bajo un modelo de ejecución realista; como se verá, esa traducción cambia las conclusiones por completo. En segundo lugar, gran parte de los resultados positivos se obtienen sin una latencia de entrada explícita, cuando la latencia es precisamente lo que destruye muchas señales de corto plazo. En tercer lugar, los entornos de criptoactivos jóvenes ofrecen pocos datos, lo que agrava el riesgo de sobreajuste y de resultados ilusorios si la validación no es estrictamente temporal.

El hueco que cubre este trabajo es, por tanto, metodológico: evaluar la predicción de corto plazo *bajo coste y latencia medida*, con validación estrictamente temporal y congelación previa del candidato, y reportar cada resultado en ticks netos acompañado de su soporte y su incertidumbre.

Capítulo 3

Material y métodos

Este capítulo describe el material (los datos) y los métodos (líneas base, protocolo de validación y modelos) del trabajo. Se ha organizado en tres bloques: la descripción del conjunto de datos, los resultados de las líneas base —que contienen la lección central del trabajo— y la metodología de modelado y entrenamiento.

3.1 Descripción del dataset

Esta sección describe el origen de los datos, su organización temporal y los controles de calidad que determinan qué entra en el conjunto de trabajo. Se introducen primero los conceptos necesarios —fuentes de datos, malla temporal y contrato de latencia, y datos obsoletos— y después se resume la composición del corpus y su análisis exploratorio.

3.1.1 Sistema de captura multifuente

Los datos de mercado se registran mediante una herramienta de captura propia, desarrollada específicamente para este trabajo. Por su carácter sensible, esta herramienta no se publica y aquí se describe únicamente a nivel funcional; lo que sí se publica (Capítulo 7) es el esquema de la consulta de datos, una muestra representativa y todo el código de análisis y modelado. A nivel funcional, por cada sesión de mercado la herramienta anota cuatro tipos de información: (i) el libro de órdenes del contrato de Polymarket y su flujo de operaciones; (ii) los metadatos del mercado (tamaño de tick, ventana temporal, comisiones); (iii) referencias externas del mercado de Bitcoin —el mercado al contado (*spot*) y los futuros perpetuos (*perpetual futures*)—; y (iv) un oráculo de precios que aporta el precio de referencia. La fuente de verdad es una base de datos relacional sobre la que se construyen las características; de ella se publican el esquema y una muestra representativa, pero no los datos completos. Todas las fuentes se alinean en el tiempo sobre una malla regular de dos segundos, como se detalla a continuación (Figura 3.1).

3.1.2 Malla temporal y contrato de latencia

Las observaciones se organizan sobre una malla temporal regular: una secuencia de instantes $t_0, t_1, t_2, \dots$ separados exactamente dos segundos, de modo que $t_{k+1} = t_k + 2$ segundos. En cada instante t_k se toma una “fotografía” del estado del mercado (libro de órdenes y referencias externas). La elección de este intervalo no es accesorio, porque define lo que




Figura 3.1: Arquitectura del sistema de captura. Las cuatro fuentes se alinean sobre una malla de dos segundos, pasan un control de calidad por sesión y forman el corpus.

en este trabajo se denomina *contrato de latencia*: el supuesto sobre cuánto tarda una decisión en poder ejecutarse. En lugar de interpolar un instante intermedio que nunca se observó, una decisión tomada con la información de t_k se evalúa contra la siguiente fotografía real, t_{k+1} ; es decir, se asume que entre observar la señal y poder operar transcurre, como mínimo, el intervalo de la malla. Este criterio hace la evaluación deliberadamente conservadora y evita el error habitual de suponer ejecución instantánea.

3.1.3 El grano del precio: un mercado casi siempre inmóvil

La malla de dos segundos fija el ritmo de observación, pero no garantiza que el mercado tenga algo nuevo que contar en cada fotografía. Medido sobre el corpus horario, la respuesta es contundente: **el 89,8 % de los incrementos del punto medio entre fotografías consecutivas es exactamente cero**. El precio no se mueve casi nunca a esa escala. Ampliar la ventana de observación atenúa el efecto, pero no lo elimina en ningún punto razonable (Tabla 3.1).

Tabla 3.1: Grano temporal del punto medio: proporción de intervalos sin ningún cambio de precio y observaciones disponibles por mercado, según la ventana de observación.

Ventana	Intervalos sin cambio	$ \Delta $ p90 (céntimos)	Obs./mercado
2 s	89,8 %	0,05	2204
30 s	60,7 %	4	134
60 s	53,7 %	6	60
120 s	47,7 %	8	24
300 s	36,5 %	15	9,5
600 s	29,6 %	21	4,5

La causa es estructural y no accidental: el *tick* de estos contratos vale un céntimo de probabilidad y la horquilla media mide **3,8 ticks**, de modo que el punto medio solo se desplaza cuando uno de los dos lados del libro salta de verdad. Conviene además descartar la explicación alternativa —que la inmovilidad la produjera el sistema de captura y no el mercado—, y cuatro comprobaciones independientes la descartan: en el 33,8 % de las fotografías con el precio inmóvil *sí* cambia la profundidad disponible en el toque, luego el capturador observa el libro y registra sus cambios; la proporción de intervalos inmóviles es homogénea entre mercados (del 84,3 % al 95,0 % entre los percentiles 10 y 90) y no se

concentra en los menos líquidos; y, como referencia externa, el activo subyacente se mueve **2,3 veces más** en los intervalos en que nuestro precio sí cambia que en los que permanece quieto, es decir, la relación con el subyacente existe y apunta en el sentido correcto.

Para dimensionar el fenómeno con justicia conviene añadir que *tampoco* el mercado al contado de Bitcoin —uno de los más líquidos que existen— registra un cambio mediano de su punto medio en intervalos de dos segundos dentro de esta misma captura. El grano no es, por tanto, una patología de la plataforma estudiada, sino un recordatorio de que dos segundos es un intervalo muy fino para observar precios medios en cualquier mercado.

Esta caracterización tiene una consecuencia metodológica de primer orden, y explica decisiones que se toman más adelante en este trabajo. Toda la familia de modelos de tiempo continuo —difusiones con saltos, cotización óptima al estilo Avellaneda-Stoikov y sus derivados— presupone un precio que evoluciona sin interrupción; aplicada a una serie inmóvil nueve de cada diez instantes, su estimación degenera. Cuando la observación tiene un grano tan grueso, el análisis en clave de tiempo continuo debe realizarse en la banda de **60 a 120 segundos**, donde alrededor de la mitad de los intervalos ya presentan movimiento real y todavía quedan entre 24 y 60 observaciones por mercado; por debajo se mide el *tick* y por encima se agota la muestra, porque estos contratos viven únicamente una hora.

3.1.4 Controles de calidad por sesión

La calidad de los datos es tan crítica como el modelo: una referencia externa retrasada o incompleta puede inducir una señal que en realidad no existe. Por ello, antes de incorporarse al conjunto de trabajo, cada sesión de mercado pasa una batería de controles de calidad y se descarta por completo si no los supera (Figura 3.2). Conviene definir primero un concepto recurrente: un dato *obsoleto* (en inglés *stale*) es un valor que no se ha actualizado cuando debería haberlo hecho —por ejemplo, una cotización externa que permanece “congelada” varios instantes de la malla porque su fuente dejó de emitir—. Un dato obsoleto parece información válida, pero no lo es, y es una de las principales fuentes de señales espurias.

Los controles aplicados a cada sesión son los siguientes:

Cobertura Fracción de instantes de la malla efectivamente observados respecto a los esperados durante la sesión; una cobertura baja indica una captura incompleta.

Continuidad Ausencia de interrupciones prolongadas en el registro de las fuentes.

Obsolescencia Proporción de instantes con datos *stale*; si una referencia se queda congelada demasiado tiempo, la sesión se rechaza.

Arranque Validación de que la sesión comenzó a capturarse correctamente, sin un periodo inicial degradado.

Huecos severos Detección de saltos temporales grandes que la malla no puede rellenar de forma fiable.

Existe además una distinción en la propia estructura del registro que condiciona qué puede usarse como característica y que conviene dejar explícita, porque no es evidente al inspeccionar los datos. No todas las columnas capturadas son series temporales: unas se observan en *cada* instante de la malla —el punto medio, las mejores posturas de compra y venta, la profundidad disponible en cada lado, la horquilla y el último precio operado—

mientras que otras son *agregados de ventana*, es decir, un único valor calculado para toda la sesión y repetido idéntico en cada una de sus fotografías; es el caso de los volúmenes y recuentos de operaciones y de las altas y bajas de órdenes. La comprobación es inmediata —basta contar valores distintos dentro de cada sesión— y el resultado es inequívoco: las columnas del segundo grupo presentan un valor único en la totalidad de las sesiones examinadas.

La distinción importa porque una columna agregada es indistinguible de una serie al inspeccionar el conjunto: tiene un valor en cada fila, del tipo correcto y sin ausencias. Usarla como si midiera actividad instantánea introduce dos errores a la vez —sobrestima enormemente el número de observaciones independientes y solapa el predictor con el intervalo que pretende anticipar—, sin que ninguna comprobación de software lo delate. Por ese motivo las características construidas en este trabajo se restringen al primer grupo.




Figura 3.2: Flujo del control de calidad por sesión. Solo las sesiones que superan todos los umbrales se incorporan al corpus.

Esta política es deliberadamente estricta: se prefiere reducir el tamaño de la muestra antes que contaminar el entrenamiento con ruido que el modelo podría confundir con una señal. Como consecuencia, el corpus efectivo es sensiblemente menor que el total capturado, lo que más adelante justifica la estrategia de regularización agresiva.

3.1.5 Composición del corpus

Se denomina *corpus* al conjunto de todas las sesiones aceptadas tras el control de calidad; sobre él se definen después las particiones temporales (entrenamiento, validación y test). El corpus principal abarca del 11 al 25 de mayo de 2026, con del orden de 2,6 millones de filas multifuente (*cross-venue*). Como conjunto fuera de muestra se reservó del 6 al 10 de junio de 2026, capturado con posterioridad a la congelación del candidato (Sección 3.4.12). La unidad de observación es la tupla **sesión** $\times$ **token** $\times$ **instante** sobre la malla de dos segundos. La Figura 3.3 resume la partición temporal.




Figura 3.3: Partición temporal del corpus. El conjunto fuera de muestra (6–10 jun) se capturó después de congelar el candidato, lo que convierte su validación en una prueba genuina.

3.1.6 Análisis exploratorio del corpus

El análisis exploratorio previo deja cuatro observaciones que condicionan todo el diseño posterior:

1. **Desequilibrio de clases.** La etiqueta direccional está dominada por la clase FLAT (quietud): a horizonte de 60 segundos, entre el 55 y el 65 % de las observaciones caen dentro de la banda de quietud. Esto vuelve engañosa la precisión bruta —un modelo que prediga siempre FLAT ya supera el 60 %— y obliga a usar precisión equilibrada (*balanced accuracy*) y F1 macro.
2. **Calidad de los datos.** En los tramos de alta volatilidad, los retardos de actualización de las referencias externas abarcan varios ciclos de la malla; tras el filtrado, el corpus efectivo es sensiblemente menor que el total capturado, lo que justifica una regularización agresiva.
3. **Patrón *prestart*.** La ventana inmediatamente anterior a la apertura del mercado concentra una densidad atípica de cancelaciones, modificaciones y cruces, lo que sugiere reposicionamiento de los participantes y una señal de microestructura diferenciada. Esta observación motiva el *modelo especialista* —un modelo entrenado exclusivamente para esa ventana, en lugar de uno generalista— que se describe más adelante en este capítulo.
4. **Acoplamiento con Bitcoin.** La correlación entre el precio del contrato y las referencias de Bitcoin es clara en ventanas de minutos pero se diluye en ventanas de segundos: el arbitraje externo no es instantáneo. Esa separación de escalas justifica combinar el libro local con las referencias externas.

En conjunto, estas cuatro observaciones no son anecdóticas: determinan decisiones concretas del resto del trabajo. El desequilibrio de clases fija la elección de métricas; la calidad de los datos y su escasez efectiva imponen la regularización agresiva y la prudencia en la validación; el patrón *prestart* define la ventana del especialista; y el acoplamiento con Bitcoin justifica el bloque de características externas. Es decir, el diseño metodológico de los apartados siguientes se deriva directamente de lo que muestran los datos, y no de elecciones arbitrarias.

3.2 Análisis exploratorio de series temporales

Antes de modelar, el corpus se somete a un análisis exploratorio formal de series temporales. Cada análisis de esta sección responde una pregunta concreta de diseño y termina en una decisión; el material es una muestra de 285–300 series mercado–contrato del corpus completo (2,3 millones de filas, 1.018 series).

Estacionariedad (ADF/KPSS). Sobre los niveles del precio medio, el contraste ADF solo rechaza la raíz unitaria en el 6,3 % de las series, y el KPSS rechaza la estacionariedad en el 99,3 %; sobre las primeras diferencias, el ADF rechaza en el 100 % y el KPSS solo en el 12,6 %. Ambos contrastes coinciden: el precio medio es integrado de orden uno y los retornos son estacionarios. La decisión derivada es modelar siempre sobre diferencias o retornos, nunca sobre niveles (Figura 3.4).

Autocorrelación (ACF/PACF). Los retornos a 2 segundos presentan una autocorrelación de primer orden media de 0,07, con cero retardos significativos de los diez primeros en la serie mediana: apenas hay estructura lineal explotable en el retorno puro. En cambio, los retornos absolutos muestran los diez primeros retardos significativos (agrupamiento de volatilidad) y el desequilibrio de profundidad del libro es extremadamente persistente (autocorrelación de primer orden 0,99). La decisión derivada es doble: las características




Figura 3.4: Contrastes de estacionariedad ADF y KPSS sobre niveles y primeras diferencias del precio medio (muestra de 285 series). El patrón conjunto —raíz unitaria en niveles, estacionariedad en diferencias— es consistente en todo el corpus.

del modelo deben buscar la señal en el estado del libro y en la volatilidad —no en el retorno retardado— y la persistencia del desequilibrio valida su uso como característica lenta (Figura 3.5).




Figura 3.5: Funciones de autocorrelación medias: retornos, retornos absolutos y desequilibrio de profundidad. La señal lineal está en el estado del libro, no en el retorno retardado.

Descomposición STL de la actividad. La serie agregada de actividad (eventos por cubo temporal) se descompone en tendencia, estacionalidad diaria y residuo; la componente estacional explica el 19,4 % de la varianza. Existe un ciclo diario real pero moderado: la actividad no es reducible a su patrón horario (Figura 3.6).

Espectro de Fourier y ciclo intrahora. El espectro de la actividad muestra picos nítidos en los periodos de 24 horas y de 1 hora (230 y 225 veces la potencia mediana, respectivamente): el ciclo de vida horario de los mercados estudiados imprime su firma en la actividad global. Dentro de la hora, el perfil medio no es plano —la razón entre el minuto más y menos activo es 2,3— y el minuto más activo es el **minuto 50**, coherente con la concentración de actividad en el tramo final de la vida del contrato que motiva el análisis del riesgo terminal del Capítulo 5 (Figura 3.7).

Calidad por sesión e imputación. La cobertura mediana de la malla de 2 segundos es del 100 % y el 99,8 % de las series supera el 99 % de cobertura. Con esta densidad, la política de imputación puede ser conservadora: arrastre del último valor observado marcando




Figura 3.6: Descomposición STL de la actividad agregada del corpus. La estacionalidad diaria explica el 19,4 % de la varianza.




Figura 3.7: Espectro de la actividad agregada y perfil intrahora. Picos en 24 h y 1 h; el minuto 50 es el más activo del ciclo horario.

el dato como **stale**, sin interpolar —interpolar inventaría microestructura precisamente donde el modelo la busca—, y exclusión de la sesión cuando la cobertura cae por debajo del umbral de calidad (Figura 3.8).




Figura 3.8: Distribución de la cobertura de la malla de 2s por serie. La densidad del corpus permite una política de imputación conservadora.

Contraste con los hechos estilizados de la literatura. Los resultados anteriores se alinean con los hechos estilizados que Dubach [16] documenta sobre el archivo *tick-level* de toda la plataforma: ciclos de actividad intradía marcados, retornos sin estructura lineal apreciable pero con volatilidad agrupada, y estado del libro persistente. La diferencia es de resolución y de alcance: aquel archivo describe la plataforma completa a nivel de evento, y este corpus añade las referencias externas sincronizadas y el contrato de latencia que permiten pasar de la descripción a la evaluación económica.

3.3 Resultados en modelos baseline

Antes de introducir cualquier modelo complejo conviene establecer una línea base sencilla y medir su comportamiento bajo condiciones realistas. Esta sección muestra que una línea base tabular alcanza una precisión direccional muy alta y, sin embargo, deja de ser rentable al introducir la latencia; este resultado es la observación que reorienta todo el trabajo.

3.3.1 Línea base tabular y el impacto de la latencia

La línea base son modelos sobrios y bien entendidos —una regresión logística balanceada y un *gradient boosting* pequeño, también balanceado— sobre el conjunto de características descrito antes, con la etiqueta direccional a un horizonte corto (16 segundos). Se entrena por *token-frame* y se evalúa por *market-frame*, para no contar dos veces el mismo instante del mercado. Esta línea base alcanza una precisión direccional cercana al 90 % y supera la validación temporal por bloques. Evaluada solo con métricas de clasificación, parece un modelo excelente. El problema aparece al introducir la entrada retrasada y el coste. La Tabla 3.2 y la Figura 3.9 muestran el rendimiento en el test terminal —el bloque

no utilizado para seleccionar la política— en función de la latencia de entrada, en un escenario conservador con filtro de *spread*.

Tabla 3.2: Rendimiento en el test terminal bajo distintas latencias (ticks netos).

Latencia	Acciones	Acierto UP	Neto medio	Neto total
0 s	64	92,2 %	+6,79	+434,44
2 s	63	39,7 %	−1,48	−93,48
4 s	66	45,5 %	−0,74	−48,83
8 s	66	43,9 %	−0,30	−19,53




Figura 3.9: Neto medio en el test terminal frente a la latencia de entrada. La señal a latencia nula es real como *markout* desde el instante de la señal, pero no sobrevive como política ejecutable con dos segundos de latencia.

La lectura de la tabla es contundente. A latencia nula la política sería extraordinaria (+6,79 ticks de media, con un 92 % de acierto en las operaciones de subida), porque mide el *markout* desde el instante exacto de la señal. Pero a dos segundos —el primer escalón realista— el acierto se desploma al 39,7 % y el neto pasa a −1,48 ticks: la oportunidad ya se ha consumido cuando la orden podría ejecutarse. Es revelador que a 4 y 8 segundos el neto *mejore* ligeramente (hacia −0,74 y −0,30): no es que operar más tarde sea mejor, sino que a esas latencias el modelo ya ni siquiera detecta la señal efímera que lo hacía perder, de modo que sus decisiones se vuelven casi aleatorias y el daño se diluye. En otras palabras, toda la ventaja vivía en una ventana de pocos segundos que la latencia hace inaccesible.

Este es el resultado que vertebra todo el trabajo: **acertar la dirección no equivale a obtener beneficio**. Con una latencia realista de dos segundos, el neto medio del test terminal cae a −1,48 ticks. El problema deja de ser de clasificación y pasa a ser de ejecución; a partir de aquí, todo modelo se evalúa por su política económica bajo coste y latencia, no por su acierto.

3.4 Metodología y entrenamiento

Esta sección detalla cómo se define el objetivo de aprendizaje, cómo se valida sin incurrir en fugas temporales, cómo se modelan los costes y la latencia, qué métricas deciden y qué progresión de modelos se evaluó hasta llegar al candidato final. El hilo conductor es que cada decisión metodológica está orientada a un objetivo: evitar resultados ilusorios y medir el rendimiento económico real.

3.4.1 Definición del objetivo

Para cada instante t se define el retorno futuro del precio medio a un horizonte H ,

$$\Delta_H(t) = \frac{m_{t+H} - m_t}{m_t}, \quad (3.1)$$

donde m_t es el precio medio del contrato. La etiqueta direccional se obtiene con un umbral θ que absorbe el *spread*, las comisiones y el ruido:

$$y_t = \begin{cases} \text{UP} & \text{si } \Delta_H(t) > \theta, \\ \text{DOWN} & \text{si } \Delta_H(t) < -\theta, \\ \text{FLAT} & \text{en otro caso.} \end{cases} \quad (3.2)$$

Esta etiqueta ternaria es útil para mirar el arco experimental en su conjunto; el especialista final, en cambio, usa los dos objetivos económicos que se definen más abajo. Las características son causales (solo usan información hasta t) y las etiquetas se calculan *a posteriori* de forma trazable, de modo que no entra información del futuro por las entradas del modelo. Todos los resultados económicos se expresan en ticks netos, que es la unidad natural del libro; no se traducen a dinero porque ello exigiría suponer un tamaño de posición y favorecería la sobreafirmación.

Los dos objetivos del especialista. El modelo final no usa la etiqueta ternaria, sino dos objetivos complementarios, porque un modelo que debe decidir si entra necesita saber algo más fino que la dirección: cuánto vale la operación y si el entorno de ejecución es favorable (Figura 3.10).




Figura 3.10: Modelo de dos cabezas. Un regresor predice el valor esperado de la operación y un clasificador predice si el relleno será “sano”. La política exige ambas condiciones.

El **regresor** predice `exec_net_cost_0p25_H60`: el neto ejecutado a 60 segundos tras descontar una fracción (0,25) del coste visible de entrada de cada operación. El **clasificador** predice `healthy_fill_proxy_0p25_H60`: una variable binaria que vale 1 cuando ese neto

es positivo *y* la operación no cae en el peor cuartil de un grupo de operaciones comparables (mismo bloque temporal, fase, nivel de *spread*, *microprice* y momento del *perp*). La independencia entre ambas cabezas es deliberada: una operación puede tener alto valor esperado pero baja probabilidad de relleno sano si el libro está degradado.

3.4.2 Ingeniería de características

El especialista recibe un vector de 36 características, todas calculadas exclusivamente con información disponible hasta el instante t . Se agrupan en cuatro bloques con una justificación clara para cada uno:

Estado del libro Resúmenes del libro de órdenes de Polymarket: precio medio, *spread*, *microprice* (precio ponderado por volumen, que anticipa la presión de compra-venta), desbalance entre niveles, coste visible de entrada y cambios recientes del precio. Describen el estado local del mercado.

Referencias externas Retornos orientados del mercado al contado y de los futuros perpetuos a 2 y 8 segundos, junto con medidas de consenso y de actualización. Capturan el acoplamiento con Bitcoin, que el análisis exploratorio mostró relevante a escala de segundos.

Volatilidad La volatilidad realizada del perpetuo a 5 segundos, empleada posteriormente en el diagnóstico de cambio de régimen.

Contexto de ventana Posición dentro de la ventana *prestart* y *proxies* de calidad del libro (cobertura e indicadores de degradación), que informan de la ejecutabilidad.

Una decisión deliberada es excluir las variables de reloj (hora, minuto, segundo): el conjunto se denomina por ello *no_clock*. El motivo es evitar que el modelo aprenda atajos temporales triviales —por ejemplo, asociar la señal a un instante concreto del día— que no generalizarían y que, en la práctica, son una forma sutil de sobreajuste. El inventario completo se recoge en el Anexo 8.

3.4.3 Validación temporal y prevención de fuga

Una partición aleatoria por filas, habitual en problemas sin estructura temporal, sería aquí un error grave: las observaciones contiguas están autocorrelacionadas y un mismo mercado puede aparecer a ambos lados del corte, de modo que el modelo acabaría “viendo el futuro”. Por ello la partición respeta siempre el orden del tiempo: el entrenamiento utiliza las sesiones más antiguas, la validación las posteriores y el test terminal el bloque final, que permanece sellado hasta el final del proceso.

En los experimentos secuenciales se refuerza esta disciplina con un protocolo fuera de pliegue (*out-of-fold*) de tipo *walk-forward* expansivo: el conjunto de entrenamiento crece hacia delante en el tiempo y, en cada pliegue, las predicciones que consume una segunda etapa proceden siempre de un modelo que no las entrenó. A ello se añaden dos protecciones en las fronteras entre bloques. La *purga* retira del entrenamiento las observaciones cuyo horizonte de etiqueta se solapa con el bloque que se está evaluando, ya que de lo contrario una etiqueta calculada con datos del bloque evaluado contaminaría el ajuste. El *embargo* descarta además un pequeño margen temporal alrededor de cada frontera, para que el solape de las secuencias históricas tampoco introduzca fuga. La política de decisión se selecciona únicamente sobre la validación, sin observar en ningún momento el test terminal.

Esta disciplina contra la fuga temporal es la principal salvaguarda frente a los resultados ilusorios que la literatura describe de forma reiterada [11, 10].

3.4.4 Modelo de costes y latencia

La latencia no se supone, se mide. En una prueba controlada del ciclo de orden de Polymarket, el tiempo entre observar la oportunidad y confirmar el emparejamiento fue de unos 0,43 segundos en el percentil 95 de la muestra válida. Aun así, por prudencia se trabaja con cifras peores: una latencia conceptual de un segundo y una latencia observable en los datos de dos segundos (la malla de captura). Conviene precisar *dónde* reside esa latencia, porque determina qué mejoras son posibles. El cómputo local —desde observar el dato hasta emitir la decisión: cálculo de características e inferencia del modelo— se midió en torno a 25 milisegundos en el percentil 95, una fracción despreciable del ciclo. El grueso lo consumen etapas que no dependen del lenguaje de implementación: la construcción y la firma criptográfica de la orden, su envío por la red hasta el emparejador de Polymarket y la confirmación del emparejamiento. La latencia que anula la señal es, por tanto, un límite de red y de microestructura, no de software: reescribir el cálculo en un lenguaje más rápido reduciría esos 25 milisegundos a unos pocos, pero dejaría intacto el resto del ciclo —de cientos de milisegundos a segundos— sin rescatar la rentabilidad del lado *taker*. Esta observación es, además, una de las razones estructurales del giro al lado *maker* (Capítulo 5): el creador de mercado pasivo no compite en esta carrera de latencia. El coste de ejecución no se fija como un número plano de ticks, sino como una fracción del coste visible de entrada de cada operación: la mitad de ese coste como referencia, un cuarto como contraste optimista y el coste completo como prueba de estrés. Modelar el coste relativo al libro de cada instante es más fiel que asumir un coste fijo e igual para todas las operaciones. Formalmente, el neto ejecutado a horizonte H con un factor de coste $c \in \{0, 0,25, 0,5, 1\}$ es

$$\text{net}_c(t) = \left(\Delta_H^{\text{ticks}}(t) - b \right) - c \cdot \kappa_t, \quad (3.3)$$

donde $\Delta_H^{\text{ticks}}(t)$ es el *markout* en ticks desde la entrada (a dos segundos del instante de señal) hasta el horizonte, b es un *buffer* fijo y κ_t es el coste visible de entrada de esa operación. Nótese que, por construcción, un factor de coste mayor produce un neto menor sobre la misma operación; por eso el resultado al coste de referencia ($c = 0,5$) es siempre inferior al optimista ($c = 0,25$) y superior al de estrés ($c = 1$).

3.4.5 Fe de erratas: el régimen de comisiones de 2026

Durante la fase final del trabajo se detectó un error en el modelo de costes que merece documentarse como corrección metodológica explícita, porque su arreglo cambia las conclusiones económicas — en la dirección que las refuerza.

Desde 2026 Polymarket aplica a los mercados de criptomonedas una comisión sobre el lado *taker* de la operación, definida en su documentación oficial [2] como

$$\text{comisión}(C, p) = C \cdot r \cdot p(1 - p), \quad (3.4)$$

donde C es el número de contratos, p el precio de ejecución y $r = 0,07$ la tasa vigente para crypto. La forma $p(1 - p)$ hace que la comisión sea máxima en torno a $p = 0,5$ —justo la zona de precios donde opera la mayor parte de este trabajo— y decrezca hacia

los extremos. La versión implementada originalmente en el código elevaba al cuadrado el término $p(1-p)$, lo que en torno al precio medio subestima el coste real en un factor de aproximadamente ocho: en $p = 0,5$, la comisión oficial es de 1,75 ticks por contrato frente a los $\sim 0,22$ ticks del modelo erróneo (Figura 3.11).




Figura 3.11: Fe de erratas del modelo de costes. Izquierda: comisión oficial de 2026 ($r p(1-p)$, $r = 0,07$) frente a la fórmula implementada originalmente, en ticks por contrato; en $p = 0,5$ la diferencia es de un factor ocho (1,75 frente a $\sim 0,22$). Derecha: distribución del precio de entrada del corpus operable de la ventana fuera de muestra ($n=6.010$ operaciones candidatas) superpuesta a la curva oficial: las operaciones se concentran precisamente donde la comisión es máxima, con un coste de entrada medio de 1,75 ticks por contrato.

Detectado el error, se corrigió la fórmula en todos los repositorios afectados y se re-evaluó la política congelada del especialista —sin reentrenar nada— sobre la misma ventana fuera de muestra, reproduciendo primero las cifras publicadas como control de integridad ($n=754$, $+0,349$ ticks netos; corte de baja volatilidad $n=318$, $+1,069$) y aplicando después la comisión oficial. El resultado se resume en la Tabla 3.3: con el régimen de comisiones de 2026, ningún corte *taker* es positivo —ni siquiera en la cota optimista que solo carga la comisión de entrada. Las comisiones medias medidas sobre el corpus (1,75 ticks la entrada, 1,71 la salida) superan por sí solas el edge bruto de la señal.

Tabla 3.3: Re-evaluación de la política congelada con la comisión oficial de 2026. Ticks netos medios por operación; «solo entrada» es la cota optimista que omite la comisión de salida.

Corte	Publicado (fee errónea)	Fee oficial 2026	
		solo entrada	ida y vuelta
Todos ($n=754$)	$+0,349$	$-1,059$	$-3,304$
Baja volatilidad ($n=318$)	$+1,069$	$-0,342$	$-2,604$

La lección es estructural, no incidental: el lado *taker* de este mercado no es económico para una señal de la magnitud encontrada, y ninguna mejora razonable del modelo lo compensa. La misma estructura de comisiones señala la salida: el programa de reembolsos al creador de mercado (*maker rebates*) reparte el 20 % del fondo de comisiones de cada mercado entre quienes aportan liquidez, con el mismo peso $p(1-p)$. La consecuencia para el diseño del trabajo es el giro al lado *maker* que articula el Capítulo 5: la señal predictiva conserva su valor, pero el vehículo económico viable es cobrar el *spread* y el reembolso, no pagarlos.

Esta corrección quedó registrada públicamente como fe de erratas antes de la evaluación prospectiva, con su propio sello de tiempo (Capítulo 7).

3.4.6 Métricas de evaluación

La elección de métricas es deliberada y responde a las características del problema. Para la fase de clasificación no se reporta la precisión bruta (*accuracy*), porque el dominio de la clase FLAT la vuelve engañosa; en su lugar se usan la **precisión equilibrada** (*balanced accuracy*) y la **F1 macro**, que promedian por clase y no premian al modelo que siempre predice quietud. Para medir la capacidad de *ordenar* las oportunidades se emplea el **AUC** (área bajo la curva ROC), independiente del umbral.

Ahora bien, la métrica que decide es económica, no de clasificación: el **neto medio por operación** bajo el modelo de costes de la ecuación (3.3). A su alrededor se reportan siempre cuatro elementos de soporte e incertidumbre: (i) el **número de operaciones y de días**, porque un neto sin soporte no es interpretable; (ii) un **intervalo de confianza bootstrap** (5 000 remuestreos, semilla fija); (iii) la **probabilidad de neto positivo** estimada sobre esa misma distribución; y (iv) el **drawdown máximo** y el número de **días positivos**, como medidas de estabilidad. Esta batería evita confundir una señal estadística con una estrategia viable.

3.4.7 La escalera de modelos

Los modelos se evalúan en una progresión incremental, de menor a mayor complejidad, exigiendo en cada salto que la complejidad añadida se justifique con evidencia de mejora bajo el mismo protocolo de costes y validación (Figura 3.12).




Figura 3.12: La escalera de modelos. Cada paso debe superar al anterior bajo el mismo protocolo; si no lo hace, se descarta.

Modelos sensibles a la latencia. El primer salto sobre el baseline consiste en incorporar la latencia ya en el etiquetado y en la selección, de modo que el modelo aprenda a elegir operaciones que sigan siendo rentables *tras* el retardo de entrada. Uno de estos modelos alcanza un AUC de test de 0,79 —una capacidad de clasificación notable— y, sin embargo, su política económica sigue siendo negativa. La conclusión refuerza la lección central: más capacidad de clasificación no implica una política rentable.

Modelos secuenciales y sobre el libro de órdenes. El siguiente nivel trata el libro como un objeto con estructura espacio-temporal. Se construyen secuencias de ocho

fotografías consecutivas y un tensor de los diez primeros niveles del libro, y sobre esa representación se evalúan cinco arquitecturas:

- una red recurrente **GRU** (capa oculta de dimensión 56) sobre la secuencia de características, que modela la dinámica temporal reciente;
- un codificador convolucional del libro, el **BookEncoder**, inspirado en DeepLOB [4, 6], que resume cada fotografía con dos convoluciones unidimensionales sobre la dimensión de niveles y un *pooling* dual,

$$\mathbf{h} = [\text{mean}_\tau \phi(\mathbf{B}_\tau) \parallel \text{max}_\tau \phi(\mathbf{B}_\tau)], \quad \phi = \text{ReLU} \circ \text{Conv1d} \circ \text{Dropout} \circ \text{ReLU} \circ \text{Conv1d}, \quad (3.5)$$

donde $\mathbf{B}_\tau$ es el libro en el paso τ y $\parallel$ denota concatenación; el *pooling* máximo capta los picos de profundidad, a menudo más informativos que la media en mercados poco líquidos;

- una **fusión** que combina la salida de la GRU y la del BookEncoder en una cabeza común, para aprovechar simultáneamente la dinámica temporal y la estructura del libro;
- una red convolucional temporal (**TCN**) orientada a clasificar el régimen de volatilidad de la sesión;
- un codificador con **auto-atención** sobre esa misma representación, en dos variantes —atención sobre la última fotografía del libro y sobre la secuencia completa—, incorporado para comprobar si el mecanismo que domina la literatura reciente de modelos de secuencia cambia el diagnóstico.

Todas estas arquitecturas aprenden representación —obtienen métricas de clasificación y de ordenación razonables, y algunas políticas *proxy* resultan positivas dentro de muestra—, pero ninguna produce una política rentable y estable cuando se exige selección causal día a día y estabilidad en todo el bloque de test. Con un horizonte de entrenamiento de unas dos semanas (unos 5 800 ejemplos) la varianza de estos modelos es demasiado alta: memorizan el periodo de entrenamiento y no generalizan al siguiente. La auto-atención es el caso más nítido de este patrón: con aproximadamente el doble de parámetros mejora el AUC de validación (0,568 frente a 0,560–0,563 de las variantes recurrente y convolucional) y, aun así, empeora la economía de test (−1,99 frente a −1,08 ticks netos al mismo umbral, con tres días negativos frente a dos). La capacidad añadida compra ordenación dentro de muestra, no política fuera de ella. Por eso el aprendizaje profundo se aparca a la espera de un volumen de datos sustancialmente mayor.

Durante la auditoría se detectó y corrigió un error de interpretación en el *score* de selección adversa (su orientación correcta es $1 - P(\text{adverso})$), lo que ilustra que una métrica positiva no basta sin auditar su significado económico. Por último, al comparar horizontes (Tabla 3.4), solo H60 conserva señal; H120 y H240 colapsan, por lo que H60 queda como único candidato.

Tabla 3.4: Selección de horizonte (ticks netos *proxy*). Solo H60 conserva señal.

Métrica	H60	H120
AUC test	0,565	0,495
Top 35 % test, coste 0,5	+0,426	−1,117
Top 35 % test, coste 1,0	+0,058	−1,491

3.4.8 Peldaños de la asignatura: baselines clásicos, kNN-DTW y MOMENT

Para situar al especialista y responder de forma explícita a las técnicas de la asignatura de series temporales, se evalúa una escalera de modelos de referencia sobre un mismo problema controlado: predecir la dirección del precio medio a horizonte H60 (60 pasos de 2s) en la foto de apertura—45s de cada mercado, con la misma capa económica (comisión taker oficial). El conjunto de evaluación son 906 casos congelados; cada modelo produce una señal de signo y se reporta su acierto direccional y su resultado bruto en ticks. Conviene subrayar que estos baselines usan un universo más amplio que el especialista final—no aplican su filtro estricto de tradabilidad—, de modo que la comparación con la cifra sellada del especialista es de contexto, no cabeza a cabeza.

Los baselines clásicos se ajustan por serie sobre el tramo pre-señal, sin información futura. El **naive-drift** (signo de la deriva reciente) y el **ARIMA(1,1,1)** son los más informativos; el **suavizado exponencial de Holt** queda por detrás, y el **kNN con distancia DTW**—biblioteca de mayo, consultas de junio, con separación temporal estricta— no supera a la deriva simple. Como demostración de forecasting estacional donde tiene sentido, un modelo de Holt-Winters sobre la actividad agregada mejora un 2,7 % el error del persistente; a horizonte de segundos sobre el precio, en cambio, el componente estacional no aporta.

El peldaño fundacional es **MOMENT-1-small**, evaluado en tres regímenes de adaptación crecientes: *zero-shot* (reconstrucción con la cola enmascarada, sin entrenar), *linear-probing* (solo la cabeza de predicción, backbone congelado) y *fine-tuning completo* (todo el modelo, entrenado en GPU). El entrenamiento usa ventanas del propio corpus muestreadas fuera de los casos de evaluación—con un margen de exclusión que garantiza que entrenamiento y evaluación no comparten ni un frame— y restringidas al mismo régimen de actividad que el corte de evaluación (Sección 3.2). La Tabla 3.5 recoge el resultado.

Tabla 3.5: Escalera de modelos de referencia sobre los 906 casos congelados (H60, comisión taker oficial). Acierto direccional y resultado bruto medio en ticks; el neto taker es negativo en todos los casos por el régimen de comisiones de 2026.

Modelo	Acierto direccional	Bruto (ticks)
ARIMA(1,1,1)	56,5 %	+0,621
naive-drift	53,1 %	+1,186
Holt (suavizado exponencial)	48,4 %	+0,516
MOMENT fine-tuning completo	47,3 %	+0,082
MOMENT linear-probing	46,6 %	−0,175
MOMENT zero-shot	45,5 %	−0,585
kNN-DTW	45,3 %	−0,209

De esta escalera se extraen dos lecturas. La primera es que la adaptación del fundacional *ayuda de forma monótona*: cada régimen mejora al anterior, tanto en acierto como en resultado bruto (zero-shot → linear-probing → fine-tuning completo), lo que confirma que el modelo capta algo de la estructura local al especializarse. La segunda, más importante, es que *ni siquiera el fine-tuning completo supera a los baselines clásicos*: naive-drift y ARIMA, con una fracción del coste computacional, se sitúan claramente por encima. El

fundacional de series temporales, la herramienta más sofisticada de la escalera, no es aquí la más precisa.

Cabe preguntarse si el fundacional mejoraría con más datos. La Figura 3.13 responde con una curva de escalado: se re-entrena el linear-probing sobre subconjuntos crecientes de ventanas (de 2.700 a 40.500) y se evalúa cada uno sobre los mismos casos congelados. La curva es esencialmente plana —el acierto oscila entre el 44 y el 47 % sin tendencia clara al alza— y se mantiene por debajo del baseline clásico en todo el rango. La conclusión es que el cuello de botella no es la cantidad de datos de entrenamiento ni la capacidad del modelo, sino el régimen de datos: a horizonte de 2 segundos, el precio medio de estos mercados apenas contiene estructura direccional explotable por encima de la deriva, con independencia de la sofisticación del modelo. Es la misma lección que atraviesa el trabajo —predecir es difícil, y donde se puede, no basta— reforzada ahora desde el lado del modelado.




Figura 3.13: Curva de escalado del fine-tuning de MOMENT (linear-probing) frente al número de ventanas de entrenamiento, evaluada sobre los 906 casos congelados. Más datos no cierran la brecha con la deriva simple: el techo lo marca el régimen de datos, no el tamaño de la muestra.

3.4.9 Especialista *prestart* H60

El candidato final es un especialista para la ventana *prestart*: un modelo de *gradient boosting* sobre histogramas (HistGradientBoosting) con las dos cabezas descritas, entrenado sobre 36 características sin variables de reloj (para evitar atajos temporales triviales). La señal se restringe a la ventana de -60 a -45 segundos respecto a la apertura, con libro saludable y coste visible acotado (Figura 3.14).

Ambas cabezas comparten una configuración de regularización agresiva (tasa de aprendizaje 0,045, hasta 220 iteraciones con parada anticipada, máximo de 15 hojas por árbol, mínimo de 120 muestras por hoja y regularización L2 de 0,10), necesaria porque el bloque de entrenamiento del especialista tiene del orden de mil observaciones útiles. La política congelada opera cuando el valor esperado predicho supera 0,75 y la probabilidad de salud




Figura 3.14: La ventana *prestart* del especialista: solo se opera entre -60 y -45 segundos respecto a la apertura del mercado, donde el análisis exploratorio detectó una densidad atípica de actividad del libro.

no baja de 0,50; ambos umbrales se seleccionaron sobre el conjunto de validación, nunca sobre el test terminal.

3.4.10 Filtro de volatilidad

Al inspeccionar el bloque fuera de muestra se observó un cambio de régimen: la fracción de sesiones de alta volatilidad pasó de un 18–22 % en entrenamiento a alrededor del 58 % (véase la Figura 4.1 del Capítulo 4). Como diagnóstico se separaron las acciones usando el umbral 0,6657, correspondiente al percentil 80 de la volatilidad de entrenamiento. El valor numérico procede, por tanto, de datos antiguos; sin embargo, la decisión de incorporar este filtro a la política se tomó después de observar el nuevo bloque. Por esa razón, el resultado filtrado no se considera una segunda validación fuera de muestra, sino un análisis *post-hoc* que genera una hipótesis para validación prospectiva.

3.4.11 Brazos de *gate* pre-registrados: estático, GARCH y clustering de regímenes

El filtro de volatilidad anterior es una hipótesis *post-hoc*, y como tal no puede validarse sobre los mismos días que la inspiraron. Para convertirla en una prueba honesta, el pre-registro compromete por adelantado *tres* brazos de *gate* de régimen, cada uno con sus parámetros fijados antes de mirar la ventana de evaluación, que se evalúan en paralelo sobre la misma selección de señales. Los tres atacan la misma pregunta —operar solo cuando el régimen se parece a aquel en el que el modelo fue entrenado— por vías de sofisticación creciente.

Brazo estático. El filtro heredado: operar solo si la volatilidad realizada del perpetuo a 5 segundos no supera 0,6657, el percentil 80 de la volatilidad de entrenamiento. Es un umbral fijo sobre una única variable; su versión de junio se reporta como diagnóstico, nunca como confirmación.

Brazo GARCH. Un modelo GARCH(1,1) con media constante sobre los retornos logarítmicos a un minuto del precio del perpetuo (en puntos básicos), ajustado *exclusivamente* con datos hasta el 31 de mayo (13.036 observaciones). El *gate* opera cuando la volatilidad condicional a un paso $\hat{\sigma}_t$ no supera 4,531 puntos básicos, el percentil 80 dentro de muestra. Los parámetros quedaron congelados ($\mu = 0,0358$, $\omega = 0,391$, $\alpha_1 = 0,0908$, $\beta_1 = 0,892$) con su resumen SHA-256 en el pre-registro. Frente al brazo estático, el GARCH sustituye un umbral fijo por una estimación dinámica de la volatilidad que se actualiza sesión a sesión, pero sin reajustar nada tras el corte de mayo.

Brazo de clustering de regímenes. Un modelo no supervisado (KMeans con k elegido por silueta, sobre características causales del tramo pre-apertura —volatilidad realizada, volumen, *spread*, actividad y rango— normalizadas de forma robusta) entrenado solo con datos anteriores a julio. La solución retenida es $k = 2$ (silueta 0,31): un régimen «tranquilo» (volatilidad $\approx 5,8$ bps) y otro «agitado» ($\approx 13,0$ bps, con más *spread* y volumen). A diferencia de los dos anteriores, no impone un umbral sobre una variable elegida a mano, sino que deja que los datos definan los regímenes; su artefacto se sella como adenda del pre-registro antes del primer corte prospectivo. Un hallazgo del cruce con la vía maker matiza su interpretación: el régimen agitado, que perjudica al lado taker, resulta *más* rentable para el maker —el mismo flujo que estorbaba a uno alimenta al otro—, lo que lo señala como candidato a *gate* de la política maker, no solo de la taker.

Capas de reporte. Sobre la selección de cada brazo se reportan, declaradas por adelantado, las capas de la Sección 3.4.5: la comparabilidad histórica (net@0,5), la capa *taker* con la comisión oficial de 2026 —cuya expectativa negativa se compromete antes de mirar los datos— y la capa *maker* simulada, cuando el simulador de colas y fills la produzca. La combinación de tres brazos pre-comprometidos y tres capas publicadas en su totalidad es lo que impide que la elección *a posteriori* del mejor resultado infle las conclusiones.

3.4.12 Protocolo de congelación

El especialista base —modelo, conjunto de características y umbrales EV/salud— se congeló antes de observar el conjunto fuera de muestra del 6 al 10 de junio. Su evaluación sin filtro constituye, por ello, la prueba fuera de muestra genuina y previene el sobreajuste por selección múltiple [12]. El filtro de volatilidad queda fuera de esa afirmación de congelación: se definió como política candidata después del diagnóstico del bloque y solo podrá validarse con observaciones posteriores al 10 de junio.

Capítulo 4

Resultados y análisis

Este capítulo separa dos niveles de evidencia que no deben confundirse. Primero se presenta la evaluación confirmatoria del especialista base, congelado antes de observar el bloque del 6 al 10 de junio. Después se documenta el diagnóstico de volatilidad realizado sobre ese mismo bloque. El segundo resultado es útil para formular una política futura, pero no constituye una nueva validación fuera de muestra.

4.1 Resultados obtenidos

4.1.1 Validación fuera de muestra del especialista base

El especialista congelado selecciona 754 unidades de acción en los cinco días fuera de muestra. Sin aplicar ningún filtro decidido a partir de esos datos, obtiene un neto medio de +0,349 ticks al coste de referencia. El promedio es positivo en tres de cinco días y pasa a ser ligeramente negativo (−0,026 ticks) cuando se carga el coste visible completo (Tabla 4.1). Esta es la estimación limpia del rendimiento fuera de muestra.

Tabla 4.1: Validación fuera de muestra del especialista base congelado. Los valores son ticks netos por unidad de acción y no incorporan el filtro de volatilidad posterior.

Métrica	Valor
Unidades de acción (n)	754
Días de soporte	5 (3/5 positivos)
Neto medio (coste 0,25, optimista)	+0,537 ticks
Neto medio (coste 0,5, referencia)	+0,349 ticks
Neto medio (coste 1,0, estrés)	−0,026 ticks

El signo positivo al coste de referencia indica que el especialista conserva una señal modesta donde los modelos anteriores habían fracasado. Sin embargo, ni la estabilidad diaria ni el escenario de coste completo permiten calificarlo como una política robusta. La lectura defendible es, por tanto, *señal parcial fuera de muestra*, no rentabilidad demostrada.

Tabla 4.2: Desglose diario del especialista base al coste de referencia.

Día	n	Neto medio @0,5
6 de junio	220	+0,666
7 de junio	97	+1,342
8 de junio	241	+0,308
9 de junio	146	−0,565
10 de junio	50	−0,105

4.1.2 Diagnóstico *post-hoc* del régimen de volatilidad

La inspección del bloque reveló que la fracción de sesiones de alta volatilidad aumentó hasta aproximadamente el 58 %, frente al 18–22 % de los periodos históricos (Figura 4.1). Para estudiar ese desplazamiento se dividió la selección con el umbral 0,6657, percentil 80 de la volatilidad de entrenamiento. El umbral numérico no se ajustó al bloque nuevo, pero la decisión de usarlo como filtro sí se tomó tras observarlo; por ello, todo lo que sigue en esta subsección es diagnóstico y exploratorio.




Figura 4.1: Fracción de sesiones de alta volatilidad por periodo. El salto del bloque nuevo motiva el análisis de régimen, pero no valida por sí mismo el filtro.

La Tabla 4.3 muestra el contraste. Hay 318 acciones de baja volatilidad, 435 de alta volatilidad y una acción sin dato de volatilidad, que una regla operativa conservadora rechazaría. Las primeras son positivas y las segundas, negativas al coste de referencia.

Tabla 4.3: Diagnóstico *post-hoc* por régimen en el bloque del 6–10 de junio (ticks por unidad de acción).

Régimen	n	@0,25	@0,5	@1,0
Baja volatilidad	318	+1,258	+1,069	+0,691
Alta volatilidad	435	+0,004	−0,183	−0,558
Volatilidad ausente	1	+3,327	+3,154	+2,807
Total sin filtro	754	+0,537	+0,349	−0,026

Si se aplica retrospectivamente el filtro de baja volatilidad, el subconjunto de 318 acciones mantiene signo positivo en los tres niveles de coste (Figura 4.3) y en los cinco días




Figura 4.2: Contraste *post-hoc* del neto medio entre baja y alta volatilidad. La separación es una hipótesis de política que requiere datos posteriores.

(Figura 4.4). Su suma cronológica presenta un drawdown diagnóstico de 88,1 ticks (Figura 4.5). Estas magnitudes describen el subconjunto observado; no son PnL de una cartera ejecutada.




Figura 4.3: Sensibilidad al coste del subconjunto de baja volatilidad. Resultado exploratorio obtenido tras inspeccionar el mismo bloque.

El remuestreo independiente de las 318 acciones produce un IC90 de $[+0,472, +1,654]$ y $P = 0,998$, pero esa estimación ignora la dependencia entre señales del mismo mercado. Hay 156 mercados y hasta ocho acciones por mercado. Un *bootstrap* agrupado por mercado amplía el IC90 a $[+0,193, +2,004]$ y reduce la probabilidad estimada a 97,6 %. Ambos cálculos son descriptivos: la selección *post-hoc* impide darles una lectura confirmatoria.

4.1.3 Registro de sombra retrospectivo

Para auditar la mecánica de la política candidata se construyó un registro de sombra *offline*: conserva cada unidad de acción, su mercado, el resumen diario y las reglas de promoción. Es una reproducción retrospectiva de lo que la regla habría indicado, no una ejecución prospectiva ni un sistema activo en tiempo real. El filtro queda congelado después del 10 de junio; solo observaciones posteriores pueden contar para las puertas de promoción.

Además, varias señales pertenecen al mismo mercado y sus horizontes H60 se solapan. Por ello se denominan *unidades de acción*, no operaciones independientes, y la suma




Figura 4.4: Neto medio diario del subconjunto *post-hoc* de baja volatilidad.




Figura 4.5: Suma acumulada y drawdown diagnóstico de 318 unidades de acción. No representa una cartera con restricciones de capital o de exposición simultánea.

acumulada no incorpora una regla de exposición máxima. Una futura sombra prospectiva deberá decidir si permite apilar posiciones o admite una sola posición por mercado.

4.1.4 Resultados con la comisión oficial de 2026 (capa taker-real)

La corrección del modelo de costes (Sección 3.4.5) obliga a re-evaluar la política congelada con la comisión oficial de 2026. La operación se hizo sin reentrenar nada: los mismos artefactos sellados, la misma selección de acciones, y como control de integridad se reprodujeron primero las cifras publicadas (la política $ev > 0,75$, $healthy \geq 0,5$ da $n = 754$ y $+0,349$ ticks netos al coste de referencia; el corte de baja volatilidad, $n = 318$ y $+1,069$). Después se aplicó la comisión real. La Tabla 4.4 resume el resultado.

El resultado es inequívoco: *ningún corte taker es positivo* bajo el régimen de comisiones vigente, ni siquiera en la cota optimista que solo carga la comisión de entrada. La comisión media de entrada (1,75 ticks) supera por sí sola el resultado bruto de la señal. Este número negativo no es un fracaso del trabajo, sino su lección central confirmada estructuralmente: una precisión direccional cercana al 90 % —demostrada en los capítulos anteriores— no

Tabla 4.4: Política congelada re-evaluada con la comisión oficial de 2026. Ticks netos medios por acción; «solo entrada» es la cota optimista que omite la comisión de salida, «ida y vuelta» carga ambas. Las comisiones medias medidas son de 1,75 ticks a la entrada y 1,71 a la salida.

Corte	Publicado (fee errónea)	Fee oficial 2026	
		solo entrada	ida y vuelta
Todas las acciones ($n = 754$)	+0,349	−1,059	−3,304
Baja volatilidad ($n = 318$)	+1,069	−0,342	−2,604

se traduce en beneficio cuando el coste de ejecución la domina. «Acertar no es ganar» deja de ser una advertencia metodológica y pasa a ser una consecuencia medida del régimen de comisiones. La política congelada se reporta, por tanto, tal cual: negativa en la capataker, lo que motiva el giro al lado maker del Capítulo 5 y no una búsqueda de umbrales que la rescaten.

4.1.5 Validación prospectiva pre-registrada

Todo lo anterior en este capítulo comparte una debilidad que ninguna técnica estadística puede reparar: se mide sobre datos que ya existían cuando se diseñó la política. Por cuidadosa que sea la separación entre entrenamiento y prueba, el analista ha visto el periodo, ha iterado sobre él y ha tomado decisiones informadas por lo que allí ocurría. La única refutación limpia de esa objeción es evaluar sobre datos que todavía no existían cuando la política quedó congelada. Esta sección recoge esa evaluación.

Cadena de compromiso

El procedimiento se diseñó para que el autor no pudiera ajustarlo después de ver los resultados, y para que un tercero pueda comprobarlo sin tener que fiarse de su palabra. Antes de que existiera un solo día de la ventana, se fijaron por escrito y se sellaron: el universo de mercados, los filtros, la configuración exacta del simulador, los brazos que se ejecutarían, las métricas que se reportarían y las reglas de decisión, junto con las huellas criptográficas de los cinco artefactos ejecutables. El documento se registró además en la cadena de bloques de Bitcoin mediante OpenTimestamps [35], de modo que su fecha es verificable con independencia del repositorio y del autor. El Anexo 8 reproduce el pre-registro y el procedimiento de verificación del sello.

La cadena tiene una divergencia deliberada que conviene declarar aquí y no en una nota al pie: la huella del motor de simulación que consta en el pre-registro no es la del motor que se ejecutó. El 13 de julio de 2026 se detectó y corrigió una errata que impedía ejecutar el brazo base, y la corrección se selló a su vez con su propia marca de tiempo. Revertir al artefacto originalmente sellado no habría hecho el experimento más honesto: lo habría hecho imposible, porque el brazo de referencia no llegaba a completar una corrida. Se conserva por tanto la cadena completa —sello original, errata, sello de la errata— y se reporta la divergencia como parte del resultado.

Ventana de evaluación

La ventana comprende **35 días completos, del 10 de julio al 13 de agosto de 2026**, ambos incluidos. Su comienzo está determinado por el pre-registro, que excluye explícitamente los días 6 a 9 de julio por haberse empleado en el desarrollo del simulador. Su final no lo decidió el autor: el 14 de agosto la captura se interrumpió por una desconexión física del almacenamiento del recolector, descrita en el Capítulo 6. El último día íntegro es el 13 de agosto.

Esa circunstancia, que operativamente fue un contratiempo, refuerza metodológicamente el resultado. La objeción más natural a cualquier evaluación prospectiva es que el analista elija cuándo parar, y que esa elección dependa de lo que va viendo. Aquí el punto de corte lo fijó un fallo de hardware tres días antes de que se ejecutara la primera evaluación, y la cobertura se verificó sobre el registro de sesiones del recolector —unas 225 sesiones diarias, sin un solo día incompleto dentro de la ventana— antes de calcular ninguna métrica de resultado. El mínimo declarado en el pre-registro era de 25 días evaluados; la ventana disponible lo supera en un 40 %.

Brazos y capas

Se ejecutan los **tres brazos declarados**, y los tres se reportan con independencia de su signo. El brazo *base* es la configuración congelada operando sin señal. El brazo *suppress_ask* suprime durante 240 segundos la cotización de venta del token favorecido por la señal H60. El brazo *tight_risk* activa, en los mercados señalados, un régimen de riesgo estricto que reduce a la mitad el límite de inventario y el sesgo de inventario y duplica el número de fotogramas en plano. La partición por el gate de regímenes congelado descrito en la Sección 3.4.11 se reporta como análisis secundario, con su hipótesis registrada de antemano.

Las métricas son las del pre-registro, sin añadidos: equity neta —caja más inventario valorado a resolución más *rebates*—, su descomposición en las tres partidas, *markout* a corto plazo, peor día y porcentaje de mercados con resultado positivo.

Reglas de decisión, declaradas antes de mirar

La Tabla 4.5 recoge las tres condiciones que el pre-registro declara para promover la política a operación en sombra, y la regla de sustitución entre brazos. Se rellenan y se obedecen sin interpretación. Conviene subrayar que un resultado negativo no es un fracaso del trabajo ni obliga a reescribir nada: el pre-registro declara explícitamente que el experimento es informativo en cualquier dirección y que todo corte se reporta completo. La contribución de esta sección es el procedimiento y su ejecución honesta, no el signo del número que produzca.

Lectura del corte

La política congelada gana dinero y aun así no pasa la puerta. El brazo base acumula +3.408,11 \$ simulados en 35 días —una media de 97,4 \$ diarios— con 10 días negativos y un 50,4 % de pares mercado-token en positivo. Pero su peor día es −235,66 \$, y la regla pre-declarada exigía no bajar de −150 \$. Falla una de las tres condiciones y, por tanto, el veredicto es **NO-GO**: la política no se promueve a operación en sombra.

Tabla 4.5: Puertas de decisión pre-declaradas para el corte prospectivo n° 1, sobre el brazo base. Las tres condiciones deben cumplirse simultáneamente.

Condición	Valor medido	¿Cumple?
Equity neta > 0	+3.408,11 \$	Sí
Peor día > -150 \$ simulados	-235,66 \$ (5-ago)	No
Días evaluados ≥ 25	35	Sí
Resultado: NO-GO		

Tabla 4.6: Resultado del corte prospectivo n° 1 por brazo, con la descomposición declarada en el pre-registro. Valores en dólares simulados sobre los 35 días de la ventana y 1.684 pares mercado-token.

Brazo	Equity neta	Caja	Terminal	Rebates	Peor día
Base	+3.408,11	+9.425,06	-6.712,95	+696,00	-235,66
<i>suppress_ask</i>	+3.397,73	+9.139,05	-6.430,98	+689,66	-241,43
<i>tight_risk</i>	+2.925,10	+8.372,26	-6.103,28	+656,12	-233,26

Conviene detenerse en esto, porque es el resultado más informativo del capítulo. La puerta no rechazó una estrategia que perdiera dinero: rechazó una rentable, y lo hizo por la única de las tres condiciones que mide riesgo y no retorno. Un criterio pre-registrado que solo aprueba no demuestra nada; este tenía dientes, y los enseñó contra un resultado económicamente favorable.

Interesa precisar contra qué se compara ese rendimiento, porque la elección del punto de referencia puede hacerlo parecer mejor o peor de lo que es. La media de 97,4 \$ diarios queda *entre* las dos referencias previas de la misma configuración: los ~ 112 \$ diarios del ajuste sobre mayo-junio, que es una cifra dentro de muestra, y los ~ 53 \$ de la validación única de julio, que era fuera de muestra pero se apoyaba en solo tres días. El retorno medio, por tanto, no mejora ni empeora de forma concluyente: se mantiene dentro de la banda ya conocida.

Lo que sí cambia es la dispersión, y conviene decirlo con precisión porque la lectura inmediata —«la cola izquierda se ha duplicado»— no resiste el contraste. El peor día pasa de $-118,46$ a $-235,66$ \$, pero **ocupa la misma posición relativa dentro de su propia ventana**: su distancia a la media, medida en desviaciones típicas diarias, es de $-2,15$ en desarrollo y $-2,13$ en la ventana prospectiva. No es un día más extremo: es el mínimo de una distribución más ancha.

Lo que se ensancha es medible y tiene dos componentes. La desviación típica de la equity *por par mercado-token* crece de 19,11 a 21,45 \$ —un 12 %, con un contraste de Brown-Forsythe que da $p = 1,7 \cdot 10^{-9}$ —, y el número de pares simultáneos por día sube de 42,4 a 48,1. Ambos efectos se componen: la desviación típica *diaria* pasa de 106,88 a 156,25 \$, un factor 1,46 cuyo contraste F queda en $p = 0,060$, marginal por el escaso número de días. El retorno medio, en cambio, no se mueve de forma detectable (111,53 frente a 97,37 \$ diarios, $p = 0,681$). El valor terminal del inventario aporta el 70,8 % de la varianza de la equity medido como cuota de covarianza —esto es, $\text{cov}(\text{terminal}, \text{equity}) / \text{var}(\text{equity})$ —, que es la descomposición aditiva pertinente cuando las partidas suman exactamente la magnitud descompuesta; conviene precisarlo porque el coeficiente de determinación de una regresión simple entre ambas series es bastante menor ($R^2 = 0,28$), y confundir ambas




Figura 4.6: Corte prospectivo pre-registrado n° 1. Arriba, equity neta acumulada por brazo sobre los 35 días de la ventana. Abajo, equity diaria del brazo base con el umbral pre-declarado de -150 \$: el corte no falla por rentabilidad —la curva acumulada termina en $+3.408$ \$— sino por la profundidad de un único día, el 5 de agosto.

cifras exageraría el poder predictivo del terminal. La partida dominante de la varianza es, en todo caso, precisamente aquella sobre la que actúan los brazos de señal.

Esto obliga a una observación crítica sobre el propio diseño de la puerta, que se hace aquí como limitación y no como atenuante: **el umbral se declaró como una cantidad absoluta, sin análisis de potencia**. Se fijó en -150 \$ contra el peor día de la validación de julio, -120 \$, con un margen del 25 %. Pero un umbral absoluto codifica implícitamente una hipótesis sobre la dispersión: con la desviación por par del desarrollo equivale a unas 1,2 desviaciones típicas diarias, mientras que con la de la ventana prospectiva ($21,45 \times \sqrt{48} \approx 148,6$) cae prácticamente sobre una sola. La probabilidad de fallar la puerta no era la misma en los dos escenarios, y el pre-registro no distinguía entre ellos. Un diseño más exigente habría declarado el umbral en unidades de dispersión, o habría acompañado la regla de la potencia estadística que le correspondía.

La objeción admite además una formulación cuantitativa que conviene hacer explícita, porque responde a la pregunta de si el umbral era siquiera alcanzable. Dada la dispersión diaria efectivamente observada, ¿cuál era el peor día *esperado* en una ventana de 35 días? Simulando 50.000 ventanas con la media y la desviación medidas, el mínimo esperado es de $-232,6$ \$ —frente a los $-235,66$ que se observaron— y la probabilidad de cruzar el umbral

de -150 \$ alcanza el 87 %. Un remuestreo *bootstrap* de los propios días observados, que no supone normalidad, da $-199,9$ \$ y un 64 %; conviene señalar que esta segunda cifra es una cota inferior por construcción, ya que el *bootstrap* del mínimo no puede generar ningún día peor que el peor efectivamente observado y por tanto subestima cualquier probabilidad de cola. Las dos estimaciones coinciden en lo esencial: **era más probable fallar la puerta que superarla, y el día que la hizo fallar no fue un suceso extraordinario sino el mínimo ordinario de una ventana de ese tamaño y esa dispersión** (Figura 4.7, izquierda).




Figura 4.7: Izquierda: distribución simulada del peor día en una ventana de 35 días bajo la dispersión medida. El día observado ($-235,66$ \$) cae junto a la moda de lo esperado, y el umbral pre-declarado queda holgadamente dentro de la región que la distribución cruza. Derecha: techo de oráculo del riesgo terminal —qué ocurriría si se retirase el percentil peor de pares—. Retirar solo el 5 % bastaría para que la puerta se superase, lo que acota el valor máximo de un modelo de riesgo terminal.

Esa misma descomposición permite acotar, por el otro extremo, cuánto valdría acertar el riesgo terminal, que es la línea que el resultado sugiere. Si se retirase con información perfecta el 5 % peor de los pares —85 de 1.684— la equity ascendería a $+6.789$ \$ y el peor día quedaría en $-125,4$ \$: la puerta se superaría. Retirando el decil, la equity llega a $+9.221$ \$ y el peor día a $-70,2$. No es una política, porque exige conocer el futuro, sino la cota superior de lo que un modelo de riesgo terminal podría aportar, y justifica que sea esa —y no la predicción direccional— la dirección de trabajo que este resultado deja abierta.

Nada de esto altera el veredicto. La regla estaba escrita, es la que se aplica y el resultado es NO-GO. Lo que cambia es la explicación de *por qué* se falla: no porque aparezca un riesgo de cola nuevo, sino porque cada operación se volvió un 12 % más dispersa y se ejecutaron más operaciones simultáneas, de modo que la distribución diaria se ensanchó lo suficiente para que su mínimo ordinario cruzara una línea fijada sobre una distribución más estrecha.

Ninguna variante de señal sustituye a la base. La regla de sustitución exigía mejorar simultáneamente la equity neta y el valor terminal. Las dos variantes mejoran el terminal —*suppress_ask* lo lleva de $-6.712,95$ a $-6.430,98$ y *tight_risk* hasta $-6.103,28$ — pero ninguna mejora la neta. Se documentan y se descartan, como estaba escrito.

El detalle importa más que el agregado, porque las variantes solo actúan sobre los 208 pa-

res que la señal toca. Restringiendo la comparación a ese subconjunto, el efecto es inequívoco: *tight_risk* reduce el inventario terminal de $-1.565,57$ a $-955,91$ —un 39 % menos— mientras la equity neta cae de $+841,44$ a $+358,44$, es decir, un 57 %. La señal H60 hace exactamente lo que el diagnóstico del Capítulo 4 anticipaba: incide sobre el inventario terminal, que era la palanca identificada. Lo que el corte añade es el precio de accionarla, y ese precio no estaba medido: controlar el riesgo terminal cuesta más de la mitad del beneficio en caja. La hipótesis era correcta y la palanca funciona; simplemente no compensa.

El *markout* confirma que la ejecución maker captura spread, pero poco. Los tres brazos quedan en torno a $+0,011$ ticks a 30 y 60 segundos. El signo es el esperado para un proveedor de liquidez, la magnitud es marginal.

Análisis secundario por régimen: la hipótesis registrada se cumple. Aplicando el gate congelado de la adenda A —entrenado únicamente con datos de mayo y junio, y por tanto sin haber visto un solo frame de la ventana— las 1.673 series se reparten en dos regímenes, siendo el agitado el de mayor volatilidad realizada (11,5 frente a 6,2). Sobre el brazo base y descartando los terminales ambiguos ($n = 1.316$), el régimen agitado rinde $+4,06$ \$ de equity media por serie frente a $+3,12$ \$ del tranquilo, y concentra además un inventario terminal menos negativo. La hipótesis declarada de antemano —que el régimen agitado favorece el neto maker— queda confirmada prospectivamente, lo que respalda la observación de desarrollo recogida en el Capítulo 3.

Qué se lleva el trabajo de aquí. Un NO-GO pre-registrado no invalida la vía maker: la sitúa. La economía del lado maker es positiva y medible donde la del lado *taker* era estructuralmente negativa, que es el giro que motiva el Capítulo 5; pero su perfil de riesgo diario, con la configuración congelada y sin respuesta competitiva del mercado, excede el umbral que este trabajo se fijó antes de mirar. La consecuencia práctica no es abandonar la línea sino que cualquier continuación debe atacar la cola izquierda —no el retorno medio— y volver a someterse a una puerta declarada de antemano.

Capas de reporte del protocolo general

El pre-registro general contempla, además de la adenda del simulador, dos capas de reporte sobre la política congelada del lado *taker*: la histórica a 0,5 y la de comisión oficial. Su corte prospectivo tiene fecha propia y posterior —el 24 de agosto de 2026— y se reporta aquí en un segundo bloque. Que las dos fechas sean distintas no es un descuido sino la consecuencia de que son dos experimentos encadenados: el del simulador maker no podía pre-registrarse hasta que el simulador existió, y por eso tiene su propia ventana, más corta y posterior. Ninguna de las dos fechas se ha movido respecto a lo sellado.

4.2 Comparativa con otros enfoques y baseline

Esta sección sitúa el resultado limpio del especialista frente a las alternativas evaluadas: las arquitecturas profundas sobre el libro de órdenes y los intentos de adaptación al cambio de régimen. La comparación justifica por qué la mejor señal disponible procede de un modelo tabular sencillo y no de una red profunda.

4.2.1 Especialista tabular frente a aprendizaje profundo

Las redes recurrentes y convolucionales sobre el libro aprenden representación —algunas políticas *proxy* resultan positivas dentro de muestra—, pero esa ventaja no sobrevive cuando se exige selección causal día a día y estabilidad en todo el bloque de test. Con unas dos semanas de datos, la capacidad necesaria para generalizar temporalmente excede lo que las redes pueden estimar de forma fiable.

El modelo tabular con regularización agresiva opera en el extremo opuesto: aumenta su sesgo pero reduce drásticamente la varianza. Restringir la señal a la ventana *prestart* acota el espacio de hipótesis. Esa combinación conserva un promedio positivo al coste de referencia en el bloque intacto, aunque todavía no supera el coste de estrés. El resultado no descarta el aprendizaje profundo; lo sitúa como una vía a reevaluar cuando el volumen de datos crezca.

4.2.2 Experimentos de adaptación al régimen

Ante el cambio de régimen se probaron reentrenamiento incremental con ventana móvil, alineación de correlaciones CORAL [13], un filtro conformal, un *ensemble* por *bootstrap*, un filtro de volatilidad adaptativo, características normalizadas por volatilidad y *distillation* de una red convolucional temporal. Ninguna alternativa produjo evidencia prospectiva robusta con tan pocos días. Este resultado negativo sigue siendo informativo, pero no permite declarar vencedor al filtro simple sobre el mismo bloque usado para proponerlo. La comparación definitiva queda aplazada hasta disponer de nuevos datos bajo una política ya congelada.

4.2.3 Diagnóstico del fallo fuera de muestra: *deep ensembles* y *drift*

La debilidad conocida de la pieza sellada es la cabeza de salud (*healthy*): su capacidad de discriminación cae del entrenamiento a la validación de forma acusada (AUC 0,79 $\rightarrow$ 0,56). Conviene explicar *por qué*, porque la causa determina si un reentrenamiento con más datos tiene techo. Se descompone la incertidumbre con un *deep ensemble*: diez réplicas de la misma cabeza entrenadas con semillas distintas, midiendo tanto su rendimiento por partición como su desacuerdo mutuo (Figura 4.8).

El diagnóstico es inequívoco en tres puntos. Primero, la caída fuera de muestra es *estable entre semillas* —la desviación del AUC entre réplicas es de apenas $\pm 0,005$ —, de modo que no es un artefacto de suerte en la inicialización: todas las réplicas coinciden en que la cabeza falla en junio. Segundo, el desacuerdo entre réplicas es *prácticamente constante* entre entrenamiento y test ($\approx 0,03$ en ambos): la incertidumbre epistémica no aumenta fuera de muestra, así que las réplicas no extrapolan de forma dispersa, sino que convergen con confianza a una función que simplemente no separa las clases en junio; promediarlas apenas mueve el AUC (0,544 $\rightarrow$ 0,547), lo que descarta que el problema sea de varianza. Tercero, un clasificador de dominio entrenado para distinguir mayo de junio a partir de las mismas características lo consigue con AUC 0,90: las distribuciones de entrada se desplazan de forma marcada entre los dos periodos, encabezadas por la base del perpetuo (*perp_basis*) y la estructura de diferencias al contado-perpetuo.

La conclusión es que el fallo de la cabeza de salud no es ruido irreducible ni un proble-

ma de capacidad del modelo, sino *concept drift* inducido por un cambio de régimen en las variables externas de Bitcoin. Esto tiene una consecuencia práctica directa para la iteración v2: reentrenar con dos o tres veces más datos del mismo periodo tiene techo, porque el obstáculo no es el tamaño de la muestra sino la cobertura del régimen; solo datos que abarquen el régimen de junio mejorarían la generalización. Es la misma lección que ya apuntaba el fracaso de las técnicas de adaptación de dominio: contra un cambio de régimen con pocos días, restringir la operativa al régimen conocido es más honesto que pretender corregirlo.




Figura 4.8: Diagnóstico del fallo fuera de muestra de la cabeza de salud. Izquierda: el AUC se desploma de entrenamiento a test con una dispersión mínima entre las diez réplicas (barras de error) y un desacuerdo entre réplicas plano (línea naranja) —el fallo es estable y no es epistémico. Derecha: un clasificador de dominio separa mayo de junio con AUC 0,90, señal de un fuerte desplazamiento de covariables encabezado por la base del perpetuo.

4.2.4 Curva de escalado de datos: tabular frente a aprendizaje profundo

La conclusión anterior —el tabular sencillo bate a la red profunda con pocos datos— invita a una objeción natural: ¿no ganaría la vía profunda con más datos, dada su mayor capacidad? Se responde empíricamente con una curva de escalado que enfrenta a ambas vías sobre la *misma* tarea y evaluación. Se predice la dirección del tramo H60 en los 906 casos congelados a partir de ventanas de contexto régimen-ajustadas y sin fuga; la vía profunda es el fine-tuning de MOMENT (Sección 3.4.8) y la tabular un *gradient boosting* sobre características clásicas derivadas de la misma ventana (retornos a varios rezagos, momentum, volatilidad realizada y distancia a 0,5). Ambas se entrenan sobre subconjuntos crecientes del mismo corpus —de 3.000 a algo más de 41.000 ventanas— y se evalúan sobre los mismos casos (Figura 4.9).

El resultado es inequívoco: la vía tabular domina a la profunda *en todo el rango de datos*. Con el corpus mínimo, la tabular acierta un 48,2 % frente al 46,0 % de MOMENT; con el corpus completo, la tabular sube hasta el 50,3 % mientras que la profunda se estanca en torno al 46,8 %. Es decir, la vía tabular no solo parte de un nivel más alto, sino que además escala al menos tan bien: la brecha no se cierra al añadir datos, se ensancha. La objeción queda respondida en negativo —al menos en este régimen de tamaño de corpus—

y refuerza la elección del modelo tabular como vehículo de la señal. La lección para el proyecto es coherente con el resto del trabajo: la complejidad del modelo no es el cuello de botella, de modo que no compra rendimiento; con dos semanas de datos, la capacidad de una red profunda es una desventaja, no una ventaja.

Conviene delimitar con exactitud qué eje recorre esta curva, porque de ello depende el alcance de la conclusión. El presupuesto de datos se varió aumentando el número de *ventanas* de entrenamiento sobre un corpus fijo de 509 mercados —1.018 pares mercado-token— pertenecientes todos a la temporalidad horaria. Como las ventanas se solapan casi por completo, lo que crece a lo largo del eje es la densidad de muestreo, no el número de trayectorias independientes, que permanece constante. Y la temporalidad horaria es solo una de las tres capturadas: un día cualquiera del corpus contiene 24 mercados a una hora, 96 a quince minutos y 284 a cinco, de modo que la curva se apoya en torno al 6 % de los mercados disponibles. La conclusión que sostiene, por tanto, es que *más muestras solapadas del mismo conjunto de trayectorias* no cierran la brecha; no llega a afirmar que no la cerraría un corpus con un orden de magnitud más de trayectorias independientes. Ese experimento sí se ha realizado, después de detectar la limitación, y se recoge a continuación.

4.2.5 Adenda C: la curva de escalado sobre trayectorias independientes

Detectada la limitación anterior, se diseñó y **pre-registró** un experimento que varía exactamente el eje que faltaba y ningún otro. El protocolo se selló antes de entrenar ningún modelo, con las huellas criptográficas de los tres artefactos ejecutables y una marca de tiempo de OpenTimestamps, y con las dos redacciones posibles del resultado escritas de antemano para que ninguna rama pudiera elegir la narración.

El corpus se amplió a las tres temporalidades capturadas sobre *los mismos 24 días*: 7.784 mercados y 15.568 pares mercado-token, frente a los 509 y 1.018 originales. Una restricción física obliga a un cambio: la rejilla es de dos segundos, de modo que un mercado de cinco minutos apenas alcanza los 150 fotogramas y el contexto de 512 de la curva publicada no cabe en él. Se fijó por tanto un contexto de **128 fotogramas en todos los brazos**, incluido el de una hora; reducirlo solo en el brazo ampliado habría confundido longitud de contexto con número de trayectorias. Los cuatro brazos —tabular y profundo, con y sin temporalidades cortas— se evalúan sobre *los mismos* 916 casos held-out de mercados horarios, que es la comparación conservadora: el brazo ampliado no puede beneficiarse de un conjunto de prueba más benévolo.

Aplicada literalmente, la regla pre-registrada activa la rama principal: el brazo profundo no supera al tabular por más de un punto porcentual en ningún punto del eje, de modo que la conclusión publicada no queda declarada artefacto del diseño muestral.

Pero la lectura honesta del experimento es más severa que su propia regla, y conviene decirlo con claridad: **ninguno de los ocho puntos se distingue del azar**. Todos los intervalos de confianza contienen el 50 % y el contraste binomial frente a esa hipótesis no baja de $p = 0,25$ en ningún caso. La regla de decisión exigía separar los brazos por un punto porcentual cuando el error estándar del acierto sobre 916 casos es de 1,65 puntos y el intervalo de una diferencia entre dos brazos alcanza los 4,6: el umbral se declaró *por debajo del suelo de ruido* del propio conjunto de evaluación. Ninguna de las dos ramas del

Tabla 4.7: Curva de escalado sobre trayectorias independientes. Acierto sobre los mismos 916 casos held-out para los cuatro brazos, con intervalo de confianza binomial al 95 %. El punto inferior de cada bloque agota el *pool* disponible y llega a 1,65–1,88 veces el máximo que la curva publicada había explorado.

Brazo	n_{train}	Trayect.	Acierto	IC 95 %
Tabular, solo 1h	45.000	950	50,55 %	[47,26; 53,83]
Profundo, solo 1h	45.000	950	49,56 %	[46,28; 52,85]
Tabular, 1h+15m+5m	45.000	2.685	50,87 %	[47,58; 54,16]
Profundo, 1h+15m+5m	45.000	2.685	49,45 %	[46,17; 52,74]
Tabular, solo 1h	74.218	952	49,45 %	[46,17; 52,74]
Profundo, solo 1h	74.218	952	48,03 %	[44,76; 51,33]
Tabular, 1h+15m+5m	84.438	2.834	49,78 %	[46,49; 53,07]
Profundo, 1h+15m+5m	84.438	2.834	48,91 %	[45,62; 52,20]

pre-registro podía, por tanto, quedar establecida con estos datos.

Es la segunda vez en este trabajo que un criterio de decisión se declara en unidades absolutas sin el análisis de potencia que le corresponde —la primera fue el umbral de peor día de la Sección 4.1.5— y la coincidencia no es casual: en ambos casos el umbral se fijó por analogía con una magnitud observada antes, y no derivándolo de la dispersión del estadístico que iba a contrastar. Queda como advertencia metodológica para cualquier continuación, y explica por qué el pre-registro, siendo condición necesaria para la honestidad de un experimento, no es condición suficiente para su poder.

Lo que sí puede afirmarse sin ambigüedad es lo negativo, y no es poco: llevando el eje hasta agotar el *pool* —1,88 veces más ventanas de las que la curva publicada llegó a explorar, y casi el triple de trayectorias independientes— **ninguna de las dos vías consigue despegarse del azar en la predicción del signo a H60**. El resultado es coherente con el diagnóstico independiente del Capítulo 3, donde se estableció que el precio medio es esencialmente una moneda al aire en la apertura de la ventana. La comparación entre arquitecturas se estaba dirimiendo, en realidad, entre dos modelos que no resuelven la tarea.

Un hallazgo no buscado: la tarea excluye los mercados cortos

El diseño pretendía multiplicar las trayectorias por quince y solo consiguió multiplicarlas por menos de tres. El motivo no es de disponibilidad de datos, y merece quedar escrito porque reencuadra la conclusión anterior.

Cada par requiere, para producir una sola ventana válida, 128 fotogramas de contexto, 60 de horizonte y un margen de seguridad anti-fuga de 188 fotogramas alrededor del corte de evaluación, con el muestreo comenzando a mitad de sesión: del orden de 376 fotogramas como mínimo. La longitud mediana de un mercado de cinco minutos es de **160 fotogramas**, menos que el propio margen de seguridad. De sus 10.812 pares, 7.116 no ofrecen ningún rango utilizable y otros 3.662 quedan anulados por el margen; sobreviven 34, que aportan 332 de las 97.752 ventanas totales. El corpus ampliado resulta ser, en la práctica, un 87 % de ventanas horarias.

La consecuencia es metodológica y no menor: lo que limita el aprendizaje aquí no es solo el régimen de los datos, sino **la geometría de la tarea**, que descarta el 94 % de los

mercados capturados antes de que empiece el entrenamiento. La elección de operar solo con mercados horarios, que en la curva original podía parecer una simplificación, resulta ser una consecuencia forzada del horizonte elegido. Una línea futura que quiera aprovechar los mercados de horizonte corto —que son los más numerosos con diferencia— no necesita más datos: necesita redefinir el horizonte de predicción.




Figura 4.9: Curva de escalado sobre la misma tarea (dirección H60, 906 casos congelados): la vía tabular (*gradient boosting*) supera a la profunda (MOMENT) en todo el presupuesto de datos, y la distancia se mantiene o crece al aumentar el número de ventanas de entrenamiento. Con este horizonte de datos, más muestras no hacen que el aprendizaje profundo alcance al tabular.

Capítulo 5

Despliegue

Este capítulo documenta la estrategia de despliegue y, sobre todo, la decisión de no operar con capital real. El especialista base ofrece una señal fuera de muestra modesta, mientras que la mejora del filtro de volatilidad procede de un análisis *post-hoc*. El siguiente paso válido no es producción, sino una sombra prospectiva con la política ya congelada.

5.1 Estrategia de despliegue y seguimiento en sombra

5.1.1 Por qué no se despliega

El resultado limpio se apoya en cinco días, solo tres son positivos y el neto pasa a ser ligeramente negativo bajo el coste completo. El subconjunto de baja volatilidad es más prometedor, pero se identificó usando esos mismos cinco días. Desplegar en estas condiciones confundiría una hipótesis razonable con una validación. Por coherencia con la tesis del trabajo —la honestidad del protocolo prevalece sobre cualquier número concreto— el proyecto se detiene antes de operar.

5.1.2 Del registro retrospectivo a la sombra prospectiva

El registro disponible es *offline* y retrospectivo: reconstruye, unidad de acción a unidad de acción, qué habría indicado la regla de baja volatilidad sobre el bloque ya observado. Sirve para comprobar la contabilidad, el resumen diario y las guardas, pero esos cinco días no cuentan como validación de la política completa.

A partir del cierre del bloque se congela la regla candidata ($\text{volatilidad}_{5s} \leq 0,6657$, $\text{EV} > 0,75$ y probabilidad de salud $\geq 0,50$). Una sombra prospectiva deberá ejecutarla sin cambios sobre fechas posteriores, registrar también las abstenciones y resolver la exposición simultánea por mercado. Solo esa evidencia podrá alimentar las puertas de promoción:

- **Candidato a seguimiento ampliado:** neto superior a 0,5 ticks, al menos 200 unidades de acción y al menos 8 días prospectivos.
- **Candidato a despliegue:** neto superior a 0,5 ticks, al menos 400 unidades, 12 días prospectivos y una regla de exposición/fill validada.

En la fecha de corte hay cero días prospectivos de la política completa. Su estado correcto es *hipótesis congelada pendiente de validación*, no candidata a bot.

5.1.3 Diseño de una hipotética API de inferencia

Solo si se superasen las puertas anteriores, un despliegue eventual tomaría la forma de un servicio de inferencia con cuatro etapas. Primero, una etapa de ingesta que reconstruyese en tiempo real el estado del mercado sobre la malla de dos segundos. Segundo, una etapa de cálculo que generase las 36 características causales del instante actual, idéntica a la del entrenamiento para evitar discrepancias entre entrenamiento y producción (*train/serve skew*). Tercero, una etapa de decisión que consultase las dos cabezas del especialista y devolviese operar o abstenerse. Y cuarto, una capa de guardas que aplicase los filtros de entorno, volatilidad y obsolescencia, además del límite de exposición por mercado.

Por encima operaría una capa de monitorización que vigilase la deriva de distribución, registrase cada decisión para auditoría y dispusiese de un interruptor de parada inmediata. Esta arquitectura es un diseño, no una implementación.

5.2 Economía de la ejecución bajo el régimen de comisiones de 2026

La corrección del modelo de costes (Sección 3.4.5) dejó una conclusión estructural: el lado *taker* de este mercado no es económico para una señal de la magnitud encontrada. Pero la misma estructura de comisiones que cierra una puerta abre otra. Esta sección desarrolla la economía del lado *maker* y el simulador construido para evaluarla, que es la aportación diferencial del trabajo en el plano del despliegue.

5.2.1 Economía del lado maker y tamaño del premio

Quien cruza el mercado (*taker*) paga una comisión $C \cdot r \cdot p(1 - p)$; quien aporta liquidez (*maker*) está exento y, además, recibe una parte del fondo de comisiones en forma de *rebate*, aproximadamente el 20 % del fondo repartido con el mismo peso $p(1 - p)$. Ese peso (Figura 5.1) concentra tanto la comisión como el reparto en torno a $p = 0,5$ —la zona de precios donde opera este trabajo— y se anula en los extremos, cerca de la resolución. El vehículo económico se invierte respecto al *taker*: donde uno paga el *spread* y la comisión, el otro los cobra.

El tamaño del premio se midió sobre la copia histórica (solo lectura) antes de construir nada. El universo de mercados horarios de Bitcoin mueve del orden de \$310.000 de notional al día (\$434.000 contando todas las temporalidades), con una concentración baja —el 10 % de mercados más grandes reúne solo el 23 % del volumen— y una distribución horaria plana: no hay «mercado estrella» ni «hora mágica» por los que competir, de modo que la ventaja está en la presencia continua, que la infraestructura 24/7 del proyecto ya proporciona. El fondo de *rebates* resultante se estima entre \$1.100 y \$3.000 al día, entre diez y veinte veces por encima del umbral por debajo del cual la vía se habría descartado por insignificante. La puerta económica del lado *maker*, por tanto, se pasa con holgura —a diferencia de la *taker*.

5.2.2 El simulador de colas y *fills*

Para evaluar la vía *maker* sin operar con dinero se construyó un simulador de ejecución sobre el libro L2 agregado a 2 segundos y la cinta de operaciones capturada, con las reglas




Figura 5.1: El peso $p(1-p)$ que gobierna la comisión taker y el reparto de *rebates* al maker: máximo en $p = 0,5$ y nulo en los extremos. La economía maker es más densa precisamente en la zona de precios intermedios donde opera el trabajo.

del *venue* separadas del motor para poder auditarlas y reutilizarlas. La estrategia base se une al mejor precio de compra y de venta sin mejorarlo, con tamaño fijo, solo cuando el *spread* alcanza un mínimo, y con un tope de inventario; recotiza cuando el mejor nivel se mueve, perdiendo su lugar en la cola.

El modelo de *fill* es deliberadamente conservador donde puede y explícito en sus sesgos donde no. La cola por delante al colocar una orden se fija en todo el tamaño visible del nivel (se asume que todos los demás llegaron antes); el flujo *taker* de cada frame consume cola cuando la última operación ocurrió a nuestro precio, y un barrido más allá del precio produce ejecución completa. Sin datos de nivel 3 no existe una verdad de cola, por lo que el simulador se declara una *cota*, no una medida: su sesgo optimista (atribuir todo el flujo del frame a nuestro nivel) y su sesgo pesimista (no adelantar a nadie tras recotizar) se netean en la calibración pendiente contra la cinta fresca. La economía por sesión se contabiliza como caja más inventario valorado a la resolución más *rebates*; el **riesgo terminal binario** está incluido: el inventario que queda al expirar liquida a 0 o a 1 según el desenlace del mercado.

El resultado más informativo del simulador no es el número —una banda de entre \$25 y \$200 diarios de beneficio bruto simulado según régimen y configuración, cuyo signo sobrevive a los ajustes estrictos— sino la *descomposición* del riesgo. La selección adversa medida por el *markout* a corto plazo es **favorable** (alrededor de +1 tick): estos libros revierten a pocos segundos, y esa misma predictibilidad de corto plazo que el taker no podía pagar por culpa de la comisión es la que cobra el maker pasivo. El coste no está ahí, sino en el **inventario retenido hasta la expiración**, que resuelve en contra —la selección adversa vive en el tramo terminal, no en el *markout* corto—. La consecuencia de diseño es directa y conecta con la Sección 5.2.3: la palanca dominante es el control de inventario —aplanar la posición antes del tramo en que el precio se decide—, no la captura de *spread* en sí. Introducir una zona plana en los últimos minutos, cotizando solo el lado que reduce inventario, es lo que separa un simulador que pierde en el terminal de uno que conserva el signo.

Las reservas de esta evaluación se declaran sin adornos. El modelo de *fill* es una cota superior; los lados SÍ y NO del mismo mercado se tratan como riesgos independientes cuando en realidad están correlacionados; el corpus es de mayo a junio, sin validación prospec-

tiva; y, sobre todo, ningún *replay* histórico puede capturar la respuesta competitiva de los creadores de mercado incumbentes (Capítulo 6), lo que sitúa la banda simulada como optimista. Es evidencia suficiente para justificar la validación prospectiva pre-registrada, no para afirmar rentabilidad.

Cotización óptima como línea de trabajo futuro. La estrategia base de este simulador cotiza de forma pasiva y controla el inventario terminal con una regla heurística (la zona plana). El paso natural es sustituir esa heurística por la teoría canónica de *market making* óptimo: el modelo de Avellaneda y Stoikov [40], cuyo *precio de reserva* sesga las cotizaciones en proporción al inventario y al tiempo restante hasta la resolución, y sus extensiones al control de riesgo de inventario [41]. Una exploración preliminar sobre el mismo corpus —fuera del pre-registro— indica que este sesgo, adaptado a la varianza de *settlement* binario $p(1-p)$, reduce la pérdida terminal que penaliza a la estrategia pasiva. Esa adaptación, construida aquí de forma heurística, coincide además con la teoría publicada casi en paralelo: la derivación por control estocástico de la cotización óptima en mercados de predicción obtiene como condición terminal de su ecuación de Hamilton-Jacobi-Bellman precisamente la varianza del *settlement* binario, $-\gamma_T q^2 p(1-p)$ con q el inventario [42], lo que respalda de forma independiente la forma funcional empleada. Su magnitud, sin embargo, resultó depender por completo del modelo de *fill*: bajo el supuesto más generoso, en el que una orden alcanzada por un barrido se ejecuta íntegra, la pérdida terminal llega a neutralizarse y la mejora neta es del orden del tres por ciento; bajo el supuesto conservador que fija el propio pre-registro —ejecución de la mitad del tamaño en los barridos— la pérdida terminal solo se atenúa y la mejora neta desaparece. Esta sensibilidad no es exclusiva de la cotización óptima: afecta al orden de mérito de cualquier política que cotice alejada del mejor precio, porque el grueso de sus ejecuciones procede precisamente de barridos. Junto con la ausencia de respuesta competitiva ya señalada, su validación real exige el simulador reactivo antes descrito. La reciente sistematización de la microestructura de los mercados de predicción descentralizados [43] enmarca esta línea dentro de un campo en rápida consolidación.

5.2.3 El tramo terminal: cuándo el precio se vuelve informativo

El riesgo central de un creador de mercado en estos contratos no está en el *spread* que cobra, sino en el inventario que le queda cuando el mercado resuelve: un contrato binario liquida a 0 o a 1, de modo que una posición sin cerrar a la expiración se enfrenta a una varianza estructural de *settlement*. Para dimensionar ese riesgo hace falta saber *cuándo* el precio deja de ser una moneda al aire sobre el desenlace. Se mide de forma directa —sin entrenar ningún modelo, como baseline previo a cualquier modelo secuencial— tratando el precio medio como estimador de la probabilidad de *settlement* y evaluando su calibración a lo largo de la vida del mercado con *proper scoring* (puntuación de Brier) por tiempo a expiración. La etiqueta es el *settlement* real, aproximado por el precio medio del último frame observado cuando este cae a menos de cinco minutos del cierre y ha convergido a 0 o 1; las series cuyo último frame queda lejos del cierre se censuran. El universo etiquetado (310 series, con balance exacto entre desenlaces) es un subconjunto sesgado del corpus —el observado cerca del cierre—, lo que se declara como limitación.

El resultado (Figura 5.2, panel izquierdo) es una caída suave y monótona de la puntuación de Brier: en la apertura del mercado (50–60 minutos a expiración) vale 0,234, apenas por debajo del 0,25 de la moneda al aire, y el acierto direccional sobre el desenlace es del

58 %; el precio no se vuelve claramente informativo hasta los últimos quince a veinte minutos, donde la puntuación cae por debajo de 0,10 (acierto del 90 % o más) y, en el último minuto, converge al settlement. Dicho de otro modo, durante la mayor parte de la vida del contrato el precio medio de Polymarket es honesto pero poco resolutivo, y toda la información se concentra en el tramo final.

El panel derecho matiza el diagnóstico con curvas de fiabilidad en dos cortes. Lejos del cierre, el precio está *bien calibrado* —un precio de 0,25 resuelve a favor en un 31 % de los casos y uno de 0,75 en un 69 %, cerca de la diagonal— pero con casi toda su masa concentrada en torno a 0,5: el mercado dice correctamente «no lo sé». Al acercarse el cierre, la distribución se polariza hacia 0 y 1 conforme llega la información, manteniendo la calibración en los extremos. La consecuencia para el diseño maker es inmediata: el precio sirve como probabilidad (no hay que corregir su sesgo), pero la ventana en la que el inventario deja de ser una apuesta y pasa a estar decidido es estrecha y tardía, lo que convierte el aplanado de inventario *antes* de ese tramo en la palanca de riesgo dominante del simulador —coherente con la concentración de actividad en el minuto 50 detectada en el análisis exploratorio (Sección 3.2).




Figura 5.2: Informatividad del precio medio sobre el settlement. Izquierda: puntuación de Brier por tiempo a expiración; el precio es casi una moneda al aire en la apertura y solo se vuelve informativo en el tramo terminal. Derecha: curvas de fiabilidad lejos (30–60 min) y cerca (1–5 min) del cierre; el precio está bien calibrado en ambos cortes, pero su masa se polariza al acercarse la expiración.

Cabe preguntarse si un modelo aprendido extraería la señal del desenlace *antes* que el precio, a partir de la microestructura (*imbalance*, flujo de órdenes, presión del libro). Se comprobó de forma directa, como paso previo a cualquier modelo secuencial: un *gradient boosting* sobre esas características, con partición temporal estricta (entrenamiento en mayo, prueba en junio, agrupando por mercado), no mejora la puntuación de Brier del propio precio (0,141 frente a 0,140) en ningún tramo de tiempo a expiración; usando *solo* el flujo, sin el precio, la puntuación es peor (0,20) y a tiempo a expiración grande cae al azar. La microestructura no aporta información sobre el settlement que el precio no capture ya: a este horizonte, el precio es prácticamente un estadístico suficiente. En consecuencia no se entrena un modelo secuencial dedicado —sobre apenas un centenar de desenlaces independientes solo añadiría riesgo de sobreajuste—, y la curva de Brier por tiempo a expiración se emplea directamente como cronograma de aplanado de inventario en el simulador.

Capítulo 6

Aspectos éticos y limitaciones

Este capítulo recoge las consideraciones éticas que han guiado el trabajo y una revisión explícita de sus limitaciones, que delimitan el alcance de cualquier conclusión.

6.1 Consideraciones éticas

El sistema estudia decisiones económicas automatizadas y es especialmente sensible al sobreajuste cuando el horizonte de datos es reducido. La actuación responsable es no operar con capital real y no convertir un diagnóstico *post-hoc* en una afirmación de rentabilidad. La política completa queda congelada para observación prospectiva, sin que los días usados para formularla cuenten de nuevo como validación.

En cuanto a los datos, se adopta un marco de confidencialidad, integridad y disponibilidad. Una referencia externa retrasada o errónea puede inducir una señal espuria; por ello el sistema se entrena solo con sesiones aceptadas, separa datos crudos, características y etiquetas, mantiene trazabilidad de los artefactos e inhibe la operativa ante datos obsoletos. El trabajo emplea datos públicos de mercado y no datos personales. El corpus completo no se distribuye por tamaño; se publican el esquema, un ledger anonimizado de acciones y el código de evaluación.

6.2 Limitaciones

Selección posterior al bloque. El especialista base sí estaba congelado y su resultado limpio es +0,349 ticks por acción al coste de referencia. El filtro de volatilidad se incorporó después de observar el cambio de régimen; por tanto, su resultado de +1,069 ticks sobre el mismo bloque es exploratorio y necesita fechas posteriores.

Soporte temporal. El conjunto fuera de muestra abarca cinco días. Tres de cinco son positivos para la política base y cinco de cinco dentro del subconjunto diagnóstico. Ninguna de las dos cifras constituye una validación definitiva.

Continuidad de la captura. El recolector no operó de forma ininterrumpida durante todo el periodo del proyecto: hay un hueco documentado entre el 14 de junio y la reanudación real, confirmada el 3 de julio de 2026 a las 08:42 UTC. El hueco no afecta a ninguna cifra reportada en este trabajo —tanto el corpus principal de entrenamiento (11-25 de

mayo) como el bloque fuera de muestra confirmatorio (6-10 de junio) se capturaron antes de que se abriera—, pero delimita el origen real de la ventana de captura continua sobre la que se apoyará la validación prospectiva (Capítulo 4).

Cierre de la ventana prospectiva. La ventana de evaluación prospectiva no la cerró una decisión metodológica sino un fallo de hardware: el 14 de agosto de 2026 a las 11:05 UTC el disco de almacenamiento del recolector se desconectó del bus USB de la Raspberry Pi y la captura se detuvo, reanudándose el 17 de agosto a las 09:23 UTC. El último día completo capturado es el 13 de agosto, y esa es la fecha de cierre de la ventana. La integridad de lo capturado se verificó antes de evaluar nada: el sistema de ficheros se recuperó mediante la reejecución de su diario, el medio no presentó errores de lectura ni antes ni después del incidente, y la cobertura diaria se comprobó una a una sobre el registro de sesiones del propio recolector. Resultan 35 días completos e ininterrumpidos, del 10 de julio al 13 de agosto, por encima del mínimo de 25 días declarado en el pre-registro. La circunstancia tiene una consecuencia metodológica favorable que conviene explicitar: el final de la ventana quedó determinado por una causa externa y ajena al experimento, y quedó determinado *antes* de que se observara ningún resultado, de modo que la elección del punto de corte no pudo verse influida por los datos que ese corte iba a revelar. El hueco posterior al 14 de agosto queda documentado en el monitor del recolector, tal y como exige el propio pre-registro para cualquier exclusión de días por fallo de captura.

Dependencia y solapamiento. Las 318 unidades del diagnóstico pertenecen a 156 mercados, con hasta ocho señales por mercado y horizontes H60 solapados. El *bootstrap* por filas subestima esa dependencia. Un remuestreo agrupado por mercado amplía el IC90 % a $[+0,193, +2,004]$, pero sigue describiendo un subconjunto elegido *post-hoc*. Además, no se ha fijado una regla de exposición simultánea; por ello la suma acumulada no es PnL de cartera.

Validación *offline*. La evaluación usa un modelo de ejecución conservador pero simplificado. No reconstruye la cola orden por orden ni incorpora rellenos parciales. El registro de sombra actual es retrospectivo; falta una ejecución prospectiva de mayor fidelidad.

Respuesta competitiva del mercado. Más allá de la fidelidad de la cola, el simulador maker hereda una limitación estructural de todo *backtest* basado en reproducción histórica: asume que el resto del mercado —y en particular los creadores de mercado incumbentes— no reacciona a las órdenes propias. En un régimen de recompensas por liquidez, esa hipótesis es optimista, porque una orden *maker* nueva compite por la cola y por el reparto de *rebates* con participantes que ajustarían su comportamiento. Ningún *replay* puede medir esa reacción; hacerlo exige un simulador reactivo, lo que se plantea como línea de trabajo futuro (Capítulo 8).

Manipulación de *settlement*. Dai, Jia y Yu [21] documentan, tras el lanzamiento del contrato de Bitcoin a cinco minutos de Polymarket, que el flujo del mercado al contado se dispara en el instante de resolución y provoca reversiones de precio posteriores, un fenómeno que desaparece en gran medida en los contratos de quince minutos. Como la vía maker de este trabajo se concentra por tamaño en los horizontes de una hora y de quince minutos, se auditó si ese patrón aparece en el corpus propio, comparando la reversión del precio de Bitcoin en los instantes de *settlement* frente a instantes placebo emparejados por hora. El patrón direccional aparece con el signo que describe ese trabajo, pero es minúsculo —los contrastes más fuertes quedan entre $-0,2$ y $-0,8$ puntos básicos, con $|t|$ entre 2,1 y 2,3— y ninguno de los seis contrastes sobre el mercado al contado sobrevive

la corrección por comparaciones múltiples de Benjamini-Hochberg al 5 %; en los futuros perpetuos la dirección coincide con estadísticos aún menores. El componente de flujo del mecanismo no es medible con esta captura —sus volúmenes son agregados móviles de varios minutos, no cinta instantánea a instantánea— y el diseño solo detecta coincidencia temporal, no atribución causal: un efecto genérico de las marcas redondas de tiempo produciría el mismo contraste. La auditoría se queda, por tanto, en una comprobación de robustez favorable a los horizontes empleados, no en una confirmación ni una refutación del mecanismo.

Reproducibilidad parcial. El repositorio permite recalcular las tablas públicas desde el ledger anonimizado y probar la lógica compartida. La reproducción integral del entrenamiento requiere el corpus privado de gran tamaño y se documenta como limitación, no como capacidad publicada.

Patrón en U. Dentro de la baja volatilidad se observa una posible relación en forma de U entre volatilidad y resultado. Como se descubrió en los mismos cinco días, se conserva solo como hipótesis para trabajo futuro.

Capítulo 7

Reproducibilidad

7.1 Enlace a repositorio GitHub

El código, los registros de resultados y los artefactos públicos de auditoría se mantienen en un repositorio:

<https://github.com/marcmaldonadorca/polymarket-btc-microstructure>

7.1.1 Estructura del repositorio

El repositorio se organiza en los siguientes directorios:

config/ Umbrales congelados de la política y configuraciones del arco.

docs/ Documentos canónicos del proceso, renumerados de forma secuencial.

notebooks/ Catorce cuadernos pedagógicos (00–13): el arco ejecutado (EDA, particiones, objetivo, línea base, latencia, secuencias, corrección del *score* adverso, especialista y auditoría del ledger) más los cuadernos autocontenidos sobre CSV públicos (EDA de series temporales, baselines clásicos, regímenes, economía maker y fundacionales); cada uno declara qué pregunta responde, qué entradas usa, qué produce y su conclusión, y enlaza su fila de **results/key_results.csv**.

scripts/ Puntos de entrada reproducibles de cada experimento.

src/ Paquete con la lógica compartida (datos, características, modelos, evaluación), con pruebas automatizadas.

results/ Tablas de resultados y ledger anonimizado de 754 unidades de acción.

sql/ Esquema de la consulta base de entrenamiento.

reports/ Esta memoria (fuente LaTeX).

7.1.2 Cómo reproducir

El entorno se prepara con un entorno virtual de Python y la instalación de las dependencias declaradas. Las pruebas automatizadas verifican la lógica de política y sus guardas. El ledger **results/final_candidate_actions_anonymized.csv** permite recalcular las tablas agregadas, los desgloses por régimen y la incertidumbre agrupada sin acceder al

corpus completo. El script que lo genera queda versionado para mantener trazabilidad, aunque su ejecución integral requiere el workspace privado de investigación.

7.1.3 Datos no publicados

El conjunto completo (del orden de 2,6 millones de filas *cross-venue*, más la base de captura) no se publica por tamaño. En su lugar se incluyen el esquema SQL, un ledger anonimizado suficiente para reproducir las cifras finales y el código del *pipeline*. Esto permite una auditoría parcial, no la reproducción bit a bit del entrenamiento. Declarar esa frontera de forma explícita es parte de la trazabilidad y reduce la deuda técnica propia de estos sistemas [15].

Capítulo 8

Conclusiones

Este trabajo ha presentado una metodología de captura de datos, validación temporal y control de costes para la predicción de corto plazo en mercados de Bitcoin de Polymarket. La conclusión central es que una precisión direccional cercana al 90 % no garantiza una política económica: con una latencia de entrada realista, el coste y la ejecución dominan el resultado.

El aprendizaje profundo aplicado a secuencias y al libro de órdenes aprende representaciones útiles, pero no produce una política estable con unas dos semanas de datos. El especialista tabular congelado conserva una señal modesta en cinco días intactos fuera de muestra: +0,349 ticks por unidad al coste de referencia, 754 unidades y tres de cinco días positivos; bajo el coste completo, el promedio es $-0,026$ ticks.

El análisis posterior detecta un cambio de régimen y propone un filtro de baja volatilidad. Sobre el mismo bloque, ese subconjunto alcanza +1,069 ticks y cinco de cinco días positivos. Su valor es el de una hipótesis prometedora, no el de una validación confirmatoria: la regla se congela después del diagnóstico y queda pendiente de datos futuros.

Las aportaciones del trabajo son cuatro: un sistema de captura y control de calidad multifuente; un protocolo temporal que incorpora coste y latencia medidos; evidencia cuantitativa de la ruptura entre predicción y ejecución; y una trazabilidad que conserva tanto los resultados negativos como la corrección de errores metodológicos. No se afirma rentabilidad real ni se presenta un bot listo para desplegar.

Trabajo futuro. La prioridad es ejecutar prospectivamente la política completa sin retocar umbrales, con una sola regla de exposición por mercado y registro de fills. Solo después podrá evaluarse el filtro de volatilidad. Con un horizonte de datos sustancialmente mayor podrán reevaluarse arquitecturas como el *Temporal Fusion Transformer* [14].

Una segunda línea, más ambiciosa, ataca la limitación estructural del simulador maker—su incapacidad para medir la respuesta competitiva del mercado (Capítulo 6)—. La reproducción histórica trata el libro como un decorado inerte; capturar cómo reaccionarían los creadores de mercado incumbentes a las órdenes propias exige un simulador *reactivo*. La línea de simuladores generativos de libros de órdenes de los últimos años ofrece el instrumental: modelos de «agente mundo» que aprenden de datos históricos una dinámica del libro capaz de reproducir cierto impacto de mercado [36], modelos generativos autorregresivos del flujo de mensajes a nivel de *token* [37] y, más recientemente, modelos de

difusión para la simulación y predicción del libro [38]; una revisión reciente sistematiza el campo [39]. Integrar uno de estos simuladores reactivos con la política congelada de este trabajo permitiría estimar la selección adversa y el reparto de *rebates* bajo competencia, no bajo el supuesto optimista del *replay*. Es, por su alcance, un trabajo de la magnitud de otra tesis; aquí se deja señalado como la continuación natural de la vía *maker*.

La regla que guía el proyecto permanece: la complejidad y cualquier afirmación económica deben ganarse su sitio con evidencia verdaderamente nueva.

Referencias

- [1] Polymarket. (2026). *Prices & Orderbooks* [Documentación]. <https://docs.polymarket.com/polymarket-learn/trading/using-the-orderbook> (Recuperado el 14 de junio de 2026).
- [2] Polymarket. (2026). *Order Lifecycle* [Documentación]. <https://docs.polymarket.com/concepts/order-lifecycle> (Recuperado el 14 de junio de 2026).
- [3] Wolfers, J., & Zitzewitz, E. (2004). Prediction Markets. *Journal of Economic Perspectives*, 18(2), 107–126.
- [4] Zhang, Z., Zohren, S., & Roberts, S. (2019). DeepLOB: Deep Convolutional Neural Networks for Limit Order Books. *IEEE Transactions on Signal Processing*, 67(11), 3001–3012.
- [5] Ntakaris, A., Magris, M., Kannianen, J., Gabbouj, M., & Iosifidis, A. (2018). Benchmark dataset for mid-price forecasting of limit order book data with machine learning methods. *Journal of Forecasting*, 37(8), 852–866.
- [6] Tsantekidis, A., Passalis, N., Tefas, A., Kannianen, J., Gabbouj, M., & Iosifidis, A. (2017). Using deep learning to detect price change indications in financial markets. *European Signal Processing Conference (EUSIPCO)*.
- [7] Sirignano, J., & Cont, R. (2019). Universal features of price formation in financial markets: perspectives from deep learning. *Quantitative Finance*, 19(9), 1449–1459.
- [8] Jha, R., et al. (2020). Deep Learning for Digital Asset Limit Order Books. *arXiv:2010.01241*.
- [9] Kearns, M., & Nevmyvaka, Y. (2013). Machine Learning for Market Microstructure and High Frequency Trading. In *High Frequency Trading: New Realities for Traders, Markets and Regulators*.
- [10] Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *The Review of Financial Studies*, 33(5), 2223–2273.
- [11] López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- [12] Bailey, D. H., & López de Prado, M. (2014). The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality. *The Journal of Portfolio Management*, 40(5), 94–107.
- [13] Sun, B., Feng, J., & Saenko, K. (2016). Return of Frustratingly Easy Domain Adaptation. *AAAI Conference on Artificial Intelligence*.
- [14] Lim, B., Arik, S. O., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers

- for Interpretable Multi-horizon Time Series Forecasting. *International Journal of Forecasting*, 37(4), 1748–1764.
- [15] Sculley, D., et al. (2015). Hidden Technical Debt in Machine Learning Systems. *Advances in Neural Information Processing Systems (NeurIPS)*.
 - [16] Dubach, P. D. (2026). The Anatomy of a Decentralized Prediction Market: Microstructure Evidence from the Polymarket Order Book. *arXiv:2604.24366*.
 - [17] Tsang, K. P., & Yang, Z. (2026). The Anatomy of a Blockchain Prediction Market: Polymarket in the 2024 U.S. Presidential Election. *arXiv:2603.03136*.
 - [18] Cheng, G., Yang, J., & Zou, H. (2026). Arbitrage Analysis in Polymarket NBA Markets. *arXiv:2605.00864*.
 - [19] Nechepurenko, M. (2026). Fill-Side Non-Retail Trading on Polymarket: An Empirical Study of Behavioral Tiers and Microstructure Signatures Under Quote-Attribution Constraints. *arXiv:2605.11640*.
 - [20] Qin, B., & Yang, R. (2026). Polymarket-v1 Database. *arXiv:2606.04217*.
 - [21] Dai, D., Jia, R., & Yu, S. (2026). Settlement Manipulation in Prediction Markets. *arXiv:2606.31675*.
 - [22] Berti, L., & Kasneci, G. (2025). TLOB: A Novel Transformer Model with Dual Attention for Price Trend Prediction with Limit Order Book Data. *arXiv:2502.15757*.
 - [23] Goswami, M., Szafer, K., Choudhry, A., Cai, Y., Li, S., & Dubrawski, A. (2024). MOMENT: A Family of Open Time-series Foundation Models. *International Conference on Machine Learning (ICML)*.
 - [24] Ansari, A. F., et al. (2024). Chronos: Learning the Language of Time Series. *Transactions on Machine Learning Research*.
 - [25] Das, A., Kong, W., Sen, R., & Zhou, Y. (2024). A Decoder-only Foundation Model for Time-series Forecasting. *International Conference on Machine Learning (ICML)*.
 - [26] Liu, C., Aksu, T., Liu, J., Liu, X., Yan, H., Pham, Q., Savarese, S., Sahoo, D., Xiong, C., & Li, J. (2025). Moirai 2.0: When Less Is More for Time Series Forecasting. *arXiv:2511.11698*.
 - [27] Hollmann, N., Müller, S., Purucker, L., Krishnakumar, A., Körfer, M., Hoo, S. B., Schirrmeister, R. T., & Hutter, F. (2025). Accurate predictions on small data with a tabular foundation model. *Nature*, 637, 319–326.
 - [28] Dong, J., Wu, H., Zhang, H., Zhang, L., Wang, J., & Long, M. (2023). SimMTM: A Simple Pre-Training Framework for Masked Time-Series Modeling. *Advances in Neural Information Processing Systems (NeurIPS)*.
 - [29] Yue, Z., Wang, Y., Duan, J., Yang, T., Huang, C., Tong, Y., & Xu, B. (2022). TS2Vec: Towards Universal Representation of Time Series. *AAAI Conference on Artificial Intelligence*.
 - [30] Lee, S., Park, T., & Lee, K. (2024). Soft Contrastive Learning for Time Series. *International Conference on Learning Representations (ICLR)*.
 - [31] Dong, J., Wu, H., Wang, Y., Qiu, Y., Zhang, L., Wang, J., & Long, M. (2024). Time-

- Siam: A Pre-Training Framework for Siamese Time-Series Modeling. *International Conference on Machine Learning (ICML)*.
- [32] Wang, D., Cheng, M., Liu, Z., & Liu, Q. (2025). TimeDART: A Diffusion Autoregressive Transformer for Self-Supervised Time Series Representation. *International Conference on Machine Learning (ICML)*.
 - [33] Harvey, C. R., Liu, Y., & Zhu, H. (2016). ...and the Cross-Section of Expected Returns. *The Review of Financial Studies*, 29(1), 5–68.
 - [34] Nosek, B. A., Ebersole, C. R., DeHaven, A. C., & Mellor, D. T. (2018). The pre-registration revolution. *Proceedings of the National Academy of Sciences*, 115(11), 2600–2606.
 - [35] Todd, P. (2016). *OpenTimestamps: Scalable, Trust-Minimized, Distributed Timestamping with Bitcoin* [Documentación]. <https://opentimestamps.org> (Recuperado el 13 de julio de 2026).
 - [36] Coletta, A., Moulin, A., Vyetenko, S., & Balch, T. (2022). Learning to Simulate Realistic Limit Order Book Markets from Data as a World Agent. *3rd ACM International Conference on AI in Finance (ICAIF)*. *arXiv:2210.09897*.
 - [37] Nagy, P., Frey, S., Sapora, S., Li, K., Calinescu, A., Zohren, S., & Foerster, J. (2023). Generative AI for End-to-End Limit Order Book Modelling: A Token-Level Autoregressive Generative Model of Message Flow Using a Deep State Space Network. *arXiv:2309.00638*.
 - [38] Backhouse, A., Li, K., Foerster, J., Calinescu, A., & Zohren, S. (2025). Painting the Market: Generative Diffusion Models for Financial Limit Order Book Simulation and Forecasting. *arXiv:2509.05107*.
 - [39] Jain, K., Firoozye, N., Kochems, J., & Treleaven, P. (2024). Limit Order Book Simulations: A Review. *arXiv:2402.17359*.
 - [40] Avellaneda, M., & Stoikov, S. (2008). High-frequency Trading in a Limit Order Book. *Quantitative Finance*, 8(3), 217–224.
 - [41] Guéant, O., Lehalle, C.-A., & Fernandez-Tapia, J. (2013). Dealing with the Inventory Risk: A Solution to the Market Making Problem. *Mathematics and Financial Economics*, 7(4), 477–507.
 - [42] Feil, D., & Nendel, M. (2026). Optimal Market Making in Prediction Markets. *arXiv:2607.17991*.
 - [43] Rahman, N., Al-Chami, J., & Clark, J. (2026). SoK: Market Microstructure for Decentralized Prediction Markets (DePMs). *arXiv:2510.15612*.

Conjunto de características

El especialista final emplea 36 características causales sin variables de reloj (*no_clock*), agrupadas por bloques:

- **Estado local del libro de Polymarket:** precio medio, *spread*, microprice, desbalance de órdenes, coste visible de entrada y deltas recientes del precio.
- **Referencias externas:** retornos orientados del mercado al contado y de los futuros perpetuos a 2 y 8 segundos; medidas de consenso y de actualización.
- **Volatilidad:** volatilidad realizada del perpetuo a 5 segundos, usada en el diagnóstico posterior de cambio de régimen.
- **Contexto de ventana:** fase de la ventana *prestart* y proxies de calidad del libro (cobertura, indicadores de degradación).

Se excluyen deliberadamente las variables de reloj (hora, minuto, segundo) para evitar que el modelo aprenda atajos temporales triviales.

Hiperparámetros de los modelos

Tabla 1: Hiperparámetros principales del especialista (HistGradientBoosting, dos cabezas).

Hiperparámetro	Valor
Tasa de aprendizaje	0,045
Iteraciones máximas	220 (con parada anticipada)
Fracción de validación interna	0,15
Máximo de hojas por árbol	15
Mínimo de muestras por hoja	120
Regularización L2	0,10

Tabla 2: Hiperparámetros principales de los modelos profundos (línea de exploración).

Hiperparámetro	Valor
Optimizador	AdamW
Tasa de aprendizaje	0,0015
Decaimiento de pesos	10^{-4}
Tamaño de lote	192
Paciencia (parada anticipada)	18 épocas
Dimensión oculta de la GRU	56
<i>Dropout (BookEncoder)</i>	0,08

El especialista base congelado opera con dos umbrales: valor esperado predicho superior a 0,75 y probabilidad de salud no inferior a 0,50. Tras el diagnóstico del bloque fuera de muestra se propone una política futura que exige, además, volatilidad realizada a 5 segundos no superior a 0,6657 (percentil 80 del entrenamiento). La incertidumbre exploratoria se estima con 5 000 remuestreos y semilla fija, tanto por filas como agrupando por mercado.

Pre-registro v2 y verificación del sello

Este anexo reproduce el compromiso de pre-registro que sostiene la validación prospectiva del Capítulo 4 y detalla cómo verificarlo de forma independiente. El documento íntegro vive en el repositorio (`docs/PREREGISTRO_V2.md`); aquí se resume su contenido comprobable.

Política congelada

La señal y la política se fijaron en el entrenamiento de mayo y no se han modificado desde entonces: universo *prestart* estricto (-60 a -45 s respecto a la apertura, $spread \leq 2$ ticks, libro saludable, coste visible acotado), dos cabezas de *gradient boosting* sobre el conjunto de características *no_clock*, y regla de operación «valor esperado $> 0,75$ y salud $\geq 0,5$ ». La integridad de los artefactos se ancla con sus resúmenes SHA-256, incluidos literalmente en el pre-registro (modelos de valor esperado y de salud, manifiesto de características y *gate* GARCH congelado).

Brazos de *gate* y capas de reporte

Se comprometieron por adelantado tres brazos de *gate* —estático heredado, GARCH(1,1) ajustado solo con datos anteriores a junio, y clustering de regímenes (adenda A)— y tres capas de reporte que se publican todas: *net@0,5* histórica, *taker* con comisión oficial (con expectativa *declarada como negativa* antes de mirar los datos) y *maker* simulado. Declarar la expectativa negativa por adelantado es lo que convierte el resultado *taker* en una confirmación y no en una racionalización *a posteriori*.

Cortes prospectivos

Los datos elegibles son la captura de la *Pi* posterior a la reanudación del recolector, procesados con el mismo *pipeline* congelado. Se fijaron dos cortes —el primero a finales de agosto, el segundo justo antes de la entrega— sin ningún vistazo intermedio a las métricas de resultado.

Verificación independiente del sello temporal

El compromiso se ancla en la cadena de Bitcoin mediante OpenTimestamps [35]. Para verificarlo sin confiar en el autor:

1. Obtener el *commit* del repositorio que introduce el pre-registro y su prueba *.ots* asociada (`docs/prereg_v2_commit.ots`).
2. Ejecutar `ots verify docs/prereg_v2_commit.ots`: la herramienta consulta un nodo de Bitcoin y confirma el bloque —y por tanto la fecha— en que quedó atestado el resumen del documento.
3. Comprobar que esa fecha es anterior al primer dato de la ventana de evaluación prospectiva. Como la atestación de Bitcoin no puede retro-fecharse, la anterioridad del compromiso queda demostrada sin necesidad de confiar en la palabra del autor ni en un sello privado.

Una fe de erratas posterior (la corrección del modelo de comisiones, Sección 3.4.5) se selló con el mismo procedimiento, de modo que la cadena de compromisos es completa y auditable.

Auditoría del ledger público

Las cifras económicas centrales del trabajo pueden recalcularse de forma independiente sin acceso al corpus privado ni a los modelos entrenados, a partir de un único fichero anonimizado que se publica con el código: el ledger de acciones candidatas (`results/final_candidate_actions_anonymized.csv`). Este anexo describe su contenido y el procedimiento de auditoría.

Contenido del ledger

El ledger contiene una fila por unidad de acción del bloque fuera de muestra (754 filas). Cada fila registra un identificador de acción, el día de sesión, los identificadores de mercado y de contrato *anonimizados* mediante *hash* (de modo que no se pueda reconstruir la identidad del mercado), el instante relativo a la apertura, el régimen de volatilidad (*high/low*) y el resultado neto en ticks a tres niveles de coste de ejecución (medio tick de referencia, y las variantes de un cuarto y de un tick completo). No incluye características del modelo ni datos crudos: es exactamente la información necesaria para auditar el resultado, y nada más.

Procedimiento de reproducción

Con solo ese fichero y una utilidad de análisis de datos, la auditoría reproduce las tres cifras que sostienen las conclusiones económicas:

1. **Resultado confirmatorio.** La media del resultado neto al coste de referencia sobre las 754 acciones (241 mercados, cinco días) es de +0,349 ticks por acción, idéntica a la cifra publicada. Bajo el coste conservador de un tick completo el promedio cae a -0,026: la señal no sobrevive al coste de estrés.
2. **Diagnóstico *post-hoc* de baja volatilidad.** Restringiendo a las 318 acciones de régimen de baja volatilidad (156 mercados), la media asciende a +1,069 ticks. Se recuerda que esta separación se decidió tras inspeccionar el bloque, por lo que es una hipótesis, no una segunda validación.
3. **Incertidumbre agrupada por mercado.** Un *bootstrap* que remuestrea mercados enteros —para no tratar como independientes las hasta ocho señales solapadas de un mismo mercado— sitúa el intervalo de confianza del 90 % del corte de baja volatilidad en [+0,193, +2,004] ticks: positivo pero ancho, coherente con el escaso soporte temporal.

El cuaderno `08_auditoria_final_ledger` ejecuta estos tres cálculos paso a paso y constituye la vía pública más directa para verificar el resultado final del trabajo con indepen-

dencia del autor.